

8 Análisis factorial: métodos prácticos

MA2003B Aplicación de métodos multivariados
en ciencia de datos

Raul Gomez



Tecnológico
de Monterrey

Introducción al análisis multivariante

En esta presentación introduciremos conceptos básicos del análisis multivariante, enfocándonos en el vector de medias y la matriz de covarianzas de un vector aleatorio.

Introducción al análisis multivariante

En esta presentación introduciremos conceptos básicos del análisis multivariante, enfocándonos en el vector de medias y la matriz de covarianzas de un vector aleatorio.

Estos conceptos son fundamentales para entender las relaciones entre múltiples variables en un conjunto de datos.

El vector de medias y la matriz de covarianzas

Definition

Sea Π una población y sea

$$X : \Pi \rightarrow \mathbb{R}^p$$

un vector aleatorio (renglón). El **vector de medias** de X se define como

$$\mu = \mathbb{E}[X] = [\mathbb{E}[X_1], \mathbb{E}[X_2], \dots, \mathbb{E}[X_p]] = [\mu_1, \mu_2, \dots, \mu_p]$$

donde X_i es la i -ésima componente de X . La **matriz de covarianzas** de X se define como

$$\Sigma = \text{Cov}[X] = \mathbb{E}[(X - \mu)^T (X - \mu)] = [\text{Cov}[X_i, X_j]]_{i,j=1}^p$$

donde $\text{Cov}[X_i, X_j] = \mathbb{E}[(X_i - \mu_i)(X_j - \mu_j)]$ es la covarianza entre las componentes i y j .

Remark

Recuerde que $\text{Cov}[X_i, X_j] = \text{Cov}[X_j, X_i]$, por lo que la matriz es simétrica. Además, $\text{Cov}[X_i, X_i] = \text{Var}[X_i]$, la varianza de la componente i . Por ello también se le llama **matriz varianza-covarianza**.

Definition

Dada una muestra de tamaño n de Π , con matriz muestral x , definimos el **vector de medias muestral** como

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \left[\frac{1}{n} \sum_{i=1}^n x_{i,1}, \frac{1}{n} \sum_{i=1}^n x_{i,2}, \dots, \frac{1}{n} \sum_{i=1}^n x_{i,p} \right]$$

donde x_i es el i -ésimo renglón de x y $x_{i,j}$ su componente j . La **matriz de covarianzas muestral** se define como

$$\hat{\Sigma} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^T (x_i - \bar{x})$$

donde $\hat{\Sigma}$ es de tamaño $p \times p$ y $\hat{\Sigma}_{i,j} = \frac{1}{n-1} \sum_{k=1}^n (x_{k,i} - \bar{x}_i)(x_{k,j} - \bar{x}_j)$ es la covarianza muestral entre las componentes i y j .

Remark

La matriz de covarianzas muestral es un estimador insesgado de la matriz de covarianzas del vector aleatorio X .

Example

Considere la siguiente matriz muestral de tamaño $n = 5$ de una población Π :

$$\begin{bmatrix} 2 & 5 & 7 \\ 4 & 3 & 6 \\ 6 & 4 & 5 \\ 8 & 2 & 4 \\ 10 & 1 & 3 \end{bmatrix}$$

Example

Para obtener el vector de medias muestral, calculamos:

$$\bar{x}_1 = \frac{2 + 4 + 6 + 8 + 10}{5} = 6$$

$$\bar{x}_2 = \frac{5 + 3 + 4 + 2 + 1}{5} = 3$$

$$\bar{x}_3 = \frac{7 + 6 + 5 + 4 + 3}{5} = 5$$

Example

Para obtener el vector de medias muestral, calculamos:

$$\bar{x}_1 = \frac{2 + 4 + 6 + 8 + 10}{5} = 6$$

$$\bar{x}_2 = \frac{5 + 3 + 4 + 2 + 1}{5} = 3$$

$$\bar{x}_3 = \frac{7 + 6 + 5 + 4 + 3}{5} = 5$$

En otras palabras,

$$\bar{x} = [6, 3, 5]$$

Example

La varianza muestral de X_j es:

$$\hat{\Sigma}_{X_j} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2$$

Example

La varianza muestral de X_j es:

$$\hat{\Sigma}_{X_j} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2$$

Por lo tanto,

$$\hat{\Sigma}_{X_1} = \frac{(2-6)^2 + (4-6)^2 + (6-6)^2 + (8-6)^2 + (10-6)^2}{4} = 10$$

$$\hat{\Sigma}_{X_2} = \frac{(5-3)^2 + (3-3)^2 + (4-3)^2 + (2-3)^2 + (1-3)^2}{4} = 2.5$$

$$\hat{\Sigma}_{X_3} = \frac{(7-5)^2 + (6-5)^2 + (5-5)^2 + (4-5)^2 + (3-5)^2}{4} = 2.5$$

Example

La covarianza muestral entre X_j y X_k es:

$$\hat{\Sigma}_{X_j, X_k} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k)$$

Estos cálculos pueden hacerse de forma similar a lo anterior; los resultados son:

$$\hat{\Sigma}_{X_1, X_2} = -4.5$$

$$\hat{\Sigma}_{X_1, X_3} = -5$$

$$\hat{\Sigma}_{X_2, X_3} = 2.25$$

Example

La matriz de covarianzas resultante es:

$$\hat{\Sigma} = \begin{bmatrix} 10 & -4.5 & -5 \\ -4.5 & 2.5 & 2.25 \\ -5 & 2.25 & 2.5 \end{bmatrix}$$

La distancia de Mahalanobis

Definition

Suponga que tenemos una población Π con un vector aleatorio X de media μ y covarianzas Σ . Si Σ es invertible, la **distancia de Mahalanobis** entre x e y en $\mathbb{R}^p$ se define como:

$$d_M(x, y) = \sqrt{(x - y)\Sigma^{-1}(x - y)^T}$$

En el contexto muestral, puede calcularse usando la matriz de covarianzas muestral $\hat{\Sigma}$:

En el contexto muestral, puede calcularse usando la matriz de covarianzas muestral $\hat{\Sigma}$:

Definition

Dada una muestra de tamaño n de Π , con matriz muestral x y matriz $\hat{\Sigma}$, la **distancia de Mahalanobis muestral** entre x_i y x_j es:

$$d_M(x_i, x_j) = \sqrt{(x_i - x_j) \hat{\Sigma}^{-1} (x_i - x_j)^T}$$

En el contexto muestral, puede calcularse usando la matriz de covarianzas muestral $\hat{\Sigma}$:

Definition

Dada una muestra de tamaño n de Π , con matriz muestral x y matriz $\hat{\Sigma}$, la **distancia de Mahalanobis muestral** entre x_i y x_j es:

$$d_M(x_i, x_j) = \sqrt{(x_i - x_j) \hat{\Sigma}^{-1} (x_i - x_j)^T}$$

Remark

La distancia de Mahalanobis mide la separación en un espacio multivariante considerando las correlaciones entre variables. Es útil para identificar atípicos.

Para ilustrar este punto, consideraremos el siguiente conjunto de datos:

Para ilustrar este punto, consideraremos el siguiente conjunto de datos:

Comenzamos tomando una muestra aleatoria x de tamaño $n = 300$ de una distribución uniforme en el intervalo $[0, 10]$.

Para ilustrar este punto, consideraremos el siguiente conjunto de datos:

Comenzamos tomando una muestra aleatoria x de tamaño $n = 300$ de una distribución uniforme en el intervalo $[0, 10]$.

Construiremos un vector de error ε de una normal con media 0 y desviación estándar 1.

Para ilustrar este punto, consideraremos el siguiente conjunto de datos:

Comenzamos tomando una muestra aleatoria x de tamaño $n = 300$ de una distribución uniforme en el intervalo $[0, 10]$.

Construiremos un vector de error ε de una normal con media 0 y desviación estándar 1.

Ahora podemos construir el vector

$$y = x + \varepsilon$$

Para ilustrar este punto, consideraremos el siguiente conjunto de datos:


Comenzamos tomando una muestra aleatoria x de tamaño $n = 300$ de una distribución uniforme en el intervalo $[0, 10]$.

Construiremos un vector de error ε de una normal con media 0 y desviación estándar 1.


Ahora podemos construir el vector

$$y = x + \varepsilon$$

El diagrama de dispersión asociado se muestra a continuación:



Ahora añadimos los puntos $(1, 1)$ y $(5, 2)$ a los datos:



Obsérvese que uno de estos puntos es claramente atípico.


Obsérvese que uno de estos puntos es claramente atípico.

Nos gustaría contar con una medida concreta que lo muestre.


Obsérvese que uno de estos puntos es claramente atípico.

Nos gustaría contar con una medida concreta que lo muestre.

Sin embargo, si usamos la distancia euclidiana, obtenemos que el punto atípico es en realidad el más cercano al vector de medias muestral:



Por otro lado, si calculamos la distancia de Mahalanobis, obtenemos que el punto atípico está más alejado del vector de medias muestral:



Escalamiento y estandarización

Supongamos ahora que tenemos un vector aleatorio X con vector de medias μ y matriz de covarianzas Σ . Podemos definir un nuevo vector aleatorio Y como sigue:

$$Y^T = AX^T + b$$

donde A es una matriz $p \times p$ y b un vector de dimensión p .

Escalamiento y estandarización

Supongamos ahora que tenemos un vector aleatorio X con vector de medias μ y matriz de covarianzas Σ . Podemos definir un nuevo vector aleatorio Y como sigue:

$$Y^T = AX^T + b$$

donde A es una matriz $p \times p$ y b un vector de dimensión p .

El vector de medias y la matriz de covarianzas del nuevo vector aleatorio Y se obtienen como:

$$\mu_Y^T = \mathbb{E}[Y]^T = A\mu^T + b$$

y

$$\Sigma_Y = \text{Cov}[Y] = A\Sigma A^T$$

Como mostraremos más adelante, siempre es posible encontrar una matriz A y un vector b tales que Y tenga media $\mu_Y = 0$ y covarianzas $\Sigma_Y = I_p$, donde I_p es la identidad de tamaño $p \times p$.

Como mostraremos más adelante, siempre es posible encontrar una matriz A y un vector b tales que Y tenga media $\mu_Y = 0$ y covarianzas $\Sigma_Y = I_p$, donde I_p es la identidad de tamaño $p \times p$.

Este proceso se conoce como **estandarización** del vector aleatorio X .

Actividad: La geometría de los datos multivariantes

Parte A: Ejercicios teóricos

1. Pruebe que la distancia de Mahalanobis se reduce a la euclidiana si la matriz de covarianzas es la identidad.
2. Muestre que la distancia de Mahalanobis es invariante bajo transformaciones afines.
3. Muestre que si estandariza cada variable en un conjunto multivariante, la matriz de covarianzas se vuelve la matriz de correlaciones.
4. Suponga que X_1 y X_2 son independientes y normales estándar. Muestre que $d_M(X, 0)^2$ sigue una χ^2 con 2 g.l., donde $d_M(X, 0)$ es la distancia de Mahalanobis al origen.

Parte B: Ejercicios prácticos

1. Genere un conjunto bidimensional de 50 puntos (dos variables correlacionadas).
2. Calcule el vector de medias y la matriz de covarianzas muestrales.
3. Escriba una función en R que calcule la distancia de Mahalanobis de cada punto a la media.
4. Identifique el punto con mayor distancia de Mahalanobis.
5. Grafique el conjunto con `ggplot2`.
6. Dibuje elipses de distancia de Mahalanobis para distancias 1, 2 y 3.
7. Coloree puntos según si su distancia es mayor que 1, 2 o 3.
8. Cree un conjunto de 3 variables.
9. Calcule distancias de Mahalanobis en 3D.
10. Grafique pares de variables con elipses proyectadas.

Parte C: Ejercicios avanzados

1. Simule 5 puntos en 3 dimensiones con una variable como combinación lineal de las otras.
2. Intente calcular la distancia de Mahalanobis y discuta la singularidad de la covarianza.
3. Aplique una transformación lineal a un conjunto 2D y verifique la invarianza de las distancias de Mahalanobis.
4. Escriba una función en R que devuelva puntos que formen una elipse de distancia de Mahalanobis.
5. Sobreponga elipses de distancia de Mahalanobis de radio arbitrario en un diagrama de dispersión.