

8 Análisis factorial: métodos prácticos

MA2003B Aplicación de métodos multivariados
en ciencia de datos

Raul Gomez



Tecnológico
de Monterrey

Análisis de conglomerados no jerárquicos

En **agrupamiento no jerárquico**, particionamos los datos en un número predeterminado de conglomerados.

Análisis de conglomerados no jerárquicos

En **agrupamiento no jerárquico**, particionamos los datos en un número predeterminado de conglomerados.

En este caso no obtenemos un dendrograma, sino un conjunto plano de conglomerados.

Análisis de conglomerados no jerárquicos

En **agrupamiento no jerárquico**, particionamos los datos en un número predeterminado de conglomerados.

En este caso no obtenemos un dendrograma, sino un conjunto plano de conglomerados.

Existen muchos métodos de agrupamiento no jerárquico, pero la mayoría pueden clasificarse como **métodos de particionado**, **métodos basados en densidad** o **métodos basados en modelos**.

Métodos de particionado

Estos métodos crean una partición de los datos en un conjunto de k conglomerados, donde k lo especifica la persona usuaria.

Métodos de particionado

Estos métodos crean una partición de los datos en un conjunto de k conglomerados, donde k lo especifica la persona usuaria.

Se apoyan en optimizar alguna función objetivo que mide la calidad del agrupamiento.

Métodos de particionado

Estos métodos crean una partición de los datos en un conjunto de k conglomerados, donde k lo especifica la persona usuaria.

Se apoyan en optimizar alguna función objetivo que mide la calidad del agrupamiento.

Los métodos de particionado más comunes son:

- **Agrupamiento k-means:** Busca particionar los datos en k conglomerados de forma que se minimice la suma de distancias cuadráticas entre cada punto y el centroide de su conglomerado asignado. El algoritmo asigna iterativamente los puntos al centroide más cercano y actualiza los centroides hasta converger.

- **Agrupamiento k-means:** Busca particionar los datos en k conglomerados de forma que se minimice la suma de distancias cuadráticas entre cada punto y el centroide de su conglomerado asignado. El algoritmo asigna iterativamente los puntos al centroide más cercano y actualiza los centroides hasta converger.
- **Agrupamiento k-medoids:** Similar a k-means, pero en lugar de usar la media como centroide, utiliza un punto real de los datos (el medoide) que minimiza la suma de distancias a los demás puntos del conglomerado. Esto lo hace más robusto al ruido y a los atípicos.

- **Agrupamiento k-means:** Busca particionar los datos en k conglomerados de forma que se minimice la suma de distancias cuadráticas entre cada punto y el centroide de su conglomerado asignado. El algoritmo asigna iterativamente los puntos al centroide más cercano y actualiza los centroides hasta converger.
- **Agrupamiento k-medoids:** Similar a k-means, pero en lugar de usar la media como centroide, utiliza un punto real de los datos (el medoide) que minimiza la suma de distancias a los demás puntos del conglomerado. Esto lo hace más robusto al ruido y a los atípicos.
- **CLARA (Clustering LARge Applications):** Extensión de k-medoids diseñada para conjuntos grandes; muestrea un subconjunto y aplica k-medoids sobre esa muestra.

- **Agrupamiento k-means:** Busca particionar los datos en k conglomerados de forma que se minimice la suma de distancias cuadráticas entre cada punto y el centroide de su conglomerado asignado. El algoritmo asigna iterativamente los puntos al centroide más cercano y actualiza los centroides hasta converger.
- **Agrupamiento k-medoids:** Similar a k-means, pero en lugar de usar la media como centroide, utiliza un punto real de los datos (el medoide) que minimiza la suma de distancias a los demás puntos del conglomerado. Esto lo hace más robusto al ruido y a los atípicos.
- **CLARA (Clustering LARge Applications):** Extensión de k-medoids diseñada para conjuntos grandes; muestrea un subconjunto y aplica k-medoids sobre esa muestra.
- **PAM (Partitioning Around Medoids):** Implementación específica de k-medoids que usa una estrategia voraz para encontrar los medoides y asignar puntos a conglomerados.

Métodos basados en densidad

Estos métodos identifican conglomerados con base en la densidad de puntos en el espacio de datos.

Métodos basados en densidad

Estos métodos identifican conglomerados con base en la densidad de puntos en el espacio de datos.

Pueden encontrar conglomerados de formas arbitrarias y son robustos al ruido.

Métodos basados en densidad

Estos métodos identifican conglomerados con base en la densidad de puntos en el espacio de datos.

Pueden encontrar conglomerados de formas arbitrarias y son robustos al ruido.

Los métodos basados en densidad más comunes son:

- **DBSCAN (Density-Based Spatial Clustering of Applications with Noise):**
Define conglomerados como zonas de alta densidad separadas por regiones de baja densidad. Requiere dos parámetros: el radio ε que define la vecindad de un punto y el número mínimo de puntos para formar una región densa. Los puntos que no pertenecen a ningún conglomerado se consideran ruido.

- **DBSCAN (Density-Based Spatial Clustering of Applications with Noise):**
Define conglomerados como zonas de alta densidad separadas por regiones de baja densidad. Requiere dos parámetros: el radio ε que define la vecindad de un punto y el número mínimo de puntos para formar una región densa. Los puntos que no pertenecen a ningún conglomerado se consideran ruido.
- **OPTICS (Ordering Points To Identify the Clustering Structure):** Extensión de DBSCAN que ordena los puntos según su densidad, permitiendo identificar conglomerados a distintos niveles de densidad.

- **DBSCAN (Density-Based Spatial Clustering of Applications with Noise):** Define conglomerados como zonas de alta densidad separadas por regiones de baja densidad. Requiere dos parámetros: el radio ε que define la vecindad de un punto y el número mínimo de puntos para formar una región densa. Los puntos que no pertenecen a ningún conglomerado se consideran ruido.
- **OPTICS (Ordering Points To Identify the Clustering Structure):** Extensión de DBSCAN que ordena los puntos según su densidad, permitiendo identificar conglomerados a distintos niveles de densidad.
- **Mean Shift:** Desplaza iterativamente cada punto hacia la media de los puntos en su vecindad, encontrando los modos de la distribución. Los conglomerados se forman alrededor de esos modos.

Métodos basados en modelos

Estos métodos suponen que los datos provienen de una mezcla de distribuciones de probabilidad subyacentes, y buscan identificar dichas distribuciones y asignar puntos a conglomerados según su probabilidad posterior de pertenencia.

Métodos basados en modelos

Estos métodos suponen que los datos provienen de una mezcla de distribuciones de probabilidad subyacentes, y buscan identificar dichas distribuciones y asignar puntos a conglomerados según su probabilidad posterior de pertenencia.

Los métodos basados en modelos más comunes son:

- **Modelos de Mezclas Gaussianas (GMM):** Modelan los datos como mezcla de varias distribuciones gaussianas, cada una representando un conglomerado. Los parámetros se estiman con el algoritmo de Expectación–Maximización (EM) y los puntos se asignan según probabilidades posteriores.

- **Modelos de Mezclas Gaussianas (GMM):** Modelan los datos como mezcla de varias distribuciones gaussianas, cada una representando un conglomerado. Los parámetros se estiman con el algoritmo de Expectación–Maximización (EM) y los puntos se asignan según probabilidades posteriores.
- **Agrupamiento bayesiano:** Usa inferencia bayesiana para estimar parámetros de las distribuciones subyacentes y asignar puntos a conglomerados. Puede incorporar conocimiento previo y manejar la incertidumbre del proceso.

- **Modelos de Mezclas Gaussianas (GMM):** Modelan los datos como mezcla de varias distribuciones gaussianas, cada una representando un conglomerado. Los parámetros se estiman con el algoritmo de Expectación–Maximización (EM) y los puntos se asignan según probabilidades posteriores.
- **Agrupamiento bayesiano:** Usa inferencia bayesiana para estimar parámetros de las distribuciones subyacentes y asignar puntos a conglomerados. Puede incorporar conocimiento previo y manejar la incertidumbre del proceso.
- **Análisis de Clases Latentes (LCA):** Usado para datos categóricos; asume que los datos provienen de una mezcla de clases latentes. Estima los parámetros de las clases y asigna puntos según probabilidades posteriores.

Elección del método adecuado

La elección del método de agrupamiento no jerárquico depende de las características de los datos y de los objetivos específicos del análisis.

Elección del método adecuado

La elección del método de agrupamiento no jerárquico depende de las características de los datos y de los objetivos específicos del análisis.

Algunas pautas para elegir el método adecuado:

- Si los datos son continuos y se espera que los conglomerados sean esféricos y de tamaño similar, k-means o k-medoids pueden ser apropiados.

- Si los datos son continuos y se espera que los conglomerados sean esféricos y de tamaño similar, k-means o k-medoids pueden ser apropiados.
- Si hay ruido o atípicos, o si se esperan conglomerados de distintas formas y tamaños, métodos basados en densidad como DBSCAN u OPTICS pueden ser más adecuados.

- Si los datos son continuos y se espera que los conglomerados sean esféricos y de tamaño similar, k-means o k-medoids pueden ser apropiados.
- Si hay ruido o atípicos, o si se esperan conglomerados de distintas formas y tamaños, métodos basados en densidad como DBSCAN u OPTICS pueden ser más adecuados.
- Si se cree que los datos provienen de una mezcla de distribuciones subyacentes, métodos basados en modelos como GMM o agrupamiento bayesiano pueden ser la mejor opción.

- Si los datos son continuos y se espera que los conglomerados sean esféricos y de tamaño similar, k-means o k-medoids pueden ser apropiados.
- Si hay ruido o atípicos, o si se esperan conglomerados de distintas formas y tamaños, métodos basados en densidad como DBSCAN u OPTICS pueden ser más adecuados.
- Si se cree que los datos provienen de una mezcla de distribuciones subyacentes, métodos basados en modelos como GMM o agrupamiento bayesiano pueden ser la mejor opción.
- Si los datos son categóricos, el Análisis de Clases Latentes (LCA) puede ser el más apropiado.

- Si los datos son continuos y se espera que los conglomerados sean esféricos y de tamaño similar, k-means o k-medoids pueden ser apropiados.
- Si hay ruido o atípicos, o si se esperan conglomerados de distintas formas y tamaños, métodos basados en densidad como DBSCAN u OPTICS pueden ser más adecuados.
- Si se cree que los datos provienen de una mezcla de distribuciones subyacentes, métodos basados en modelos como GMM o agrupamiento bayesiano pueden ser la mejor opción.
- Si los datos son categóricos, el Análisis de Clases Latentes (LCA) puede ser el más apropiado.
- Si el conjunto es grande, considere métodos como CLARA, diseñados para manejar grandes volúmenes de manera eficiente.

Evaluación de los resultados de agrupamiento

Evaluar la calidad del agrupamiento es crucial para confirmar que el método elegido capturó la estructura subyacente de los datos.

Evaluación de los resultados de agrupamiento

Evaluar la calidad del agrupamiento es crucial para confirmar que el método elegido capturó la estructura subyacente de los datos.

Algunas técnicas comunes para evaluar resultados de agrupamiento:

- **Validación interna:** Usa métricas que evalúan la calidad del agrupamiento con base en los propios datos, sin referencia externa. Algunas métricas comunes:

- **Validación interna:** Usa métricas que evalúan la calidad del agrupamiento con base en los propios datos, sin referencia externa. Algunas métricas comunes:
 - **Índice de silueta:** Mide qué tan similar es un punto a su propio conglomerado frente a otros. Valores mayores indican conglomerados mejor definidos.

- **Validación interna:** Usa métricas que evalúan la calidad del agrupamiento con base en los propios datos, sin referencia externa. Algunas métricas comunes:
 - **Índice de silueta:** Mide qué tan similar es un punto a su propio conglomerado frente a otros. Valores mayores indican conglomerados mejor definidos.
 - **Índice de Davies–Bouldin:** Evalúa la razón de similitud promedio de cada conglomerado con su más similar. Valores bajos indican mejor agrupamiento.

- **Validación interna:** Usa métricas que evalúan la calidad del agrupamiento con base en los propios datos, sin referencia externa. Algunas métricas comunes:
 - **Índice de silueta:** Mide qué tan similar es un punto a su propio conglomerado frente a otros. Valores mayores indican conglomerados mejor definidos.
 - **Índice de Davies–Bouldin:** Evalúa la razón de similitud promedio de cada conglomerado con su más similar. Valores bajos indican mejor agrupamiento.
 - **Índice de Calinski–Harabasz:** Mide la razón de varianza entre–conglomerados vs. intra–conglomerados. Valores altos indican conglomerados mejor definidos.

- **Validación externa:** Compara los resultados con etiquetas conocidas o verdad-terreno, si está disponible. Métricas comunes:

- **Validación externa:** Compara los resultados con etiquetas conocidas o verdad-terreno, si está disponible. Métricas comunes:
 - **Índice de Rand Ajustado (ARI):** Mide la similitud con la verdad-terreno, ajustando por azar. Valores altos indican mayor acuerdo.

- **Validación externa:** Compara los resultados con etiquetas conocidas o verdad-terreno, si está disponible. Métricas comunes:
 - **Índice de Rand Ajustado (ARI):** Mide la similitud con la verdad-terreno, ajustando por azar. Valores altos indican mayor acuerdo.
 - **Información Mutua Normalizada (NMI):** Mide la información compartida entre el agrupamiento y la verdad-terreno. Valores altos indican mayor acuerdo.

- **Análisis de estabilidad:** Evalúa la robustez aplicando el algoritmo a distintos subconjuntos o añadiendo ruido. Resultados consistentes entre corridas indican estabilidad.

- **Análisis de estabilidad:** Evalúa la robustez aplicando el algoritmo a distintos subconjuntos o añadiendo ruido. Resultados consistentes entre corridas indican estabilidad.
- **Inspección visual:** Diagramas de dispersión, mapas de calor o dendrogramas (si aplica) ayudan a entender la estructura y a detectar problemas potenciales.

Ejemplo en R

Ilustraremos algunos métodos de agrupamiento no jerárquico usando el conocido conjunto iris.

Ejemplo en R

Ilustraremos algunos métodos de agrupamiento no jerárquico usando el conocido conjunto iris.

Usaremos sólo las variables Sepal.Width y Sepal.Length para simplificar.

Ejemplo en R

Ilustraremos algunos métodos de agrupamiento no jerárquico usando el conocido conjunto iris.

Usaremos sólo las variables Sepal.Width y Sepal.Length para simplificar.

Los métodos que compararemos son:

- **k-means clustering (a partitioning method)**
- **PAM (Partitioning Around Medoids, a k-medoids method)**
- **Gaussian Mixture Models (GMM, a model-based method)**
- **DBSCAN (a density-based method)**

Agrupamiento de Iris (sépalos)

