

2 Modelos de regresión lineal simple

MA2003B Aplicación de métodos multivariados
en ciencia de datos

Raul Gomez



El modelo de regresión lineal simple

En un **modelo de regresión simple**, suponemos que tenemos una **variable independiente** X_0 (también conocida como **variable explicativa** o **predictora**), y una **variable dependiente** Y_0 (también conocida como **variable de respuesta**).

El modelo de regresión lineal simple

En un **modelo de regresión simple**, suponemos que tenemos una **variable independiente** X_0 (también conocida como **variable explicativa** o **predictora**), y una **variable dependiente** Y_0 (también conocida como **variable de respuesta**).

Suponemos además que estas variables satisfacen una relación de la forma:

$$Y_0 = f_0(X_0) + \varepsilon_0$$

donde f_0 es una función desconocida que describe la relación entre ambas variables, y ε_0 es una variable aleatoria que representa el **error** o **ruido** en la relación entre X_0 y Y_0 .

Uno de los objetivos del **aprendizaje estadístico** (también conocido como **aprendizaje automático** o **machine learning**), es tratar de aproximar la función f_0 a partir de un conjunto de datos

$$\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$$

dado.

Uno de los objetivos del **aprendizaje estadístico** (también conocido como **aprendizaje automático** o **machine learning**), es tratar de aproximar la función f_0 a partir de un conjunto de datos

$$\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$$

dado.

De manera más precisa, consideramos vectores aleatorios

$$X = (X_1, X_2, \dots, X_n)$$

$$Y = (Y_1, Y_2, \dots, Y_n)$$

que representan los posibles valores de las observaciones independientes y dependientes, respectivamente, en una muestra dada.

Uno de los objetivos del **aprendizaje estadístico** (también conocido como **aprendizaje automático** o **machine learning**), es tratar de aproximar la función f_0 a partir de un conjunto de datos

$$\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$$

dado.

De manera más precisa, consideramos vectores aleatorios

$$X = (X_1, X_2, \dots, X_n)$$

$$Y = (Y_1, Y_2, \dots, Y_n)$$

que representan los posibles valores de las observaciones independientes y dependientes, respectivamente, en una muestra dada.

En este contexto, un **método de aprendizaje** consiste de una función $\hat{F}$, que depende de los vectores aleatorios X e Y , y que cuando se evalúa en los datos observados produce una función $\hat{f}$ que aproxima a la función desconocida f_0 .

Observación

En muchos modelos de aprendizaje estadístico es común tomar el vector $X = x$ como fijo, en cuyo caso la función $\hat{F}$ depende únicamente del vector aleatorio Y .

Para hacer estas ideas un poco más concretas, consideremos el caso particular en el que la función desconocida f_0 es una función lineal, es decir,

$$f_0(X_0) = b_0 + b_1 X_0$$

y supondremos además que $\varepsilon_0 \sim N(0, \sigma^2)$ es una variable aleatoria con distribución normal de media 0 y varianza σ^2 .

Para hacer estas ideas un poco más concretas, consideremos el caso particular en el que la función desconocida f_0 es una función lineal, es decir,

$$f_0(X_0) = b_0 + b_1 X_0$$

y supondremos además que $\varepsilon_0 \sim N(0, \sigma^2)$ es una variable aleatoria con distribución normal de media 0 y varianza σ^2 .

Este contexto se conoce como el **modelo de regresión lineal simple** y es uno de los métodos más utilizados en aprendizaje estadístico.

Notemos que en este caso nuestro objetivo es encontrar una expresión que nos permita aproximar los parámetros desconocidos b_0 y b_1 en términos de los datos observados.

Notemos que en este caso nuestro objetivo es encontrar una expresión que nos permita aproximar los parámetros desconocidos b_0 y b_1 en términos de los datos observados.

Definiremos el **estimador de mínimos cuadrados** para los parámetros b_0 y b_1 como:

$$\hat{B}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})Y_i}{\sum_{i=1}^n (x_i - \bar{x})^2}$$
$$\hat{B}_0 = \bar{Y} - \hat{B}_1 \bar{x}$$

Notemos que en este caso nuestro objetivo es encontrar una expresión que nos permita aproximar los parámetros desconocidos b_0 y b_1 en términos de los datos observados.

Definiremos el **estimador de mínimos cuadrados** para los parámetros b_0 y b_1 como:

$$\hat{B}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})Y_i}{\sum_{i=1}^n (x_i - \bar{x})^2}$$
$$\hat{B}_0 = \bar{Y} - \hat{B}_1 \bar{x}$$

Notemos que en estas expresiones estamos considerando el vector $X = x$ como fijo, mientras que el vector $Y = (Y_1, Y_2, \dots, Y_n)$ se sigue considerando como un vector aleatorio.

En otras palabras, las fórmulas anteriores definen dos variables aleatorias $\hat{B}_0$ y $\hat{B}_1$ que dependen linealmente del vector aleatorio Y .

En otras palabras, las fórmulas anteriores definen dos variables aleatorias $\hat{B}_0$ y $\hat{B}_1$ que dependen linealmente del vector aleatorio Y .

Finalmente, definimos la función

$$\hat{F}(X_0) = \hat{B}_0 + \hat{B}_1 X_0$$

la cual se conoce como el **estimador de mínimos cuadrados** para la función f_0 .

Notemos ahora que si evaluamos estos estimadores en el vector de datos observados $Y = y$, obtenemos los valores

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})y_i}{\sum_{i=1}^n (x_i - \bar{x})^2}$$
$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

que coinciden con los coeficientes de la recta de mejor ajuste por mínimos cuadrados que obtuvimos en la sección anterior.

Por lo tanto, el estimador de mínimos cuadrados para la función f_0 evaluado en los datos observados es la recta de mejor ajuste por mínimos cuadrados:

$$\hat{f}(X_0) = \hat{\beta}_0 + \hat{\beta}_1 X_0$$

Para hacer este caso un poco más concreto, supongamos que fijamos los valores

$$b_0 = 0$$

$$b_1 = 1$$

y tomamos cinco valores para la variable independiente X_0 que se encuentren uniformemente distribuidos en el intervalo $[0, 10]$

En particular, podemos considerar el vector

$$x = (2.88, 7.88, 4.09, 8.83, 9.4)$$

De acuerdo a nuestro modelo, los valores correspondientes de la variable dependiente Y_0 deberían de satisfacer una relación de la forma

$$Y_0 = b_0 + b_1 X_0 + \varepsilon_0 = X_0 + \varepsilon_0$$

donde $\varepsilon_0 \sim N(0, \sigma^2)$.

De acuerdo a nuestro modelo, los valores correspondientes de la variable dependiente Y_0 deberían de satisfacer una relación de la forma

$$Y_0 = b_0 + b_1 X_0 + \varepsilon_0 = X_0 + \varepsilon_0$$

donde $\varepsilon_0 \sim N(0, \sigma^2)$.

Supongamos que tomamos $\sigma^2 = 1$,

y consideremos el vector de observaciones dependientes

$$y = (1.19, 9.12, 3.98, 8.71, 9.59)$$

De acuerdo a nuestro modelo, los valores correspondientes de la variable dependiente Y_0 deberían de satisfacer una relación de la forma

$$Y_0 = b_0 + b_1 X_0 + \varepsilon_0 = X_0 + \varepsilon_0$$

donde $\varepsilon_0 \sim N(0, \sigma^2)$.

Supongamos que tomamos $\sigma^2 = 1$,

y consideremos el vector de observaciones dependientes

$$y = (1.19, 9.12, 3.98, 8.71, 9.59)$$

De manera gráfica, podemos visualizar los datos observados de la siguiente manera:




Figure 1: Diagrama de dispersión de los datos simulados.

Calculamos ahora

$$\bar{x} = 6.62$$

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = 34.66$$

Calculamos ahora

$$\bar{x} = 6.62$$

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = 34.66$$

Podemos calcular ahora las fórmulas para los estimadores de mínimos cuadrados:

$$\hat{B}_1 = -0.11Y_1 + 0.04Y_2 + -0.07Y_3 + 0.06Y_4 + 0.08Y_5$$

$$\hat{B}_0 = 0.91Y_1 + -0.04Y_2 + 0.68Y_3 + -0.22Y_4 + -0.33Y_5$$

Se sigue que nuestro método de aprendizaje está dado por la función

$$\begin{aligned}\hat{F}(X_0) &= \hat{B}_0 + \hat{B}_1 X_0 \\ &= 0.91 Y_1 + -0.04 Y_2 + 0.68 Y_3 + -0.22 Y_4 + -0.33 Y_5 \\ &\quad + (-0.11 Y_1 + 0.04 Y_2 + -0.07 Y_3 + 0.06 Y_4 + 0.08 Y_5) X_0\end{aligned}$$

Notemos que esta expresión depende no solamente de la variable aleatoria X_0 , sino también de las variables aleatorias $Y_1, Y_2, \dots, Y_5$.

Notemos que esta expresión depende no solamente de la variable aleatoria X_0 , sino también de las variables aleatorias $Y_1, Y_2, \dots, Y_5$.

Evaluando ahora este estimador en los datos observados $Y = y$, obtenemos los valores

$$\hat{\beta}_1 = 1.24$$

$$\hat{\beta}_0 = -1.71$$

y la función estimada se convierte en:

$$\hat{f}(X_0) = -1.71 + 1.24X_0$$

La cual se puede visualizar en la siguiente figura:




Figure 2: Línea recta que mejor se ajusta a los datos simulados.

Notemos que los valores estimados para los parámetros b_0 y b_1 no coinciden exactamente con los valores reales que utilizamos para simular los datos.