

3 Intervalos de confianza y predicción en regresión

MA2003B Aplicación de métodos multivariados
en ciencia de datos

Raul Gomez



Tecnológico
de Monterrey

Intervalos de confianza y predicción en regresión lineal

En esta sección retomaremos nuestro modelo de regresión lineal simple, pero haremos más énfasis en su descripción utilizando álgebra lineal.

Intervalos de confianza y predicción en regresión lineal

En esta sección retomaremos nuestro modelo de regresión lineal simple, pero haremos más énfasis en su descripción utilizando álgebra lineal.

Empecemos recordando que nuestro modelo está dado por la ecuación

$$Y_0 = b_0 + b_1 X_0 + \varepsilon_0$$

donde $\varepsilon_0 \sim N(0, \sigma^2)$.

Recordemos también que estamos considerando los vectores aleatorios

$$X = \begin{bmatrix} X_1 \\ \vdots \\ X_n \end{bmatrix} \quad Y = \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix}$$

Recordemos también que estamos considerando los vectores aleatorios

$$X = \begin{bmatrix} X_1 \\ \vdots \\ X_n \end{bmatrix} \quad Y = \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix}$$

Suponemos además que tenemos los vectores de observaciones

$$x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \quad y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}$$

donde cada par (x_i, y_i) es una realización del vector aleatorio (X_i, Y_i) para $i = 1, \dots, n$.

Consideraremos ahora la matriz de diseño

$$\Phi = \begin{bmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}$$

Consideraremos ahora la matriz de diseño

$$\Phi = \begin{bmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}$$

Entonces la fórmula para expresar nuestro método de aprendizaje de mínimos cuadrados puede escribirse de la siguiente manera:

$$\hat{B} = AY$$

donde

$$A = (\Phi^T \Phi)^{-1} \Phi^T$$

es la matriz de proyección sobre el subespacio generado por las columnas de la matriz de diseño Φ .

Notemos que como $\hat{B}$ es una combinación lineal de variables aleatorias normales, entonces $\hat{B}$ también es una variable aleatoria normal.

Notemos que como $\hat{B}$ es una combinación lineal de variables aleatorias normales, entonces $\hat{B}$ también es una variable aleatoria normal.

En particular, podemos calcular su esperanza y su varianza de la siguiente manera:

$$\begin{aligned}E[\hat{B}] &= E[AY] = AE[Y] = A\Phi B = B \\ \text{Var}(\hat{B}) &= \text{Var}(AY) = A\text{Var}(Y)A^T = \sigma^2 AA^T = \sigma^2(\Phi^T \Phi)^{-1}\end{aligned}$$

donde hemos utilizado el hecho de que $\text{Var}(Y) = \sigma^2 I_n$.

Notemos que como $\hat{B}$ es una combinación lineal de variables aleatorias normales, entonces $\hat{B}$ también es una variable aleatoria normal.

En particular, podemos calcular su esperanza y su varianza de la siguiente manera:

$$\begin{aligned}E[\hat{B}] &= E[AY] = AE[Y] = A\Phi B = B \\ \text{Var}(\hat{B}) &= \text{Var}(AY) = A\text{Var}(Y)A^T = \sigma^2 AA^T = \sigma^2(\Phi^T \Phi)^{-1}\end{aligned}$$

donde hemos utilizado el hecho de que $\text{Var}(Y) = \sigma^2 I_n$.

Notemos, en particular, que el estimador $\hat{B}$ es insesgado, es decir, $E[\hat{B}] = B$.

De manera más explícita, la matriz de covarianza de $\hat{B}$ está dada por:

$$\text{Var}(\hat{B}) = \sigma^2 \begin{bmatrix} \frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} & -\frac{\bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ -\frac{\bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2} & \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \end{bmatrix}$$

De manera más explícita, la matriz de covarianza de $\hat{B}$ está dada por:

$$\text{Var}(\hat{B}) = \sigma^2 \begin{bmatrix} \frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} & -\frac{\bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ -\frac{\bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2} & \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \end{bmatrix}$$

Notemos que, en particular,

$$\hat{B}_0 \sim N \left(b_0, \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right) \right)$$

y

$$\hat{B}_1 \sim N \left(b_1, \sigma^2 \left(\frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \right) \right)$$

Quisiéramos ahora construir intervalos de confianza para los parámetros b_0 y b_1 .

Quisiéramos ahora construir intervalos de confianza para los parámetros b_0 y b_1 .

Para ello, necesitamos una estimación de la varianza σ^2 .

Quisiéramos ahora construir intervalos de confianza para los parámetros b_0 y b_1 .

Para ello, necesitamos una estimación de la varianza σ^2 .

Recordemos que una estimación insesgada de σ^2 está dada por:

$$\hat{S}^2 = \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{F}(X_i))^2$$

donde $\hat{F}(X_i) = \hat{B}_0 + \hat{B}_1 X_i$.

Notemos que la cantidad $n - 2$ aparece en el denominador porque hemos estimado dos parámetros a partir de los datos. Por tanto, la siguiente variable tiene una distribución t de Student con $n - 2$ grados de libertad:

$$T_j = \frac{\hat{B}_j - b_j}{\hat{S} \sqrt{\text{Var}(\hat{B}_j) / \sigma^2}} \sim t_{n-2}$$

para $j = 0, 1$.

Notemos que la cantidad $n - 2$ aparece en el denominador porque hemos estimado dos parámetros a partir de los datos. Por tanto, la siguiente variable tiene una distribución t de Student con $n - 2$ grados de libertad:

$$T_j = \frac{\hat{B}_j - b_j}{\hat{S} \sqrt{\text{Var}(\hat{B}_j) / \sigma^2}} \sim t_{n-2}$$

para $j = 0, 1$.

Por lo tanto, un intervalo de confianza para el parámetro b_j con un nivel de confianza $1 - \alpha$ está dado por:

$$\left(\hat{\beta}_j - t_{\alpha/2, n-2} \hat{S} \sqrt{\text{Var}(\hat{\beta}_j) / \sigma^2}, \quad \hat{B}_j + t_{\alpha/2, n-2} \hat{S} \sqrt{\text{Var}(\hat{B}_j) / \sigma^2} \right)$$

donde $t_{\alpha/2, n-2}$ es el cuantil superior de orden $\alpha/2$ de la distribución t de Student con $n - 2$ grados de libertad.

Para construir un intervalo de confianza para la media de la variable dependiente Y_0 en un valor específico de la variable independiente $X_0 = x_0$, consideremos la predicción puntual dada por:

$$\hat{Y}_0 = \hat{B}_0 + \hat{B}_1 x_0$$

Para construir un intervalo de confianza para la media de la variable dependiente Y_0 en un valor específico de la variable independiente $X_0 = x_0$, consideremos la predicción puntual dada por:

$$\hat{Y}_0 = \hat{B}_0 + \hat{B}_1 x_0$$

Notemos que $\hat{Y}_0$ es una variable aleatoria normal cuya esperanza y varianza están dadas por:

$$E[\hat{Y}_0] = E[\hat{B}_0 + \hat{B}_1 x_0] = b_0 + b_1 x_0$$

$$\text{Var}(\hat{Y}_0) = \text{Var}(\hat{B}_0 + \hat{B}_1 x_0) = \sigma^2 \left(\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)$$

Por lo tanto, la siguiente variable tiene una distribución t de Student con $n - 2$ grados de libertad:

$$T_C = \frac{\hat{Y}_0 - E[\hat{Y}_0]}{\hat{S} \sqrt{\text{Var}(\hat{Y}_0) / \sigma^2}} \sim t_{n-2}$$

Un intervalo de confianza para la media de la variable dependiente Y_0 en el valor $X_0 = x_0$ con un nivel de confianza $1 - \alpha$ está dado por:

$$\left(\hat{Y}_0 - t_{\alpha/2, n-2} \hat{S} \sqrt{\text{Var}(\hat{Y}_0) / \sigma^2}, \quad \hat{Y}_0 + t_{\alpha/2, n-2} \hat{S} \sqrt{\text{Var}(\hat{Y}_0) / \sigma^2} \right)$$

Un intervalo de confianza para la media de la variable dependiente Y_0 en el valor $X_0 = x_0$ con un nivel de confianza $1 - \alpha$ está dado por:

$$\left(\hat{Y}_0 - t_{\alpha/2, n-2} \hat{S} \sqrt{\text{Var}(\hat{Y}_0) / \sigma^2}, \quad \hat{Y}_0 + t_{\alpha/2, n-2} \hat{S} \sqrt{\text{Var}(\hat{Y}_0) / \sigma^2} \right)$$

Finalmente, quisiéramos construir un intervalo de predicción para una nueva observación de la variable dependiente Y_0 en el valor $X_0 = x_0$. Consideremos la nueva observación

$$Y_0 = b_0 + b_1 x_0 + \varepsilon_0$$

Un intervalo de confianza para la media de la variable dependiente Y_0 en el valor $X_0 = x_0$ con un nivel de confianza $1 - \alpha$ está dado por:

$$\left(\hat{Y}_0 - t_{\alpha/2, n-2} \hat{S} \sqrt{\text{Var}(\hat{Y}_0) / \sigma^2}, \quad \hat{Y}_0 + t_{\alpha/2, n-2} \hat{S} \sqrt{\text{Var}(\hat{Y}_0) / \sigma^2} \right)$$

Finalmente, quisiéramos construir un intervalo de predicción para una nueva observación de la variable dependiente Y_0 en el valor $X_0 = x_0$. Consideremos la nueva observación

$$Y_0 = b_0 + b_1 x_0 + \varepsilon_0$$

donde $\varepsilon_0 \sim N(0, \sigma^2)$.

Un intervalo de confianza para la media de la variable dependiente Y_0 en el valor $X_0 = x_0$ con un nivel de confianza $1 - \alpha$ está dado por:

$$\left(\hat{Y}_0 - t_{\alpha/2, n-2} \hat{S} \sqrt{\text{Var}(\hat{Y}_0) / \sigma^2}, \quad \hat{Y}_0 + t_{\alpha/2, n-2} \hat{S} \sqrt{\text{Var}(\hat{Y}_0) / \sigma^2} \right)$$

Finalmente, quisiéramos construir un intervalo de predicción para una nueva observación de la variable dependiente Y_0 en el valor $X_0 = x_0$. Consideremos la nueva observación

$$Y_0 = b_0 + b_1 x_0 + \varepsilon_0$$

donde $\varepsilon_0 \sim N(0, \sigma^2)$.

Notemos que la diferencia entre la nueva observación Y_0 y la predicción puntual $\hat{Y}$ es una variable aleatoria normal cuya esperanza y varianza están dadas por:

$$E[Y_0 - \hat{Y}_0] = E[Y_0] - E[\hat{Y}_0] = 0$$

$$\text{Var}(Y_0 - \hat{Y}_0) = \text{Var}(Y_0) + \text{Var}(\hat{Y}_0) = \sigma^2 \left(1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)$$

Por lo tanto, la siguiente variable tiene una distribución t de Student con $n - 2$ grados de libertad:

$$T_P = \frac{Y_0 - \hat{Y}_0}{\hat{S} \sqrt{\text{Var}(Y_0 - \hat{Y}_0) / \sigma^2}} \sim t_{n-2}$$

Por lo tanto, la siguiente variable tiene una distribución t de Student con $n - 2$ grados de libertad:

$$T_P = \frac{Y_0 - \hat{Y}_0}{\hat{S} \sqrt{\text{Var}(Y_0 - \hat{Y}_0) / \sigma^2}} \sim t_{n-2}$$

Un intervalo de predicción para una nueva observación de la variable dependiente Y_0 en el valor $X_0 = x_0$ con un nivel de confianza $1 - \alpha$ está dado por:

$$\left(\hat{y}_0 - t_{\alpha/2, n-2} \hat{S} \sqrt{\text{Var}(Y_0 - \hat{Y}_0) / \sigma^2}, \quad \hat{y}_0 + t_{\alpha/2, n-2} \hat{S} \sqrt{\text{Var}(Y_0 - \hat{Y}_0) / \sigma^2} \right)$$