

3 Adecuación del modelo

MA2003B Aplicación de métodos multivariados
en ciencia de datos

Raul Gomez



Tecnológico
de Monterrey

Modelo de regresión lineal múltiple

Hasta el momento hemos considerado únicamente modelos con una sola variable independiente.

Modelo de regresión lineal múltiple

Hasta el momento hemos considerado únicamente modelos con una sola variable independiente.

Sin embargo, en muchos casos es posible que la variable de interés dependa de múltiples variables independientes.

Modelo de regresión lineal múltiple

Hasta el momento hemos considerado únicamente modelos con una sola variable independiente.

Sin embargo, en muchos casos es posible que la variable de interés dependa de múltiples variables independientes.

En este caso, el modelo de regresión lineal simple se extiende al modelo de regresión lineal múltiple, en el cual la variable dependiente Y depende linealmente de múltiples variables independientes $X_{01}, X_{02}, \dots, X_{0p}$.

De manera más específica, supondremos que tenemos un modelo de la forma

$$Y_0 = b_0 + b_1X_{01} + b_2X_{02} + \cdots + b_pX_{0p} + \varepsilon$$

De manera más específica, supondremos que tenemos un modelo de la forma

$$Y_0 = b_0 + b_1X_{01} + b_2X_{02} + \cdots + b_pX_{0p} + \varepsilon$$

En este modelo, Y_0 es la variable dependiente

De manera más específica, supondremos que tenemos un modelo de la forma

$$Y_0 = b_0 + b_1X_{01} + b_2X_{02} + \cdots + b_pX_{0p} + \varepsilon$$

En este modelo, Y_0 es la variable dependiente

Las variables independientes son: $X_{01}, X_{02}, \dots, X_{0p}$

De manera más específica, supondremos que tenemos un modelo de la forma

$$Y_0 = b_0 + b_1X_{01} + b_2X_{02} + \cdots + b_pX_{0p} + \varepsilon$$

En este modelo, Y_0 es la variable dependiente

Las variables independientes son: $X_{01}, X_{02}, \dots, X_{0p}$

Los parámetros del modelo son: $b_0, b_1, \dots, b_p$

De manera más específica, supondremos que tenemos un modelo de la forma

$$Y_0 = b_0 + b_1X_{01} + b_2X_{02} + \cdots + b_pX_{0p} + \varepsilon$$

En este modelo, Y_0 es la variable dependiente

Las variables independientes son: $X_{01}, X_{02}, \dots, X_{0p}$

Los parámetros del modelo son: $b_0, b_1, \dots, b_p$

El término de error está dado por

$$\varepsilon \sim \mathcal{N}(0, \sigma^2)$$

Para considerar nuestras muestras de datos, consideraremos la matriz aleatoria

$$X = \begin{bmatrix} X_{11} & X_{12} & \dots & X_{1p} \\ X_{21} & X_{22} & \dots & X_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} & X_{n2} & \dots & X_{np} \end{bmatrix}$$

Para considerar nuestras muestras de datos, consideraremos la matriz aleatoria

$$X = \begin{bmatrix} X_{11} & X_{12} & \dots & X_{1p} \\ X_{21} & X_{22} & \dots & X_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} & X_{n2} & \dots & X_{np} \end{bmatrix}$$

mantendremos el vector aleatorio

$$Y = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}$$

que hemos utilizado anteriormente.

Supongamos ahora que tenemos un vector de observaciones independientes

$$x = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix}$$

Supongamos ahora que tenemos un vector de observaciones independientes

$$x = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix}$$

Entonces, podemos definir la matriz de diseño

$$\Phi = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix}$$

y podemos definir las matrices $D^2 = (\Phi^T \Phi)^{-1}$, $A = D^2 \Phi^T$ y $H = \Phi A$.

Entonces, el vector de coeficientes de la recta de mejor ajuste por mínimos cuadrados está dado por

$$\hat{B} = AY \sim \mathcal{N}(b, \sigma^2 D^2)$$

mientras que el vector de predicciones está dado por

$$\hat{Y} = HY$$

Notemos que en este caso el estimador para la varianza del error está dado por

$$\hat{S}^2 = \frac{\|Y - \hat{Y}\|^2}{n - (p + 1)} = \sum_{i=1}^n \frac{(Y_i - \hat{Y}_i)^2}{n - (p + 1)}$$

Ahora dado cualquier vector de observaciones dependientes

$$y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

podemos evaluar los estimadores anteriores en los datos observados para obtener el vector de coeficientes de la recta de mejor ajuste por mínimos cuadrados.

En particular, el vector de coeficientes está dado por

$$\hat{\beta} = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_p \end{bmatrix} = Ay$$

En particular, el vector de coeficientes está dado por

$$\hat{\beta} = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_p \end{bmatrix} = Ay$$

mientras que el vector de predicciones está dado por

$$\hat{y} = \begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_n \end{bmatrix} = Hy$$

Notemos que podemos realizar estos cálculos para cualquier conjunto de datos dados, sin embargo, para que el modelo de regresión lineal múltiple sea adecuado, es necesario que se cumplan ciertas condiciones.