

El modelo discriminante Gaussiano

MA2003B Aplicación de métodos multivariados
en ciencia de datos

Raul Gomez



Tecnológico
de Monterrey

El modelo discriminante Gaussiano

El **análisis discriminante lineal** (LDA, por sus siglas en inglés) es un método de clasificación supervisada que permite separar dos o más clases basándose en las características más relevantes capturadas por un conjunto de datos dado.

El modelo discriminante Gaussiano

El **análisis discriminante lineal** (LDA, por sus siglas en inglés) es un método de clasificación supervisada que permite separar dos o más clases basándose en las características más relevantes capturadas por un conjunto de datos dado.

Este método de clasificación se basa en el **modelo discriminante gaussiano**, que asume que nuestra población se encuentra separada en K clases distintas (también conocidas como grupos o categorías) por una variable categórica G .

El modelo discriminante Gaussiano

El **análisis discriminante lineal** (LDA, por sus siglas en inglés) es un método de clasificación supervisada que permite separar dos o más clases basándose en las características más relevantes capturadas por un conjunto de datos dado.

Este método de clasificación se basa en el **modelo discriminante gaussiano**, que asume que nuestra población se encuentra separada en K clases distintas (también conocidas como grupos o categorías) por una variable categórica G .

El modelo también asume que tenemos un vector aleatorio continuo

$$X = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix}$$

que captura las características relevantes de los individuos en nuestra población.

Una de las hipótesis más importantes de este modelo es que para cada grupo $G = i$, el vector aleatorio X sigue una distribución normal multivariada con media μ_i y matriz de covarianza Σ , es decir,

$$X|(G = i) \sim \mathcal{N}(\mu_i, \Sigma)$$

Una de las hipótesis más importantes de este modelo es que para cada grupo $G = i$, el vector aleatorio X sigue una distribución normal multivariada con media μ_i y matriz de covarianza Σ , es decir,

$$X|(G = i) \sim \mathcal{N}(\mu_i, \Sigma)$$

Notemos que la matriz de covarianza es la misma para todos los grupos.

Una de las hipótesis más importantes de este modelo es que para cada grupo $G = i$, el vector aleatorio X sigue una distribución normal multivariada con media μ_i y matriz de covarianza Σ , es decir,

$$X|(G = i) \sim \mathcal{N}(\mu_i, \Sigma)$$

Notemos que la matriz de covarianza es la misma para todos los grupos.

Esta condición es conocida como **homocedasticidad** y es uno de los supuestos fundamentales del modelo discriminante gaussiano.

El clasificador Bayesiano

Recordemos que una **función de clasificación** es una función g que asigna a cada observación $X = x$ una clase $G = i$, es decir, $g(x) = i$.

El clasificador Bayesiano

Recordemos que una **función de clasificación** es una función g que asigna a cada observación $X = x$ una clase $G = i$, es decir, $g(x) = i$.

El objetivo del análisis discriminante lineal es encontrar una función de clasificación que minimice la **tasa de error de clasificación**, la cual está dada por

$$R(g) = E[1_{g(X) \neq G}] = P(g(X) \neq G)$$

donde $1_{g(X) \neq G}$ es una variable indicadora que toma el valor de 1 si la clasificación es incorrecta y 0 en caso contrario, $E[1_{g(X) \neq G}]$ es la esperanza de esta variable aleatoria y $P(g(X) \neq G)$ es la probabilidad de que la clasificación sea incorrecta.

Teorema (Teorema de Bayes para clasificación)

El clasificador que minimiza la tasa de error de clasificación es el **clasificador de Bayes** $\hat{g}$ que está dado por

$$\hat{g}(x) = \arg \max_i P(G = i | X = x)$$

donde $P(G = i | X = x)$ es la probabilidad condicional de que la clase sea $G = i$ dado que la observación es $X = x$.

Las funciones discriminantes lineales

Buscamos ahora una forma más explícita para el clasificador de Bayes bajo el modelo discriminante gaussiano.

Las funciones discriminantes lineales

Buscamos ahora una forma más explícita para el clasificador de Bayes bajo el modelo discriminante gaussiano.

Empezaremos por introducir las llamadas **probabilidades previas** (también conocidas como **probabilidades a priori** o **priors**) de cada clase, las cuales están dadas por

$$\pi_i = P(G = i)$$

Las funciones discriminantes lineales

Buscamos ahora una forma más explícita para el clasificador de Bayes bajo el modelo discriminante gaussiano.

Empezaremos por introducir las llamadas **probabilidades previas** (también conocidas como **probabilidades a priori** o **priors**) de cada clase, las cuales están dadas por

$$\pi_i = P(G = i)$$

Notemos que este valor es simplemente la probabilidad de que un individuo seleccionado al azar de entre nuestra población pertenezca a la clase $G = i$.

También consideraremos las **probabilidades posteriores** (también conocidas como **probabilidades a posteriori** o **posteriors**) de cada clase, las cuales están dadas por

$$P(G = i | X = x)$$

En este caso, este valor representa la probabilidad de que un individuo pertenezca a la clase $G = i$ una vez que hemos observado sus características $X = x$.

También consideraremos las **probabilidades posteriores** (también conocidas como **probabilidades a posteriori** o **posteriors**) de cada clase, las cuales están dadas por

$$P(G = i | X = x)$$

En este caso, este valor representa la probabilidad de que un individuo pertenezca a la clase $G = i$ una vez que hemos observado sus características $X = x$.

Para calcular este valor, recordemos que estamos suponiendo que $X | (G = i) \sim \mathcal{N}(\mu_i, \Sigma)$, por lo que la función de densidad condicional de X dado $G = i$ está dada por

$$f_i(X) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} (X - \mu_i)^T \Sigma^{-1} (X - \mu_i) \right)$$

Usando la fórmula de Bayes, podemos expresar las probabilidades posteriores en términos de las probabilidades previas y las funciones de densidad condicional:

$$P(G = i|X = x) = \frac{\pi_i f_i(x)}{\sum_j \pi_j f_j(x)}$$

Usando la fórmula de Bayes, podemos expresar las probabilidades posteriores en términos de las probabilidades previas y las funciones de densidad condicional:

$$P(G = i|X = x) = \frac{\pi_i f_i(x)}{\sum_j \pi_j f_j(x)}$$

Notemos que el denominador en el lado derecho de esta ecuación es el mismo para todas las clases.

Usando la fórmula de Bayes, podemos expresar las probabilidades posteriores en términos de las probabilidades previas y las funciones de densidad condicional:

$$P(G = i|X = x) = \frac{\pi_i f_i(x)}{\sum_j \pi_j f_j(x)}$$

Notemos que el denominador en el lado derecho de esta ecuación es el mismo para todas las clases.

En particular, la probabilidad posterior $P(G = i|X = x)$ es un múltiplo positivo de la cantidad $\pi_i f_i(x)$, en símbolos,

$$P(G = i|X = x) \propto \pi_i f_i(x)$$

Se sigue que para encontrar el clasificador de Bayes, podemos concentrarnos en la expresión $\pi_i f_i(x)$.

Se sigue que para encontrar el clasificador de Bayes, podemos concentrarnos en la expresión $\pi_i f_i(x)$.

De hecho, como el logaritmo es una función monótonamente creciente, nos basta con concentrarnos en maximizar

$$\begin{aligned}\log(\pi_i f_i(x)) &= \log(\pi_i) + \log(f_i(x)) \\ &= \log(\pi_i) - \frac{p}{2} \log(2\pi) - \frac{1}{2} \log(|\Sigma|) - \frac{1}{2} (x - \mu_i)^T \Sigma^{-1} (x - \mu_i) \\ &= \log(\pi_i) - \frac{p}{2} \log(2\pi) - \frac{1}{2} \log(|\Sigma|) - \frac{1}{2} x^T \Sigma^{-1} x + \mu_i^T \Sigma^{-1} x - \frac{1}{2} \mu_i^T \Sigma^{-1} \mu_i\end{aligned}$$

Notemos que la expresión

$$-\frac{p}{2} \log(2\pi) - \frac{1}{2} \log(|\Sigma|) - \frac{1}{2} x^T \Sigma^{-1} x$$

aparece en todas nuestras clases.

Notemos que la expresión

$$-\frac{p}{2}\log(2\pi) - \frac{1}{2}\log(|\Sigma|) - \frac{1}{2}x^T\Sigma^{-1}x$$

aparece en todas nuestras clases.

Por lo tanto, si definimos las **funciones discriminantes lineales** como

$$\delta_i(x) = \mu_i^T \Sigma^{-1} x - \frac{1}{2} \mu_i^T \Sigma^{-1} \mu_i + \log(\pi_i)$$

entonces tenemos que las diferencias

$$\Delta_{i,j}(x) = \log(\pi_i f_i(x)) - \log(\pi_j f_j(x)) = \delta_i(x) - \delta_j(x)$$

dependen únicamente de estas funciones.

Notemos que la expresión

$$-\frac{p}{2}\log(2\pi) - \frac{1}{2}\log(|\Sigma|) - \frac{1}{2}x^T\Sigma^{-1}x$$

aparece en todas nuestras clases.

Por lo tanto, si definimos las **funciones discriminantes lineales** como

$$\delta_i(x) = \mu_i^T \Sigma^{-1} x - \frac{1}{2} \mu_i^T \Sigma^{-1} \mu_i + \log(\pi_i)$$

entonces tenemos que las diferencias

$$\Delta_{i,j}(x) = \log(\pi_i f_i(x)) - \log(\pi_j f_j(x)) = \delta_i(x) - \delta_j(x)$$

dependen únicamente de estas funciones.

En particular, el clasificador de Bayes se puede reescribir como

$$\hat{g}(x) = \arg \max_i \delta_i(x)$$

Las variables canónicas

Además de proporcionar un método de clasificación, una de las aplicaciones más importantes del análisis discriminante lineal es la reducción de la dimensionalidad de los datos.

Las variables canónicas

Además de proporcionar un método de clasificación, una de las aplicaciones más importantes del análisis discriminante lineal es la reducción de la dimensionalidad de los datos.

De manera más explícita, el análisis discriminante lineal nos permite definir nuevas variables, llamadas **variables canónicas**, que capturan toda la información relevante para separar las distintas clases, pero en un espacio de menor dimensión.

Las variables canónicas

Además de proporcionar un método de clasificación, una de las aplicaciones más importantes del análisis discriminante lineal es la reducción de la dimensionalidad de los datos.

De manera más explícita, el análisis discriminante lineal nos permite definir nuevas variables, llamadas **variables canónicas**, que capturan toda la información relevante para separar las distintas clases, pero en un espacio de menor dimensión.

Para poder definir estas variables, empecemos por notar que la media total de la población está dada por

$$\mu = E[X] = \sum_i \pi_i \mu_i$$

Definimos ahora la **matriz de dispersión total** como

$$ST = E[(X - \mu)(X - \mu)^T] = \text{Var}[X]$$

Definimos ahora la **matriz de dispersión total** como

$$ST = E[(X - \mu)(X - \mu)^T] = \text{Var}[X]$$

Consideraremos también la **matriz de dispersión dentro de los grupos**, la cual está dada por

$$SW = E_G[\text{Var}_X[X|G]] = \sum_i \pi_i \Sigma = \Sigma$$

donde E_G representa la esperanza con respecto a la variable categórica G y $\text{Var}_X[X|G]$ representa la varianza condicional de X dado G .

Definimos ahora la **matriz de dispersión total** como

$$ST = E[(X - \mu)(X - \mu)^T] = \text{Var}[X]$$

Consideraremos también la **matriz de dispersión dentro de los grupos**, la cual está dada por

$$SW = E_G[\text{Var}_X[X|G]] = \sum_i \pi_i \Sigma = \Sigma$$

donde E_G representa la esperanza con respecto a la variable categórica G y $\text{Var}_X[X|G]$ representa la varianza condicional de X dado G .

Finalmente, consideraremos la **matriz de dispersión entre los grupos**, la cual está dada por

$$SB = \text{Var}_G[E_X[X|G]] = \sum_i \pi_i (\mu_i - \mu)(\mu_i - \mu)^T$$

donde Var_G representa la varianza con respecto a la variable categórica G y $E_X[X|G]$ representa la esperanza condicional de X dado G .

Ya con estas definiciones, podemos escribir la **fórmula de la descomposición de la varianza** que nos dice que

$$ST = SW + SB$$

Ya con estas definiciones, podemos escribir la **fórmula de la descomposición de la varianza** que nos dice que

$$ST = SW + SB$$

Notemos ahora que si $a = [a_1, a_2, \dots, a_p]$ es una matriz de $1 \times p$, entonces podemos considerar la variable aleatoria $Y = aX$, la cual es una combinación lineal de las variables originales $X_1, X_2, \dots, X_p$.

Ya con estas definiciones, podemos escribir la **fórmula de la descomposición de la varianza** que nos dice que

$$ST = SW + SB$$

Notemos ahora que si $a = [a_1, a_2, \dots, a_p]$ es una matriz de $1 \times p$, entonces podemos considerar la variable aleatoria $Y = aX$, la cual es una combinación lineal de las variables originales $X_1, X_2, \dots, X_p$.

La varianza total de esta nueva variable está dada por

$$\text{Var}[Y] = a(ST)a^T$$

Ya con estas definiciones, podemos escribir la **fórmula de la descomposición de la varianza** que nos dice que

$$ST = SW + SB$$

Notemos ahora que si $a = [a_1, a_2, \dots, a_p]$ es una matriz de $1 \times p$, entonces podemos considerar la variable aleatoria $Y = aX$, la cual es una combinación lineal de las variables originales $X_1, X_2, \dots, X_p$.

La varianza total de esta nueva variable está dada por

$$\text{Var}[Y] = a(ST)a^T$$

la varianza dentro de los grupos está dada por

$$E_G[\text{Var}_Y[Y|G]] = a(SW)a^T = a\Sigma a^T$$

Ya con estas definiciones, podemos escribir la **fórmula de la descomposición de la varianza** que nos dice que

$$ST = SW + SB$$

Notemos ahora que si $a = [a_1, a_2, \dots, a_p]$ es una matriz de $1 \times p$, entonces podemos considerar la variable aleatoria $Y = aX$, la cual es una combinación lineal de las variables originales $X_1, X_2, \dots, X_p$.

La varianza total de esta nueva variable está dada por

$$\text{Var}[Y] = a(ST)a^T$$

la varianza dentro de los grupos está dada por

$$E_G[\text{Var}_Y[Y|G]] = a(SW)a^T = a\Sigma a^T$$

y la varianza entre los grupos está dada por

$$\text{Var}_G[E_Y[Y|G]] = a(SB)a^T$$

Para construir nuestras variable canónicas, buscamos variables que maximicen la varianza entre los grupos en relación con la varianza dentro de los grupos.

Para construir nuestras variable canónicas, buscamos variables que maximicen la varianza entre los grupos en relación con la varianza dentro de los grupos.

En otras palabras, queremos maximizar el **cociente de Rayleigh** definido como

$$J(a) = \frac{aSBa^T}{aSWa^T}$$

De manera más precisa, el **criterio de Fisher** nos dice que las variables canónicas deben de satisfacer las siguientes condiciones:

De manera más precisa, el **criterio de Fisher** nos dice que las variables canónicas deben de satisfacer las siguientes condiciones:

- La primera variable canónica $Y_1 = a_1 X$ es aquella que maximiza el cociente $J(a)$, es decir,

$$a_1 = \arg \max_a J(a)$$

De manera más precisa, el **criterio de Fisher** nos dice que las variables canónicas deben de satisfacer las siguientes condiciones:

- La primera variable canónica $Y_1 = a_1 X$ es aquella que maximiza el cociente $J(a)$, es decir,

$$a_1 = \arg \max_a J(a)$$

- La j -ésima variable canónica $Y_j = a_j X$ es aquella que maximiza el cociente $J(a)$ bajo la restricción de que no esté correlacionada, dentro de los grupos, con las variables canónicas anteriores, es decir,

$$a_j = \arg \max_a J(a) \quad \text{sujeto a} \quad \text{Cov}[Y_i, Y_j | G] = 0 \quad \text{para } i < j$$

Es importante notar que el número máximo de variables canónicas que se pueden obtener es $\min(p, K - 1)$, donde p es el número de características en nuestro vector aleatorio X y K es el número de clases en nuestra población.

Es importante notar que el número máximo de variables canónicas que se pueden obtener es $\min(p, K - 1)$, donde p es el número de características en nuestro vector aleatorio X y K es el número de clases en nuestra población.

Esto se debe a que la matriz de dispersión entre los grupos SB tiene rango máximo $r = \min(p, K - 1)$.

Es importante notar que el número máximo de variables canónicas que se pueden obtener es $\min(p, K - 1)$, donde p es el número de características en nuestro vector aleatorio X y K es el número de clases en nuestra población.

Esto se debe a que la matriz de dispersión entre los grupos SB tiene rango máximo $r = \min(p, K - 1)$.

Finalmente, se puede verificar que las funciones

$$\Delta_{i,j}(x) = \delta_i(x) - \delta_j(x)$$

solo dependen de las primeras r variables canónicas. En particular, esto implica que el clasificador de Bayes también solo depende de estas variables.