

Ajuste y adecuación del modelo discriminante gaussiano

MA2003B Aplicación de métodos multivariados
en ciencia de datos

Raul Gomez



Tecnológico
de Monterrey

Ajuste y adecuación del modelo discriminante gaussiano

Previamente discutimos el modelo del discriminante gaussiano desde un punto de vista teórico.

Ajuste y adecuación del modelo discriminante gaussiano

Previamente discutimos el modelo del discriminante gaussiano desde un punto de vista teórico.

También describimos como reducir la dimensionalidad de nuestro modelo proyectando los resultados de nuestras observaciones en el espacio LDA y mostramos como podemos construir funciones discriminantes lineales que nos permiten clasificar nuestras observaciones basadas solamente en esta información.

Ajuste y adecuación del modelo discriminante gaussiano

Previamente discutimos el modelo del discriminante gaussiano desde un punto de vista teórico.

También describimos como reducir la dimensionalidad de nuestro modelo proyectando los resultados de nuestras observaciones en el espacio LDA y mostramos como podemos construir funciones discriminantes lineales que nos permiten clasificar nuestras observaciones basadas solamente en esta información.

Mostraremos ahora como podemos ajustar este modelo a un conjunto de datos dado y verificar la adecuación de este ajuste.

Ajuste y adecuación del modelo discriminante gaussiano

Previamente discutimos el modelo del discriminante gaussiano desde un punto de vista teórico.

También describimos como reducir la dimensionalidad de nuestro modelo proyectando los resultados de nuestras observaciones en el espacio LDA y mostramos como podemos construir funciones discriminantes lineales que nos permiten clasificar nuestras observaciones basadas solamente en esta información.

Mostraremos ahora como podemos ajustar este modelo a un conjunto de datos dado y verificar la adecuación de este ajuste.

Una vez que tenemos un modelo ajustado y verificado, podemos utilizar las técnicas descritas con anterioridad para reducir la dimensionalidad de nuestro conjunto de datos y construir funciones discriminantes lineales que nos permitan clasificar nuevas observaciones.

Ajuste del modelo discriminante gaussiano

Recordemos que el modelo discriminante gaussiano depende de los siguientes parámetros:

Ajuste del modelo discriminante gaussiano

Recordemos que el modelo discriminante gaussiano depende de los siguientes parámetros:

- Los vectores de medias μ_k para cada clase $k = 1, \dots, K$.

Ajuste del modelo discriminante gaussiano

Recordemos que el modelo discriminante gaussiano depende de los siguientes parámetros:

- Los vectores de medias μ_k para cada clase $k = 1, \dots, K$.
- La matriz de covarianza común Σ .

Ajuste del modelo discriminante gaussiano

Recordemos que el modelo discriminante gaussiano depende de los siguientes parámetros:

- Los vectores de medias μ_k para cada clase $k = 1, \dots, K$.
- La matriz de covarianza común Σ .
- Los pesos a priori π_k para cada clase $k = 1, \dots, K$.

Nuestro objetivo es estimar estos parámetros a partir de un conjunto de datos etiquetado $\{(x_i, g_i)\}_{i=1}^n$, donde x_i es el vector de características y g_i es la etiqueta de clase correspondiente.

Nuestro objetivo es estimar estos parámetros a partir de un conjunto de datos etiquetado $\{(x_i, g_i)\}_{i=1}^n$, donde x_i es el vector de características y g_i es la etiqueta de clase correspondiente.

Existen dos enfoques principales para ajustar el modelo discriminante gaussiano: el enfoque clásico de LDA que utiliza la estimación de Fisher (FE) para la matriz de varianza común, y el enfoque basado en la estimación por máxima verosimilitud (MLE).

El método de estimación de Fisher (FE)

El método de estimación de Fisher (FE)

- Las medias de cada clase se estiman como el promedio de los vectores de características dentro de cada clase:

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i|g_i=k} x_i,$$

El método de estimación de Fisher (FE)

- Las medias de cada clase se estiman como el promedio de los vectores de características dentro de cada clase:

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i|g_i=k} x_i,$$

- La matriz de covarianza común se estima como:

$$\hat{\Sigma}_{\text{MLE}} = \frac{1}{n-K} \sum_{k=1}^K \sum_{i|g_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^T,$$

El método de estimación de Fisher (FE)

- Las medias de cada clase se estiman como el promedio de los vectores de características dentro de cada clase:

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i|g_i=k} x_i,$$

- La matriz de covarianza común se estima como:

$$\hat{\Sigma}_{\text{MLE}} = \frac{1}{n - K} \sum_{k=1}^K \sum_{i|g_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^T,$$

- Los pesos a priori se estiman como la proporción de observaciones en cada clase:

$$\hat{\pi}_k = \frac{n_k}{n}$$

El método de estimación de Fisher (FE)

- Las medias de cada clase se estiman como el promedio de los vectores de características dentro de cada clase:

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i|g_i=k} x_i,$$

- La matriz de covarianza común se estima como:

$$\hat{\Sigma}_{\text{MLE}} = \frac{1}{n - K} \sum_{k=1}^K \sum_{i|g_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^T,$$

- Los pesos a priori se estiman como la proporción de observaciones en cada clase:

$$\hat{\pi}_k = \frac{n_k}{n}$$

Este enfoque es el que se utiliza comúnmente en la literatura estadística y que se implementa en R a través de la función `lda()` del paquete MASS.

El método de máxima verosimilitud (MLE)

El método de máxima verosimilitud (MLE)

- Las medias de cada clase se estiman de la misma manera que en el método FE:

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i|g_i=k} x_i$$

El método de máxima verosimilitud (MLE)

- Las medias de cada clase se estiman de la misma manera que en el método FE:

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i|g_i=k} x_i$$

- La matriz de covarianza común se estima como:

$$\hat{\Sigma}_{\text{MLE}} = \frac{1}{n} \sum_{k=1}^K \sum_{i|g_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^T$$

El método de máxima verosimilitud (MLE)

- Las medias de cada clase se estiman de la misma manera que en el método FE:

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i|g_i=k} x_i$$

- La matriz de covarianza común se estima como:

$$\hat{\Sigma}_{\text{MLE}} = \frac{1}{n} \sum_{k=1}^K \sum_{i|g_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^T$$

- Los pesos a priori se estiman como:

$$\hat{\pi}_k = \frac{n_k}{n}$$

El método de máxima verosimilitud (MLE)

- Las medias de cada clase se estiman de la misma manera que en el método FE:

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i|g_i=k} x_i$$

- La matriz de covarianza común se estima como:

$$\hat{\Sigma}_{\text{MLE}} = \frac{1}{n} \sum_{k=1}^K \sum_{i|g_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^T$$

- Los pesos a priori se estiman como:

$$\hat{\pi}_k = \frac{n_k}{n}$$

Notemos que el estimador de la matriz de varianza es sesgado. Este enfoque es más común en la literatura de aprendizaje automático y se utiliza en implementaciones como la función `LinearDiscriminantAnalysis` del paquete `scikit-learn` en Python.

Comparación de los enfoques FE y MLE

Notemos que la única diferencia entre estos dos enfoques está dada en la forma en la que estimamos la matriz de covarianza común Σ .

Comparación de los enfoques FE y MLE

Notemos que la única diferencia entre estos dos enfoques está dada en la forma en la que estimamos la matriz de covarianza común Σ .

De manera más precisa, tenemos que:

$$\hat{\Sigma}_{\text{FE}} = \frac{n}{n-K} \hat{\Sigma}_{\text{MLE}}$$

Comparación de los enfoques FE y MLE

Notemos que la única diferencia entre estos dos enfoques está dada en la forma en la que estimamos la matriz de covarianza común Σ .

De manera más precisa, tenemos que:

$$\hat{\Sigma}_{\text{FE}} = \frac{n}{n-K} \hat{\Sigma}_{\text{MLE}}$$

En términos prácticos, esto significa que cuando utilizamos el enfoque FE para calcular las funciones discriminantes, estas funciones le dan más importancia a los valores de los priors en comparación con el enfoque MLE que le da más peso al cálculo de las medias de las clases.

Comparación de los enfoques FE y MLE

Notemos que la única diferencia entre estos dos enfoques está dada en la forma en la que estimamos la matriz de covarianza común Σ .

De manera más precisa, tenemos que:

$$\hat{\Sigma}_{\text{FE}} = \frac{n}{n-K} \hat{\Sigma}_{\text{MLE}}$$

En términos prácticos, esto significa que cuando utilizamos el enfoque FE para calcular las funciones discriminantes, estas funciones le dan más importancia a los valores de los priors en comparación con el enfoque MLE que le da más peso al cálculo de las medias de las clases.

Cada uno de estos métodos tiene sus propias ventajas y desventajas, y la elección entre ellos depende de las características específicas del conjunto de datos y del problema en cuestión.

Comparación de los enfoques FE y MLE

Notemos que la única diferencia entre estos dos enfoques está dada en la forma en la que estimamos la matriz de covarianza común Σ .

De manera más precisa, tenemos que:

$$\hat{\Sigma}_{\text{FE}} = \frac{n}{n-K} \hat{\Sigma}_{\text{MLE}}$$

En términos prácticos, esto significa que cuando utilizamos el enfoque FE para calcular las funciones discriminantes, estas funciones le dan más importancia a los valores de los priors en comparación con el enfoque MLE que le da más peso al cálculo de las medias de las clases.

Cada uno de estos métodos tiene sus propias ventajas y desventajas, y la elección entre ellos depende de las características específicas del conjunto de datos y del problema en cuestión.

Contexto	FE LDA	MLE LDA
Tamaño de muestra muy pequeño	✓	
Priors muy desbalanceados	✓	
Confianza alta en los valores de los priors	✓	
Clases balanceadas		✓
Clases bien separadas		✓
Alta dimensionalidad	✓	
Muestras muy grandes	✓	✓

Verificación de la adecuación del modelo discriminante gaussiano

Una vez ajustado el modelo discriminante gaussiano a un conjunto de datos, es crucial verificar la adecuación de este ajuste.

Verificación de la adecuación del modelo discriminante gaussiano

Una vez ajustado el modelo discriminante gaussiano a un conjunto de datos, es crucial verificar la adecuación de este ajuste.

Esto implica evaluar si las suposiciones del modelo se cumplen y si el modelo es capaz de capturar la estructura subyacente de los datos.

Verificación de la adecuación del modelo discriminante gaussiano

Una vez ajustado el modelo discriminante gaussiano a un conjunto de datos, es crucial verificar la adecuación de este ajuste.

Esto implica evaluar si las suposiciones del modelo se cumplen y si el modelo es capaz de capturar la estructura subyacente de los datos.

A continuación describiremos las pruebas y técnicas más comunes para verificar la adecuación del modelo discriminante gaussiano.

Pruebas de normalidad multivariada

Una de las suposiciones fundamentales del modelo discriminante gaussiano es que las observaciones dentro de cada clase siguen una distribución normal multivariada.

Pruebas de normalidad multivariada

Una de las suposiciones fundamentales del modelo discriminante gaussiano es que las observaciones dentro de cada clase siguen una distribución normal multivariada.

Para verificar esta suposición, podemos utilizar pruebas estadísticas como la prueba de Mardia, la prueba de Henze-Zirkler o la prueba de Royston.

Pruebas de normalidad multivariada

Una de las suposiciones fundamentales del modelo discriminante gaussiano es que las observaciones dentro de cada clase siguen una distribución normal multivariada.

Para verificar esta suposición, podemos utilizar pruebas estadísticas como la prueba de Mardia, la prueba de Henze-Zirkler o la prueba de Royston.

Estas pruebas evalúan si los datos dentro de cada clase se ajustan a una distribución normal multivariada.

Pruebas de normalidad multivariada

Una de las suposiciones fundamentales del modelo discriminante gaussiano es que las observaciones dentro de cada clase siguen una distribución normal multivariada.

Para verificar esta suposición, podemos utilizar pruebas estadísticas como la prueba de Mardia, la prueba de Henze-Zirkler o la prueba de Royston.

Estas pruebas evalúan si los datos dentro de cada clase se ajustan a una distribución normal multivariada.

Para realizar estas pruebas en R, podemos utilizar el paquete `MVN` que proporciona funciones para llevar a cabo estas pruebas de normalidad multivariada.

Pruebas de normalidad multivariada

Una de las suposiciones fundamentales del modelo discriminante gaussiano es que las observaciones dentro de cada clase siguen una distribución normal multivariada.

Para verificar esta suposición, podemos utilizar pruebas estadísticas como la prueba de Mardia, la prueba de Henze-Zirkler o la prueba de Royston.

Estas pruebas evalúan si los datos dentro de cada clase se ajustan a una distribución normal multivariada.

Para realizar estas pruebas en R, podemos utilizar el paquete `MVN` que proporciona funciones para llevar a cabo estas pruebas de normalidad multivariada.

Otro método para evaluar la normalidad multivariada es mediante gráficos Q-Q multivariados o gráficos de dispersión de pares de variables dentro de cada clase.

Pruebas de normalidad multivariada

Una de las suposiciones fundamentales del modelo discriminante gaussiano es que las observaciones dentro de cada clase siguen una distribución normal multivariada.

Para verificar esta suposición, podemos utilizar pruebas estadísticas como la prueba de Mardia, la prueba de Henze-Zirkler o la prueba de Royston.

Estas pruebas evalúan si los datos dentro de cada clase se ajustan a una distribución normal multivariada.

Para realizar estas pruebas en R, podemos utilizar el paquete `MVN` que proporciona funciones para llevar a cabo estas pruebas de normalidad multivariada.

Otro método para evaluar la normalidad multivariada es mediante gráficos Q-Q multivariados o gráficos de dispersión de pares de variables dentro de cada clase.

Pruebas de Homoscedasticidad

Para evaluar si las matrices de covarianza de las diferentes clases son iguales (homoscedasticidad), podemos utilizar la prueba de Box's M.

Pruebas de Homoscedasticidad

Para evaluar si las matrices de covarianza de las diferentes clases son iguales (homoscedasticidad), podemos utilizar la prueba de Box's M.

Esta prueba evalúa la hipótesis nula de que todas las matrices de covarianza son iguales contra la alternativa de que al menos una es diferente.

Pruebas de Homoscedasticidad

Para evaluar si las matrices de covarianza de las diferentes clases son iguales (homoscedasticidad), podemos utilizar la prueba de Box's M.

Esta prueba evalúa la hipótesis nula de que todas las matrices de covarianza son iguales contra la alternativa de que al menos una es diferente.

En R, podemos utilizar la función `boxM()` del paquete `biotools` para llevar a cabo esta prueba.

Además de la prueba de Box's M, podemos utilizar gráficos de dispersión de las variables dentro de cada clase para visualizar las diferencias en las matrices de covarianza.

Pruebas de Homoscedasticidad

Para evaluar si las matrices de covarianza de las diferentes clases son iguales (homoscedasticidad), podemos utilizar la prueba de Box's M.

Esta prueba evalúa la hipótesis nula de que todas las matrices de covarianza son iguales contra la alternativa de que al menos una es diferente.

En R, podemos utilizar la función `boxM()` del paquete `biotools` para llevar a cabo esta prueba.

Además de la prueba de Box's M, podemos utilizar gráficos de dispersión de las variables dentro de cada clase para visualizar las diferencias en las matrices de covarianza.

Si las elipses de dispersión son similares en forma y tamaño, esto sugiere homoscedasticidad.

Evaluación del rendimiento del modelo

Finalmente, es importante evaluar el rendimiento del modelo discriminante gaussiano en términos de su capacidad para clasificar correctamente las observaciones.

Evaluación del rendimiento del modelo

Finalmente, es importante evaluar el rendimiento del modelo discriminante gaussiano en términos de su capacidad para clasificar correctamente las observaciones.

Podemos utilizar técnicas como la validación cruzada para estimar la tasa de error de clasificación del modelo.

Evaluación del rendimiento del modelo

Finalmente, es importante evaluar el rendimiento del modelo discriminante gaussiano en términos de su capacidad para clasificar correctamente las observaciones.

Podemos utilizar técnicas como la validación cruzada para estimar la tasa de error de clasificación del modelo.

Además, podemos construir una matriz de confusión para visualizar el desempeño del modelo en términos de verdaderos positivos, falsos positivos, verdaderos negativos y falsos negativos.

Modelos alternativos

En caso de que las suposiciones del modelo discriminante gaussiano no se cumplan, podemos considerar modelos alternativos como el modelo discriminante cuadrático (QDA) que permite diferentes matrices de covarianza para cada clase, o modelos basados en técnicas no paramétricas como los árboles de decisión o los métodos de vecinos más cercanos (k-NN).

Modelos alternativos

En caso de que las suposiciones del modelo discriminante gaussiano no se cumplan, podemos considerar modelos alternativos como el modelo discriminante cuadrático (QDA) que permite diferentes matrices de covarianza para cada clase, o modelos basados en técnicas no paramétricas como los árboles de decisión o los métodos de vecinos más cercanos (k-NN).

Estos modelos pueden ser más flexibles y adaptarse mejor a conjuntos de datos que no cumplen con las suposiciones del modelo discriminante gaussiano.