

Método LDA paso a paso para la selección de variables

MA2003B Aplicación de métodos multivariados
en ciencia de datos

Raul Gomez



Tecnológico
de Monterrey

Método LDA paso a paso para la selección de variables

El análisis discriminante lineal (LDA) es una técnica poderosa para clasificar observaciones en grupos basándose en variables predictoras.

Método LDA paso a paso para la selección de variables

El análisis discriminante lineal (LDA) es una técnica poderosa para clasificar observaciones en grupos basándose en variables predictoras.

Sin embargo, es común que no todas las variables predictoras disponibles satisfagan los supuestos del modelo o contribuyan significativamente a la discriminación entre grupos.

Método LDA paso a paso para la selección de variables

El análisis discriminante lineal (LDA) es una técnica poderosa para clasificar observaciones en grupos basándose en variables predictoras.

Sin embargo, es común que no todas las variables predictoras disponibles satisfagan los supuestos del modelo o contribuyan significativamente a la discriminación entre grupos.

En estos casos, disminuir el número de variables puede disminuir el ruido y mejorar la interpretabilidad y el desempeño del modelo, especialmente cuando se presentan problemas de multicolinealidad o de heterocedasticidad.

Método LDA paso a paso para la selección de variables

El análisis discriminante lineal (LDA) es una técnica poderosa para clasificar observaciones en grupos basándose en variables predictoras.

Sin embargo, es común que no todas las variables predictoras disponibles satisfagan los supuestos del modelo o contribuyan significativamente a la discriminación entre grupos.

En estos casos, disminuir el número de variables puede disminuir el ruido y mejorar la interpretabilidad y el desempeño del modelo, especialmente cuando se presentan problemas de multicolinealidad o de heterocedasticidad.

En este capítulo describiremos un enfoque de selección de variables paso a paso (stepwise) para LDA utilizando el paquete `klaR` en R.

Criterio de selección

En R, el paquete `klaR` ofrece la función `stepclass()` que implementa un procedimiento de selección de variables paso a paso para modelos de clasificación, incluyendo LDA.

Criterio de selección

En R, el paquete `klaR` ofrece la función `stepclass()` que implementa un procedimiento de selección de variables paso a paso para modelos de clasificación, incluyendo LDA.

El criterio utilizado para evaluar la inclusión o exclusión de variables es la tasa de error de clasificación estimada mediante validación cruzada (por defecto, leave-one-out).

Criterio de selección

En R, el paquete `klaR` ofrece la función `stepclass()` que implementa un procedimiento de selección de variables paso a paso para modelos de clasificación, incluyendo LDA.

El criterio utilizado para evaluar la inclusión o exclusión de variables es la tasa de error de clasificación estimada mediante validación cruzada (por defecto, leave-one-out).

El objetivo es minimizar esta tasa de error.

La función `stepclass()` permite tres estrategias de selección:

La función `stepclass()` permite tres estrategias de selección:

1. **Búsqueda hacia adelante** (`direction = "forward"`): comienza con un modelo nulo (sólo el intercepto) y añade variables una por una, seleccionando en cada paso la variable que más reduce la tasa de error.

La función `stepclass()` permite tres estrategias de selección:

1. **Búsqueda hacia adelante** (`direction = "forward"`): comienza con un modelo nulo (sólo el intercepto) y añade variables una por una, seleccionando en cada paso la variable que más reduce la tasa de error.
2. **Búsqueda hacia atrás** (`direction = "backward"`): comienza con un modelo completo (todas las variables) y elimina variables una por una, seleccionando en cada paso la variable cuya eliminación más reduce la tasa de error.

La función `stepclass()` permite tres estrategias de selección:

1. **Búsqueda hacia adelante** (`direction = "forward"`): comienza con un modelo nulo (sólo el intercepto) y añade variables una por una, seleccionando en cada paso la variable que más reduce la tasa de error.
2. **Búsqueda hacia atrás** (`direction = "backward"`): comienza con un modelo completo (todas las variables) y elimina variables una por una, seleccionando en cada paso la variable cuya eliminación más reduce la tasa de error.
3. **Búsqueda mixta** (`direction = "both"`): combina ambos enfoques, permitiendo añadir o eliminar variables en cada paso según cuál acción reduzca más la tasa de error.

Flujo recomendado

Para llevar a cabo la selección de variables paso a paso en LDA, usualmente se recomienda seguir el siguiente flujo:

Flujo recomendado

Para llevar a cabo la selección de variables paso a paso en LDA, usualmente se recomienda seguir el siguiente flujo:

1. **Preparación de datos**

Flujo recomendado

Para llevar a cabo la selección de variables paso a paso en LDA, usualmente se recomienda seguir el siguiente flujo:

1. **Preparación de datos**
2. **Aplicación de `stepclass()`**

Flujo recomendado

Para llevar a cabo la selección de variables paso a paso en LDA, usualmente se recomienda seguir el siguiente flujo:

1. **Preparación de datos**
2. **Aplicación de `stepclass()`**
3. **Ajuste del modelo final**

Flujo recomendado

Para llevar a cabo la selección de variables paso a paso en LDA, usualmente se recomienda seguir el siguiente flujo:

1. **Preparación de datos**
2. **Aplicación de `stepclass()`**
3. **Ajuste del modelo final**
4. **Verificación de supuestos**

Flujo recomendado

Para llevar a cabo la selección de variables paso a paso en LDA, usualmente se recomienda seguir el siguiente flujo:

1. **Preparación de datos**
2. **Aplicación de `stepclass()`**
3. **Ajuste del modelo final**
4. **Verificación de supuestos**
5. **Interpretación y reporte**

Ejemplo ilustrativo

Como ejemplo ilustrativo, consideraremos el conjunto de datos penguins del paquete `palmerpenguins`, que contiene medidas morfológicas de tres especies de pingüinos: Adelia, Chinstrap y Gentoo.

Ejemplo ilustrativo

Como ejemplo ilustrativo, consideraremos el conjunto de datos `penguins` del paquete `palmerpenguins`, que contiene medidas morfológicas de tres especies de pingüinos: Adelia, Chinstrap y Gentoo.

Nuestro objetivo es clasificar las especies basándonos en las medidas disponibles, seleccionando las variables más relevantes mediante el método paso a paso.

Ejemplo ilustrativo

Como ejemplo ilustrativo, consideraremos el conjunto de datos `penguins` del paquete `palmerpenguins`, que contiene medidas morfológicas de tres especies de pingüinos: Adelia, Chinstrap y Gentoo.

Nuestro objetivo es clasificar las especies basándonos en las medidas disponibles, seleccionando las variables más relevantes mediante el método paso a paso.

Los resultados obtenidos son los siguientes:

Resultados obtenidos

Las fórmulas finales obtenidas con cada estrategia son:

Método	Fórmula
Forward	$species \sim bill_length_mm + flipper_length_mm$
Backward	$species \sim bill_length_mm + bill_depth_mm + body_mass_g$
Both	$species \sim bill_length_mm + flipper_length_mm$

Los resultados para las tasas de exactitud son:

Table 1: Exactitud de los modelos LDA por método de selección

Método	Exactitud
Forward	0.9561
Backward	0.9883
Both	0.9561

La matriz de confusión para el método hacia adelante es:

Table 2: Matriz de confusión (Forward)

Verdadero \ Predicción	Adelie	Chinstrap	Gentoo
Adelie	146	3	2
Chinstrap	6	59	3
Gentoo	0	1	122

La matriz de confusión para el método hacia atrás es:

Table 3: Matriz de confusión (Backward)

Verdadero \ Predicción	Adelie	Chinstrap	Gentoo
Adelie	150	1	0
Chinstrap	3	65	0
Gentoo	0	0	123

Finalmente, para el método mixto la matriz de confusión es:

Table 4: Matriz de confusión (Both)

Verdadero \ Predicción	Adelie	Chinstrap	Gentoo
Adelie	146	3	2
Chinstrap	6	59	3
Gentoo	0	1	122

Verificación de supuestos

Es importante verificar los supuestos del modelo LDA con las variables seleccionadas.

Verificación de supuestos

Es importante verificar los supuestos del modelo LDA con las variables seleccionadas.

Podemos utilizar pruebas estadísticas y gráficos para evaluar la normalidad multivariada y la homogeneidad de matrices de covarianza.

Verificación de supuestos

Es importante verificar los supuestos del modelo LDA con las variables seleccionadas.

Podemos utilizar pruebas estadísticas y gráficos para evaluar la normalidad multivariada y la homogeneidad de matrices de covarianza.

Empezaremos por revisar la normalidad multivariada utilizando el test de Mardia.

Los resultados del test de Mardia para la selección hacia adelante son:

Table 5: Test de Mardia para normalidad multivariada (Forward)

Test	Statistic	p.value	Method	MVN
Mardia Skewness	58.996	0.001	asymptotic	Not normal
Mardia Kurtosis	-1.555	0.12	asymptotic	Normal

Para la selección hacia atrás tenemos los siguientes resultados:

Table 6: Test de Mardia para normalidad multivariada (Backward)

Test	Statistic	p.value	Method	MVN
Mardia Skewness	105.893	0.001	asymptotic	Not normal
Mardia Kurtosis	-3.995	0.001	asymptotic	Not normal

Finalmente, para el método mixto los resultados son:

Table 7: Test de Mardia para normalidad multivariada (Both)

Test	Statistic	p.value	Method	MVN
Mardia Skewness	58.996	0.001	asymptotic	Not normal
Mardia Kurtosis	-1.555	0.12	asymptotic	Normal

Para evaluar la homogeneidad de matrices de covarianza, podemos utilizar la prueba de Box.

Table 8: Prueba de Box para homogeneidad de matrices de covarianza

Método	Estadístico	Grados de libertad	Valor p
Forward	20.3041	6	0.0024
Backward	46.0082	12	0.0000
Both	20.3041	6	0.0024

Interpretación y reporte

En este ejemplo, hemos aplicado el método de selección de variables paso a paso para LDA utilizando el conjunto de datos de pingüinos.

Interpretación y reporte

En este ejemplo, hemos aplicado el método de selección de variables paso a paso para LDA utilizando el conjunto de datos de pingüinos.

Observamos que las diferentes estrategias de selección (hacia adelante, hacia atrás y mixta) pueden conducir a diferentes conjuntos de variables seleccionadas, lo que afecta la exactitud del modelo.

Interpretación y reporte

En este ejemplo, hemos aplicado el método de selección de variables paso a paso para LDA utilizando el conjunto de datos de pingüinos.

Observamos que las diferentes estrategias de selección (hacia adelante, hacia atrás y mixta) pueden conducir a diferentes conjuntos de variables seleccionadas, lo que afecta la exactitud del modelo.

Una vez seleccionado el modelo final realizamos una evaluación exhaustiva del desempeño y verificamos los supuestos del modelo.

Interpretación y reporte

En este ejemplo, hemos aplicado el método de selección de variables paso a paso para LDA utilizando el conjunto de datos de pingüinos.

Observamos que las diferentes estrategias de selección (hacia adelante, hacia atrás y mixta) pueden conducir a diferentes conjuntos de variables seleccionadas, lo que afecta la exactitud del modelo.

Una vez seleccionado el modelo final realizamos una evaluación exhaustiva del desempeño y verificamos los supuestos del modelo.

Notemos que las pruebas de normalidad multivariada y homogeneidad de matrices de covarianza nos proporcionan información valiosa sobre la adecuación del modelo LDA con las variables seleccionadas.

En nuestro caso, los supuestos no se cumplen completamente, sin embargo, el modelo sigue siendo útil para la clasificación.

En nuestro caso, los supuestos no se cumplen completamente, sin embargo, el modelo sigue siendo útil para la clasificación.

Finalmente, es crucial documentar todo el proceso de selección y evaluación para asegurar la reproducibilidad y transparencia del análisis.