

1 Estructura y organización de datos

MA2003B Aplicación de métodos multivariados
en ciencia de datos

Raul Gomez



Tecnológico
de Monterrey

Datos ordenados y el Tidyverse

El Tidyverse es una colección de paquetes de R diseñados para la ciencia de datos.

Datos ordenados y el Tidyverse

El Tidyverse es una colección de paquetes de R diseñados para la ciencia de datos.

Proporciona una interfaz coherente y amigable para la manipulación, visualización y análisis de datos.

Datos ordenados y el Tidyverse

El Tidyverse es una colección de paquetes de R diseñados para la ciencia de datos.

Proporciona una interfaz coherente y amigable para la manipulación, visualización y análisis de datos.

La idea central detrás del diseño del Tidyverse es el concepto de “datos ordenados”.

Definition

Datos ordenados es una forma de estructurar conjuntos de datos para simplificar su uso. En datos ordenados:

1. Cada variable forma una columna.

Definition

Datos ordenados es una forma de estructurar conjuntos de datos para simplificar su uso.

En datos ordenados:

1. Cada variable forma una columna.
2. Cada observación forma una fila.

Definition

Datos ordenados es una forma de estructurar conjuntos de datos para simplificar su uso.

En datos ordenados:

1. Cada variable forma una columna.
2. Cada observación forma una fila.
3. Cada tipo de unidad observacional forma una tabla.

Definition

Datos ordenados es una forma de estructurar conjuntos de datos para simplificar su uso.

En datos ordenados:

1. Cada variable forma una columna.
2. Cada observación forma una fila.
3. Cada tipo de unidad observacional forma una tabla.

Esta estructura facilita la manipulación, el análisis y la visualización de datos, pues se alinea con la forma en que normalmente se procesan en R.

Tibbles y pipes

En el Tidyverse, los datos se representan con un tipo especial de data frame llamado **tibble**.

Tibbles y pipes

En el Tidyverse, los datos se representan con un tipo especial de data frame llamado **tibble**.

Los tibbles son más amigables que los data frames tradicionales, pues ofrecen mejor impresión y comportamiento de subconjuntos.

Tibbles y pipes

En el Tidyverse, los datos se representan con un tipo especial de data frame llamado **tibble**.

Los tibbles son más amigables que los data frames tradicionales, pues ofrecen mejor impresión y comportamiento de subconjuntos.

También permiten un manejo más intuitivo de los datos. En particular, están diseñados para funcionar fluidamente con el operador pipe (`%>%`), que permite encadenar múltiples operaciones de manera clara y concisa.

Tibbles y pipes

En el Tidyverse, los datos se representan con un tipo especial de data frame llamado **tibble**.

Los tibbles son más amigables que los data frames tradicionales, pues ofrecen mejor impresión y comportamiento de subconjuntos.

También permiten un manejo más intuitivo de los datos. En particular, están diseñados para funcionar fluidamente con el operador pipe (`%>%`), que permite encadenar múltiples operaciones de manera clara y concisa.

Para ilustrar estas ideas, en la siguiente sección realizaremos la limpieza del conjunto de la OMS (“WHO”), para asegurar que el tibble asociado cumpla los principios de datos ordenados.

Tibbles y pipes

En el Tidyverse, los datos se representan con un tipo especial de data frame llamado **tibble**.

Los tibbles son más amigables que los data frames tradicionales, pues ofrecen mejor impresión y comportamiento de subconjuntos.

También permiten un manejo más intuitivo de los datos. En particular, están diseñados para funcionar fluidamente con el operador pipe (`%>%`), que permite encadenar múltiples operaciones de manera clara y concisa.

Para ilustrar estas ideas, en la siguiente sección realizaremos la limpieza del conjunto de la OMS (“WHO”), para asegurar que el tibble asociado cumpla los principios de datos ordenados.

Esto suele ser el primer paso en el Análisis Exploratorio de Datos (EDA) y es crucial para

Ordenando el conjunto de la OMS

Antes de comenzar, debemos cargar las librerías necesarias y el conjunto de la OMS:

```
library("tidyverse")
library("here")
library("cowplot")
library("patchwork")
library("krulRutils")
library("ISLR2")
library("magrittr")

options(scipen = 999) # Desactivar notación científica
data(who)
```

Ahora podemos iniciar nuestro proceso de “ordenamiento”.

Ahora podemos iniciar nuestro proceso de “ordenamiento”.

El principal problema de este conjunto es que contiene variables (como “new_sp_m014”) poco claras y que contienen más de una pieza de información.

Ahora podemos iniciar nuestro proceso de “ordenamiento”.

El principal problema de este conjunto es que contiene variables (como “new_sp_m014”) poco claras y que contienen más de una pieza de información.

Por ello debemos separarlas e introducir mejores nombres para ellas y sus valores asociados.

```
who_tidy <- who %>%  
  pivot_longer(  
    cols = starts_with("new"),  
    names_to = "key",  
    values_to = "cases",  
    values_drop_na = TRUE  
  ) %>%  
  mutate(  
    key = if_else(  
      startsWith(key, "newrel"),  
      sub("newrel", "new_rel", key),  
      key  
    ),  
    cases = as.integer(cases)  
  )
```

```
who_tidy <- who_tidy %>%  
  separate(key, into = c("new", "type", "sexage"), sep = "_") %>%  
  separate(sexage, into = c("sex", "age"), sep = 1) %>%  
  select(-new, -iso2, -iso3)
```

Ahora queremos convertir las columnas “type”, “sex” y “age” en factores. Empezamos construyendo las siguientes tablas de correspondencia:

```
who_type_lookup_tbl <- tibble(  
  code = c("ep", "rel", "sn", "sp"),  
  label = c(  
    "Tuberculosis extrapulmonar",  
    "Caso de recaída",  
    "TB pulmonar baciloscopía negativa",  
    "TB pulmonar baciloscopía positiva"  
  )  
)
```

```
who_sex_lookup_tbl <- tibble(  
  code = c("f", "m"),  
  label = c("Mujer", "Hombre")  
)
```

```
who_age_lookup_tbl <- tibble(  
  code = c("014", "1524", "2534", "3544", "4554", "5564", "65"),  
  label = c(  
    "0-14",  
    "15-24",  
    "25-34",  
    "35-44",  
    "45-54",  
    "55-64",  
    "65+"  
  )  
)
```

Ahora podemos añadir las columnas factor para las variables correspondientes en el conjunto de la OMS:

```
who_factor <- who_tidy %>%  
  convert_codes_to_factor(  
    code_col = type,  
    lookup_tbl = who_type_lookup_tbl,  
    lookup_code_col = code,  
    lookup_label_col = label,  
  )
```

```
who_factor <- who_factor %>%  
  convert_codes_to_factor(  
    code_col = sex,  
    lookup_tbl = who_sex_lookup_tbl,  
    lookup_code_col = code,  
    lookup_label_col = label,  
  )
```

```
who_factor <- who_factor %>%  
  convert_codes_to_factor(  
    code_col = age,  
    lookup_tbl = who_age_lookup_tbl,  
    lookup_code_col = code,  
    lookup_label_col = label,  
  )
```

Finalmente, queremos usar esta información para analizar el número de casos de tuberculosis por tipo y sexo. Comenzamos generando el tibble de frecuencias correspondiente.

```
who_type_sex_tbl <- who_factor %>%  
  count(type_factor, sex_factor, wt = cases, name = "cases") %>%  
  print(n = Inf)
```

```
# A tibble: 8 x 3
```

	type_factor <fct>	sex_factor <fct>	cases <int>
1	Tuberculosis extrapulmonar	Mujer	941880
2	Tuberculosis extrapulmonar	Hombre	1044299
3	Caso de recaída	Mujer	1201596
4	Caso de recaída	Hombre	2018976
5	TB pulmonar baciloscopía negativa	Mujer	2439139
6	TB pulmonar baciloscopía negativa	Hombre	3840388
7	TB pulmonar baciloscopía positiva	Mujer	11324409
8	TB pulmonar baciloscopía positiva	Hombre	20586831

La “Gramática de los Gráficos” y ggplot2

El concepto de la “Gramática de los Gráficos” fue introducido por Leland Wilkinson en su libro de 1999 **The Grammar of Graphics**.

La “Gramática de los Gráficos” y ggplot2

El concepto de la “Gramática de los Gráficos” fue introducido por Leland Wilkinson en su libro de 1999 **The Grammar of Graphics**.

Esto proporciona un marco para entender cómo crear visualizaciones de forma sistemática. Descompone el proceso en componentes como datos, estéticas, geometrías, estadísticas, coordenadas y temas.

La “Gramática de los Gráficos” y ggplot2

El concepto de la “Gramática de los Gráficos” fue introducido por Leland Wilkinson en su libro de 1999 **The Grammar of Graphics**.

Esto proporciona un marco para entender cómo crear visualizaciones de forma sistemática. Descompone el proceso en componentes como datos, estéticas, geometrías, estadísticas, coordenadas y temas.

El paquete `ggplot2` implementa esta gramática en R, permitiendo construir visualizaciones complejas por capas.

Capas en ggplot2

En ggplot2, las gráficas se construyen añadiendo múltiples **capas** que definen los componentes de la visualización.

Capas en ggplot2

En ggplot2, las gráficas se construyen añadiendo múltiples **capas** que definen los componentes de la visualización.

Cada capa corresponde a un aspecto específico de la gráfica y, juntas, forman la visualización completa.

Estas capas incluyen:

1. **Datos:** El conjunto a visualizar; es la fuente de la información de la gráfica.
2. **Estéticas:** Mapeos que relacionan variables con propiedades visuales, por ejemplo:
 - Posición en los ejes x e y.
 - Color, relleno.
 - Tamaño, forma.
 - Transparencia.

Estos mapeos definen **qué** datos se muestran y **cómo** se representan visualmente.

3. **Geometrías:** Objetos geométricos que muestran los datos; por ejemplo:

- `geom_point()` para diagramas de dispersión.
- `geom_line()` para gráficas de líneas.
- `geom_col()` para barras.
- `geom_histogram()` para histogramas.

La geometría controla **cómo** se dibujan los datos.

4. **Transformaciones estadísticas:** Cálculos opcionales aplicados a los datos antes de graficar, tales como:

- `stat_bin()` para agrupar en histogramas.
- `stat_smooth()` para ajustar curvas suaves.

Estos son pasos de preprocesamiento para la visualización.

5. **Escalas:** Definen cómo se traducen los valores a propiedades visuales; también controlan ejes, leyendas y guías.

6. **Coordenadas:** El sistema de coordenadas usado, como cartesiano (`coord_cartesian()`), polar (`coord_polar()`) o invertido (`coord_flip()`).

7. **Facetado:** Métodos para dividir los datos y mostrar múltiples gráficas en una cuadrícula:

- `facet_wrap()`
- `facet_grid()`


8. **Etiquetas:** `labs()` agrega títulos, etiquetas de ejes y pies.

9. **Temas:** `theme()` controla la apariencia general (fuentes, fondo, rejillas).

Cada capa puede combinarse y personalizarse para construir gráficas complejas y elegantes. Esta **gramática por capas** permite pensar la gráfica como la composición de componentes independientes, y no como un objeto monolítico.

Ilustraremos estos conceptos graficando el número de casos de tuberculosis por tipo y sexo, usando el tibble de frecuencias creado antes.

```
who_type_sex_plot <- who_type_sex_tbl %>%  
  ggplot(aes(x = type_factor, y = cases, fill = sex_factor)) +  
  geom_col(position = "dodge") +  
  c_scale_fill("C rose", "C blue") +  
  labs(  
    title = "Casos de tuberculosis por tipo y sexo",  
    x = "Tipo de tuberculosis",  
    y = "Casos",  
    fill = "Sexo"  
  ) +  
  theme_krul()  
  
who_type_sex_plot
```



El conjunto Billboard

El problema con el conjunto Billboard, según los principios de “datos ordenados”, es que las semanas en que una canción aparece en la lista están representadas como columnas, lo cual dificulta el análisis.

El conjunto Billboard

El problema con el conjunto Billboard, según los principios de “datos ordenados”, es que las semanas en que una canción aparece en la lista están representadas como columnas, lo cual dificulta el análisis.


Usando las técnicas aprendidas, debemos ordenar el conjunto para analizar la evolución del ranking de la canción “Who Let The Dogs Out” de “Baha Men” en el Billboard Hot 100.

El conjunto Billboard

El problema con el conjunto Billboard, según los principios de “datos ordenados”, es que las semanas en que una canción aparece en la lista están representadas como columnas, lo cual dificulta el análisis.

Usando las técnicas aprendidas, debemos ordenar el conjunto para analizar la evolución del ranking de la canción “Who Let The Dogs Out” de “Baha Men” en el Billboard Hot 100.

La visualización final debe verse como la que se muestra a continuación.



Bibliografía

-  Cleveland, W. S. (1993) *The Elements of Graphing Data*. Hobart Press.
-  Hyndman, R. J., and Athanasopoulos, G. (2021) *Forecasting: Principles and Practice* (3rd ed.). OTexts. <https://otexts.com/fpp3/>
-  Wickham, H. (2014) Tidy data. *Journal of Statistical Software*, 59(10), 1–23. <https://doi.org/10.18637/jss.v059.i10>
-  Wickham, H. (2016) *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag.
-  Wickham, H., and Grolemund, G. (2017) *R for Data Science: Import, Tidy, Transform, Visualize, and Model Data*. O'Reilly Media.
-  Wickham, H. (2019) Functional programming with purrr. *UseR! Conference*.

Bibliografía

-  Wickham, H., et al. (2019) Welcome to the tidyverse. *Journal of Open Source Software*, 4(43), 1686. <https://doi.org/10.21105/joss.01686>
-  Wilkinson, L. (1999) *The Grammar of Graphics*. Springer-Verlag.