

8 Análisis factorial: métodos prácticos

MA2003B Aplicación de métodos multivariados
en ciencia de datos

Raul Gomez



Tecnológico
de Monterrey

Análisis de componentes principales

El Análisis de Componentes Principales (PCA) es una técnica poderosa para reducir la dimensionalidad de un conjunto de datos preservando la mayor información posible (medida por la varianza).

Análisis de componentes principales

El Análisis de Componentes Principales (PCA) es una técnica poderosa para reducir la dimensionalidad de un conjunto de datos preservando la mayor información posible (medida por la varianza).

Transforma las variables originales en un nuevo conjunto de variables no correlacionadas llamadas **componentes principales**, ordenadas por la varianza que explican.

Entendiendo la varianza total

Sea Σ la matriz de covarianzas de un conjunto dado.

Entendiendo la varianza total

Sea Σ la matriz de covarianzas de un conjunto dado.

La **varianza total** de los datos viene dada por la traza de la matriz de covarianzas:

$$\text{Total Variance} = \text{Tr}\Sigma = \sum_{i=1}^p \Sigma_{ii},$$

en donde Σ_{ii} son las entradas diagonales de Σ (varianzas de cada variable).

Ahora, usando la descomposición en valores y vectores propios (SVD) de Σ , existen matrices Q y Λ tales que:

$$\Sigma = Q\Lambda Q^T,$$

en donde Λ es diagonal y contiene los valores singulares $\lambda_1, \dots, \lambda_p$ de Σ .

Ahora, usando la descomposición en valores y vectores propios (SVD) de Σ , existen matrices Q y Λ tales que:

$$\Sigma = Q\Lambda Q^T,$$

en donde Λ es diagonal y contiene los valores singulares $\lambda_1, \dots, \lambda_p$ de Σ .

Estos valores propios permiten expresar la varianza total como:

$$\text{Total Variance} = \text{Tr}\Sigma = \text{Tr}Q\Lambda Q^T = \text{Tr}\Lambda = \lambda_1 + \dots + \lambda_p.$$

Las columnas de Q son las **direcciones de componentes principales**; los valores de Λ indican cuánta varianza explica cada componente.

Las columnas de Q son las **direcciones de componentes principales**; los valores de Λ indican cuánta varianza explica cada componente.

El primer componente (mayor valor propio) capta la mayor varianza; el segundo, la segunda mayor, y así sucesivamente.

Estos componentes inducen un nuevo sistema de coordenadas para nuestros datos.

Estos componentes inducen un nuevo sistema de coordenadas para nuestros datos.

Los valores en ese sistema son las **puntuaciones de componentes principales**.

Estos componentes inducen un nuevo sistema de coordenadas para nuestros datos.

Los valores en ese sistema son las **puntuaciones de componentes principales**.

Se relacionan con las variables originales mediante:

$$X = Q(PC) + \bar{x}$$

y

$$PC = Q^T(X - \bar{x})$$

Aquí X es el vector en coordenadas originales, PC el vector de puntuaciones y $\bar{x}$ el vector de medias.

Estos componentes inducen un nuevo sistema de coordenadas para nuestros datos.

Los valores en ese sistema son las **puntuaciones de componentes principales**.

Se relacionan con las variables originales mediante:


$$X = Q(PC) + \bar{x}$$

y

$$PC = Q^T(X - \bar{x})$$

Aquí X es el vector en coordenadas originales, PC el vector de puntuaciones y $\bar{x}$ el vector de medias.

Para ilustrar estas ideas, consideremos de nuevo el conjunto mostrado en la siguiente figura:



Recuerde que este conjunto tiene 300 observaciones de dos variables, X y Y .

Recuerde que este conjunto tiene 300 observaciones de dos variables, X y Y .

La primera variable proviene de una distribución uniforme entre 0 y 10.

Recuerde que este conjunto tiene 300 observaciones de dos variables, X y Y .

La primera variable proviene de una distribución uniforme entre 0 y 10.

La segunda se genera como $Y = X + \varepsilon$, con ε normal de media 0 y desviación estándar 1.

La matriz de covarianzas de este conjunto es:

$$\Sigma = \begin{bmatrix} 7.874751 & 7.7745959 \\ 7.7745959 & 8.6510962 \end{bmatrix}$$

La matriz de covarianzas de este conjunto es:

$$\Sigma = \begin{bmatrix} 7.874751 & 7.7745959 \\ 7.7745959 & 8.6510962 \end{bmatrix}$$

La varianza total es:

$$\text{Total Variance} = \text{Tr}\Sigma = \Sigma_{11} + \Sigma_{22} = 16.5258472$$

Ahora vemos la descomposición en valores singulares de Σ para obtener:

$$Q = \begin{bmatrix} 0.689251 & -0.7245227 \\ 0.7245227 & 0.689251 \end{bmatrix}$$

y

$$\Lambda = \begin{bmatrix} 16.0472039 & 0 \\ 0 & 0.4786433 \end{bmatrix}$$

Las direcciones de los componentes principales son las columnas de Q , y la varianza explicada por cada componente la da el valor singular correspondiente en Λ .

Las direcciones de los componentes principales son las columnas de Q , y la varianza explicada por cada componente la da el valor singular correspondiente en Λ .

En particular, como el vector de medias es:

$$\bar{x} = 4.9961185$$

$$\bar{y} = 5.019733$$

tenemos que la relación entre variables originales y coordenadas en componentes principales es:

$$X = 0.689251PC_1 + -0.7245227PC_2 + 4.9961185$$

$$Y = 0.7245227PC_1 + 0.689251PC_2 + 5.019733$$

y

$$PC_1 = 0.689251(X - 4.9961185) + 0.7245227(Y - 5.019733)$$

$$PC_2 = -0.7245227(X - 4.9961185) + 0.689251(Y - 5.019733)$$

tenemos que la relación entre variables originales y coordenadas en componentes principales es:

$$X = 0.689251PC_1 + -0.7245227PC_2 + 4.9961185$$

$$Y = 0.7245227PC_1 + 0.689251PC_2 + 5.019733$$

y


$$PC_1 = 0.689251(X - 4.9961185) + 0.7245227(Y - 5.019733)$$

$$PC_2 = -0.7245227(X - 4.9961185) + 0.689251(Y - 5.019733)$$


usando estas fórmulas, podemos proyectar los datos originales en el primero y segundo componentes principales. Los resultados se muestran a continuación:

Proyecciones de componentes principales

Proyección en el primer componente principal



Proyección en el segundo componente principal



El ACP se usa a menudo para reducción de dimensionalidad.

El ACP se usa a menudo para reducción de dimensionalidad.

Es decir, queremos reducir el número de variables reteniendo tanta información como sea posible.

El ACP se usa a menudo para reducción de dimensionalidad.

Es decir, queremos reducir el número de variables reteniendo tanta información como sea posible.

Para decidir cuántos componentes conservar, revisamos la varianza explicada por cada uno.

Una forma común de visualizar esto es mediante el **gráfico scree**.

Una forma común de visualizar esto es mediante el **gráfico scree**.

El scree muestra los valores singulares en el eje y y el número de componente en el eje x .

Una forma común de visualizar esto es mediante el **gráfico scree**.

El scree muestra los valores singulares en el eje y y el número de componente en el eje x .

Ayuda a identificar el punto donde la varianza explicada se estabiliza (el “codo”).

Otro gráfico útil es el de **varianza acumulada**, que muestra la proporción acumulada explicada por los componentes.

Otro gráfico útil es el de **varianza acumulada**, que muestra la proporción acumulada explicada por los componentes.

La proporción de varianza explicada por el k -ésimo componente es:

$$\frac{\lambda_k}{\sum_{i=1}^p \lambda_i}$$

Este gráfico ayuda a decidir cuántos componentes se requieren para explicar, por ejemplo, 70% o 90% de la varianza.

Para ilustrar esto, usaremos el conjunto **Iris**, que contiene mediciones de cuatro variables:

1. Sepal Length
2. Sepal Width
3. Petal Length
4. Petal Width

Para tres especies de iris:

1. Iris setosa
2. Iris versicolor
3. Iris virginica

Aplicaremos ACP a las cuatro variables y crearemos un scree para visualizar la varianza explicada por cada componente.

Aplicaremos ACP a las cuatro variables y crearemos un scree para visualizar la varianza explicada por cada componente.

Las matrices de covarianzas para cada especie son:

$$\Sigma_{setosa} = \begin{bmatrix} 0.12 & 0.1 & 0.02 & 0.01 \\ 0.1 & 0.14 & 0.01 & 0.01 \\ 0.02 & 0.01 & 0.03 & 0.01 \\ 0.01 & 0.01 & 0.01 & 0.01 \end{bmatrix}$$

$$\Sigma_{versicolor} = \begin{bmatrix} 0.27 & 0.09 & 0.18 & 0.06 \\ 0.09 & 0.1 & 0.08 & 0.04 \\ 0.18 & 0.08 & 0.22 & 0.07 \\ 0.06 & 0.04 & 0.07 & 0.04 \end{bmatrix}$$

$$\Sigma_{virginica} = \begin{bmatrix} 0.4 & 0.09 & 0.3 & 0.05 \\ 0.09 & 0.1 & 0.07 & 0.05 \\ 0.3 & 0.07 & 0.3 & 0.05 \\ 0.05 & 0.05 & 0.05 & 0.08 \end{bmatrix}$$

Los valores singulares para cada especie son:

$$\Lambda_{setosa} = \begin{bmatrix} 0.24 & 0 & 0 & 0 \\ 0 & 0.04 & 0 & 0 \\ 0 & 0 & 0.03 & 0 \\ 0 & 0 & 0 & 0.01 \end{bmatrix}$$

$$\Lambda_{versicolor} = \begin{bmatrix} 0.49 & 0 & 0 & 0 \\ 0 & 0.07 & 0 & 0 \\ 0 & 0 & 0.05 & 0 \\ 0 & 0 & 0 & 0.01 \end{bmatrix}$$

$$\Lambda_{virginica} = \begin{bmatrix} 0.7 & 0 & 0 & 0 \\ 0 & 0.11 & 0 & 0 \\ 0 & 0 & 0.05 & 0 \\ 0 & 0 & 0 & 0.03 \end{bmatrix}$$

Las direcciones de componentes principales asociadas son las columnas de las matrices

$$Q_{setosa} = \begin{bmatrix} -0.67 & 0.6 & 0.44 & -0.04 \\ -0.73 & -0.62 & -0.27 & -0.02 \\ -0.1 & 0.49 & -0.83 & -0.24 \\ -0.06 & 0.13 & -0.2 & 0.97 \end{bmatrix}$$

$$Q_{versicolor} = \begin{bmatrix} -0.69 & 0.67 & -0.27 & 0.1 \\ -0.31 & -0.57 & -0.73 & -0.23 \\ -0.62 & -0.34 & 0.63 & -0.32 \\ -0.21 & -0.34 & 0.06 & 0.92 \end{bmatrix}$$

$$Q_{virginica} = \begin{bmatrix} -0.74 & -0.17 & -0.53 & 0.37 \\ -0.2 & 0.75 & -0.33 & -0.54 \\ -0.63 & -0.17 & 0.65 & -0.39 \\ -0.12 & 0.62 & 0.43 & 0.65 \end{bmatrix}$$

Las direcciones de componentes principales asociadas son las columnas de las matrices

$$Q_{setosa} = \begin{bmatrix} -0.67 & 0.6 & 0.44 & -0.04 \\ -0.73 & -0.62 & -0.27 & -0.02 \\ -0.1 & 0.49 & -0.83 & -0.24 \\ -0.06 & 0.13 & -0.2 & 0.97 \end{bmatrix}$$


$$Q_{versicolor} = \begin{bmatrix} -0.69 & 0.67 & -0.27 & 0.1 \\ -0.31 & -0.57 & -0.73 & -0.23 \\ -0.62 & -0.34 & 0.63 & -0.32 \\ -0.21 & -0.34 & 0.06 & 0.92 \end{bmatrix}$$

$$Q_{virginica} = \begin{bmatrix} -0.74 & -0.17 & -0.53 & 0.37 \\ -0.2 & 0.75 & -0.33 & -0.54 \\ -0.63 & -0.17 & 0.65 & -0.39 \\ -0.12 & 0.62 & 0.43 & 0.65 \end{bmatrix}$$


The scree plot and cumulative variance plot for the three species are shown in the following figure:

Gráfico scree y varianza acumulada para el conjunto Iris

Gráfico scree del conjunto Iris



Varianza acumulada explicada por los componentes principale



Cargas y biplots

Recuerde que la ecuación

$$PC = Q^T (X - \bar{x})$$

da la relación entre las variables originales y las puntuaciones en componentes.

Cargas y biplots

Recuerde que la ecuación

$$PC = Q^T (X - \bar{x})$$

da la relación entre las variables originales y las puntuaciones en componentes.

Con esta ecuación podemos calcular rápidamente las puntuaciones para cada observación.

Cargas y biplots

Recuerde que la ecuación

$$PC = Q^T (X - \bar{x})$$

da la relación entre las variables originales y las puntuaciones en componentes.

Con esta ecuación podemos calcular rápidamente las puntuaciones para cada observación.

Los coeficientes de esta ecuación son las **cargas** de los componentes; indican cuánto aporta cada variable a cada componente.

Un **biplot** muestra simultáneamente las puntuaciones de las observaciones y las cargas de las variables en el mismo gráfico.

Un **biplot** muestra simultáneamente las puntuaciones de las observaciones y las cargas de las variables en el mismo gráfico.

Esto permite visualizar cómo contribuyen las variables y cómo se distribuyen las observaciones en el espacio de componentes.

Un **biplot** muestra simultáneamente las puntuaciones de las observaciones y las cargas de las variables en el mismo gráfico.

Esto permite visualizar cómo contribuyen las variables y cómo se distribuyen las observaciones en el espacio de componentes.

Para ilustrar el concepto, crearemos biplots de los dos primeros componentes del conjunto **iris** por especie.

Un **biplot** muestra simultáneamente las puntuaciones de las observaciones y las cargas de las variables en el mismo gráfico.

Esto permite visualizar cómo contribuyen las variables y cómo se distribuyen las observaciones en el espacio de componentes.

Para ilustrar el concepto, crearemos biplots de los dos primeros componentes del conjunto **iris** por especie.

Comenzamos encontrando las cargas de cada especie: tomamos las dos primeras columnas de Q_{setosa} , $Q_{versicolor}$ y $Q_{virginica}$ mostradas arriba.

$$\text{Loadings}_{\text{setosa}} = \begin{bmatrix} -0.67 & 0.6 \\ -0.73 & -0.62 \\ -0.1 & 0.49 \\ -0.06 & 0.13 \end{bmatrix}$$

$$\text{Loadings}_{\text{versicolor}} = \begin{bmatrix} -0.69 & 0.67 \\ -0.31 & -0.57 \\ -0.62 & -0.34 \\ -0.21 & -0.34 \end{bmatrix}$$




$$\text{Loadings}_{\text{virginica}} = \begin{bmatrix} -0.74 & -0.17 \\ -0.2 & 0.75 \\ -0.63 & -0.17 \\ -0.12 & 0.62 \end{bmatrix}$$

Podemos entonces calcular las puntuaciones en componentes para cada observación multiplicando los valores originales por estas matrices.

Podemos entonces calcular las puntuaciones en componentes para cada observación multiplicando los valores originales por estas matrices.

Los biplots resultantes para cada especie se muestran en la figura siguiente:

Biplots de especies de Iris (PC1 vs PC2)



Resumen del proceso de ACP

En general, al realizar ACP se recomienda seguir estos pasos:

1. **Estandarizar los datos (si es necesario).** No siempre es obvio si estandarizar o no. Guías:

- Si las variables están en escalas distintas (ej. estatura en cm, peso en kg), suele recomendarse estandarizar.
- Si están en la misma escala y varianzas similares, podría no ser necesario.
- Si las varianzas difieren mucho, estandarizar ayuda a dar peso similar a todas.

2. Calcular la matriz de covarianzas.

- Captura cómo varían conjuntamente las variables.
- Es de tamaño $p \times p$, donde p es el número de variables.

3. Encontrar la SVD de la matriz de covarianzas.

- Los autovalores miden la varianza explicada por cada componente.
- Los autovectores dan las direcciones (combinaciones lineales) de los componentes.

4. Ordenar los componentes.

- Ordenar los valores singulares de mayor a menor.
- El vector singular del mayor valor es el primer componente principal.

5. Decidir cuántos componentes conservar.

- *Criterio de Kaiser*: conservar valores singulares > 1 (para matriz de correlación).
- *Gráfico scree*: buscar el “codo” donde se estabiliza la varianza explicada.
- *Varianza acumulada*: conservar los necesarios para explicar 70% – 90%.

6. Obtener puntuaciones y cargas.

- Proyectar los datos originales en los componentes seleccionados.
- Usar la fórmula: $PC = Q^T (X - \bar{x})$.

7. Interpretar los componentes.

- Examinar las *cargas* para ver qué variables contribuyen más.
- Valores absolutos mayores indican mayor influencia.
- Usar biplots para ver puntuaciones y cargas.
- Reducir dimensión antes de regresión, clustering u otros análisis.
- Reducir ruido descartando componentes de baja varianza.