

8 Análisis factorial: métodos prácticos

MA2003B Aplicación de métodos multivariados
en ciencia de datos

Raul Gomez



Tecnológico
de Monterrey

Análisis factorial: modelos teóricos

El **análisis factorial** es una técnica estadística ampliamente utilizada para identificar patrones ocultos o estructuras latentes detrás de grandes conjuntos de variables observadas.

Análisis factorial: modelos teóricos

El **análisis factorial** es una técnica estadística ampliamente utilizada para identificar patrones ocultos o estructuras latentes detrás de grandes conjuntos de variables observadas.

El objetivo es reducir la complejidad agrupando variables relacionadas en un número menor de **factores** subyacentes, más fáciles de interpretar.

Algunas áreas de aplicación comunes incluyen:

- **Psicología y ciencias sociales:** rasgos latentes como inteligencia, ansiedad, dimensiones de personalidad o satisfacción.

Algunas áreas de aplicación comunes incluyen:

- **Psicología y ciencias sociales:** rasgos latentes como inteligencia, ansiedad, dimensiones de personalidad o satisfacción.
- **Mercadotecnia e investigación de consumidores:** motivos de compra, percepciones de marca o segmentos.

Algunas áreas de aplicación comunes incluyen:

- **Psicología y ciencias sociales:** rasgos latentes como inteligencia, ansiedad, dimensiones de personalidad o satisfacción.
- **Mercadotecnia e investigación de consumidores:** motivos de compra, percepciones de marca o segmentos.
- **Finanzas y economía:** factores ocultos de rendimientos, indicadores macro o riesgos.

Algunas áreas de aplicación comunes incluyen:

- **Psicología y ciencias sociales:** rasgos latentes como inteligencia, ansiedad, dimensiones de personalidad o satisfacción.
- **Mercadotecnia e investigación de consumidores:** motivos de compra, percepciones de marca o segmentos.
- **Finanzas y economía:** factores ocultos de rendimientos, indicadores macro o riesgos.
- **Educación:** análisis de reactivos para medir habilidades comunes.

Algunas áreas de aplicación comunes incluyen:

- **Psicología y ciencias sociales:** rasgos latentes como inteligencia, ansiedad, dimensiones de personalidad o satisfacción.
- **Mercadotecnia e investigación de consumidores:** motivos de compra, percepciones de marca o segmentos.
- **Finanzas y economía:** factores ocultos de rendimientos, indicadores macro o riesgos.
- **Educación:** análisis de reactivos para medir habilidades comunes.
- **Ciencias biológicas y de la salud:** estructuras latentes en datos genéticos o reportes de pacientes.

En la práctica, se usa cuando se sospecha que unas cuantas dimensiones no observadas explican las correlaciones entre muchas variables.

En la práctica, se usa cuando se sospecha que unas cuantas dimensiones no observadas explican las correlaciones entre muchas variables.

Es especialmente útil para construir escalas de medición, reducir datos y comprender la estructura de conjuntos complejos.

Planteamiento del análisis factorial

El contexto teórico es una relación de la forma

$$X = \mu + LF + \varepsilon$$

donde:

- X is a random vector of p observed variables (indicators).

Planteamiento del análisis factorial

El contexto teórico es una relación de la forma

$$X = \mu + LF + \varepsilon$$

donde:

- X is a random vector of p observed variables (indicators).
- μ is a constant vector of dimension p .

Planteamiento del análisis factorial

El contexto teórico es una relación de la forma

$$X = \mu + LF + \varepsilon$$

donde:

- X is a random vector of p observed variables (indicators).
- μ is a constant vector of dimension p .
- L is a $p \times m$ constant matrix known as the matrix of **factor loadings**.

Planteamiento del análisis factorial

El contexto teórico es una relación de la forma

$$X = \mu + LF + \varepsilon$$

donde:

- X is a random vector of p observed variables (indicators).
- μ is a constant vector of dimension p .
- L is a $p \times m$ constant matrix known as the matrix of **factor loadings**.
- $F \sim \mathcal{N}(0, I_m)$ is a vector of m latent factors (unobserved variables).

Planteamiento del análisis factorial

El contexto teórico es una relación de la forma

$$X = \mu + LF + \varepsilon$$

donde:

- X is a random vector of p observed variables (indicators).
- μ is a constant vector of dimension p .
- L is a $p \times m$ constant matrix known as the matrix of **factor loadings**.
- $F \sim \mathcal{N}(0, I_m)$ is a vector of m latent factors (unobserved variables).
- $\varepsilon \sim \mathcal{N}(0, \Psi)$ is a vector of unique errors (specific variances), with Ψ diagonal.

Planteamiento del análisis factorial

El contexto teórico es una relación de la forma

$$X = \mu + LF + \varepsilon$$

donde:

- X is a random vector of p observed variables (indicators).
- μ is a constant vector of dimension p .
- L is a $p \times m$ constant matrix known as the matrix of **factor loadings**.
- $F \sim \mathcal{N}(0, I_m)$ is a vector of m latent factors (unobserved variables).
- $\varepsilon \sim \mathcal{N}(0, \Psi)$ is a vector of unique errors (specific variances), with Ψ diagonal.
- F and ε are assumed to be independent, in particular $\text{Cov}[F, \varepsilon] = 0$.

Como consecuencia de estas suposiciones, tenemos

$$\mathbb{E}[X] = \mathbb{E}[\mu + LF + \varepsilon] = \mathbb{E}[\mu] + L\mathbb{E}[F] + \mathbb{E}[\varepsilon] = \mu$$

Como consecuencia de estas suposiciones, tenemos

$$\mathbb{E}[X] = \mathbb{E}[\mu + LF + \varepsilon] = \mathbb{E}[\mu] + L\mathbb{E}[F] + \mathbb{E}[\varepsilon] = \mu$$

y

$$\begin{aligned}\text{Var}[X] &= \text{Var}[LF + \varepsilon] \\ &= \mathbb{E}[(LF + \varepsilon)(LF + \varepsilon)^T] \\ &= \mathbb{E}[LFF^T L^T] + \mathbb{E}[\varepsilon\varepsilon^T] + \mathbb{E}[LF\varepsilon^T] + \mathbb{E}[\varepsilon F^T L^T] \\ &= L\mathbb{E}[FF^T]L^T + \mathbb{E}[\varepsilon\varepsilon^T] + L\mathbb{E}[F\varepsilon^T] + \mathbb{E}[\varepsilon F^T]L^T \\ &= LI_m L^T + \Psi + L0 + 0L^T \\ &= LL^T + \Psi\end{aligned}$$

Como consecuencia de estas suposiciones, tenemos

$$\mathbb{E}[X] = \mathbb{E}[\mu + LF + \varepsilon] = \mathbb{E}[\mu] + L\mathbb{E}[F] + \mathbb{E}[\varepsilon] = \mu$$

y

$$\begin{aligned}\text{Var}[X] &= \text{Var}[LF + \varepsilon] \\ &= \mathbb{E}[(LF + \varepsilon)(LF + \varepsilon)^T] \\ &= \mathbb{E}[LFF^T L^T] + \mathbb{E}[\varepsilon\varepsilon^T] + \mathbb{E}[LF\varepsilon^T] + \mathbb{E}[\varepsilon F^T L^T] \\ &= L\mathbb{E}[FF^T]L^T + \mathbb{E}[\varepsilon\varepsilon^T] + L\mathbb{E}[F\varepsilon^T] + \mathbb{E}[\varepsilon F^T]L^T \\ &= LI_m L^T + \Psi + L0 + 0L^T \\ &= LL^T + \Psi\end{aligned}$$

Además, como X es combinación lineal de normales, se sigue que

$$X \sim \mathcal{N}(\mu, LL^T + \Psi)$$

La descomposición $\text{Var}[X] = LL^T + \Psi$ muestra que la varianza total de X se divide en dos componentes:

La descomposición $\text{Var}[X] = LL^T + \Psi$ muestra que la varianza total de X se divide en dos componentes:

- **Varianza común (LL^T):** parte explicada por los factores comunes F ; captura la variabilidad compartida atribuible a la estructura latente.

La descomposición $\text{Var}[X] = LL^T + \Psi$ muestra que la varianza total de X se divide en dos componentes:

- **Varianza común (LL^T):** parte explicada por los factores comunes F ; captura la variabilidad compartida atribuible a la estructura latente.
- **Varianza única (Ψ):** parte específica de cada variable observada no explicada por los factores (errores de medición u otra variabilidad propia).

La descomposición $\text{Var}[X] = LL^T + \Psi$ muestra que la varianza total de X se divide en dos componentes:

- **Varianza común (LL^T):** parte explicada por los factores comunes F ; captura la variabilidad compartida atribuible a la estructura latente.
- **Varianza única (Ψ):** parte específica de cada variable observada no explicada por los factores (errores de medición u otra variabilidad propia).

En particular, la varianza de cada variable observada X_i puede escribirse como

$$\text{Var}[X_i] = \sum_{j=1}^m L_{ij}^2 + \sigma_i^2$$

donde $h_i^2 = \sum_{j=1}^m L_{ij}^2$ es la **comunalidad** de X_i (porción explicada por factores comunes) y σ_i^2 la varianza única.

Estimación de puntuaciones factoriales

Suponga que tenemos el modelo

$$X = \mu + LF + \varepsilon$$

con las mismas condiciones que antes.

Estimación de puntuaciones factoriales

Suponga que tenemos el modelo

$$X = \mu + LF + \varepsilon$$

con las mismas condiciones que antes.

Entonces la distribución conjunta de X y F viene dada por

$$\begin{bmatrix} X \\ F \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \mu \\ 0 \end{bmatrix}, \begin{bmatrix} LL^T + \Psi & L \\ L^T & I_m \end{bmatrix} \right)$$

Estimación de puntuaciones factoriales

Suponga que tenemos el modelo

$$X = \mu + LF + \varepsilon$$

con las mismas condiciones que antes.

Entonces la distribución conjunta de X y F viene dada por

$$\begin{bmatrix} X \\ F \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \mu \\ 0 \end{bmatrix}, \begin{bmatrix} LL^T + \Psi & L \\ L^T & I_m \end{bmatrix} \right)$$

Observe que, en particular,

$$\text{Cov}[X, F] = \mathbb{E}[(X - \mu)(F - 0)^T] = \mathbb{E}[(LF + \varepsilon)F^T] = L\mathbb{E}[FF^T] + \mathbb{E}[\varepsilon F^T] = LI_m + 0 = L$$

Usando propiedades de la normal multivariante, podemos derivar la distribución condicional de F dado X .

Usando propiedades de la normal multivariante, podemos derivar la distribución condicional de F dado X .

Esta distribución condicional también es normal, con media y covarianza dadas por

$$[F|X = x] \sim \mathcal{N} \left(L^T (LL^T + \Psi)^{-1} (x - \mu), I_m - L^T (LL^T + \Psi)^{-1} L \right)$$

La media de esta distribución condicional,

$$\mathbb{E}[F|X = x] = L^T(LL^T + \Psi)^{-1}(x - \mu)$$

se conoce como la **puntuación factorial** para el dato observado $X = x$.

La media de esta distribución condicional,

$$\mathbb{E}[F|X = x] = L^T(LL^T + \Psi)^{-1}(x - \mu)$$

se conoce como la **puntuación factorial** para el dato observado $X = x$.

Proporciona una estimación de los factores latentes con base en las variables observadas y las cargas.

La media de esta distribución condicional,

$$\mathbb{E}[F|X = x] = L^T (LL^T + \Psi)^{-1}(x - \mu)$$

se conoce como la **puntuación factorial** para el dato observado $X = x$.

Proporciona una estimación de los factores latentes con base en las variables observadas y las cargas.

La matriz de covarianzas

$$I_m - L^T (LL^T + \Psi)^{-1} L$$

representa la incertidumbre asociada a las puntuaciones factoriales.

Remark

Nótese que si

$$f = \mathbb{E}[F|X = x] = L^T(LL^T + \Psi)^{-1}(x - \mu)$$

entonces, en general, el **residuo**

$$r(x) = x - \mu - Lf$$

es distinto de cero.

Remark

Nótese que si

$$f = \mathbb{E}[F|X = x] = L^T(LL^T + \Psi)^{-1}(x - \mu)$$

entonces, en general, el **residuo**

$$r(x) = x - \mu - Lf$$

es distinto de cero.

De hecho, como función de la variable aleatoria X , el residuo tiene distribución

$$r(X) \sim \mathcal{N}\left(0, L(I_m + L^T\Psi^{-1}L)^{-1}L^T + \Psi\right)$$

Rotación de factores

Un aspecto importante del AF es que los factores no están definidos de manera única.

Rotación de factores

Un aspecto importante del AF es que los factores no están definidos de manera única.

Si F es un vector de factores, cualquier transformación ortogonal $F^* = QF$ (con $Q^T Q = I$) produce nuevos factores que explican la misma varianza en las variables observadas.

Rotación de factores

Un aspecto importante del AF es que los factores no están definidos de manera única.

Si F es un vector de factores, cualquier transformación ortogonal $F^* = QF$ (con $Q^T Q = I$) produce nuevos factores que explican la misma varianza en las variables observadas.

In particular,

$$\text{Var}[F^*] = \text{Var}[QF] = Q \text{Var}[F] Q^T = Q I_m Q^T = I_m$$

Rotación de factores

Un aspecto importante del AF es que los factores no están definidos de manera única.

Si F es un vector de factores, cualquier transformación ortogonal $F^* = QF$ (con $Q^T Q = I$) produce nuevos factores que explican la misma varianza en las variables observadas.

In particular,

$$\text{Var}[F^*] = \text{Var}[QF] = Q \text{Var}[F] Q^T = Q I_m Q^T = I_m$$

Las correspondientes cargas factoriales se transforman como

$$L^* = LQ^T$$

En otras palabras, si

$$X = \mu + LF + \varepsilon$$

es un modelo factorial válido, entonces también lo es

$$X = \mu + L^*F^* + \varepsilon = \mu + LQ^T QF + \varepsilon = \mu + LF + \varepsilon$$

En otras palabras, si

$$X = \mu + LF + \varepsilon$$

es un modelo factorial válido, entonces también lo es

$$X = \mu + L^*F^* + \varepsilon = \mu + LQ^T QF + \varepsilon = \mu + LF + \varepsilon$$

Esto significa que la solución de un AF no es única y diferentes rotaciones conducen a interpretaciones distintas.

En otras palabras, si

$$X = \mu + LF + \varepsilon$$

es un modelo factorial válido, entonces también lo es

$$X = \mu + L^*F^* + \varepsilon = \mu + LQ^T QF + \varepsilon = \mu + LF + \varepsilon$$

Esto significa que la solución de un AF no es única y diferentes rotaciones conducen a interpretaciones distintas.

En la siguiente presentación exploraremos métodos prácticos y técnicas de rotación orientadas a obtener soluciones más interpretables.