

8 Análisis factorial: métodos prácticos

MA2003B Aplicación de métodos multivariados
en ciencia de datos

Raul Gomez



Tecnológico
de Monterrey

Factor Analysis: Practical Models

Factor Analysis: Practical Methods

Recordemos del capítulo anterior que el modelo clásico de AF está dado por

$$X = \mu + LF + \varepsilon$$

donde:

Factor Analysis: Practical Methods

Recordemos del capítulo anterior que el modelo clásico de AF está dado por

$$X = \mu + LF + \varepsilon$$

donde:

- X es un vector aleatorio de p variables observadas (indicadores).
- μ es un vector constante de dimensión p .
- L es una matriz $p \times m$ de *cargas factoriales*.
- $F \sim \mathcal{N}(0, I_m)$ es un vector de m factores latentes (no observados), normales con media cero e identidad como covarianzas.
- $\varepsilon \sim \mathcal{N}(0, \Psi)$ es un vector de errores únicos (varianzas específicas), normales con media cero y covarianzas diagonales $\Psi = \text{diag}(\sigma_1^2, \dots, \sigma_p^2)$.
- Se asume independencia entre F y ε , en particular $\text{Cov}[F, \varepsilon] = 0$.

Notice that, since $\varepsilon \sim \mathcal{N}(0, \Psi)$, this model is completely specified by the parameters μ , L , and Ψ . In this chapter we will discuss practical methods for estimating these parameters from data, as well as methods for estimating the latent factors F (known as *factor scores*) for our observations once the model parameters have been estimated.

Evaluación de la factorizabilidad

The first step in applying factor analysis to a dataset is to assess whether the data is suitable for factor analysis, i.e., whether the observed variables exhibit sufficient correlations to justify the use of a factor model.

Evaluación de la factorizabilidad

The first step in applying factor analysis to a dataset is to assess whether the data is suitable for factor analysis, i.e., whether the observed variables exhibit sufficient correlations to justify the use of a factor model.

Several statistical tests and measures can be used to evaluate the factorability of a dataset:

1. **Correlation Matrix Examination:** A preliminary step is to visually inspect the correlation matrix of the observed variables. Look for patterns of high correlations (e.g., > 0.3) among variables, which suggest that they may share common underlying factors.
2. **Bartlett's Test of Sphericity:** This test evaluates the hypothesis that the correlation matrix is an identity matrix, which would indicate that the variables are uncorrelated and unsuitable for factor analysis. A significant result ($p\text{-value} < 0.05$) suggests that the variables are correlated enough to proceed with factor analysis.
3. **Kaiser-Meyer-Olkin (KMO) Measure of Sampling Adequacy:** The KMO statistic measures the proportion of variance in the observed variables that can be attributed to underlying common factors, relative to variance that is unique to each variable. It ranges from 0 to 1, with values closer to 1 indicating that factor analysis is likely to be useful. A KMO value above 0.6 is generally considered acceptable for factor analysis.

Decidir el número de factores

Determinar cuántos factores retener es un paso crucial que impacta los resultados e interpretaciones.

Decidir el número de factores

Determinar cuántos factores retener es un paso crucial que impacta los resultados e interpretaciones.

Pueden emplearse varios métodos:

1. **Criterio de autovalor (Kaiser):** conservar factores con valores singulares > 1 .
2. **Gráfico scree:** buscar el “codo” donde la pendiente cambia notablemente.
3. **Análisis paralelo:** comparar valores singulares observados con los de datos aleatorios del mismo tamaño; conservar si los supera.
4. **Índices de ajuste:** en métodos confirmatorios (CFA), usar RMSEA, TLI, etc., para evaluar el ajuste según el número de factores.

Extracción de factores

Una vez decidido el número de factores, el siguiente paso es extraerlos. Métodos comunes:

Extracción de factores

Una vez decidido el número de factores, el siguiente paso es extraerlos. Métodos comunes:

1. **Ejes principales (PAF):** se centra en la varianza compartida; estima comunalidades iterativamente y extrae factores de la matriz de correlación reducida.
2. **Máxima verosimilitud (ML):** estima cargas maximizando la verosimilitud; permite contrastes sobre la estructura y entrega índices de ajuste.

Rotación de factores

Tras extraer factores, suele ser útil rotarlos para lograr una estructura más simple e interpretable.

Rotación de factores

Tras extraer factores, suele ser útil rotarlos para lograr una estructura más simple e interpretable.

La rotación puede ser ortogonal (factores no correlacionados) u oblicua (factores correlacionados).

Rotación de factores

Tras extraer factores, suele ser útil rotarlos para lograr una estructura más simple e interpretable.

La rotación puede ser ortogonal (factores no correlacionados) u oblicua (factores correlacionados).

Métodos comunes:

1. **Varimax:** ortogonal; maximiza la varianza de las cargas al cuadrado en cada factor, promoviendo estructuras simples.
2. **Quartimax:** ortogonal; simplifica filas de la matriz de cargas buscando que cada variable cargue en pocos factores.
3. **Equamax:** ortogonal híbrido; equilibra objetivos de varimax y quartimax.
4. **Promax:** oblicua; parte de varimax y eleva cargas a una potencia para simplificar permitiendo correlación entre factores.

Cálculo de puntuaciones factoriales

Tras estimar cargas y rotar, el siguiente paso es calcular las puntuaciones factoriales de cada observación.

Cálculo de puntuaciones factoriales

Tras estimar cargas y rotar, el siguiente paso es calcular las puntuaciones factoriales de cada observación.

Las puntuaciones representan los valores estimados de los factores latentes para cada individuo, a partir de sus variables observadas.

Cálculo de puntuaciones factoriales

Tras estimar cargas y rotar, el siguiente paso es calcular las puntuaciones factoriales de cada observación.

Las puntuaciones representan los valores estimados de los factores latentes para cada individuo, a partir de sus variables observadas.

Existen varios métodos para calcularlas:

1. **Método de regresión:** estima puntuaciones al ajustar variables observadas sobre las cargas; es insesgado pero puede no preservar la varianza original de los factores.
2. **Método de Bartlett:** minimiza la varianza residual de las variables; produce puntuaciones más fiables y con menor error de medición.
3. **Método de Anderson–Rubin:** genera puntuaciones no correlacionadas y estandarizadas; útil cuando los factores se asumen ortogonales.

Evaluación del ajuste del modelo

Tras ajustar un modelo de AF, es importante evaluar qué tan bien ajusta a los datos.

Evaluación del ajuste del modelo

Tras ajustar un modelo de AF, es importante evaluar qué tan bien ajusta a los datos.

Pueden usarse varias pruebas e índices de ajuste:

1. **Chi-cuadrada de ajuste:** contrasta que la matriz de covarianzas implicada por el modelo coincide con la observada. Un p no significativo (> 0.05) sugiere buen ajuste.
2. **RMSEA:** discrepancia por g.l. entre matrices observada e implicada; < 0.06 suele indicar buen ajuste.
3. **TLI:** compara el ajuste del modelo con uno nulo; > 0.95 indica buen ajuste.
4. **SRMR:** discrepancia media estandarizada entre correlaciones observadas y predichas; < 0.08 indica buen ajuste.

Visualización del modelo

Visualizar resultados del AF ayuda a interpretar factores y relaciones entre variables.

Visualización del modelo

Visualizar resultados del AF ayuda a interpretar factores y relaciones entre variables.

Técnicas comunes:

1. **Gráfico scree:** valores singulares en orden descendente; ayuda a decidir factores a retener.
2. **Gráfico de cargas:** dispersión de cargas para ver cómo cargan variables, especialmente tras rotación.
3. **Biplot:** combina puntuaciones y cargas en un solo gráfico.
4. **Mapa de calor de cargas:** visualiza magnitudes de cargas por variable y factor.

Remark

Los gráficos de cargas y los biplots sólo tienen sentido con 2 o 3 factores; de otro modo no se visualizan adecuadamente.

Ejemplo: AF del conjunto Holzinger–Swineford

Mostraremos un ejemplo con el conjunto “HolzingerSwineford1939” del paquete “lavaan”.

Ejemplo: AF del conjunto Holzinger–Swineford

Mostraremos un ejemplo con el conjunto “HolzingerSwineford1939” del paquete “lavaan”.

Este conjunto contiene puntajes de 9 pruebas cognitivas aplicadas a 301 estudiantes de 7º y 8º grado.

Ejemplo: AF del conjunto Holzinger–Swineford

Mostraremos un ejemplo con el conjunto “HolzingerSwineford1939” del paquete “lavaan”.

Este conjunto contiene puntajes de 9 pruebas cognitivas aplicadas a 301 estudiantes de 7º y 8º grado.

Las pruebas buscan medir 3 habilidades latentes: visoespacial, verbal y velocidad. Aquí nos enfocamos en x4–x9 para ajustar un modelo de dos factores y visualizar el biplot.

Ejemplo: AF del conjunto Holzinger–Swineford

Mostraremos un ejemplo con el conjunto “HolzingerSwineford1939” del paquete “lavaan”.

Este conjunto contiene puntajes de 9 pruebas cognitivas aplicadas a 301 estudiantes de 7º y 8º grado.

Las pruebas buscan medir 3 habilidades latentes: visoespacial, verbal y velocidad. Aquí nos enfocamos en x_4 – x_9 para ajustar un modelo de dos factores y visualizar el biplot.

La descripción de cada prueba es la siguiente:


1. **Paragraph (x4)**: Comprensión lectora. Leer párrafos cortos y responder sobre idea principal, detalles e inferencias.
2. **Sentence (x5)**: Completar oraciones. Elegir la palabra o frase que mejor complete una oración; enfatiza vocabulario en contexto y sintaxis.
3. **Word Meaning (x6)**: Vocabulario. Seleccionar el mejor sinónimo/definición de una palabra objetivo.
4. **Addition (x7)**: Aritmética cronometrada. Completar sumas simples rápida y correctamente; mide velocidad de procesamiento.
5. **Counting Dots (x8)**: Conteo visual rápido. Contar grupos pequeños de puntos en muchos ítems; mide escaneo visual y precisión.
6. **Straight–Curved Capitals (x9)**: Discriminación perceptual. Identificar letras mayúsculas con sólo trazos rectos, bajo límite de tiempo.

Assessing Factorability

Iniciamos el proceso evaluando la factorizabilidad para x_4 – x_9 . Primero reunimos la información necesaria.

Mostramos el mapa de calor de correlaciones:

Mapa de calor de correlaciones (x4–x9)



Obsérvese la fuerte correlación entre las pruebas verbales (x_4 , x_5 , x_6) y entre las de rapidez (x_7 , x_8 , x_9), pero no entre ambos grupos.

Obsérvese la fuerte correlación entre las pruebas verbales (x_4 , x_5 , x_6) y entre las de rapidez (x_7 , x_8 , x_9), pero no entre ambos grupos.

Esto sugiere que una solución de dos factores es adecuada. Reportamos los resultados de Bartlett y la medida KMO:

Obsérvese la fuerte correlación entre las pruebas verbales (x_4 , x_5 , x_6) y entre las de rapidez (x_7 , x_8 , x_9), pero no entre ambos grupos.

Esto sugiere que una solución de dos factores es adecuada. Reportamos los resultados de Bartlett y la medida KMO:

Bartlett's test of sphericity = 0

Kaiser-Meyer-Olkin measure = 0.7308774

Obsérvese la fuerte correlación entre las pruebas verbales (x_4 , x_5 , x_6) y entre las de rapidez (x_7 , x_8 , x_9), pero no entre ambos grupos.

Esto sugiere que una solución de dos factores es adecuada. Reportamos los resultados de Bartlett y la medida KMO:

Bartlett's test of sphericity = 0

Kaiser-Meyer-Olkin measure = 0.7308774

Como se observa, todas las pruebas indican que el AF es apropiado para este conjunto.

Decidir el número de factores

Usaremos un gráfico scree y uno de varianza acumulada para decidir cuántos factores retener.


Decidir el número de factores

Usaremos un gráfico scree y uno de varianza acumulada para decidir cuántos factores retener.


Como usamos la matriz de correlaciones, buscamos valores singulares > 1 (criterio de Kaiser) y el “codo” en el scree.

Gráfico scree y varianza acumulada

Gráfico scree



Varianza acumulada



Nótese que tanto el scree como la varianza acumulada sugieren que una solución de dos factores es apropiada para las seis pruebas consideradas.

Extracción, rotación y puntuación de factores

Aun cuando extraer, rotar y puntuar son pasos teóricamente distintos, en la práctica suelen realizarse juntos con paquetes estadísticos. Usaremos `psych::fa` para hacer los tres a la vez: ajustaremos un modelo de 2 factores por máxima verosimilitud (ML), calcularemos puntuaciones por el método de regresión y aplicaremos rotación varimax para simplificar la estructura.

Evaluación del ajuste

Evaluamos ahora qué tan bien la solución ML de 2 factores reproduce las correlaciones observadas. Para ello calculamos χ^2 , RMSEA, CFI, TLI y RMSR.

Los resultados de estas pruebas son:

$$\chi^2 \text{ Test} = 0.1156716$$

$$\text{RMSEA} = 0.0531269$$

$$\text{TLI} = 0.9804573$$


$$\text{RMSR} = 0.0411927$$

Todas las pruebas indican que el modelo de 2 factores ajusta bien a los datos.

Visualización del modelo

Finalmente, visualizaremos el modelo con un biplot. También rotaremos manualmente los factores para ilustrar qué podría ocurrir si no eligiéramos una rotación adecuada.

Rotación Varimax



Rotación manual

