

8 Análisis factorial: métodos prácticos

MA2003B Aplicación de métodos multivariados
en ciencia de datos

Raul Gomez



Tecnológico
de Monterrey

Análisis de conglomerados jerárquicos

Clustering (agrupamiento) es una técnica de aprendizaje no supervisado que agrupa puntos de datos similares con base en sus características.

Análisis de conglomerados jerárquicos

Clustering (agrupamiento) es una técnica de aprendizaje no supervisado que agrupa puntos de datos similares con base en sus características.

A diferencia del aprendizaje supervisado, el agrupamiento no depende de etiquetas o categorías predefinidas.

Análisis de conglomerados jerárquicos

Clustering (agrupamiento) es una técnica de aprendizaje no supervisado que agrupa puntos de datos similares con base en sus características.

A diferencia del aprendizaje supervisado, el agrupamiento no depende de etiquetas o categorías predefinidas.

En su lugar, identifica patrones y estructuras dentro de los propios datos.

Los métodos de agrupamiento suelen clasificarse en dos familias principales:

Los métodos de agrupamiento suelen clasificarse en dos familias principales:

1. **Agrupamiento jerárquico**: Estos métodos crean un **dendrograma** (también llamado **diagrama de árbol**) que representa la estructura taxonómica de los datos. Es especialmente útil para conjuntos pequeños y cuando se desconoce el número de conglomerados.

Los métodos de agrupamiento suelen clasificarse en dos familias principales:

1. **Agrupamiento jerárquico:** Estos métodos crean un **dendrograma** (también llamado **diagrama de árbol**) que representa la estructura taxonómica de los datos. Es especialmente útil para conjuntos pequeños y cuando se desconoce el número de conglomerados.
2. **Agrupamiento no jerárquico:** Métodos como K-medias y DBSCAN particionan los datos en un número predefinido de conglomerados o con base en la densidad. Generalmente escalan mejor para conjuntos grandes.

Entendiendo los dendrogramas

Un dendrograma es un diagrama en forma de árbol que ilustra la estructura taxonómica de nuestros datos de acuerdo con un algoritmo de agrupamiento jerárquico.

Entendiendo los dendrogramas

Un dendrograma es un diagrama en forma de árbol que ilustra la estructura taxonómica de nuestros datos de acuerdo con un algoritmo de agrupamiento jerárquico.

Proporciona una representación visual de cómo se agrupan los puntos según sus similitudes.

Entendiendo los dendrogramas

Un dendrograma es un diagrama en forma de árbol que ilustra la estructura taxonómica de nuestros datos de acuerdo con un algoritmo de agrupamiento jerárquico.

Proporciona una representación visual de cómo se agrupan los puntos según sus similitudes.


El eje vertical representa la distancia o disimilitud entre conglomerados, mientras que el eje horizontal representa los puntos individuales o los propios conglomerados.

Al cortar el dendrograma a una altura específica, podemos determinar el número de conglomerados que deseamos considerar para nuestro análisis.

Al cortar el dendrograma a una altura específica, podemos determinar el número de conglomerados que deseamos considerar para nuestro análisis.


Como ilustración, consideremos el diagrama de dispersión del conjunto Iris (considerando sólo las variables “Sepal.Length” y “Sepal.Width”), donde cada punto está coloreado según la especie de la flor:

Iris Dataset: Sepal Length vs Sepal Width




Ahora consideraremos un dendrograma asociado a este conjunto y mostraremos cómo cortarlo a distintas alturas conduce a diferentes números de conglomerados:

Dendrogram cuts



Clusters



Realización del agrupamiento jerárquico

Existen varios métodos para realizar agrupamiento jerárquico, pero los más comunes son:

Realización del agrupamiento jerárquico

Existen varios métodos para realizar agrupamiento jerárquico, pero los más comunes son:

- **Agrupamiento aglomerativo:** Enfoque ascendente en el que cada punto inicia como su propio conglomerado y, de manera iterativa, se fusionan parejas de conglomerados según su similitud hasta formar uno solo o cumplir un criterio de parada.

Realización del agrupamiento jerárquico

Existen varios métodos para realizar agrupamiento jerárquico, pero los más comunes son:

- **Agrupamiento aglomerativo:** Enfoque ascendente en el que cada punto inicia como su propio conglomerado y, de manera iterativa, se fusionan parejas de conglomerados según su similitud hasta formar uno solo o cumplir un criterio de parada.
- **Agrupamiento divisivo:** Enfoque descendente en el que todos los puntos empiezan en un único conglomerado y este se divide recursivamente en conglomerados más pequeños con base en la disimilitud hasta que cada punto queda solo o se satisface un criterio de parada.

Una vez elegido el método, debemos definir una métrica de distancia para medir la similitud entre puntos de datos.

Una vez elegido el método, debemos definir una métrica de distancia para medir la similitud entre puntos de datos.

Algunas métricas de distancia comunes incluyen:

- **Distancia euclidiana:** La métrica más común; calcula la distancia en línea recta entre dos puntos en un espacio multidimensional.

- **Distancia euclidiana:** La métrica más común; calcula la distancia en línea recta entre dos puntos en un espacio multidimensional.
- **Distancia de Mahalanobis:** Considera las correlaciones entre variables y es útil al trabajar con datos multivariados.

- **Distancia euclidiana:** La métrica más común; calcula la distancia en línea recta entre dos puntos en un espacio multidimensional.
- **Distancia de Mahalanobis:** Considera las correlaciones entre variables y es útil al trabajar con datos multivariados.
- **Distancia de Canberra:** Sensible a pequeños cambios en los datos y útil cuando se trabaja con datos dispersos (escasos). La fórmula para la distancia de Canberra entre dos puntos p y q es:

$$d(p, q) = \sum_{i=1}^n \frac{|p_i - q_i|}{|p_i| + |q_i|}$$

donde n es el número de dimensiones, y p_i y q_i son las coordenadas de los puntos p y q , respectivamente.

- **Distancia Manhattan:** También conocida como norma L^1 o distancia de taxista; calcula la distancia entre dos puntos sumando las diferencias absolutas de sus coordenadas. Es especialmente útil en alta dimensión o cuando los datos tienen estructura en rejilla. La fórmula para la distancia Manhattan entre dos puntos p y q es:

$$d(p, q) = \sum_{i=1}^n |p_i - q_i|$$

- **Distancia Manhattan:** También conocida como norma L^1 o distancia de taxista; calcula la distancia entre dos puntos sumando las diferencias absolutas de sus coordenadas. Es especialmente útil en alta dimensión o cuando los datos tienen estructura en rejilla. La fórmula para la distancia Manhattan entre dos puntos p y q es:

$$d(p, q) = \sum_{i=1}^n |p_i - q_i|$$

- **Distancia de Minkowski:** Generalización de las distancias Euclidiana y Manhattan, que permite distintos valores del parámetro p para controlar el cálculo. La distancia de Minkowski entre dos puntos p y q se define como:

$$d(p, q) = \left(\sum_{i=1}^n |p_i - q_i|^p \right)^{1/p}$$

Cuando $p = 1$, corresponde a la distancia Manhattan; cuando $p = 2$, corresponde a la distancia Euclidiana.

Finalmente, debemos elegir un criterio de enlace para determinar cómo se calcula la distancia entre conglomerados. Algunos criterios comunes son:

Finalmente, debemos elegir un criterio de enlace para determinar cómo se calcula la distancia entre conglomerados. Algunos criterios comunes son:

- **Enlace simple (single)**: Define la distancia entre dos conglomerados como la mínima distancia entre cualquier par de puntos de cada conglomerado. Tiende a crear conglomerados alargados en cadena y es sensible al ruido y a los valores atípicos.

Finalmente, debemos elegir un criterio de enlace para determinar cómo se calcula la distancia entre conglomerados. Algunos criterios comunes son:

- **Enlace simple (single)**: Define la distancia entre dos conglomerados como la mínima distancia entre cualquier par de puntos de cada conglomerado. Tiende a crear conglomerados alargados en cadena y es sensible al ruido y a los valores atípicos.
- **Enlace completo (complete)**: Define la distancia entre dos conglomerados como la máxima distancia entre cualquier par de puntos de cada conglomerado. Tiende a crear conglomerados compactos y aproximadamente esféricos, y es menos sensible al ruido y a atípicos que el enlace simple.

- **Enlace promedio (average):** Define la distancia entre dos conglomerados como la distancia promedio entre todos los pares de puntos de cada conglomerado. Proporciona un equilibrio entre enlace simple y completo, y es menos sensible al ruido y a atípicos.

- **Enlace promedio (average):** Define la distancia entre dos conglomerados como la distancia promedio entre todos los pares de puntos de cada conglomerado. Proporciona un equilibrio entre enlace simple y completo, y es menos sensible al ruido y a atípicos.
- **Enlace de Ward:** Minimiza la varianza total intra-conglomerado al fusionar los conglomerados que implican el menor incremento de varianza. Suele crear conglomerados compactos y aproximadamente esféricos, y es menos sensible al ruido y a atípicos en comparación con otros criterios.

Una vez elegidos el método, la métrica de distancia y el criterio de enlace, podemos realizar el agrupamiento jerárquico usando la función `hclust` en R.

Una vez elegidos el método, la métrica de distancia y el criterio de enlace, podemos realizar el agrupamiento jerárquico usando la función `hclust` en R.

Como se mostró en el ejemplo anterior, después podemos visualizar los resultados con un dendrograma y cortarlo a una altura específica para determinar el número de conglomerados.