

8 Análisis factorial: métodos prácticos

MA2003B Aplicación de métodos multivariados
en ciencia de datos

Raul Gomez



Tecnológico
de Monterrey

Asimetría, curtosis y gráficos QQ

Como es bien sabido, cualquier distribución normal queda completamente determinada por su media y su desviación estándar.

Asimetría, curtosis y gráficos QQ

Como es bien sabido, cualquier distribución normal queda completamente determinada por su media y su desviación estándar.

Sin embargo, muchos conjuntos de datos del mundo real no siguen una distribución normal.

Asimetría, curtosis y gráficos QQ

Como es bien sabido, cualquier distribución normal queda completamente determinada por su media y su desviación estándar.

Sin embargo, muchos conjuntos de datos del mundo real no siguen una distribución normal.

En esta presentación exploraremos otras distribuciones y mostraremos cómo los conceptos de asimetría y curtosis ayudan a entender su forma.

Asimetría, curtosis y gráficos QQ

Como es bien sabido, cualquier distribución normal queda completamente determinada por su media y su desviación estándar.

Sin embargo, muchos conjuntos de datos del mundo real no siguen una distribución normal.

En esta presentación exploraremos otras distribuciones y mostraremos cómo los conceptos de asimetría y curtosis ayudan a entender su forma.

También introduciremos los gráficos QQ, herramientas útiles para comparar la distribución de un conjunto de datos contra una distribución teórica (usualmente la normal).

Asimetría

Definition

La **asimetría** de una variable aleatoria X es el tercer momento estandarizado, dado por

$$\gamma_1 = \frac{\mu_3}{\sigma^3} = \frac{\mathbb{E}[(X - \mu)^3]}{\sigma^3},$$

donde $\mu = \mathbb{E}[X]$ es la media y $\sigma = \sqrt{\mathbb{E}[(X - \mu)^2]}$ es la desviación estándar de X .

Asimetría

Definition

La **asimetría** de una variable aleatoria X es el tercer momento estandarizado, dado por

$$\gamma_1 = \frac{\mu_3}{\sigma^3} = \frac{\mathbb{E}[(X - \mu)^3]}{\sigma^3},$$

donde $\mu = \mathbb{E}[X]$ es la media y $\sigma = \sqrt{\mathbb{E}[(X - \mu)^2]}$ es la desviación estándar de X .

La asimetría mide la falta de simetría de una distribución de probabilidad.

Asimetría

Definition

La **asimetría** de una variable aleatoria X es el tercer momento estandarizado, dado por

$$\gamma_1 = \frac{\mu_3}{\sigma^3} = \frac{\mathbb{E}[(X - \mu)^3]}{\sigma^3},$$

donde $\mu = \mathbb{E}[X]$ es la media y $\sigma = \sqrt{\mathbb{E}[(X - \mu)^2]}$ es la desviación estándar de X .

La asimetría mide la falta de simetría de una distribución de probabilidad.

Una distribución es **positivamente asimétrica** (o con cola a la derecha) si tiene una cola más larga a la derecha, y **negativamente asimétrica** (o con cola a la izquierda) si la cola más larga está a la izquierda.

Distribución Gamma

Definition

Decimos que una variable aleatoria continua X sigue una **distribución Gamma** con parámetro de forma $\alpha > 0$ y de tasa $\beta > 0$, si su función de densidad (PDF) es

$$f_X(x; \alpha, \beta) = \begin{cases} \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, & x > 0, \\ 0, & x \leq 0, \end{cases} \quad (1)$$

donde $\Gamma(\alpha)$ denota la función Gamma, definida como

$$\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t} dt.$$

Los parámetros α y β controlan la forma y la tasa de la distribución, respectivamente.

Entre otras aplicaciones, la distribución Gamma se usa con frecuencia para modelar el número total de reclamaciones de seguros en un periodo dado.

Entre otras aplicaciones, la distribución Gamma se usa con frecuencia para modelar el número total de reclamaciones de seguros en un periodo dado.

Remark

La asimetría de una distribución Gamma está dada por

$$\gamma_1 = \frac{2}{\sqrt{\alpha}}.$$

Esto implica que la asimetría es siempre positiva y que se acerca a cero conforme α crece. En otras palabras, la distribución se vuelve más simétrica a medida que α aumenta.




Figure 1: PDF de la distribución Gamma con media y mediana destacadas.

Curtosis

Definition

La **curtosis** de una variable aleatoria X es el cuarto momento estandarizado, dado por

$$\beta_2 = \frac{\mu_4}{\sigma^4} = \frac{\mathbb{E}[(X - \mu)^4]}{\sigma^4},$$

donde $\mu = \mathbb{E}[X]$ es la media y $\sigma = \sqrt{\mathbb{E}[(X - \mu)^2]}$ es la desviación estándar de X .

Curtosis

Definition

La **curtosis** de una variable aleatoria X es el cuarto momento estandarizado, dado por

$$\beta_2 = \frac{\mu_4}{\sigma^4} = \frac{\mathbb{E}[(X - \mu)^4]}{\sigma^4},$$

donde $\mu = \mathbb{E}[X]$ es la media y $\sigma = \sqrt{\mathbb{E}[(X - \mu)^2]}$ es la desviación estándar de X .

La curtosis mide el grosor de las colas de una distribución.

Curtosis

Definition

La **curtosis** de una variable aleatoria X es el cuarto momento estandarizado, dado por

$$\beta_2 = \frac{\mu_4}{\sigma^4} = \frac{\mathbb{E}[(X - \mu)^4]}{\sigma^4},$$

donde $\mu = \mathbb{E}[X]$ es la media y $\sigma = \sqrt{\mathbb{E}[(X - \mu)^2]}$ es la desviación estándar de X .

La curtosis mide el grosor de las colas de una distribución.

Una distribución con alta curtosis tiene colas más pesadas y un pico más agudo que una normal; con baja curtosis, colas más ligeras y un pico más plano.

Curtosis

Definition

La **curtosis** de una variable aleatoria X es el cuarto momento estandarizado, dado por

$$\beta_2 = \frac{\mu_4}{\sigma^4} = \frac{\mathbb{E}[(X - \mu)^4]}{\sigma^4},$$

donde $\mu = \mathbb{E}[X]$ es la media y $\sigma = \sqrt{\mathbb{E}[(X - \mu)^2]}$ es la desviación estándar de X .

La curtosis mide el grosor de las colas de una distribución.

Una distribución con alta curtosis tiene colas más pesadas y un pico más agudo que una normal; con baja curtosis, colas más ligeras y un pico más plano.

La curtosis de una normal es 3; por ello suele calcularse la **curtosis en exceso** dada por:

$$\gamma_2 = \beta_2 - 3.$$

Distribución de Laplace

Definition

Decimos que una variable aleatoria continua X sigue una **distribución de Laplace** con parámetro de localización $\mu \in \mathbb{R}$ y escala $b > 0$, si su PDF es

$$f_X(x; \mu, b) = \frac{1}{2b} \exp\left(-\frac{|x - \mu|}{b}\right), \quad x \in \mathbb{R}. \quad (2)$$

Los parámetros μ y b controlan la localización y la escala de la distribución, respectivamente.

Entre otras aplicaciones, la distribución de Laplace se utiliza en procesamiento de imágenes para modelar ruido.

Entre otras aplicaciones, la distribución de Laplace se utiliza en procesamiento de imágenes para modelar ruido.

Remark

La curtosis en exceso de una distribución de Laplace es

$$\gamma_2 = 3.$$

Esto significa que la distribución de Laplace tiene colas más pesadas que la normal.




Figure 2: PDF de la distribución de Laplace con media cero y varianza uno.

Gráficos QQ

Los gráficos QQ, o gráficos cuantil-cuantil, son herramientas gráficas para comparar la distribución de un conjunto de datos contra una distribución teórica, como la normal.

Gráficos QQ

Los gráficos QQ, o gráficos cuantil-cuantil, son herramientas gráficas para comparar la distribución de un conjunto de datos contra una distribución teórica, como la normal.

Son especialmente útiles para evaluar la normalidad de los datos.

Cómo construir un gráfico QQ

Para construir un gráfico QQ, sigue estos pasos:

1. **Ordena los datos muestrales:** Acomoda los datos en orden creciente:

$$x_{(1)} \leq x_{(2)} \leq \cdots \leq x_{(n)}.$$

2. **Calcula las posiciones de trazado (cuantiles empíricos):** Para cada valor ordenado $x_{(i)}$, calcula la probabilidad correspondiente

$$p_i = \frac{2i-1}{2n}, \quad i = 1, 2, \dots, n.$$

Cómo construir un gráfico QQ

3. **Encuentra los cuantiles teóricos de la distribución normal:** Calcula los cuantiles teóricos usando la función de distribución acumulada inversa (CDF inversa) de la normal:

$$q_i = \Phi^{-1}(p_i),$$

donde Φ^{-1} es la función cuantil de la normal estándar.

4. **Traza los puntos:** Grafica los pares $(q_i, x_{(i)})$ con q_i en el eje x y $x_{(i)}$ en el eje y.
5. **Agrega una línea de referencia:** Típicamente se agrega una línea que pasa por el primer y tercer cuartil para ayudar a evaluar la normalidad.

Mientras más cerca caigan los puntos de esta línea, más se parece la muestra a la distribución normal especificada.

Distribución Gamma: gráfico QQ e histograma




Figure 3: Gráfico QQ e histograma de la muestra de la distribución Gamma.

Distribución de Laplace: gráfico QQ e histograma




Figure 4: Gráfico QQ e histograma de la muestra de la distribución de Laplace.

Asimetría y curtosis muestrales

Hasta ahora hemos definido asimetría y curtosis para variables aleatorias.

Asimetría y curtosis muestrales

Hasta ahora hemos definido asimetría y curtosis para variables aleatorias.

Sin embargo, en la práctica trabajamos con muestras, no con poblaciones completas.

Asimetría y curtosis muestrales

Hasta ahora hemos definido asimetría y curtosis para variables aleatorias.

Sin embargo, en la práctica trabajamos con muestras, no con poblaciones completas.

Por lo tanto, necesitamos definir la asimetría muestral y la curtosis muestral.

Definition

Sea $x_1, x_2, \dots, x_n$ una muestra de tamaño n . La **media muestral** $\bar{x}$ y la **varianza muestral** s^2 son

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

La **asimetría muestral** g_1 es

$$g_1 = \frac{n}{(n-1)(n-2)} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^3.$$

La **curtosis en exceso muestral** g_2 viene dada por

$$g_2 = \frac{n(n+1)}{(n-1)(n-2)(n-3)} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^4 - \frac{3(n-1)^2}{(n-2)(n-3)}.$$

Como ejemplo, calcularemos la asimetría y la curtosis en exceso muestrales de las muestras Gamma y Laplace mostradas antes.

Como ejemplo, calcularemos la asimetría y la curtosis en exceso muestrales de las muestras Gamma y Laplace mostradas antes.

Para la muestra Gamma tenemos:

```
Rows: 1
```

```
Columns: 2
```

```
$ sample_skewness      <dbl> 1.293772
```

```
$ sample_excess_kurtosis <dbl> -0.8356471
```


Como ejemplo, calcularemos la asimetría y la curtosis en exceso muestrales de las muestras Gamma y Laplace mostradas antes.

Para la muestra Gamma tenemos:

```
Rows: 1
```

```
Columns: 2
```

```
$ sample_skewness      <dbl> 1.293772
```

```
$ sample_excess_kurtosis <dbl> -0.8356471
```

Para la muestra de Laplace tenemos:

```
Rows: 1
```

```
Columns: 2
```

```
$ sample_skewness      <dbl> -0.07876743
```

```
$ sample_excess_kurtosis <dbl> 3.726374
```

Escalamiento y estandarización

En muchas situaciones, puede suceder que las unidades con las que medimos distintas variables no sean compatibles.

Escalamiento y estandarización

En muchas situaciones, puede suceder que las unidades con las que medimos distintas variables no sean compatibles.

Por ejemplo, podríamos tener un conjunto con estaturas en centímetros y pesos en kilogramos.

Escalamiento y estandarización

En muchas situaciones, puede suceder que las unidades con las que medimos distintas variables no sean compatibles.

Por ejemplo, podríamos tener un conjunto con estaturas en centímetros y pesos en kilogramos.

En tales casos, suele ser útil **escalar** las variables para hacerlas comparables.

Escalamiento de variables aleatorias

Definition

Una **transformación afín** de una variable aleatoria X es una transformación de la forma

$$Y = aX + b$$

donde a y b son constantes.

Escalamiento de variables aleatorias

Definition

Una **transformación afín** de una variable aleatoria X es una transformación de la forma

$$Y = aX + b$$

donde a y b son constantes.

Remark

En estadística, a las transformaciones afines a menudo se les llama **escalamientos** (aunque incluyan un componente de traslación).

Supongamos ahora que X tiene media μ y desviación estándar σ .

Supongamos ahora que X tiene media μ y desviación estándar σ .

Entonces la variable aleatoria

$$Y = aX + b$$

tendrá media $a\mu + b$ y desviación estándar $|a|\sigma$.

Supongamos ahora que X tiene media μ y desviación estándar σ .

Entonces la variable aleatoria

$$Y = aX + b$$

tendrá media $a\mu + b$ y desviación estándar $|a|\sigma$.

En particular, si elegimos $a = 1/\sigma$ y $b = -\mu/\sigma$, entonces la variable

$$Z = \frac{X - \mu}{\sigma}$$

tendrá media 0 y desviación estándar 1.

En particular, si elegimos $a = 1/\sigma$ y $b = -\mu/\sigma$, entonces la variable

$$Z = \frac{X - \mu}{\sigma}$$

tendrá media 0 y desviación estándar 1.

En particular, si elegimos $a = 1/\sigma$ y $b = -\mu/\sigma$, entonces la variable

$$Z = \frac{X - \mu}{\sigma}$$

tendrá media 0 y desviación estándar 1.

Esta transformación afín particular se llama **estandarización**, y la variable resultante Z es la versión **estandarizada** de X . A Z también se le llama **puntaje z** de X .

En particular, si elegimos $a = 1/\sigma$ y $b = -\mu/\sigma$, entonces la variable

$$Z = \frac{X - \mu}{\sigma}$$

tendrá media 0 y desviación estándar 1.

Esta transformación afín particular se llama **estandarización**, y la variable resultante Z es la versión **estandarizada** de X . A Z también se le llama **puntaje z** de X .

Remark

Obsérvese que si X no es normal, entonces Z **no** tendrá distribución normal estándar. Estandarizar no vuelve normal a una distribución que no lo es.

Observation

Por definición,

$$\gamma_1(Z) = \mathbb{E}[Z^3] = \frac{\mathbb{E}[(X - \mu)^3]}{\sigma^3} = \gamma_1(X)$$

y

$$\gamma_2(Z) = \mathbb{E}[Z^4] - 3 = \frac{\mathbb{E}[(X - \mu)^4]}{\sigma^4} - 3 = \gamma_2(X).$$

Como ejemplo, consideremos de nuevo la distribución Gamma que introducimos antes. En este caso tenemos

$$\mu = \frac{\alpha}{\beta} \quad \text{and} \quad \sigma = \frac{\sqrt{\alpha}}{\beta}.$$

Como ejemplo, consideremos de nuevo la distribución Gamma que introdujimos antes. En este caso tenemos

$$\mu = \frac{\alpha}{\beta} \quad \text{and} \quad \sigma = \frac{\sqrt{\alpha}}{\beta}.$$

Con esta información podemos graficar la versión estandarizada de la distribución Gamma y compararla con la original.

Distribución Gamma: original y estandarizada




Figure 5: Comparación de la función de densidad (PDF) de la distribución Gamma original y estandarizada.

Escalamiento de muestras

Para una muestra dada, no siempre se conoce la distribución subyacente.

Escalamiento de muestras

Para una muestra dada, no siempre se conoce la distribución subyacente.

En particular, puede que no sepamos la media ni la desviación estándar de la población.

Escalamiento de muestras

Para una muestra dada, no siempre se conoce la distribución subyacente.

En particular, puede que no sepamos la media ni la desviación estándar de la población.

Aun así, podemos intentar escalar los datos, teniendo en cuenta que hay más de un método de escalamiento.

Los más comunes son:

1. **Estandarización**: usa la media muestral y la desviación estándar muestral para escalar los datos. La muestra estandarizada es

$$T = \frac{X - \bar{X}}{S},$$

donde $\bar{X}$ es la media muestral y S la desviación estándar muestral.

2. **Escalamiento Min-Max**: ajusta los datos a un rango fijo, usualmente $[0, 1]$. La muestra escalada es

$$T = \frac{X - \min(X)}{\max(X) - \min(X)},$$

donde $\min(X)$ y $\max(X)$ son el mínimo y máximo de la muestra, respectivamente. Es muy sensible a atípicos, pues usa extremos.

3. **Escalamiento robusto**: escala usando la mediana y el rango intercuartílico (IQR).

La muestra escalada es

$$T = \frac{X - \text{median}(X)}{\text{IQR}(X)},$$

donde $\text{IQR}(X) = Q_3 - Q_1$ es el rango intercuartílico. Es más robusto a atípicos que Min-Max, pues usa mediana e IQR.

4. **Normalización**: divide cada dato por la norma del vector. La muestra normalizada es

$$T = \frac{X}{\|X\|},$$

donde $\|X\|$ es la norma. Se usa menos que los anteriores.

Remark

Como ya se mencionó, escalar no vuelve normal a una distribución no normal. En particular, la asimetría y curtosis en exceso muestrales no cambian.

Remark

Como ya se mencionó, escalar no vuelve normal a una distribución no normal. En particular, la asimetría y curtosis en exceso muestrales no cambian.

Como ejemplo, consideraremos los distintos métodos aplicados a la muestra Gamma generada antes.

Comparison of Scaling Methods Applied to the Gamma Sample




Figure 6: Comparación de distintos métodos de escalamiento aplicados a la muestra Gamma.

Activity: Visualizing the Non-Normality of Samples

For each of the following distributions, construct a sample of size 300 and compute their associated sample Skewness and Kurtosis. After that, construct and compare their associated QQ plots and histograms.

1. Exponential distribution with rate parameter $\lambda = 1$.
2. Uniform distribution on the interval $[0, 1]$.
3. Beta distribution with shape parameters $\alpha = 2$ and $\beta = 5$.
4. Cauchy distribution with location parameter $x_0 = 0$ and scale parameter $\gamma = 1$.
5. Chi-squared distribution with degrees of freedom $k = 3$.

Normality Testing

Aunque los gráficos QQ son útiles para evaluar visualmente la normalidad, pueden ser subjetivos e imprecisos.

Normality Testing

Aunque los gráficos QQ son útiles para evaluar visualmente la normalidad, pueden ser subjetivos e imprecisos.

Por ello, es necesario recurrir a pruebas estadísticas más objetivas y precisas para determinar si los datos siguen una distribución normal.

Normality Testing

Aunque los gráficos QQ son útiles para evaluar visualmente la normalidad, pueden ser subjetivos e imprecisos.

Por ello, es necesario recurrir a pruebas estadísticas más objetivas y precisas para determinar si los datos siguen una distribución normal.

Exploraremos ahora pruebas comunes de normalidad y algunas transformaciones para acercar los datos a la normalidad.

Pruebas de normalidad

Existen varias pruebas para determinar si un conjunto sigue una normal. Algunas de las más usadas son:

1. **Shapiro–Wilk**: basada en la correlación entre los datos y puntajes normales. Potente en muestras pequeñas (< 50), aunque puede ser demasiado sensible en muestras grandes.
2. **Kolmogorov–Smirnov**: compara la función de distribución empírica con la CDF normal. No paramétrica, aplicable a cualquier tamaño; menos potente que Shapiro–Wilk en muestras pequeñas y sensible a escala y localización.

3. **Anderson–Darling**: similar a KS pero da más peso a las colas; potente en muestras pequeñas.
4. **Jarque–Bera**: basada en asimetría y curtosis; potente en muestras grandes, pero puede ser muy sensible en muestras pequeñas.

Aplicaremos ahora estas pruebas a la muestra Gamma creada en el capítulo anterior:

Los resultados de las pruebas de normalidad son los siguientes:

```
# A tibble: 4 x 2
  test_factor      p_value
  <fct>          <dbl>
1 Shapiro-Wilk    1.58e-12
2 Kolmogorov-Smirnov 7.93e- 3
3 Anderson-Darling 9.02e-16
4 Jarque-Bera      0
```

Los resultados de las pruebas de normalidad son los siguientes:

```
# A tibble: 4 x 2
  test_factor      p_value
  <fct>          <dbl>
1 Shapiro-Wilk    1.58e-12
2 Kolmogorov-Smirnov 7.93e- 3
3 Anderson-Darling 9.02e-16
4 Jarque-Bera      0
```

Como podemos ver, ninguna de estas pruebas fue particularmente exitosa, lo cual no sorprende dado que la distribución Gamma no es normal.

Transformaciones

Para que los datos se parezcan más a normales, podemos aplicar distintas transformaciones a una muestra. Algunas comunes son:

1. **Transformación de Box–Cox**: familia de potencias aplicable sólo a datos positivos.

Se define por:

$$\tilde{X} = \begin{cases} \frac{X^\lambda - 1}{\lambda} & \text{if } \lambda \neq 0 \\ \log(X) & \text{if } \lambda = 0 \end{cases}$$

donde λ es un parámetro.

2. **Transformación de Yeo–Johnson**: similar a Box–Cox pero admite valores negativos; útil para asimetrías positivas o negativas. Está dada por:

$$\tilde{X} = \begin{cases} \frac{((X+1)^\lambda - 1)}{\lambda} & \text{if } X \geq 0, \lambda \neq 0 \\ \frac{-((-X+1)^{2-\lambda} - 1)}{2-\lambda} & \text{if } X < 0, \lambda \neq 2 \\ \log(X+1) & \text{if } X \geq 0, \lambda = 0 \\ \log(-X+1) & \text{if } X < 0, \lambda = 2 \end{cases}$$

donde λ es un parámetro.

Aplicaremos ahora la transformación de Box–Cox a la muestra Gamma con $\lambda = 0, 0.25, 0.5, 0.75$ y 1:

Comparación de transformaciones Box-Cox con distintos valores de lambda




Figure 7: Comparación de diferentes transformaciones Box-Cox.

Optimización de normalidad

Queremos encontrar el valor óptimo de λ que maximiza la log-verosimilitud de los datos transformados.

Optimización de normalidad

Queremos encontrar el valor óptimo de λ que maximiza la log-verosimilitud de los datos transformados.

La siguiente figura muestra el perfil de log-verosimilitud para la transformación de Box–Cox aplicada a la muestra Gamma:




Figure 8: Perfil de log-verosimilitud para la transformación de Box-Cox.

Finalmente, podemos extraer el valor óptimo de λ y transformar los datos con ese valor:

```
# A tibble: 4 x 2
  test_factor      p_value
  <fct>          <dbl>
1 Shapiro-Wilk    0.974
2 Kolmogorov-Smirnov 1.000
3 Anderson-Darling 0.977
4 Jarque-Bera     0.878
```

Finalmente, podemos extraer el valor óptimo de λ y transformar los datos con ese valor:

```
# A tibble: 4 x 2
  test_factor      p_value
  <fct>          <dbl>
1 Shapiro-Wilk    0.974
2 Kolmogorov-Smirnov 1.000
3 Anderson-Darling 0.977
4 Jarque-Bera     0.878
```

Como puede verse, la transformación de Box–Cox con el λ óptimo mejora significativamente la normalidad: todas las pruebas arrojan valores- p altos. A continuación mostramos el gráfico QQ y el histograma de los datos transformados:

Transformación Gamma óptima




Figure 9: Gráfico QQ e histograma de la transformación Gamma óptima.