



**Tecnológico
de Monterrey**

**MA2003B Aplicación de Métodos Multivariados
en Ciencia de Datos**

Módulo 2: Relaciones de Dependencia

Profesor: Raul Gomez
Correo: rgomez@tec.mx
Oficina: A4-123A

Tabla de contenidos

I	Análisis de Regresión	3
1.	Método de mínimos cuadrados	5
2.	El modelo de regresión lineal simple	15
2.1.	Estimación de parámetros por intervalos de confianza	16
2.2.	Bandas de confianza y de predicción	17
3.	Adecuación del modelo	19
3.1.	Bondad de ajuste	21
3.2.	Significancia global del modelo	22
3.3.	Diagnóstico de residuos	22
3.4.	Puntos influyentes y de alta palanca	23
3.5.	Heterocedasticidad	23
3.6.	Multicolinealidad	24
3.7.	Linealidad	24
3.8.	Ejemplos	25

Parte I

Análisis de Regresión

Capítulo 1

Método de mínimos cuadrados

Supongamos que tenemos un conjunto de datos

$$((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$$

Por ejemplo, consideremos el siguiente conjunto de datos simulado:

```
library(tidyverse)
library(krulRutils)
library(latex2exp)

set.seed(123)

n <- 50
x_data <- runif(n, min = 0, max = 10)
epsilon_data <- rnorm(n, mean = 0, sd = 1)
y_data <- x_data + epsilon_data

sample_data_tbl <- tibble(
  x = x_data,
  y = y_data
)
```

Notemos que podemos visualizar estos datos mediante un diagrama de dispersión:

```
sample_data_plot <- sample_data_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_point(
    color = c_pal("C red"),
    size = 1,
    alpha = 1
  ) +
  coord_fixed() +
  labs(
```

```
title = "Datos simulados",
x = TeX("$X_{0}$"),
y = TeX("$Y_{0}$")
) +
theme_krul()

sample_data_plot
```




Figura 1.1: Diagrama de dispersión de los datos simulados.

Nos gustaría encontrar la línea recta que mejor se ajuste a estos datos. Hay varias formas de definir “mejor ajuste”, pero una de las más comunes es minimizar la suma de los errores al cuadrado (SSE por sus siglas en inglés) entre los valores observados y los valores correspondientes sobre la línea recta propuesta. De manera más precisa, buscamos una recta

$$Y_0 = \hat{f}(X_0) = \hat{\beta}_0 + \hat{\beta}_1 X_0$$

tal que si definimos $\hat{y}_i = \hat{f}(x_i)$ entonces minimicemos la suma

$$\text{SSE} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (1.1)$$

```
fitted_data_tbl <- sample_data_tbl %>%
  mutate(
    fitted = fitted(lm(y ~ x, data = .))
  )
```



```
fitted_data_plot <- fitted_data_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
  geom_segment(
    aes(xend = x, yend = fitted),
    color = c_pal("C green"),
    alpha = 1
  ) +
  geom_point(color = c_pal("C red"), size = 1, alpha = 1) +
  geom_point(
    aes(x = x, y = fitted),
    color = c_pal("C red"),
    size = 1,
    alpha = 1
  ) +
  coord_fixed() +
  labs(
    title = "Recta ajustada",
    x = TeX("$X_{0}$"),
    y = TeX("$Y_{0}$")
  ) +
  theme_krul()

fitted_data_plot
```




Figura 1.2: Línea recta que mejor se ajusta a los datos simulados, bajo el criterio de mínimos cuadrados. En otras palabras, esta es la línea recta que minimiza el SSE.

Para encontrar la fórmula para $\hat{\beta}_0$ y $\hat{\beta}_1$ en términos de nuestros datos, utilizaremos un poco de álgebra lineal. Empecemos por fijar los vectores

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

que llamaremos el *vector de las observaciones independientes* y el *vector de las observaciones dependientes*, respectivamente. Fijamos ahora la llamada *matriz de diseño*, dada por,

$$\Phi = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}$$

y notamos que si definimos

$$\hat{y} = \begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_n \end{bmatrix}$$

entonces $\hat{y} = \Phi \hat{\beta}$ donde

$$\hat{\beta} = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{bmatrix}$$

Notemos que para minimizar la suma de los errores al cuadrado dada en la ecuación (1.1), necesitamos encontrar la proyección ortogonal del vector y sobre el espacio generado por las columnas de la matriz Φ . Empezamos por calcular la *matriz de coeficientes*

$$D^2 = (\Phi^T \Phi)^{-1} = \begin{bmatrix} \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} & -\frac{\bar{x}}{S_{xx}} \\ -\frac{\bar{x}}{S_{xx}} & \frac{1}{S_{xx}} \end{bmatrix}$$

donde

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{y} \quad S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$$

Calculamos ahora la *matriz de estimadores de mínimos cuadrados*

$$A = D^2 \Phi^T = (\Phi^T \Phi)^{-1} \Phi^T = \begin{bmatrix} \frac{1}{n} + \frac{\bar{x}(\bar{x}-x_1)}{S_{xx}} & \cdots & \frac{1}{n} + \frac{\bar{x}(\bar{x}-x_n)}{S_{xx}} \\ \frac{x_1-\bar{x}}{S_{xx}} & \cdots & \frac{x_n-\bar{x}}{S_{xx}} \end{bmatrix}$$

y, finalmente, calculamos la *matriz sombrero*

$$H = \Phi A = \Phi (\Phi^T \Phi)^{-1} \Phi^T$$

Notemos que las entradas de la matriz H están dadas por:

$$h_{ij} = \frac{1}{n} + \frac{(x_i - \bar{x})(x_j - \bar{x})}{S_{xx}}$$

en particular,

$$h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}$$

Utilizando estas matrices, podemos calcular

$$\hat{\beta} = Ay \quad \text{y} \quad \hat{y} = Hy$$

Para ilustrar este procedimiento, consideremos el siguiente ejemplo.

Ejemplo. Consideremos el siguiente conjunto de datos:

```
set.seed(123)

n <- 5
x_data <- 1:n
epsilon_data <- rnorm(n, mean = 0, sd = n / 10)
y_data <- x_data + epsilon_data
sample_data_tbl <- tibble(
  x = x_data,
  y = y_data
)
```

Notemos que los vectores de observaciones independientes y dependientes son:

$$x = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{bmatrix} \quad y = \begin{bmatrix} 0.72 \\ 1.88 \\ 3.78 \\ 4.04 \\ 5.06 \end{bmatrix}$$

y la matriz de diseño es:

```
Phi <- matrix(c(rep(1, n), x_data), nrow = n, ncol = 2)
```

$$\Phi = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{bmatrix}$$

Calculamos ahora la matriz de coeficientes:

```
D2 <- solve(t(Phi) %*% Phi)
```

$$D^2 = \begin{bmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{bmatrix}$$

y la matriz de estimadores de mínimos cuadrados:

```
A <- D2 %*% t(Phi)
```

$$A = \begin{bmatrix} 0.8 & 0.5 & 0.2 & -0.1 & -0.4 \\ -0.2 & -0.1 & 0 & 0.1 & 0.2 \end{bmatrix}$$

Finalmente, la matriz sombrero es:

```
H <- Phi %*% A
```

$$H = \begin{bmatrix} 0.6 & 0.4 & 0.2 & 0 & -0.2 \\ 0.4 & 0.3 & 0.2 & 0.1 & 0 \\ 0.2 & 0.2 & 0.2 & 0.2 & 0.2 \\ 0 & 0.1 & 0.2 & 0.3 & 0.4 \\ -0.2 & 0 & 0.2 & 0.4 & 0.6 \end{bmatrix}$$

Utilizando estas matrices, podemos rápidamente calcular los vectores $\hat{\beta}$ y $\hat{y}$:

```
beta_hat <- A %*% y_data
y_hat <- H %*% y_data
```

$$\hat{\beta} = \begin{bmatrix} -0.16 \\ 1.08 \end{bmatrix} \quad \hat{y} = \begin{bmatrix} 0.93 \\ 2.01 \\ 3.1 \\ 4.18 \\ 5.26 \end{bmatrix}$$

Notemos que en este caso la suma de los errores al cuadrado (SSE) es:

```
sse <- sum((y_data - y_hat)^2)
```

$$\text{SSE} = 0.59$$

La siguiente figura ilustra el ajuste por mínimos cuadrados para este conjunto de datos:

```
fitted_example_data_tbl <- sample_data_tbl %>%
  mutate(
    fitted = as.vector(y_hat)
  )
fitted_example_data_plot <- fitted_example_data_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
  geom_segment(
    aes(xend = x, yend = fitted),
    color = c_pal("C green"),
    alpha = 1
  ) +
  geom_point(color = c_pal("C red"), size = 1, alpha = 1) +
```

```
geom_point(
  aes(x = x, y = fitted),
  color = c_pal("C red"),
  size = 1,
  alpha = 1
) +
coord_fixed() +
labs(
  title = "Recta ajustada",
  x = TeX("$X_{0}$"),
  y = TeX("$Y_{0}$")
) +
theme_krul()
fitted_example_data_plot
```




Figura 1.3: Ajuste por mínimos cuadrados para el conjunto de datos del ejemplo.

Notemos que este proceso se puede aplicar a cualquier conjunto de datos dado, sin embargo una de las aplicaciones más comunes de este método es tratar de predecir el valor de la variable Y_0 dado un valor específico de la variable X_0 que no se encuentre en el conjunto de datos original. Se sigue que para que estas predicciones sean de utilidad, es necesario que el comportamiento de nuestros datos siga una tendencia lineal, ya que en caso contrario las predicciones podrían no ser confiables. Por ejemplo, consideremos el ajuste por el método de mínimos cuadrados para los siguientes conjuntos de datos:

```
library(patchwork)

set.seed(123)

n <- 500
x_data1 <- runif(n, min = 0, max = 10)
epsilon_data1 <- rnorm(n, mean = 0, sd = 50)
y_data1 <- (x_data1)^3 + epsilon_data1

x_data2 <- runif(n, min = 0, max = 10)
epsilon_data2 <- rnorm(n, mean = 0, sd = 0.1)
y_data2 <- sin(x_data2) + epsilon_data2

x_data3 <- runif(n, min = 0, max = 10)
y_data3 <- runif(n, min = 0, max = 10)

x_data4 <- runif(n, min = 0, max = 10)
y_data4 <- mapply(function(mu, sigma) rnorm(1, mean = mu, sd = sigma),
                  mu = x_data4,
                  sigma = x_data4)

sample_data1_tbl <- tibble(
  x = x_data1,
  y = y_data1
)

sample_data2_tbl <- tibble(
  x = x_data2,
  y = y_data2
)

sample_data3_tbl <- tibble(
  x = x_data3,
  y = y_data3
)

sample_data4_tbl <- tibble(
  x = x_data4,
  y = y_data4
)

sample_data1_plot <- sample_data1_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_point(
    color = c_pal("C red"),
```

```
      size = 1,
      alpha = 1
    ) +
    geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
    labs(
      title = "Datos cúbicos",
      x = "",
      y = ""
    ) +
    theme_krul()

sample_data2_plot <- sample_data2_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_point(
    color = c_pal("C red"),
    size = 1,
    alpha = 1
  ) +
  geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
  labs(
    title = "Datos senoidales",
    x = "",
    y = ""
  ) +
  theme_krul()

sample_data3_plot <- sample_data3_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_point(
    color = c_pal("C red"),
    size = 1,
    alpha = 1
  ) +
  geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
  labs(
    title = "Datos aleatorios",
    x = "",
    y = ""
  ) +
  theme_krul()

sample_data4_plot <- sample_data4_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_point(
    color = c_pal("C red"),
```

```
size = 1,
alpha = 1
) +
geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
labs(
  title = "Datos con varianza creciente",
  x = "",
  y = ""
) +
theme_krul()

sample_data_plot <- (sample_data1_plot + sample_data2_plot) /
  (sample_data3_plot + sample_data4_plot)

sample_data_plot
```




Figura 1.4: Ajuste por mínimos cuadrados para diferentes conjuntos de datos.

Es bastante claro que en estos casos el ajuste por mínimos cuadrados no es el método adecuado para realizar predicciones confiables. En general, este método solo es efectivo cuando se cumplen ciertas hipótesis que estudiaremos en las siguientes secciones, cuando introduciremos el modelo de regresión lineal desde un punto de vista estadístico.

Capítulo 2

El modelo de regresión lineal simple

En un *modelo de regresión simple*, suponemos que tenemos una *variable independiente* X_0 (también conocida como *variable explicativa* o *predictora*), y una *variable dependiente* Y_0 (también conocida como *variable de respuesta*). Suponemos además que estas variables satisfacen una relación de la forma:

$$Y_0 = f_0(X_0) + \epsilon_0$$

donde f_0 es una función desconocida que describe la relación entre ambas variables, y ϵ_0 es una variable aleatoria que representa el *error* o *ruido* en la relación entre X_0 e Y_0 . Uno de los objetivos del *aprendizaje estadístico* (también conocido como *aprendizaje automático* o *machine learning*), es tratar de aproximar la función f_0 a partir de un conjunto de datos

$$((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$$

dado. De manera más precisa, consideremos vectores aleatorios

$$X = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{bmatrix}, \quad Y = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}$$

que representan los posibles valores de las observaciones independientes y dependientes, respectivamente, en una muestra dada. En este contexto, un *método de aprendizaje* consiste de una función $\hat{F}$, que depende de los vectores aleatorios X e Y , y que cuando se evalúa en los datos observados produce una función $\hat{f}$ que aproxima a la función desconocida f_0 .

Nota 2.0.1. En muchos modelos de aprendizaje estadístico es común tomar el vector $X = x$ como fijo, en cuyo caso la función $\hat{F}$ depende únicamente del vector aleatorio Y .

Para hacer estas ideas un poco más concretas, consideremos el caso particular en el que la función desconocida f_0 es una función lineal, es decir,

$$f_0(X_0) = b_0 + b_1 X_0$$

y supondremos además que $\epsilon_0 \sim \mathcal{N}(0, \sigma^2)$ es una variable aleatoria con distribución normal de media 0 y varianza σ^2 . Este contexto se conoce como el *modelo de regresión lineal simple* y es uno de los modelos más utilizados en aprendizaje estadístico. Notemos que en este caso nuestro objetivo es encontrar una expresión que nos permita aproximar los parámetros desconocidos b_0 y b_1 en términos de los datos observados. Para ello consideraremos las expresiones que obtuvimos en la sección anterior para los coeficientes de la recta de mejor ajuste por mínimos cuadrados, pero utilizando ahora el vector aleatorio Y en lugar del vector de observaciones y . En otras palabras, definiremos

$$\Phi = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}$$

y consideraremos las matrices $D^2 = (\Phi^T \Phi)^{-1}$, $A = D^2 \Phi^T$ y $H = \Phi A$. Entonces podemos definir el *vector aleatorio de estimadores de mínimos cuadrados* como:

$$\hat{B} = AY$$

Notemos que, a diferencia de la sección anterior, en este caso $\hat{B}$ no es un vector de valores fijos, sino que es un vector aleatorio que depende linealmente del vector aleatorio Y . Además, de las propiedades de la distribución normal multivariada, sabemos que

$$\hat{B} \sim \mathcal{N}(b, \sigma^2 D^2)$$

donde

$$b = \begin{bmatrix} b_0 \\ b_1 \end{bmatrix}$$

es el vector de parámetros desconocidos. Notemos que, en particular, el vector aleatorio $\hat{B}$ es un estimador insesgado del vector de parámetros b , es decir, $E[\hat{B}] = b$. Notemos además que si evaluamos el vector aleatorio $\hat{B}$ en los datos observados $Y = y$, obtenemos el vector de coeficientes $\hat{\beta}$ de la recta de mejor ajuste por mínimos cuadrados que obtuvimos en la sección anterior. Una vez hechas estas observaciones, nuestro siguiente objetivo será construir los intervalos de confianza para los parámetros b_0 y b_1 .

2.1. Estimación de parámetros por intervalos de confianza

Empecemos por definir las cantidades

$$d_0^2 = D_{11}^2 = \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}$$

$$d_1^2 = D_{22}^2 = \frac{1}{S_{xx}}$$

donde

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$$

tal y como lo habíamos definido en la sección anterior. Entonces

$$\begin{aligned}\hat{B}_0 &\sim \mathcal{N}(b_0, \sigma^2 d_0^2) \\ \hat{B}_1 &\sim \mathcal{N}(b_1, \sigma^2 d_1^2)\end{aligned}$$

Consideremos ahora la variable aleatoria

$$\hat{S}^2 = \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

donde

$$\hat{Y} = \begin{bmatrix} \hat{Y}_1 \\ \hat{Y}_2 \\ \vdots \\ \hat{Y}_n \end{bmatrix} = HY$$

es el *vector aleatorio de predicciones por mínimos cuadrados*. Entonces tenemos que

$$\frac{(n-2)\hat{S}^2}{\sigma^2} \sim \chi_{n-2}^2$$

y, además, la variable aleatoria $\hat{S}^2$ es independiente de las variables aleatorias $\hat{B}_0$ y $\hat{B}_1$. Por lo tanto, podemos construir las nuevas variables aleatorias

$$\begin{aligned}T_0 &= \frac{\hat{B}_0 - b_0}{\hat{S}d_0} \sim t_{n-2} \\ T_1 &= \frac{\hat{B}_1 - b_1}{\hat{S}d_1} \sim t_{n-2}\end{aligned}$$

donde t_{n-2} denota la distribución t de Student con $n-2$ grados de libertad. Con esta información, podemos construir ahora los intervalos de confianza para los parámetros b_0 y b_1 , tal y como nos lo habíamos propuesto. Empecemos por fijar un nivel de significancia α y sea $t_{\alpha/2, n-2}$ el cuantil superior de orden $\alpha/2$ de la distribución t de Student correspondiente. Entonces, si tomamos $\hat{s}$ como el valor de la variable aleatoria $\hat{S}$ evaluada en el vector de datos observados $Y = y$, tenemos que los intervalos de confianza buscados son

$$(\hat{\beta}_0 - t_{\alpha/2, n-2} \hat{s}d_0, \hat{\beta}_0 + t_{\alpha/2, n-2} \hat{s}d_0)$$

para b_0 , y

$$(\hat{\beta}_1 - t_{\alpha/2, n-2} \hat{s}d_1, \hat{\beta}_1 + t_{\alpha/2, n-2} \hat{s}d_1)$$

para b_1 .

2.2. Bandas de confianza y de predicción

Una vez obtenidos los intervalos de confianza para los parámetros b_0 y b_1 , nos gustaría obtener ahora los intervalos de confianza para los posibles valores de la variable dependiente Y_0 en un valor

específico de la variable independiente $X_0 = x_0$. Para esto empezaremos por considerar la matriz de diseño en el punto x_0 :

$$\Phi_0 = \begin{bmatrix} 1 & x_0 \end{bmatrix}$$

y definiremos el vector aleatorio

$$\hat{Y}_0 = \Phi_0 \hat{B} = \hat{B}_0 + \hat{B}_1 x_0$$

Notemos que este vector aleatorio depende solamente de las variables $\hat{B}_0$ y $\hat{B}_1$ (las cuales, a su vez, dependen solamente de las variables $Y_1, Y_2, \dots, Y_n$), y es independiente de la variable aleatoria Y_0 . Usando nuevamente las propiedades de la distribución normal multivariada, podemos ver que

$$\hat{Y}_0 \sim \mathcal{N}(\Phi_0 b, \sigma^2 d_c^2)$$

donde

$$d_c^2 = \Phi_0 D^2 \Phi_0^T = \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}$$

Finalmente, como $\hat{Y}_0$ es independiente de la variable aleatoria $\hat{S}^2$, podemos construir la variable aleatoria

$$T_c = \frac{\hat{Y}_0 - \Phi_0 b}{\hat{S} d_c} \sim t_{n-2}$$

Se sigue que para construir un intervalo de confianza para el valor esperado de la variable dependiente Y_0 en el punto $X_0 = x_0$, basta con tomar el intervalo

$$(\hat{y}_0 - t_{\alpha/2, n-2} \hat{S} d_c, \hat{y}_0 + t_{\alpha/2, n-2} \hat{S} d_c)$$

donde $\hat{y}_0$ es el valor de la variable aleatoria $\hat{Y}_0$ evaluada en los datos observados $Y = y$. Notemos que este intervalo depende del punto $X_0 = x_0$ que hayamos elegido. De manera más general, podemos considerar el conjunto de todos los intervalos de confianza para todos los posibles valores de x_0 , el cual se conoce como la *banda de confianza* del modelo de regresión lineal simple.

Para terminar, notemos que como Y_0 es independiente de $\hat{Y}_0$, tenemos que

$$Y_0 - \hat{Y}_0 \sim \mathcal{N}(0, \sigma^2 d_p^2)$$

donde

$$d_p^2 = 1 + d_c^2 = 1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}$$

Usando nuevamente la variable aleatoria $\hat{S}^2$, podemos definir ahora

$$T_p = \frac{Y_0 - \hat{Y}_0}{\hat{S} d_p} \sim t_{n-2}$$

y, de manera similar a como lo hicimos antes, podemos construir un *intervalo de predicción* para el valor de la variable dependiente Y_0 en el punto $X_0 = x_0$ como

$$(\hat{y}_0 - t_{\alpha/2, n-2} \hat{S} d_p, \hat{y}_0 + t_{\alpha/2, n-2} \hat{S} d_p)$$

Nuevamente, el conjunto de todos estos intervalos de predicción para todos los posibles valores de x_0 se conoce como la *banda de predicción* del modelo de regresión lineal simple.

Capítulo 3

Adecuación del modelo

Hasta el momento hemos considerado únicamente modelos con una sola variable independiente. Sin embargo, en muchos casos es posible que la variable de interés dependa de múltiples variables independientes. En este caso, el modelo de regresión lineal simple se extiende al modelo de regresión lineal múltiple, en el cual la variable dependiente Y depende linealmente de múltiples variables independientes $X_1, X_2, \dots, X_p$. En esta sección consideraremos el modelo de regresión lineal múltiple y discutiremos algunas de las condiciones que deben cumplirse para que este modelo sea adecuado. De manera más específica, supondremos que tenemos un modelo de la forma

$$Y_0 = b_0 + b_1 X_{01} + b_2 X_{02} + \dots + b_p X_{0p} + \epsilon$$

donde Y_0 es la variable dependiente, $X_{01}, X_{02}, \dots, X_{0p}$ son las variables independientes, $b_0, b_1, \dots, b_p$ son los parámetros del modelo y ϵ es un término de error aleatorio con distribución $\mathcal{N}(0, \sigma^2)$. Para considerar nuestras muestras de datos, consideraremos la matriz aleatoria

$$X = \begin{bmatrix} X_{11} & X_{12} & \dots & X_{1p} \\ X_{21} & X_{22} & \dots & X_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} & X_{n2} & \dots & X_{np} \end{bmatrix}$$

y mantendremos el vector aleatorio

$$Y = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}$$

que hemos utilizado anteriormente. Supongamos ahora que tenemos un vector de observaciones independientes

$$x = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix}$$

Entonces, podemos definir la matriz de diseño

$$\Phi = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix}$$

y podemos definir las matrices $D^2 = (\Phi^T \Phi)^{-1}$, $A = D^2 \Phi^T$ y $H = \Phi A$. Entonces, el vector de coeficientes de la recta de mejor ajuste por mínimos cuadrados está dado por

$$\hat{B} = AY \sim \mathcal{N}(b, \sigma^2 D^2)$$

mientras que el vector de predicciones está dado por

$$\hat{Y} = HY$$

Notemos que en este caso el estimador para la varianza del error está dado por

$$\hat{S}^2 = \frac{\|Y - \hat{Y}\|^2}{n - (p + 1)} = \sum_{i=1}^n \frac{(Y_i - \hat{Y}_i)^2}{n - (p + 1)}$$

Ahora dado cualquier vector de observaciones dependientes

$$y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

podemos evaluar los estimadores anteriores en los datos observados para obtener el vector de coeficientes de la recta de mejor ajuste por mínimos cuadrados. En particular, el vector de coeficientes está dado por

$$\hat{\beta} = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_p = Ay \end{bmatrix}$$

mientras que el vector de predicciones está dado por

$$\hat{y} = \begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_n \end{bmatrix} = Hy$$

Notemos que podemos realizar estos cálculos para cualquier conjunto de datos dados, sin embargo, para que el modelo de regresión lineal múltiple sea adecuado, es necesario que se cumplan ciertas condiciones. En este capítulo discutiremos algunas de estas condiciones y presentaremos algunas herramientas para evaluar la adecuación del modelo.

3.1. Bondad de ajuste

Una de las primeras herramientas que podemos utilizar para evaluar la adecuación del modelo de regresión lineal múltiple es el coeficiente de determinación, también conocido como R^2 . Este coeficiente mide la proporción de la variabilidad total de la variable dependiente que es explicada por el modelo de regresión. El coeficiente de determinación está dado por

$$R^2 = 1 - \frac{SSE}{SST}$$

donde

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

es la suma de los cuadrados de los errores y

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2$$

es la suma total de los cuadrados. Notemos que como

$$SST = SSR + SSE$$

donde

$$SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

es la suma de los cuadrados de la regresión, podemos expresar el coeficiente de determinación como

$$R^2 = \frac{SSR}{SST}$$

en particular, el coeficiente de determinación siempre toma valores entre 0 y 1, donde un valor cercano a 1 indica que el modelo explica una gran proporción de la variabilidad de la variable dependiente, mientras que un valor cercano a 0 indica que el modelo no explica mucha de la variabilidad.

Además del coeficiente de determinación, es común utilizar el coeficiente de determinación ajustado, el cual tiene en cuenta el número de variables independientes en el modelo. Este coeficiente está dado por

$$R_{adj}^2 = 1 - \left(\frac{n-1}{n-(p+1)} \right) \frac{SSE}{SST}$$

donde p es el número de variables independientes en el modelo. El coeficiente de determinación ajustado penaliza la inclusión de variables independientes que no contribuyen significativamente a la explicación de la variabilidad de la variable dependiente. Por lo tanto, es una medida más adecuada para comparar modelos con diferentes números de variables independientes. Finalmente, también podemos considerar el error estandar de la estimación, el cual está dado por

$$SEE = \sqrt{\frac{SSE}{n-(p+1)}}$$

Notemos que estas cantidades nos proporcionan una idea general de la adecuación del modelo, pero no nos permiten evaluar si se cumplen las condiciones necesarias para que el modelo sea válido. En las siguientes secciones discutiremos algunas de estas condiciones y presentaremos herramientas para evaluarlas.

3.2. Significancia global del modelo

Una de las condiciones más importantes para que el modelo de regresión lineal múltiple sea adecuado es que al menos una de las variables independientes tenga un efecto significativo sobre la variable dependiente. Para evaluar esta condición, podemos utilizar la prueba de hipótesis conocida como ANOVA (análisis de varianza). En esta prueba, consideramos las hipótesis nula y alternativa:

$$H_0 : b_1 = b_2 = \dots = b_p = 0$$

$$H_A : \text{Al menos uno de los } b_j \text{ es diferente de } 0$$

La estadística de prueba para esta hipótesis está dada por

$$F = \frac{(SSR/p)}{(SSE/(n - (p + 1)))}$$

donde SSR es la suma de los cuadrados de la regresión y SSE es la suma de los cuadrados de los errores. Bajo la hipótesis nula, esta estadística sigue una distribución F con p y $n - (p + 1)$ grados de libertad. Por lo tanto, podemos calcular el valor p asociado a esta estadística y compararlo con un nivel de significancia predefinido (por ejemplo, $\alpha = 0.05$) para decidir si rechazamos o no la hipótesis nula. Si rechazamos la hipótesis nula, podemos concluir que al menos una de las variables independientes tiene un efecto significativo sobre la variable dependiente, lo cual es una condición necesaria para que el modelo sea adecuado.

3.3. Diagnóstico de residuos

Otra condición importante para la adecuación del modelo de regresión lineal múltiple es que los residuos del modelo (es decir, las diferencias entre los valores observados y los valores predichos por el modelo) deben seguir una distribución normal con media cero y varianza constante. Para evaluar esta condición, podemos utilizar diversas herramientas gráficas y estadísticas. Una herramienta gráfica común es el gráfico de residuos versus valores ajustados, en el cual graficamos los residuos del modelo en función de los valores predichos por el modelo. En este gráfico, esperamos ver una distribución aleatoria de los residuos alrededor de cero, sin patrones evidentes. Si observamos patrones en este gráfico (por ejemplo, una forma curva), esto puede indicar que el modelo no es adecuado y que se deben considerar transformaciones de las variables o la inclusión de términos adicionales en el modelo. Otra herramienta gráfica es el gráfico Q-Q (quantile-quantile), en el cual graficamos los cuantiles de los residuos del modelo contra los cuantiles de una distribución normal. En este gráfico, esperamos ver una línea recta si los residuos siguen una distribución normal. Si observamos desviaciones significativas de la línea recta, esto puede indicar que los residuos no siguen una distribución normal, lo cual puede afectar la validez del modelo.

Además de las herramientas gráficas, también podemos utilizar pruebas estadísticas para evaluar la normalidad y homocedasticidad de los residuos. Por ejemplo, podemos utilizar la prueba de Shapiro-Wilk para evaluar la normalidad de los residuos, y la prueba de Breusch-Pagan para evaluar la homocedasticidad (es decir, si la varianza de los residuos es constante). Si estas pruebas indican que los residuos no cumplen con estas condiciones, esto puede afectar la validez del modelo y se deben considerar ajustes adicionales.

En resumen, la adecuación del modelo de regresión lineal múltiple depende de diversas condiciones que deben ser evaluadas cuidadosamente. El coeficiente de determinación y el coeficiente de determinación ajustado nos proporcionan una idea general de la adecuación del modelo, mientras que la prueba ANOVA y el diagnóstico de residuos nos permiten evaluar condiciones específicas necesarias para la validez del modelo. Es importante utilizar estas herramientas de manera conjunta para asegurar que el modelo sea adecuado para los datos analizados.

3.4. Puntos influyentes y de alta palanca

Finalmente, otra consideración importante en la adecuación del modelo de regresión lineal múltiple es la presencia de puntos influyentes y de alta palanca en los datos. Estos puntos pueden tener un impacto significativo en los resultados del modelo y pueden distorsionar las estimaciones de los parámetros y las predicciones. Para identificar estos puntos, podemos utilizar diversas medidas estadísticas, como la distancia de Cook y la palanca de Hat. La distancia de Cook mide el impacto de cada punto en las estimaciones de los parámetros del modelo, mientras que la palanca de Hat mide la influencia de cada punto en los valores predichos por el modelo. En general, se considera que un punto es influyente si su distancia de Cook es mayor que un umbral predefinido (por ejemplo, $4/n$), y se considera que un punto tiene alta palanca si su palanca de Hat es mayor que $2(p+1)/n$, donde p es el número de variables independientes y n es el número de observaciones. Al identificar estos puntos, podemos evaluar su impacto en el modelo y considerar si es necesario excluirllos o tratarlos de manera especial. En algunos casos, puede ser apropiado utilizar técnicas de regresión robusta que sean menos sensibles a la presencia de puntos influyentes y de alta palanca. En resumen, la identificación y tratamiento de puntos influyentes y de alta palanca es una parte importante del proceso de evaluación de la adecuación del modelo de regresión lineal múltiple. Al considerar estas medidas junto con las otras herramientas discutidas en esta sección, podemos asegurar que el modelo sea adecuado y confiable para los datos analizados.

3.5. Heterocedasticidad

Otra condición importante para la adecuación del modelo de regresión lineal múltiple es la homocedasticidad, es decir, que la varianza de los residuos sea constante a lo largo de todos los niveles de las variables independientes. Si la varianza de los residuos varía significativamente, esto puede indicar la presencia de heterocedasticidad, lo cual puede afectar la validez del modelo y las inferencias estadísticas basadas en él. Para evaluar la homocedasticidad, podemos utilizar diversas herramientas gráficas y estadísticas. Una herramienta gráfica común es el gráfico de residuos versus valores ajustados, en el cual graficamos los residuos del modelo en función de los valores predichos por el modelo. En este gráfico, esperamos ver una distribución aleatoria de los residuos alrededor de cero, sin patrones evidentes. Si observamos un patrón en forma de embudo (es decir, que la variabilidad de los residuos aumenta o disminuye con los valores ajustados), esto puede indicar la presencia de heterocedasticidad. Además de las herramientas gráficas, también podemos utilizar pruebas estadísticas para evaluar la homocedasticidad de los residuos. Por ejemplo, podemos utilizar la prueba de Breusch-Pagan o la prueba de White para evaluar si la varianza de los residuos es constante. Si estas pruebas indican que hay heterocedasticidad presente, esto puede afectar la validez del modelo y se deben considerar ajustes adicionales. En algunos casos, puede ser apropiado utilizar transformaciones de las variables dependientes o independientes para estabilizar la varianza, o

utilizar técnicas de regresión robusta que sean menos sensibles a la heterocedasticidad. En resumen, la evaluación de la homocedasticidad es una parte importante del proceso de evaluación de la adecuación del modelo de regresión lineal múltiple. Al considerar estas herramientas junto con las otras discutidas en esta sección, podemos asegurar que el modelo sea adecuado y confiable para los datos analizados.

3.6. Multicolinealidad

Finalmente, otra consideración importante en la adecuación del modelo de regresión lineal múltiple es la presencia de multicolinealidad entre las variables independientes. La multicolinealidad ocurre cuando dos o más variables independientes están altamente correlacionadas entre sí, lo cual puede dificultar la estimación precisa de los coeficientes del modelo y afectar la interpretación de los resultados. Para evaluar la multicolinealidad, podemos utilizar diversas medidas estadísticas, como el factor de inflación de la varianza (VIF, por sus siglas en inglés). El VIF mide cuánto se incrementa la varianza de un coeficiente estimado debido a la multicolinealidad con otras variables independientes. En general, se considera que una variable independiente tiene un problema significativo de multicolinealidad si su VIF es mayor que 10. Al identificar variables con alta multicolinealidad, podemos considerar diversas estrategias para abordar este problema. Una opción es eliminar una o más de las variables altamente correlacionadas del modelo, lo cual puede simplificar el modelo y mejorar la interpretabilidad. Otra opción es combinar las variables correlacionadas en una sola variable mediante técnicas como el análisis de componentes principales. En algunos casos, puede ser apropiado utilizar técnicas de regresión regularizada, como la regresión Ridge o Lasso, que pueden manejar mejor la multicolinealidad al penalizar los coeficientes del modelo. En resumen, la evaluación y manejo de la multicolinealidad es una parte importante del proceso de evaluación de la adecuación del modelo de regresión lineal múltiple. Al considerar estas medidas junto con las otras herramientas discutidas en esta sección, podemos asegurar que el modelo sea adecuado y confiable para los datos analizados.

3.7. Linealidad

Otra condición fundamental para la adecuación del modelo de regresión lineal múltiple es la linealidad, es decir, que la relación entre las variables independientes y la variable dependiente sea lineal. Si la relación no es lineal, el modelo puede no capturar adecuadamente la relación entre las variables, lo cual puede afectar la validez del modelo y las predicciones basadas en él. Para evaluar la linealidad, podemos utilizar diversas herramientas gráficas y estadísticas. Una herramienta gráfica común es el gráfico de residuos versus cada una de las variables independientes, en el cual graficamos los residuos del modelo en función de cada variable independiente. En estos gráficos, esperamos ver una distribución aleatoria de los residuos alrededor de cero, sin patrones evidentes. Si observamos patrones curvos o sistemáticos en estos gráficos, esto puede indicar que la relación entre la variable independiente y la variable dependiente no es lineal. Además de las herramientas gráficas, también podemos utilizar pruebas estadísticas para evaluar la linealidad. Por ejemplo, podemos utilizar la prueba de Ramsey RESET para evaluar si hay términos no lineales significativos en el modelo. Si esta prueba indica que hay términos no lineales presentes, esto puede afectar la validez del modelo y se deben considerar ajustes adicionales. En algunos casos, puede ser apropiado utilizar transformaciones de las variables dependientes o independientes para lograr una relación más lineal,

o incluir términos polinomiales o interacciones en el modelo para capturar relaciones no lineales. En resumen, la evaluación de la linealidad es una parte importante del proceso de evaluación de la adecuación del modelo de regresión lineal múltiple. Al considerar estas herramientas junto con las otras discutidas en esta sección, podemos asegurar que el modelo sea adecuado y confiable para los datos analizados.

3.8. Ejemplos

Consideremos los siguientes conjuntos de datos:

```
set.seed(123)

n <- 500
x_data1 <- runif(n, min = 0, max = 10)
epsilon_data1 <- rnorm(n, mean = 0, sd = 50)
y_data1 <- (x_data1)^3 + epsilon_data1

x_data2 <- runif(n, min = 0, max = 10)
epsilon_data2 <- rnorm(n, mean = 0, sd = 0.1)
y_data2 <- sin(x_data2) + epsilon_data2

x_data3 <- runif(n, min = 0, max = 10)
y_data3 <- runif(n, min = 0, max = 10)

x_data4 <- runif(n, min = 0, max = 10)
y_data4 <- mapply(function(mu, sigma) rnorm(1, mean = mu, sd = sigma),
                  mu = x_data4,
                  sigma = x_data4)

sample_data1_tbl <- tibble(
  x = x_data1,
  y = y_data1
)

sample_data2_tbl <- tibble(
  x = x_data2,
  y = y_data2
)

sample_data3_tbl <- tibble(
  x = x_data3,
  y = y_data3
)

sample_data4_tbl <- tibble(
  x = x_data4,
```

```
y = y_data4  
)
```

Podemos ajustar un modelo de regresión lineal simple a cada uno de estos conjuntos de datos y evaluar la adecuación del modelo utilizando las herramientas discutidas en esta sección.

```
library(ggfortify)  
model1 <- lm(y ~ x, data = sample_data1_tbl)  
model2 <- lm(y ~ x, data = sample_data2_tbl)  
model3 <- lm(y ~ x, data = sample_data3_tbl)  
model4 <- lm(y ~ x, data = sample_data4_tbl)  
  
summary(model1)
```

Call:

```
lm(formula = y ~ x, data = sample_data1_tbl)
```

Residuals:

Min	1Q	Median	3Q	Max
-260.47	-94.88	-27.82	94.28	335.29

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-213.79	11.13	-19.20	<2e-16 ***
x	92.58	1.95	47.49	<2e-16 ***


Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 123.9 on 498 degrees of freedom

Multiple R-squared: 0.8191, Adjusted R-squared: 0.8188

F-statistic: 2255 on 1 and 498 DF, p-value: < 2.2e-16

```
autoplot(model1)
```



Para el segundo conjunto de datos:

```
summary(model2)
```

Call:

```
lm(formula = y ~ x, data = sample_data2_tbl)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-1.36022	-0.58820	0.08391	0.59813	1.08796

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.22733	0.06133	3.707	0.000234 ***
x	-0.01785	0.01059	-1.686	0.092470 .


Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.6819 on 498 degrees of freedom

Multiple R-squared: 0.005674, Adjusted R-squared: 0.003677

F-statistic: 2.842 on 1 and 498 DF, p-value: 0.09247

```
autoplot(model2)
```



Para el tercer conjunto de datos:

```
summary(model3)
```

Call:

```
lm(formula = y ~ x, data = sample_data3_tbl)
```

Residuals:

Min	1Q	Median	3Q	Max
-5.147	-2.733	-0.032	2.655	4.950

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	5.20947	0.27038	19.267	<2e-16 ***
x	-0.02730	0.04684	-0.583	0.56


Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.008 on 498 degrees of freedom

Multiple R-squared: 0.0006814, Adjusted R-squared: -0.001325

F-statistic: 0.3396 on 1 and 498 DF, p-value: 0.5603

```
autoplot(model3)
```



Finalmente, para el cuarto conjunto de datos:

```
summary(model4)
```

Call:

```
lm(formula = y ~ x, data = sample_data4_tbl)
```

Residuals:

Min	1Q	Median	3Q	Max
-20.4426	-2.6517	-0.0617	2.7239	21.9819

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.16289	0.49421	0.33	0.742
x	0.93369	0.08753	10.67	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.456 on 498 degrees of freedom

Multiple R-squared: 0.186, Adjusted R-squared: 0.1843

F-statistic: 113.8 on 1 and 498 DF, p-value: < 2.2e-16

```
autoplot(model4)
```

