



Tecnológico de Monterrey

Aplicación de Métodos Multivariados en Ciencia de Datos

Módulo 2: Relaciones de Dependencia

Raúl Gómez Muñoz
Blanca Rosa Ruiz Hernández

Tabla de contenidos

I Análisis de Regresión

1. Regresión lineal	1
1.1. Intervalos de confianza	1
1.2. Regresión lineal simple	2

Parte I

Análisis de Regresión

Capítulo 1

Regresión lineal

1.1. Intervalos de confianza

Supongamos que tenemos una variable aleatoria Y_0 que sigue una distribución normal con media μ y varianza σ^2 , es decir,

$$Y_0 \sim N(\mu, \sigma^2)$$

Supongamos además que queremos recolectar una muestra de tamaño n de esta variable aleatoria, que utilizaremos para estimar el valor de la media μ . Utilizaremos las variables aleatorias $Y_1, Y_2, \dots, Y_n$ para denotar los posibles valores de la muestra. Notemos que estas variables aleatorias son independientes e idénticamente distribuidas (i.i.d.) y que cada una de ellas sigue la misma distribución normal que Y_0 , es decir,

$$Y_i \sim N(\mu, \sigma^2) \quad i = 1, 2, \dots, n$$

Para estimar el valor de μ , utilizaremos la media muestral, definida como

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$$

Notemos que la media muestral $\bar{Y}$ es una variable aleatoria que también sigue una distribución normal, con media μ y varianza σ^2/n , es decir,

$$\bar{Y} \sim N(\mu, \sigma^2/n)$$

En particular, $E[\bar{Y}] = \mu$, es decir, la media muestral es un estimador insesgado de la media poblacional μ . Además, la varianza de la media muestral es σ^2/n , lo que significa que a medida que aumentamos el tamaño de la muestra n , la varianza de la media muestral disminuye, y por lo tanto, la media muestral se vuelve más precisa como estimador de μ . Además, si definimos la variable aleatoria

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$$

entonces S^2 es un estimador insesgado de la varianza poblacional σ^2 , es decir, $E[S^2] = \sigma^2$. Notemos que la variable aleatoria S^2 sigue una distribución chi-cuadrado con $n - 1$ grados de libertad, es decir,

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$$

Además las variables aleatorias $\bar{Y}$ y S^2 son independientes, por lo tanto podemos definir la variable aleatoria

$$T = \frac{\bar{Y} - \mu}{S/\sqrt{n}} \sim t_{n-1}$$

donde t_{n-1} denota la distribución t de Student con $n - 1$ grados de libertad. Notemos que la variable aleatoria T es una función de la media muestral $\bar{Y}$, la varianza muestral S^2 y el tamaño de la muestra n , y que su distribución no depende del valor de μ ni de σ^2 . Sea ahora $t_{\alpha/2, n-1}$ el cuantil de orden $1 - \alpha/2$ de la distribución t de Student con $n - 1$ grados de libertad, en otras palabras,

$$P(-t_{\alpha/2, n-1} \leq T \leq t_{\alpha/2, n-1}) = 1 - \alpha$$

Reescribiendo esta desigualdad en términos de μ , obtenemos

$$P\left(\bar{Y} - t_{\alpha/2, n-1} \frac{S}{\sqrt{n}} \leq \mu \leq \bar{Y} + t_{\alpha/2, n-1} \frac{S}{\sqrt{n}}\right) = 1 - \alpha$$

Supongamos ahora que realizamos el muestreo correspondiente y obtenemos los valores de la muestra $y_1, y_2, \dots, y_n$. Calculamos entonces la media muestral $\bar{y}$ y la varianza muestral s^2 , y obtenemos el intervalo de confianza para μ dado por

$$\left(\bar{y} - t_{\alpha/2, n-1} \frac{s}{\sqrt{n}}, \bar{y} + t_{\alpha/2, n-1} \frac{s}{\sqrt{n}}\right)$$

con un nivel de confianza del $100(1 - \alpha)\%$. Notemos que este intervalo de confianza es un intervalo aleatorio, ya que depende de los valores de la muestra, y que si repetimos el muestreo muchas veces, aproximadamente el $100(1 - \alpha)\%$ de los intervalos de confianza obtenidos contendrán el valor verdadero de μ .

De manera más explícita,

1.2. Regresión lineal simple

Supongamos que tenemos un conjunto de datos

$$((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$$

Por ejemplo, consideremos el siguiente conjunto de datos simulado:

```
library(tidyverse)
library(krnlRutils)
library(latex2exp)

set.seed(123)
```


1. Regresión lineal

```
n <- 50
x_data <- runif(n, min = 0, max = 10)
epsilon_data <- rnorm(n, mean = 0, sd = 1)
y_data <- x_data + epsilon_data

sample_data_tbl <- tibble(
  x = x_data,
  y = y_data
)
```

Notemos que podemos visualizar estos datos mediante un diagrama de dispersión:

```
sample_data_plot <- sample_data_tbl |>
  ggplot(aes(x = x, y = y)) +
  geom_point(
    color = c_pal("C red"),
    size = 1,
    alpha = 1
  ) +
  labs(
    title = "Datos simulados",
    x = TeX("$X_{0}$"),
    y = TeX("$Y_{0}$")
  ) +
  theme_krul()

sample_data_plot
```

Datos simulados




Figura 1.1: Diagrama de dispersión de los datos simulados.

Nos gustaría encontrar la línea recta que mejor se ajuste a estos datos. Hay varias formas de definir “mejor ajuste”, pero una de las más comunes es minimizar la suma de los errores al cuadrado (SSE por sus siglas en inglés) entre los valores observados y los valores correspondientes sobre la línea recta propuesta. De manera más precisa, buscamos una recta

$$Y_0 = \hat{f}(X_0) = \hat{\beta}_0 + \hat{\beta}_1 X_0$$

tal que si definimos $\hat{y}_i = \hat{f}(x_i)$ entonces minimicemos la suma

$$\text{SSE} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (1.1)$$

```
model <- lm(y ~ x, data = sample_data_tbl)

fitted_data_tbl <- sample_data_tbl |>
  mutate(
    fitted = fitted(model)
  )

fitted_data_plot <- fitted_data_tbl |>
  ggplot(aes(x = x, y = y)) +
  geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
  geom_segment(
    aes(xend = x, yend = fitted),
    color = c_pal("C green"),
    alpha = 1
  )
```

1. Regresión lineal

```
) +
geom_point(color = c_pal("C red"), size = 1, alpha = 1) +
geom_point(
  aes(x = x, y = fitted),
  color = c_pal("C red"),
  size = 1,
  alpha = 1
) +
coord_fixed() +
labs(
  title = "Recta ajustada",
  x = TeX("$X_{0}$"),
  y = TeX("$Y_{0}$")
) +
theme_krul()

fitted_data_plot
```




Figura 1.2: Línea recta que mejor se ajusta a los datos simulados, bajo el criterio de mínimos cuadrados. En otras palabras, esta es la línea recta que minimiza el SSE.

Para encontrar la fórmula para $\hat{\beta}_0$ y $\hat{\beta}_1$ en términos de nuestros datos, utilizaremos un poco de

álgebra lineal. Empecemos por fijar los vectores

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

que llamaremos el *vector de las observaciones independientes* y el *vector de las observaciones dependientes*, respectivamente. Fijamos ahora la llamada *matriz de diseño*, dada por,

$$\Phi = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}$$

y notamos que si definimos

$$\hat{y} = \begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_n \end{bmatrix}$$

entonces $\hat{y} = \Phi \hat{\beta}$ donde

$$\hat{\beta} = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{bmatrix}$$

Notemos que para minimizar la suma de los errores al cuadrado dada en la ecuación (1.1), necesitamos encontrar la proyección ortogonal del vector y sobre el espacio generado por las columnas de la matriz Φ . Empezamos por calcular la *matriz de coeficientes*

$$D^2 = (\Phi^T \Phi)^{-1} = \begin{bmatrix} \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} & -\frac{\bar{x}}{S_{xx}} \\ -\frac{\bar{x}}{S_{xx}} & \frac{1}{S_{xx}} \end{bmatrix}$$

donde

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad y \quad S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$$

Calculamos ahora la *matriz de estimadores de mínimos cuadrados*

$$A = D^2 \Phi^T = (\Phi^T \Phi)^{-1} \Phi^T = \begin{bmatrix} \frac{1}{n} + \frac{\bar{x}(\bar{x}-x_1)}{S_{xx}} & \cdots & \frac{1}{n} + \frac{\bar{x}(\bar{x}-x_n)}{S_{xx}} \\ \frac{x_1-\bar{x}}{S_{xx}} & \cdots & \frac{x_n-\bar{x}}{S_{xx}} \end{bmatrix}$$

y, finalmente, calculamos la *matriz sombrero*

$$H = \Phi A = \Phi (\Phi^T \Phi)^{-1} \Phi^T$$

Notemos que las entradas de la matriz H están dadas por:

$$h_{ij} = \frac{1}{n} + \frac{(x_i - \bar{x})(x_j - \bar{x})}{S_{xx}}$$

1. Regresión lineal

en particular,

$$h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}$$

Utilizando estas matrices, podemos calcular

$$\hat{\beta} = Ay \quad \text{y} \quad \hat{y} = Hy$$

Para ilustrar este procedimiento, consideremos el siguiente ejemplo.

Ejemplo. Consideremos el siguiente conjunto de datos:

```
set.seed(123)

n <- 5
x_data <- 1:n
epsilon_data <- rnorm(n, mean = 0, sd = n / 10)
y_data <- x_data + epsilon_data
sample_data_tbl <- tibble(
  x = x_data,
  y = y_data
)
```

Notemos que los vectores de observaciones independientes y dependientes son:

$$x = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{bmatrix} \quad y = \begin{bmatrix} 0.72 \\ 1.88 \\ 3.78 \\ 4.04 \\ 5.06 \end{bmatrix}$$

y la matriz de diseño es:

```
Phi <- matrix(c(rep(1, n), x_data), nrow = n, ncol = 2)
```

$$\Phi = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{bmatrix}$$

Calculamos ahora la matriz de coeficientes:

```
D2 <- solve(t(Phi) %*% Phi)
```

$$D^2 = \begin{bmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{bmatrix}$$

y la matriz de estimadores de mínimos cuadrados:

```
A <- D2 %*% t(Phi)
```

$$A = \begin{bmatrix} 0.8 & 0.5 & 0.2 & -0.1 & -0.4 \\ -0.2 & -0.1 & 0 & 0.1 & 0.2 \end{bmatrix}$$

Finalmente, la matriz sombrero es:

```
H <- Phi %*% A
```

$$H = \begin{bmatrix} 0.6 & 0.4 & 0.2 & 0 & -0.2 \\ 0.4 & 0.3 & 0.2 & 0.1 & 0 \\ 0.2 & 0.2 & 0.2 & 0.2 & 0.2 \\ 0 & 0.1 & 0.2 & 0.3 & 0.4 \\ -0.2 & 0 & 0.2 & 0.4 & 0.6 \end{bmatrix}$$

Utilizando estas matrices, podemos rápidamente calcular los vectores $\hat{\beta}$ y $\hat{y}$:

```
beta_hat <- A %*% y_data
y_hat <- H %*% y_data
```

$$\hat{\beta} = \begin{bmatrix} -0.16 \\ 1.08 \end{bmatrix} \quad \hat{y} = \begin{bmatrix} 0.93 \\ 2.01 \\ 3.1 \\ 4.18 \\ 5.26 \end{bmatrix}$$

Notemos que en este caso la suma de los errores al cuadrado (SSE) es:

```
sse <- sum((y_data - y_hat)^2)
```

$$SSE = 0.59$$

La siguiente figura ilustra el ajuste por mínimos cuadrados para este conjunto de datos:

```
fitted_example_data_tbl <- sample_data_tbl |>
  mutate(
    fitted = as.vector(y_hat)
  )
fitted_example_data_plot <- fitted_example_data_tbl |>
  ggplot(aes(x = x, y = y)) +
  geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
  geom_segment(
    aes(xend = x, yend = fitted),
    color = c_pal("C green"),
    alpha = 1
  ) +
  geom_point(color = c_pal("C red"), size = 1, alpha = 1) +
```

1. Regresión lineal

```
geom_point(  
  aes(x = x, y = fitted),  
  color = c_pal("C red"),  
  size = 1,  
  alpha = 1  
) +  
coord_fixed() +  
labs(  
  title = "Recta ajustada",  
  x = TeX("$X_{0}$"),  
  y = TeX("$Y_{0}$")  
) +  
theme_krul()  
fitted_example_data_plot
```




Figura 1.3: Ajuste por mínimos cuadrados para el conjunto de datos del ejemplo.

Notemos que este proceso se puede aplicar a cualquier conjunto de datos dado, sin embargo una de las aplicaciones más comunes de este método es tratar de predecir el valor de la variable Y_0 dado un valor específico de la variable X_0 que no se encuentre en el conjunto de datos original. Se sigue que para que estas predicciones sean de utilidad, es necesario que el comportamiento de nuestros datos siga una tendencia lineal, ya que en caso contrario las predicciones podrían no ser confiables. Por ejemplo, consideremos el ajuste por el método de mínimos cuadrados para los siguientes conjuntos de datos:

```
library(patchwork)

set.seed(123)

n <- 500
x_data1 <- runif(n, min = 0, max = 10)
epsilon_data1 <- rnorm(n, mean = 0, sd = 50)
y_data1 <- (x_data1)^3 + epsilon_data1

x_data2 <- runif(n, min = 0, max = 10)
epsilon_data2 <- rnorm(n, mean = 0, sd = 0.1)
y_data2 <- sin(x_data2) + epsilon_data2

x_data3 <- runif(n, min = 0, max = 10)
y_data3 <- runif(n, min = 0, max = 10)

x_data4 <- runif(n, min = 0, max = 10)
y_data4 <- mapply(function(mu, sigma) rnorm(1, mean = mu, sd = sigma),
  mu = x_data4,
  sigma = x_data4
)

sample_data1_tbl <- tibble(
  x = x_data1,
  y = y_data1
)

sample_data2_tbl <- tibble(
  x = x_data2,
  y = y_data2
)

sample_data3_tbl <- tibble(
  x = x_data3,
  y = y_data3
)

sample_data4_tbl <- tibble(
  x = x_data4,
  y = y_data4
)

sample_data1_plot <- sample_data1_tbl |>
  ggplot(aes(x = x, y = y)) +
  geom_point(
```


1. Regresión lineal

```
    color = c_pal("C red"),
    size = 1,
    alpha = 1
) +
geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
labs(
  title = "Datos cúbicos",
  x = "",
  y = ""
) +
theme_krul()

sample_data2_plot <- sample_data2_tbl |>
ggplot(aes(x = x, y = y)) +
geom_point(
  color = c_pal("C red"),
  size = 1,
  alpha = 1
) +
geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
labs(
  title = "Datos senoidales",
  x = "",
  y = ""
) +
theme_krul()

sample_data3_plot <- sample_data3_tbl |>
ggplot(aes(x = x, y = y)) +
geom_point(
  color = c_pal("C red"),
  size = 1,
  alpha = 1
) +
geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
labs(
  title = "Datos aleatorios",
  x = "",
  y = ""
) +
theme_krul()

sample_data4_plot <- sample_data4_tbl |>
ggplot(aes(x = x, y = y)) +
geom_point(
```

```
color = c_pal("C red"),
size = 1,
alpha = 1
) +
geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
labs(
  title = "Datos con varianza creciente",
  x = "",
  y = ""
) +
theme_krul()

sample_data_plot <- (sample_data1_plot + sample_data2_plot) /
  (sample_data3_plot + sample_data4_plot)

sample_data_plot
```




Figura 1.4: Ajuste por mínimos cuadrados para diferentes conjuntos de datos.

Es bastante claro que en estos casos el ajuste por mínimos cuadrados no es el método adecuado para realizar predicciones confiables. En general, este método solo es efectivo cuando se cumplen ciertas hipótesis que estudiaremos en las siguientes secciones, cuando introduciremos el modelo de regresión lineal desde un punto de vista estadístico.