



**Tecnológico
de Monterrey**

**MA2003B Aplicación de Métodos Multivariados
en Ciencia de Datos**

Módulo 2: Relaciones de Dependencia

Profesor: Raul Gomez
Correo: rgomez@tec.mx
Oficina: A4-123A

Tabla de contenidos

I	Análisis de Regresión	3
1.	Método de mínimos cuadrados	5
2.	Intervalos de confianza y predicción en regresión lineal	15

Parte I

Análisis de Regresión

Capítulo 1

Método de mínimos cuadrados

Supongamos que tenemos un conjunto de datos

$$((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$$

Por ejemplo, consideremos el siguiente conjunto de datos simulado:

```
library(tidyverse)
library(krulRutils)
library(latex2exp)

set.seed(123)

n <- 50
x_data <- runif(n, min = 0, max = 10)
epsilon_data <- rnorm(n, mean = 0, sd = 1)
y_data <- x_data + epsilon_data

sample_data_tbl <- tibble(
  x = x_data,
  y = y_data
)
```

Notemos que podemos visualizar estos datos mediante un diagrama de dispersión:

```
sample_data_plot <- sample_data_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_point(
    color = c_pal("C red"),
    size = 1,
    alpha = 1
  ) +
  coord_fixed() +
  labs(
```

```
title = "Datos simulados",
x = TeX("$X_{0}$"),
y = TeX("$Y_{0}$")
) +
theme_krul()

sample_data_plot
```




Figura 1.1: Diagrama de dispersión de los datos simulados.

Nos gustaría encontrar la línea recta que mejor se ajuste a estos datos. Hay varias formas de definir “mejor ajuste”, pero una de las más comunes es minimizar la suma de los errores al cuadrado (SSE por sus siglas en inglés) entre los valores observados y los valores correspondientes sobre la línea recta propuesta. De manera más precisa, buscamos una recta

$$Y_0 = \hat{f}(X_0) = \hat{\beta}_0 + \hat{\beta}_1 X_0$$

tal que si definimos $\hat{y}_i = \hat{f}(x_i)$ entonces minimicemos la suma

$$\text{SSE} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (1.1)$$

```
fitted_data_tbl <- sample_data_tbl %>%
  mutate(
    fitted = fitted(lm(y ~ x, data = .))
  )
```



```
fitted_data_plot <- fitted_data_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
  geom_segment(
    aes(xend = x, yend = fitted),
    color = c_pal("C green"),
    alpha = 1
  ) +
  geom_point(color = c_pal("C red"), size = 1, alpha = 1) +
  geom_point(
    aes(x = x, y = fitted),
    color = c_pal("C red"),
    size = 1,
    alpha = 1
  ) +
  coord_fixed() +
  labs(
    title = "Recta ajustada",
    x = TeX("$X_{0}$"),
    y = TeX("$Y_{0}$")
  ) +
  theme_krul()

fitted_data_plot
```




Figura 1.2: Línea recta que mejor se ajusta a los datos simulados, bajo el criterio de mínimos cuadrados. En otras palabras, esta es la línea recta que minimiza el SSE.

Para encontrar la fórmula para $\hat{\beta}_0$ y $\hat{\beta}_1$ en términos de nuestros datos, utilizaremos un poco de álgebra lineal. Empecemos por fijar los vectores

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

que llamaremos el *vector de las observaciones independientes* y el *vector de las observaciones dependientes*, respectivamente. Fijamos ahora la llamada *matriz de diseño*, dada por,

$$\Phi = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}$$

y notamos que si definimos

$$\hat{y} = \begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_n \end{bmatrix}$$

entonces $\hat{y} = \Phi \hat{\beta}$ donde

$$\hat{\beta} = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{bmatrix}$$

Notemos que para minimizar la suma de los errores al cuadrado dada en la ecuación (1.1), necesitamos encontrar la proyección ortogonal del vector y sobre el espacio generado por las columnas de la matriz Φ . Empezamos por calcular la *matriz de coeficientes*

$$D^2 = (\Phi^T \Phi)^{-1} = \begin{bmatrix} \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} & -\frac{\bar{x}}{S_{xx}} \\ -\frac{\bar{x}}{S_{xx}} & \frac{1}{S_{xx}} \end{bmatrix}$$

donde

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{y} \quad S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$$

Calculamos ahora la *matriz de estimadores de mínimos cuadrados*

$$A = D^2 \Phi^T = (\Phi^T \Phi)^{-1} \Phi^T = \begin{bmatrix} \frac{1}{n} + \frac{\bar{x}(\bar{x}-x_1)}{S_{xx}} & \cdots & \frac{1}{n} + \frac{\bar{x}(\bar{x}-x_n)}{S_{xx}} \\ \frac{x_1-\bar{x}}{S_{xx}} & \cdots & \frac{x_n-\bar{x}}{S_{xx}} \end{bmatrix}$$

y, finalmente, calculamos la *matriz sombrero*

$$H = \Phi A = \Phi (\Phi^T \Phi)^{-1} \Phi^T$$

Notemos que las entradas de la matriz H están dadas por:

$$h_{ij} = \frac{1}{n} + \frac{(x_i - \bar{x})(x_j - \bar{x})}{S_{xx}}$$

en particular,

$$h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}$$

Utilizando estas matrices, podemos calcular

$$\hat{\beta} = Ay \quad \text{y} \quad \hat{y} = Hy$$

Para ilustrar este procedimiento, consideremos el siguiente ejemplo.

Ejemplo. Consideremos el siguiente conjunto de datos:

```
set.seed(123)

n <- 5
x_data <- 1:n
epsilon_data <- rnorm(n, mean = 0, sd = n / 10)
y_data <- x_data + epsilon_data
sample_data_tbl <- tibble(
  x = x_data,
  y = y_data
)
```

Notemos que los vectores de observaciones independientes y dependientes son:

$$x = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{bmatrix} \quad y = \begin{bmatrix} 0.72 \\ 1.88 \\ 3.78 \\ 4.04 \\ 5.06 \end{bmatrix}$$

y la matriz de diseño es:

```
Phi <- matrix(c(rep(1, n), x_data), nrow = n, ncol = 2)
```

$$\Phi = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{bmatrix}$$

Calculamos ahora la matriz de coeficientes:

```
D2 <- solve(t(Phi) %*% Phi)
```

$$D^2 = \begin{bmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{bmatrix}$$

y la matriz de estimadores de mínimos cuadrados:

```
A <- D2 %*% t(Phi)
```

$$A = \begin{bmatrix} 0.8 & 0.5 & 0.2 & -0.1 & -0.4 \\ -0.2 & -0.1 & 0 & 0.1 & 0.2 \end{bmatrix}$$

Finalmente, la matriz sombrero es:

```
H <- Phi %*% A
```

$$H = \begin{bmatrix} 0.6 & 0.4 & 0.2 & 0 & -0.2 \\ 0.4 & 0.3 & 0.2 & 0.1 & 0 \\ 0.2 & 0.2 & 0.2 & 0.2 & 0.2 \\ 0 & 0.1 & 0.2 & 0.3 & 0.4 \\ -0.2 & 0 & 0.2 & 0.4 & 0.6 \end{bmatrix}$$

Utilizando estas matrices, podemos rápidamente calcular los vectores $\hat{\beta}$ y $\hat{y}$:

```
beta_hat <- A %*% y_data
y_hat <- H %*% y_data
```

$$\hat{\beta} = \begin{bmatrix} -0.16 \\ 1.08 \end{bmatrix} \quad \hat{y} = \begin{bmatrix} 0.93 \\ 2.01 \\ 3.1 \\ 4.18 \\ 5.26 \end{bmatrix}$$

Notemos que en este caso la suma de los errores al cuadrado (SSE) es:

```
sse <- sum((y_data - y_hat)^2)
```

$$SSE = 0.59$$

La siguiente figura ilustra el ajuste por mínimos cuadrados para este conjunto de datos:

```
fitted_example_data_tbl <- sample_data_tbl %>%
  mutate(
    fitted = as.vector(y_hat)
  )
fitted_example_data_plot <- fitted_example_data_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
  geom_segment(
    aes(xend = x, yend = fitted),
    color = c_pal("C green"),
    alpha = 1
  ) +
  geom_point(color = c_pal("C red"), size = 1, alpha = 1) +
```

```
geom_point(  
  aes(x = x, y = fitted),  
  color = c_pal("C red"),  
  size = 1,  
  alpha = 1  
) +  
coord_fixed() +  
labs(  
  title = "Recta ajustada",  
  x = TeX("$X_{0}$"),  
  y = TeX("$Y_{0}$")  
) +  
theme_krul()  
fitted_example_data_plot
```




Figura 1.3: Ajuste por mínimos cuadrados para el conjunto de datos del ejemplo.

Notemos que este proceso se puede aplicar a cualquier conjunto de datos dado, sin embargo una de las aplicaciones más comunes de este método es tratar de predecir el valor de la variable Y_0 dado un valor específico de la variable X_0 que no se encuentre en el conjunto de datos original. Se sigue que para que estas predicciones sean de utilidad, es necesario que el comportamiento de nuestros datos siga una tendencia lineal, ya que en caso contrario las predicciones podrían no ser confiables. Por ejemplo, consideremos el ajuste por el método de mínimos cuadrados para los siguientes conjuntos de datos:

```
library(patchwork)

set.seed(123)

n <- 500
x_data1 <- runif(n, min = 0, max = 10)
epsilon_data1 <- rnorm(n, mean = 0, sd = 50)
y_data1 <- (x_data1)^3 + epsilon_data1

x_data2 <- runif(n, min = 0, max = 10)
epsilon_data2 <- rnorm(n, mean = 0, sd = 0.1)
y_data2 <- sin(x_data2) + epsilon_data2

x_data3 <- runif(n, min = 0, max = 10)
y_data3 <- runif(n, min = 0, max = 10)

x_data4 <- runif(n, min = 0, max = 10)
y_data4 <- mapply(function(mu, sigma) rnorm(1, mean = mu, sd = sigma),
                  mu = x_data4,
                  sigma = x_data4)

sample_data1_tbl <- tibble(
  x = x_data1,
  y = y_data1
)

sample_data2_tbl <- tibble(
  x = x_data2,
  y = y_data2
)

sample_data3_tbl <- tibble(
  x = x_data3,
  y = y_data3
)

sample_data4_tbl <- tibble(
  x = x_data4,
  y = y_data4
)

sample_data1_plot <- sample_data1_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_point(
    color = c_pal("C red"),
```

```
      size = 1,
      alpha = 1
    ) +
    geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
    labs(
      title = "Datos cúbicos",
      x = "",
      y = ""
    ) +
    theme_krul()

sample_data2_plot <- sample_data2_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_point(
    color = c_pal("C red"),
    size = 1,
    alpha = 1
  ) +
  geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
  labs(
    title = "Datos senoidales",
    x = "",
    y = ""
  ) +
  theme_krul()

sample_data3_plot <- sample_data3_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_point(
    color = c_pal("C red"),
    size = 1,
    alpha = 1
  ) +
  geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
  labs(
    title = "Datos aleatorios",
    x = "",
    y = ""
  ) +
  theme_krul()

sample_data4_plot <- sample_data4_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_point(
    color = c_pal("C red"),
```

```
size = 1,
alpha = 1
) +
geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
labs(
  title = "Datos con varianza creciente",
  x = "",
  y = ""
) +
theme_krul()

sample_data_plot <- (sample_data1_plot + sample_data2_plot) /
  (sample_data3_plot + sample_data4_plot)

sample_data_plot
```




Figura 1.4: Ajuste por mínimos cuadrados para diferentes conjuntos de datos.

Es bastante claro que en estos casos el ajuste por mínimos cuadrados no es el método adecuado para realizar predicciones confiables. En general, este método solo es efectivo cuando se cumplen ciertas hipótesis que estudiaremos en las siguientes secciones, cuando introduciremos el modelo de regresión lineal desde un punto de vista estadístico.

Capítulo 2

Intervalos de confianza y predicción en regresión lineal

En esta sección retomaremos nuestro modelo de regresión lineal simple, pero haremos más énfasis en su descripción utilizando álgebra lineal. Empecemos recordando que nuestro modelo está dado por la ecuación

$$Y_0 = b_0 + b_1 X_0 + \epsilon_0$$

donde $\epsilon_0 \sim N(0, \sigma^2)$. Recordemos también que estamos considerando los vectores aleatorios

$$X = \begin{bmatrix} X_1 \\ \vdots \\ X_n \end{bmatrix} \quad Y = \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix}$$

Suponemos además que tenemos los vectores de observaciones

$$x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \quad y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}$$

donde cada par (x_i, y_i) es una realización del vector aleatorio (X_i, Y_i) para $i = 1, \dots, n$. Consideraremos ahora la matriz de diseño

$$\Phi = \begin{bmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}$$

Entonces la fórmula para expresar nuestro método de aprendizaje de mínimos cuadrados puede escribirse de la siguiente manera:

$$\hat{B} = AY$$

donde

$$A = (\Phi^T \Phi)^{-1} \Phi^T$$

es la matriz de proyección sobre el subespacio generado por las columnas de la matriz de diseño Φ . Notemos que como $\hat{B}$ es una combinación lineal de variables aleatorias normales, entonces $\hat{B}$ también

es una variable aleatoria normal. En particular, podemos calcular su esperanza y su varianza de la siguiente manera:

$$\begin{aligned} E[\hat{B}] &= E[AY] = AE[Y] = A\Phi B = B \\ \text{Var}(\hat{B}) &= \text{Var}(AY) = A\text{Var}(Y)A^T = \sigma^2 AA^T = \sigma^2(\Phi^T \Phi)^{-1} \end{aligned}$$

donde hemos utilizado el hecho de que $\text{Var}(Y) = \sigma^2 I_n$. Notemos, en particular, que el estimador $\hat{B}$ es insesgado, es decir, $E[\hat{B}] = B$. De manera más explícita, la matriz de covarianza de $\hat{B}$ está dada por:

$$\text{Var}(\hat{B}) = \sigma^2 \begin{bmatrix} \frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} & -\frac{\sum_{i=1}^n \bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ -\frac{\sum_{i=1}^n \bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2} & \frac{\sum_{i=1}^n \bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \end{bmatrix}$$

Notemos que, en particular,

$$\hat{B}_0 \sim N\left(b_0, \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\right)\right)$$

y

$$\hat{B}_1 \sim N\left(b_1, \sigma^2 \left(\frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2}\right)\right)$$

Quisiéramos ahora construir intervalos de confianza para los parámetros b_0 y b_1 . Para ello, necesitamos una estimación de la varianza σ^2 . Recordemos que una estimación insesgada de σ^2 está dada por:

$$\hat{S}^2 = \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{F}(X_i))^2$$

donde $\hat{F}(X_i) = \hat{B}_0 + \hat{B}_1 X_i$. Notemos que la cantidad $n-2$ aparece en el denominador porque hemos estimado dos parámetros a partir de los datos. Por tanto, la siguiente variable tiene una distribución t de Student con $n-2$ grados de libertad:

$$T_j = \frac{\hat{B}_j - b_j}{\hat{S} \sqrt{\text{Var}(\hat{B}_j)/\sigma^2}} \sim t_{n-2}$$

para $j = 0, 1$. Por lo tanto, un intervalo de confianza para el parámetro b_j con un nivel de confianza $1 - \alpha$ está dado por:

$$\left(\hat{\beta}_j - t_{\alpha/2, n-2} \hat{s} \sqrt{\text{Var}(\hat{\beta}_j)/\sigma^2}, \quad \hat{B}_j + t_{\alpha/2, n-2} \hat{s} \sqrt{\text{Var}(\hat{B}_j)/\sigma^2} \right)$$

donde $t_{\alpha/2, n-2}$ es el cuantil superior de orden $\alpha/2$ de la distribución t de Student con $n-2$ grados de libertad.

Para construir un intervalo de confianza para la media de la variable dependiente Y_0 en un valor específico de la variable independiente $X_0 = x_0$, consideremos la predicción puntual dada por:

$$\hat{Y}_0 = \hat{B}_0 + \hat{B}_1 x_0$$

Notemos que $\hat{Y}_0$ es una variable aleatoria normal cuya esperanza y varianza están dadas por:

$$E[\hat{Y}_0] = E[\hat{B}_0 + \hat{B}_1 x_0] = b_0 + b_1 x_0$$

$$\text{Var}(\hat{Y}_0) = \text{Var}(\hat{B}_0 + \hat{B}_1 x_0) = \sigma^2 \left(\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)$$

Por lo tanto, la siguiente variable tiene una distribución t de Student con $n - 2$ grados de libertad:

$$T_C = \frac{\hat{Y}_0 - E[\hat{Y}_0]}{\hat{S} \sqrt{\text{Var}(\hat{Y}_0)/\sigma^2}} \sim t_{n-2}$$

Un intervalo de confianza para la media de la variable dependiente Y_0 en el valor $X_0 = x_0$ con un nivel de confianza $1 - \alpha$ está dado por:

$$\left(\hat{Y}_0 - t_{\alpha/2, n-2} \hat{S} \sqrt{\text{Var}(\hat{Y}_0)/\sigma^2}, \quad \hat{Y}_0 + t_{\alpha/2, n-2} \hat{S} \sqrt{\text{Var}(\hat{Y}_0)/\sigma^2} \right)$$

Finalmente, quisiéramos construir un intervalo de predicción para una nueva observación de la variable dependiente Y_0 en el valor $X_0 = x_0$. Consideremos la nueva observación

$$Y_0 = b_0 + b_1 x_0 + \epsilon_0$$

donde $\epsilon_0 \sim N(0, \sigma^2)$. Notemos que la diferencia entre la nueva observación Y_0 y la predicción puntual $\hat{Y}$ es una variable aleatoria normal cuya esperanza y varianza están dadas por:

$$E[Y_0 - \hat{Y}_0] = E[Y_0] - E[\hat{Y}_0] = 0$$

$$\text{Var}(Y_0 - \hat{Y}_0) = \text{Var}(Y_0) + \text{Var}(\hat{Y}_0) = \sigma^2 \left(1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)$$

Por lo tanto, la siguiente variable tiene una distribución t de Student con $n - 2$ grados de libertad:

$$T_P = \frac{Y_0 - \hat{Y}_0}{\hat{S} \sqrt{\text{Var}(Y_0 - \hat{Y}_0)/\sigma^2}} \sim t_{n-2}$$

Un intervalo de predicción para una nueva observación de la variable dependiente Y_0 en el valor $X_0 = x_0$ con un nivel de confianza $1 - \alpha$ está dado por:

$$\left(\hat{y}_0 - t_{\alpha/2, n-2} \hat{s} \sqrt{\text{Var}(Y_0 - \hat{Y}_0)/\sigma^2}, \quad \hat{y}_0 + t_{\alpha/2, n-2} \hat{s} \sqrt{\text{Var}(Y_0 - \hat{Y}_0)/\sigma^2} \right)$$

