



MA2003B Aplicación de Métodos Multivariados en Ciencia de Datos

Módulo 2: Relaciones de Dependencia

Profesor: Raul Gomez
Correo: rgomez@tec.mx
Oficina: A4-123A

Tabla de contenidos

I	Análisis de Regresión Lineal	3
1.	Método de mínimos cuadrados	5
2.	El modelo de regresión lineal simple	15
2.1.	Estimación de parámetros por intervalos de confianza	16
2.2.	Bandas de confianza y de predicción	17
3.	Significancia y verosimilitud en el modelo de regresión lineal	19
3.1.	La función de verosimilitud	19
3.2.	Significancia del modelo y de los parámetros	20
II	Análisis Discriminante Lineal	23
4.	El modelo discriminante gaussiano	25
4.1.	El clasificador bayesiano	25
4.2.	Las funciones discriminantes lineales	26
4.3.	Las variables canónicas	27
5.	Ajuste y adecuación del modelo discriminante gaussiano	29
5.1.	Ajuste del modelo discriminante gaussiano	29
5.1.1.	El método de estimación de Fisher (FE)	29
5.1.2.	El método de máxima verosimilitud (MLE)	30
5.1.3.	Comparación de los enfoques FE y MLE	31
5.2.	Verificación de la adecuación del modelo discriminante gaussiano	31
5.2.1.	Pruebas de normalidad multivariada	31
5.2.2.	Pruebas de Homoscedasticidad	32
5.2.3.	Evaluación del rendimiento del modelo	32
5.3.	Modelos alternativos	32

Parte I

Análisis de Regresión Lineal

Capítulo 1

Método de mínimos cuadrados

Supongamos que tenemos un conjunto de datos

$$((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$$

Por ejemplo, consideremos el siguiente conjunto de datos simulado:

```
library(tidyverse)
library(krulRutils)
library(latex2exp)

set.seed(123)

n <- 50
x_data <- runif(n, min = 0, max = 10)
epsilon_data <- rnorm(n, mean = 0, sd = 1)
y_data <- x_data + epsilon_data

sample_data_tbl <- tibble(
  x = x_data,
  y = y_data
)
```

Notemos que podemos visualizar estos datos mediante un diagrama de dispersión:

```
sample_data_plot <- sample_data_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_point(
    color = c_pal("C red"),
    size = 1,
    alpha = 1
  ) +
  coord_fixed() +
  labs(
```

```
title = "Datos simulados",
x = TeX("$X_{0}$"),
y = TeX("$Y_{0}$")
) +
theme_krul()

sample_data_plot
```




Figura 1.1: Diagrama de dispersión de los datos simulados.

Nos gustaría encontrar la línea recta que mejor se ajuste a estos datos. Hay varias formas de definir “mejor ajuste”, pero una de las más comunes es minimizar la suma de los errores al cuadrado (SSE por sus siglas en inglés) entre los valores observados y los valores correspondientes sobre la línea recta propuesta. De manera más precisa, buscamos una recta

$$Y_0 = \hat{f}(X_0) = \hat{\beta}_0 + \hat{\beta}_1 X_0$$

tal que si definimos $\hat{y}_i = \hat{f}(x_i)$ entonces minimicemos la suma

$$\text{SSE} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (1.1)$$

```
fitted_data_tbl <- sample_data_tbl %>%
  mutate(
    fitted = fitted(lm(y ~ x, data = .))
  )
```

```
fitted_data_plot <- fitted_data_tbl %>%  
  ggplot(aes(x = x, y = y)) +  
  geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +  
  geom_segment(  
    aes(xend = x, yend = fitted),  
    color = c_pal("C green"),  
    alpha = 1  
  ) +  
  geom_point(color = c_pal("C red"), size = 1, alpha = 1) +  
  geom_point(  
    aes(x = x, y = fitted),  
    color = c_pal("C red"),  
    size = 1,  
    alpha = 1  
  ) +  
  coord_fixed() +  
  labs(  
    title = "Recta ajustada",  
    x = TeX("$X_{0}$"),  
    y = TeX("$Y_{0}$")  
  ) +  
  theme_krul()  
  
fitted_data_plot
```

Recta ajustada




Figura 1.2: Línea recta que mejor se ajusta a los datos simulados, bajo el criterio de mínimos cuadrados. En otras palabras, esta es la línea recta que minimiza el SSE.

Para encontrar la fórmula para $\hat{\beta}_0$ y $\hat{\beta}_1$ en términos de nuestros datos, utilizaremos un poco de álgebra lineal. Empecemos por fijar los vectores

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

que llamaremos el *vector de las observaciones independientes* y el *vector de las observaciones dependientes*, respectivamente. Fijamos ahora la llamada *matriz de diseño*, dada por,

$$\Phi = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}$$

y notamos que si definimos

$$\hat{y} = \begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_n \end{bmatrix}$$

entonces $\hat{y} = \Phi \hat{\beta}$ donde

$$\hat{\beta} = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{bmatrix}$$

Notemos que para minimizar la suma de los errores al cuadrado dada en la ecuación (1.1), necesitamos encontrar la proyección ortogonal del vector y sobre el espacio generado por las columnas de la matriz Φ . Empezamos por calcular la *matriz de coeficientes*

$$D^2 = (\Phi^T \Phi)^{-1} = \begin{bmatrix} \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} & -\frac{\bar{x}}{S_{xx}} \\ -\frac{\bar{x}}{S_{xx}} & \frac{1}{S_{xx}} \end{bmatrix}$$

donde

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{y} \quad S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$$

Calculamos ahora la *matriz de estimadores de mínimos cuadrados*

$$A = D^2 \Phi^T = (\Phi^T \Phi)^{-1} \Phi^T = \begin{bmatrix} \frac{1}{n} + \frac{\bar{x}(\bar{x}-x_1)}{S_{xx}} & \cdots & \frac{1}{n} + \frac{\bar{x}(\bar{x}-x_n)}{S_{xx}} \\ \frac{x_1-\bar{x}}{S_{xx}} & \cdots & \frac{x_n-\bar{x}}{S_{xx}} \end{bmatrix}$$

y, finalmente, calculamos la *matriz sombrero*

$$H = \Phi A = \Phi (\Phi^T \Phi)^{-1} \Phi^T$$

Notemos que las entradas de la matriz H están dadas por:

$$h_{ij} = \frac{1}{n} + \frac{(x_i - \bar{x})(x_j - \bar{x})}{S_{xx}}$$

en particular,

$$h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}$$

Utilizando estas matrices, podemos calcular

$$\hat{\beta} = Ay \quad \text{y} \quad \hat{y} = Hy$$

Para ilustrar este procedimiento, consideremos el siguiente ejemplo.

Ejemplo. Consideremos el siguiente conjunto de datos:

```
set.seed(123)

n <- 5
x_data <- 1:n
epsilon_data <- rnorm(n, mean = 0, sd = n / 10)
y_data <- x_data + epsilon_data
sample_data_tbl <- tibble(
  x = x_data,
  y = y_data
)
```

Notemos que los vectores de observaciones independientes y dependientes son:

$$x = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{bmatrix} \quad y = \begin{bmatrix} 0.72 \\ 1.88 \\ 3.78 \\ 4.04 \\ 5.06 \end{bmatrix}$$

y la matriz de diseño es:

```
Phi <- matrix(c(rep(1, n), x_data), nrow = n, ncol = 2)
```

$$\Phi = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{bmatrix}$$

Calculamos ahora la matriz de coeficientes:

```
D2 <- solve(t(Phi) %*% Phi)
```

$$D^2 = \begin{bmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{bmatrix}$$

y la matriz de estimadores de mínimos cuadrados:

```
A <- D2 %*% t(Phi)
```

$$A = \begin{bmatrix} 0.8 & 0.5 & 0.2 & -0.1 & -0.4 \\ -0.2 & -0.1 & 0 & 0.1 & 0.2 \end{bmatrix}$$

Finalmente, la matriz sombrero es:

```
H <- Phi %*% A
```

$$H = \begin{bmatrix} 0.6 & 0.4 & 0.2 & 0 & -0.2 \\ 0.4 & 0.3 & 0.2 & 0.1 & 0 \\ 0.2 & 0.2 & 0.2 & 0.2 & 0.2 \\ 0 & 0.1 & 0.2 & 0.3 & 0.4 \\ -0.2 & 0 & 0.2 & 0.4 & 0.6 \end{bmatrix}$$

Utilizando estas matrices, podemos rápidamente calcular los vectores $\hat{\beta}$ y $\hat{y}$:

```
beta_hat <- A %*% y_data
y_hat <- H %*% y_data
```

$$\hat{\beta} = \begin{bmatrix} -0.16 \\ 1.08 \end{bmatrix} \quad \hat{y} = \begin{bmatrix} 0.93 \\ 2.01 \\ 3.1 \\ 4.18 \\ 5.26 \end{bmatrix}$$

Notemos que en este caso la suma de los errores al cuadrado (SSE) es:

```
sse <- sum((y_data - y_hat)^2)
```

$$\text{SSE} = 0.59$$

La siguiente figura ilustra el ajuste por mínimos cuadrados para este conjunto de datos:

```
fitted_example_data_tbl <- sample_data_tbl %>%
  mutate(
    fitted = as.vector(y_hat)
  )
fitted_example_data_plot <- fitted_example_data_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
  geom_segment(
    aes(xend = x, yend = fitted),
    color = c_pal("C green"),
    alpha = 1
  ) +
  geom_point(color = c_pal("C red"), size = 1, alpha = 1) +
```

```
geom_point(
  aes(x = x, y = fitted),
  color = c_pal("C red"),
  size = 1,
  alpha = 1
) +
coord_fixed() +
labs(
  title = "Recta ajustada",
  x = TeX("$X_{0}$"),
  y = TeX("$Y_{0}$")
) +
theme_krul()
fitted_example_data_plot
```




Figura 1.3: Ajuste por mínimos cuadrados para el conjunto de datos del ejemplo.

Notemos que este proceso se puede aplicar a cualquier conjunto de datos dado, sin embargo una de las aplicaciones más comunes de este método es tratar de predecir el valor de la variable Y_0 dado un valor específico de la variable X_0 que no se encuentre en el conjunto de datos original. Se sigue que para que estas predicciones sean de utilidad, es necesario que el comportamiento de nuestros datos siga una tendencia lineal, ya que en caso contrario las predicciones podrían no ser confiables. Por ejemplo, consideremos el ajuste por el método de mínimos cuadrados para los siguientes conjuntos de datos:

```
library(patchwork)

set.seed(123)

n <- 500
x_data1 <- runif(n, min = 0, max = 10)
epsilon_data1 <- rnorm(n, mean = 0, sd = 50)
y_data1 <- (x_data1)^3 + epsilon_data1

x_data2 <- runif(n, min = 0, max = 10)
epsilon_data2 <- rnorm(n, mean = 0, sd = 0.1)
y_data2 <- sin(x_data2) + epsilon_data2

x_data3 <- runif(n, min = 0, max = 10)
y_data3 <- runif(n, min = 0, max = 10)

x_data4 <- runif(n, min = 0, max = 10)
y_data4 <- mapply(function(mu, sigma) rnorm(1, mean = mu, sd = sigma),
                  mu = x_data4,
                  sigma = x_data4)

sample_data1_tbl <- tibble(
  x = x_data1,
  y = y_data1
)

sample_data2_tbl <- tibble(
  x = x_data2,
  y = y_data2
)

sample_data3_tbl <- tibble(
  x = x_data3,
  y = y_data3
)

sample_data4_tbl <- tibble(
  x = x_data4,
  y = y_data4
)

sample_data1_plot <- sample_data1_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_point(
    color = c_pal("C red"),
```

```
      size = 1,
      alpha = 1
    ) +
    geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
    labs(
      title = "Datos cúbicos",
      x = "",
      y = ""
    ) +
    theme_krul()

sample_data2_plot <- sample_data2_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_point(
    color = c_pal("C red"),
    size = 1,
    alpha = 1
  ) +
  geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
  labs(
    title = "Datos senoidales",
    x = "",
    y = ""
  ) +
  theme_krul()

sample_data3_plot <- sample_data3_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_point(
    color = c_pal("C red"),
    size = 1,
    alpha = 1
  ) +
  geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
  labs(
    title = "Datos aleatorios",
    x = "",
    y = ""
  ) +
  theme_krul()

sample_data4_plot <- sample_data4_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_point(
    color = c_pal("C red"),
```

```
size = 1,
alpha = 1
) +
geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
labs(
  title = "Datos con varianza creciente",
  x = "",
  y = ""
) +
theme_krul()

sample_data_plot <- (sample_data1_plot + sample_data2_plot) /
  (sample_data3_plot + sample_data4_plot)

sample_data_plot
```




Figura 1.4: Ajuste por mínimos cuadrados para diferentes conjuntos de datos.

Es bastante claro que en estos casos el ajuste por mínimos cuadrados no es el método adecuado para realizar predicciones confiables. En general, este método solo es efectivo cuando se cumplen ciertas hipótesis que estudiaremos en las siguientes secciones, cuando introduciremos el modelo de regresión lineal desde un punto de vista estadístico.

Capítulo 2

El modelo de regresión lineal simple

En un *modelo de regresión simple*, suponemos que tenemos una *variable independiente* X_0 (también conocida como *variable explicativa* o *predictora*), y una *variable dependiente* Y_0 (también conocida como *variable de respuesta*). Suponemos además que estas variables satisfacen una relación de la forma:

$$Y_0 = f_0(X_0) + \epsilon_0$$

donde f_0 es una función desconocida que describe la relación entre ambas variables, y ϵ_0 es una variable aleatoria que representa el *error* o *ruido* en la relación entre X_0 e Y_0 . Uno de los objetivos del *aprendizaje estadístico* (también conocido como *aprendizaje automático* o *machine learning*), es tratar de aproximar la función f_0 a partir de un conjunto de datos

$$((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$$

dado. De manera más precisa, consideremos vectores aleatorios

$$X = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{bmatrix}, \quad Y = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}$$

que representan los posibles valores de las observaciones independientes y dependientes, respectivamente, en una muestra dada. En este contexto, un *método de aprendizaje* consiste de una función $\hat{F}$, que depende de los vectores aleatorios X e Y , y que cuando se evalúa en los datos observados produce una función $\hat{f}$ que aproxima a la función desconocida f_0 .

Nota 2.0.1. En muchos modelos de aprendizaje estadístico es común tomar el vector $X = x$ como fijo, en cuyo caso la función $\hat{F}$ depende únicamente del vector aleatorio Y .

Para hacer estas ideas un poco más concretas, consideremos el caso particular en el que la función desconocida f_0 es una función lineal, es decir,

$$f_0(X_0) = b_0 + b_1 X_0$$

y supondremos además que $\epsilon_0 \sim \mathcal{N}(0, \sigma^2)$ es una variable aleatoria con distribución normal de media 0 y varianza σ^2 . Este contexto se conoce como el *modelo de regresión lineal simple* y es uno de los modelos más utilizados en aprendizaje estadístico. Notemos que en este caso nuestro objetivo es encontrar una expresión que nos permita aproximar los parámetros desconocidos b_0 y b_1 en términos de los datos observados. Para ello consideraremos las expresiones que obtuvimos en la sección anterior para los coeficientes de la recta de mejor ajuste por mínimos cuadrados, pero utilizando ahora el vector aleatorio Y en lugar del vector de observaciones y . En otras palabras, definiremos

$$\Phi = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}$$

y consideraremos las matrices $D^2 = (\Phi^T \Phi)^{-1}$, $A = D^2 \Phi^T$ y $H = \Phi A$. Entonces podemos definir el *vector aleatorio de estimadores de mínimos cuadrados* como:

$$\hat{B} = AY$$

Notemos que, a diferencia de la sección anterior, en este caso $\hat{B}$ no es un vector de valores fijos, sino que es un vector aleatorio que depende linealmente del vector aleatorio Y . Además, de las propiedades de la distribución normal multivariada, sabemos que

$$\hat{B} \sim \mathcal{N}(b, \sigma^2 D^2)$$

donde

$$b = \begin{bmatrix} b_0 \\ b_1 \end{bmatrix}$$

es el vector de parámetros desconocidos. Notemos que, en particular, el vector aleatorio $\hat{B}$ es un estimador insesgado del vector de parámetros b , es decir, $E[\hat{B}] = b$. Notemos además que si evaluamos el vector aleatorio $\hat{B}$ en los datos observados $Y = y$, obtenemos el vector de coeficientes $\hat{\beta}$ de la recta de mejor ajuste por mínimos cuadrados que obtuvimos en la sección anterior. Una vez hechas estas observaciones, nuestro siguiente objetivo será construir los intervalos de confianza para los parámetros b_0 y b_1 .

2.1. Estimación de parámetros por intervalos de confianza

Empecemos por definir las cantidades

$$d_0^2 = D_{11}^2 = \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}$$

$$d_1^2 = D_{22}^2 = \frac{1}{S_{xx}}$$

donde

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$$

tal y como lo habíamos definido en la sección anterior. Entonces

$$\begin{aligned}\hat{B}_0 &\sim \mathcal{N}(b_0, \sigma^2 d_0^2) \\ \hat{B}_1 &\sim \mathcal{N}(b_1, \sigma^2 d_1^2)\end{aligned}$$

Consideremos ahora la variable aleatoria

$$\hat{S}^2 = \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

donde

$$\hat{Y} = \begin{bmatrix} \hat{Y}_1 \\ \hat{Y}_2 \\ \vdots \\ \hat{Y}_n \end{bmatrix} = HY$$

es el *vector aleatorio de predicciones por mínimos cuadrados*. Entonces tenemos que

$$\frac{(n-2)\hat{S}^2}{\sigma^2} \sim \chi_{n-2}^2$$

y, además, la variable aleatoria $\hat{S}^2$ es independiente de las variables aleatorias $\hat{B}_0$ y $\hat{B}_1$. Por lo tanto, podemos construir las nuevas variables aleatorias

$$\begin{aligned}T_0 &= \frac{\hat{B}_0 - b_0}{\hat{S}d_0} \sim t_{n-2} \\ T_1 &= \frac{\hat{B}_1 - b_1}{\hat{S}d_1} \sim t_{n-2}\end{aligned}$$

donde t_{n-2} denota la distribución t de Student con $n-2$ grados de libertad. Con esta información, podemos construir ahora los intervalos de confianza para los parámetros b_0 y b_1 , tal y como nos lo habíamos propuesto. Empecemos por fijar un nivel de significancia α y sea $t_{\alpha/2, n-2}$ el cuantil superior de orden $\alpha/2$ de la distribución t de Student correspondiente. Entonces, si tomamos $\hat{s}$ como el valor de la variable aleatoria $\hat{S}$ evaluada en el vector de datos observados $Y = y$, tenemos que los intervalos de confianza buscados son

$$(\hat{\beta}_0 - t_{\alpha/2, n-2} \hat{s}d_0, \hat{\beta}_0 + t_{\alpha/2, n-2} \hat{s}d_0)$$

para b_0 , y

$$(\hat{\beta}_1 - t_{\alpha/2, n-2} \hat{s}d_1, \hat{\beta}_1 + t_{\alpha/2, n-2} \hat{s}d_1)$$

para b_1 .

2.2. Bandas de confianza y de predicción

Una vez obtenidos los intervalos de confianza para los parámetros b_0 y b_1 , nos gustaría obtener ahora los intervalos de confianza para los posibles valores de la variable dependiente Y_0 en un valor

específico de la variable independiente $X_0 = x_0$. Para esto empezaremos por considerar la matriz de diseño en el punto x_0 :

$$\Phi_0 = \begin{bmatrix} 1 & x_0 \end{bmatrix}$$

y definiremos el vector aleatorio

$$\hat{Y}_0 = \Phi_0 \hat{B} = \hat{B}_0 + \hat{B}_1 x_0$$

Notemos que este vector aleatorio depende solamente de las variables $\hat{B}_0$ y $\hat{B}_1$ (las cuales, a su vez, dependen solamente de las variables $Y_1, Y_2, \dots, Y_n$), y es independiente de la variable aleatoria Y_0 . Usando nuevamente las propiedades de la distribución normal multivariada, podemos ver que

$$\hat{Y}_0 \sim \mathcal{N}(\Phi_0 b, \sigma^2 d_c^2)$$

donde

$$d_c^2 = \Phi_0 D^2 \Phi_0^T = \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}$$

Finalmente, como $\hat{Y}_0$ es independiente de la variable aleatoria $\hat{S}^2$, podemos construir la variable aleatoria

$$T_c = \frac{\hat{Y}_0 - \Phi_0 b}{\hat{S} d_c} \sim t_{n-2}$$

Se sigue que para construir un intervalo de confianza para el valor esperado de la variable dependiente Y_0 en el punto $X_0 = x_0$, basta con tomar el intervalo

$$(\hat{y}_0 - t_{\alpha/2, n-2} \hat{S} d_c, \hat{y}_0 + t_{\alpha/2, n-2} \hat{S} d_c)$$

donde $\hat{y}_0$ es el valor de la variable aleatoria $\hat{Y}_0$ evaluada en los datos observados $Y = y$. Notemos que este intervalo depende del punto $X_0 = x_0$ que hayamos elegido. De manera más general, podemos considerar el conjunto de todos los intervalos de confianza para todos los posibles valores de x_0 , el cual se conoce como la *banda de confianza* del modelo de regresión lineal simple.

Para terminar, notemos que como Y_0 es independiente de $\hat{Y}_0$, tenemos que

$$Y_0 - \hat{Y}_0 \sim \mathcal{N}(0, \sigma^2 d_p^2)$$

donde

$$d_p^2 = 1 + d_c^2 = 1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}$$

Usando nuevamente la variable aleatoria $\hat{S}^2$, podemos definir ahora

$$T_p = \frac{Y_0 - \hat{Y}_0}{\hat{S} d_p} \sim t_{n-2}$$

y, de manera similar a como lo hicimos antes, podemos construir un *intervalo de predicción* para el valor de la variable dependiente Y_0 en el punto $X_0 = x_0$ como

$$(\hat{y}_0 - t_{\alpha/2, n-2} \hat{S} d_p, \hat{y}_0 + t_{\alpha/2, n-2} \hat{S} d_p)$$

Nuevamente, el conjunto de todos estos intervalos de predicción para todos los posibles valores de x_0 se conoce como la *banda de predicción* del modelo de regresión lineal simple.

Capítulo 3

Significancia y verosimilitud en el modelo de regresión lineal

Recordemos que estamos considerando un modelo de regresión lineal de la forma:

$$Y_0 = b_0 + b_1 X_{01} + b_2 X_{02} + \cdots + b_p X_{0p} + \epsilon_0$$

donde $\epsilon_0 \sim \mathcal{N}(0, \sigma^2)$. Notemos que este modelo depende de los parámetros $b_0, b_1, \dots, b_p$ y σ^2 . En este capítulo, nos enfocaremos en el estudio de estos parámetros y sus propiedades estadísticas. En particular, nos interesará conocer la significancia de los parámetros y la función de verosimilitud de los mismos.

3.1. La función de verosimilitud

Supongamos que tenemos un conjunto de datos

$$x = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

La función de verosimilitud del modelo de regresión lineal es una función que nos da una medida de la consistencia entre los datos dados y los parámetros considerados en el modelo. En nuestro caso, la función de verosimilitud es:

$$L(b_0, b_1, \dots, b_p, \sigma^2 | x, y) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{(y_i - (b_0 + b_1 x_{i1} + \cdots + b_p x_{ip}))^2}{2\sigma^2} \right)$$

que corresponde, simplemente, a la función de densidad del modelo considerado con los parámetros indicados y los datos observados. Notemos que en esta función, al contrario del capítulo anterior, estamos considerando los datos x e y como fijos, y los parámetros $b_0, b_1, \dots, b_p$ y σ^2 como variables. Nuestro siguiente objetivo será encontrar los valores de estos parámetros que maximicen la función de verosimilitud, es decir, que hagan que los datos observados sean lo más consistentes posible con el

modelo. Empezaremos por considerar la log-verosimilitud, que es simplemente el logaritmo natural de la función de verosimilitud:

$$\begin{aligned}\ell(b_0, b_1, \dots, b_p, \sigma^2 | x, y) &= \log L(b_0, b_1, \dots, b_p, \sigma^2 | x, y) \\ &= -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - (b_0 + b_1 x_{i1} + \dots + b_p x_{ip}))^2\end{aligned}\quad (3.1)$$

notemos que maximizar la función de verosimilitud es equivalente a maximizar la log-verosimilitud, ya que el logaritmo es una función monótonamente creciente. Por otro lado, para encontrar los valores de

$$b = \begin{bmatrix} b_0 \\ b_1 \\ \vdots \\ b_p \end{bmatrix}$$

que maximicen la log-verosimilitud, nos basta con minimizar la expresión:

$$\sum_{i=1}^n (y_i - (b_0 + b_1 x_{i1} + \dots + b_p x_{ip}))^2$$

Se sigue que podemos utilizar el método de los mínimos cuadrados para encontrar los valores de los parámetros que buscamos:

$$b_{\text{MLE}} = \hat{\beta} = (\Phi^T \Phi)^{-1} \Phi^T y$$

donde

$$\Phi = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix}$$

es la matriz de diseño asociada a nuestros datos. Finalmente, para encontrar el valor de σ^2 que maximice la log-verosimilitud, podemos derivar la expresión (3.1) con respecto a σ^2 y encontrar el valor que hace que la derivada sea cero. Esto nos lleva a la siguiente expresión para el estimador de máxima verosimilitud de σ^2 :

$$\sigma_{\text{MLE}}^2 = \frac{1}{n} \sum_{i=1}^n [y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \dots + \hat{\beta}_p x_{ip})]^2 = \frac{\text{sse}}{n}$$

Desde este punto de vista, hemos obtenido una función que a cada conjunto de datos le asigna su máxima verosimilitud o, más precisamente, su máxima log-verosimilitud bajo el modelo de regresión lineal. Notemos que este valor está dado de manera explícita por:

$$\ell(\hat{\beta}, \sigma_{\text{MLE}}^2 | x, y) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log\left(\frac{\text{sse}}{n}\right) - \frac{n}{2}$$

3.2. Significancia del modelo y de los parámetros

Nos gustaría ahora poder afirmar que los valores de las variables independientes $X_{01}, X_{02}, \dots, X_{0p}$ tienen un efecto significativo en la variable dependiente Y_0 . En particular, nos gustaría poder

afirmar que al menos uno de los parámetros $b_1, b_2, \dots, b_p$ es significativamente distinto de cero. De acuerdo al formalismo de las pruebas de hipótesis, lo que debemos hacer ahora es plantear una hipótesis nula que dice que todos los parámetros son iguales y tratar de reunir una evidencia estadísticamente significativa que nos permita rechazar esta hipótesis. Con estas consideraciones en mente, consideraremos la *suma total de cuadrados* (SST, por sus siglas en inglés) definida como:

$$SST = \sum_{i=1}^n (Y_i - \bar{Y})^2 = \|Y - \bar{Y}\mathbf{1}\|^2$$

donde

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$$

es la media muestral de la variable dependiente y $\mathbf{1}$ es el vector columna de n entradas iguales a uno. La SST se puede interpretar como una variable aleatoria que mide la variabilidad total de los datos asociados a una observación y se puede descomponer como

$$SST = SSR + SSE$$

donde

$$SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \|Y - \hat{Y}\|^2$$

es la suma de los errores al cuadrado que habíamos considerado anteriormente y que corresponde a la variabilidad de los datos que no es explicada por el modelo, y

$$SSR = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 = \|\hat{Y} - \bar{Y}\mathbf{1}\|^2$$

es la *suma de cuadrados de la regresión* y corresponde a la variabilidad de los datos que nuestro modelo explica. Como ya habíamos mencionado anteriormente,

$$\frac{SSE}{\sigma^2} \sim \chi_{n-p-1}^2$$

Por otro lado, bajo la hipótesis nula de que todos los parámetros $b_1, b_2, \dots, b_p$ son iguales a cero, se puede demostrar que

$$\frac{SSR}{\sigma^2} \sim \chi_p^2$$

y además, que SSE y SSR son independientes. Con estas consideraciones en mente, podemos definir el estadístico de prueba

$$F = \frac{SSR/p}{SSE/(n-p-1)} \sim F_{p, n-p-1}$$

donde $F_{p, n-p-1}$ es la distribución F de Fisher con p y $n-p-1$ grados de libertad. Notemos que valores grandes de F indican que la variabilidad explicada por el modelo es grande en comparación con la variabilidad no explicada, lo cual constituye evidencia en contra de la hipótesis nula. Por lo tanto, para nuestra prueba de hipótesis, usaremos una regla de una cola por la derecha. En particular, si f es el valor de nuestro estadístico F evaluado en una observación $Y = y$, entonces el p -valor de la prueba es

$$p_F = P_F(F \geq f)$$

Si $p < \alpha$, para algún nivel de significancia α preestablecido, entonces rechazamos la hipótesis nula y concluimos que al menos uno de los parámetros $b_1, b_2, \dots, b_p$ es significativamente diferente de cero. Resumiendo, tenemos el siguiente procedimiento para evaluar la significancia del modelo de regresión lineal:

1. Plantear la hipótesis nula y la hipótesis alternativa:

H_0 : Todos los parámetros son iguales a cero, es decir $b_1 = b_2 = \dots = b_p = 0$

H_1 : Al menos uno de los parámetros $b_1, b_2, \dots, b_p$ es diferente de cero.

2. Calcular el estadístico de prueba

$$F = \frac{SSR/p}{SSE/(n-p-1)}$$

para el vector de datos observados $Y = y$.

3. Calcular el p -valor de la prueba

$$p_F = P_{F,p,n-p-1}(F \geq f)$$

donde f es el valor del estadístico F calculado en el paso anterior.

4. Si $p_F < \alpha$, para algún nivel de significancia α preestablecido, entonces rechazamos la hipótesis nula y concluimos que al menos uno de los parámetros $b_1, b_2, \dots, b_p$ es significativamente diferente de cero.

Parte II

Análisis Discriminante Lineal

Capítulo 4

El modelo discriminante gaussiano

El *análisis discriminante lineal* (LDA, por sus siglas en inglés) es un método de clasificación supervisada que permite separar dos o más clases basándose en las características más relevantes capturadas por un conjunto de datos dado. Este método de clasificación se basa en el *modelo discriminante gaussiano*, que asume que nuestra población se encuentra separada en K clases distintas (también conocidas como grupos o categorías) por una variable categórica G . El modelo también asume que tenemos un vector aleatorio continuo

$$X = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix}$$

que captura las características relevantes de los individuos en nuestra población. Una de las hipótesis más importantes de este modelo es que para cada grupo $G = i$, el vector aleatorio X sigue una distribución normal multivariada con media μ_i y matriz de covarianza Σ , es decir,

$$X|(G = i) \sim \mathcal{N}(\mu_i, \Sigma)$$

Notemos que la matriz de covarianza es la misma para todos los grupos. Esta condición es conocida como *homocedasticidad* y es uno de los supuestos fundamentales del modelo discriminante gaussiano.

4.1. El clasificador bayesiano

Recordemos que una *función de clasificación* es una función g que asigna a cada observación $X = x$ una clase $G = i$, es decir, $g(x) = i$. El objetivo del análisis discriminante lineal es encontrar una función de clasificación que minimice la *tasa de error de clasificación*, la cual está dada por

$$R(g) = E[1_{g(X) \neq G}] = P(g(X) \neq G)$$

donde $1_{g(X) \neq G}$ es una variable indicadora que toma el valor de 1 si la clasificación es incorrecta y 0 en caso contrario, $E[1_{g(X) \neq G}]$ es la esperanza de esta variable aleatoria y $P(g(X) \neq G)$ es la probabilidad de que la clasificación sea incorrecta. La solución al problema de encontrar la función de clasificación óptima está dada por el teorema de Bayes:

Teorema 4.1.1 (Teorema de Bayes para clasificación). *El clasificador que minimiza la tasa de error de clasificación es el clasificador de Bayes $\hat{g}$ que está dado por*

$$\hat{g}(x) = \arg \max_i P(G = i | X = x)$$

donde $P(G = i | X = x)$ es la probabilidad condicional de que la clase sea $G = i$ dado que la observación es $X = x$.

4.2. Las funciones discriminantes lineales

Buscamos ahora una forma más explícita para el clasificador de Bayes bajo el modelo discriminante gaussiano. Empezaremos por introducir las llamadas *probabilidades previas* (también conocidas como *probabilidades a priori* o *priors*) de cada clase, las cuales están dadas por

$$\pi_i = P(G = i)$$

Notemos que este valor es simplemente la probabilidad de que un individuo seleccionado al azar de entre nuestra población pertenezca a la clase $G = i$. También consideraremos las *probabilidades posteriores* (también conocidas como *probabilidades a posteriori* o *posteriors*) de cada clase, las cuales están dadas por

$$P(G = i | X = x)$$

En este caso, este valor representa la probabilidad de que un individuo pertenezca a la clase $G = i$ una vez que hemos observado sus características $X = x$. Para calcular este valor, recordemos que estamos suponiendo que $X | (G = i) \sim \mathcal{N}(\mu_i, \Sigma)$, por lo que la función de densidad condicional de X dado $G = i$ está dada por

$$f_i(X) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} (X - \mu_i)^T \Sigma^{-1} (X - \mu_i) \right)$$

Usando la fórmula de Bayes, podemos expresar las probabilidades posteriores en términos de las probabilidades previas y las funciones de densidad condicional:

$$P(G = i | X = x) = \frac{\pi_i f_i(x)}{\sum_j \pi_j f_j(x)}$$

Notemos que el denominador en el lado derecho de esta ecuación es el mismo para todas las clases. En particular, la probabilidad posterior $P(G = i | X = x)$ es un múltiplo positivo de la cantidad $\pi_i f_i(x)$, en símbolos,

$$P(G = i | X = x) \propto \pi_i f_i(x)$$

Se sigue que para encontrar el clasificador de Bayes, podemos concentrarnos en la expresión $\pi_i f_i(x)$. De hecho, como el logaritmo es una función monótonamente creciente, nos basta con concentrarnos en maximizar

$$\begin{aligned} \log(\pi_i f_i(x)) &= \log(\pi_i) + \log(f_i(x)) \\ &= \log(\pi_i) - \frac{p}{2} \log(2\pi) - \frac{1}{2} \log(|\Sigma|) - \frac{1}{2} (x - \mu_i)^T \Sigma^{-1} (x - \mu_i) \\ &= \log(\pi_i) - \frac{p}{2} \log(2\pi) - \frac{1}{2} \log(|\Sigma|) - \frac{1}{2} x^T \Sigma^{-1} x + \mu_i^T \Sigma^{-1} x - \frac{1}{2} \mu_i^T \Sigma^{-1} \mu_i \end{aligned}$$

Notemos que la expresión

$$-\frac{p}{2} \log(2\pi) - \frac{1}{2} \log(|\Sigma|) - \frac{1}{2} x^T \Sigma^{-1} x$$

aparece en todas nuestras clases. Por lo tanto, si definimos las *funciones discriminantes lineales* como

$$\delta_i(x) = \mu_i^T \Sigma^{-1} x - \frac{1}{2} \mu_i^T \Sigma^{-1} \mu_i + \log(\pi_i)$$

entonces tenemos que las diferencias

$$\Delta_{i,j}(x) = \log(\pi_i f_i(x)) - \log(\pi_j f_j(x)) = \delta_i(x) - \delta_j(x)$$

dependen únicamente de estas funciones. En particular, el clasificador de Bayes se puede reescribir como

$$\hat{g}(x) = \arg \max_i \delta_i(x)$$

4.3. Las variables canónicas

Además de proporcionar un método de clasificación, una de las aplicaciones más importantes del análisis discriminante lineal es la reducción de la dimensionalidad de los datos. De manera más explícita, el análisis discriminante lineal nos permite definir nuevas variables, llamadas *variables canónicas*, que capturan toda la información relevante para separar las distintas clases, pero en un espacio de menor dimensión. Para poder definir estas variables, empecemos por notar que la media total de la población está dada por

$$\mu = E[X] = \sum_i \pi_i \mu_i$$

Definimos ahora la *matriz de dispersión total* como

$$ST = E[(X - \mu)(X - \mu)^T] = \text{Var}[X]$$

Consideraremos también la *matriz de dispersión dentro de los grupos*, la cual está dada por

$$SW = E_G[\text{Var}_X[X|G]] = \sum_i \pi_i \Sigma = \Sigma$$

donde E_G representa la esperanza con respecto a la variable categórica G y $\text{Var}_X[X|G]$ representa la varianza condicional de X dado G . Finalmente, consideraremos la *matriz de dispersión entre los grupos*, la cual está dada por

$$SB = \text{Var}_G[E_X[X|G]] = \sum_i \pi_i (\mu_i - \mu)(\mu_i - \mu)^T$$

donde Var_G representa la varianza con respecto a la variable categórica G y $E_X[X|G]$ representa la esperanza condicional de X dado G . Ya con estas definiciones, podemos escribir la *fórmula de la descomposición de la varianza* que nos dice que

$$ST = SW + SB$$

Notemos ahora que si $a = [a_1, a_2, \dots, a_p]$ es una matriz de $1 \times p$, entonces podemos considerar la variable aleatoria $Y = aX$, la cual es una combinación lineal de las variables originales $X_1, X_2, \dots, X_p$. La varianza total de esta nueva variable está dada por

$$\text{Var}[Y] = a(\text{ST})a^T$$

la varianza dentro de los grupos está dada por

$$E_G[\text{Var}_Y[Y|G]] = a(\text{SW})a^T = a\Sigma a^T$$

y la varianza entre los grupos está dada por

$$\text{Var}_G[E_Y[Y|G]] = a(\text{SB})a^T$$

Para construir nuestras variable canónicas, buscamos variables que maximicen la varianza entre los grupos en relación con la varianza dentro de los grupos. En otras palabras, queremos maximizar el *cociente de Rayleigh* definido como

$$J(a) = \frac{a\text{SB}a^T}{a\text{SW}a^T}$$

De manera más precisa, el *criterio de Fisher* nos dice que las variables canónicas deben de satisfacer las siguientes condiciones:

- La primera variable canónica $Y_1 = a_1X$ es aquella que maximiza el cociente $J(a)$, es decir,

$$a_1 = \arg \max_a J(a)$$

- La j -ésima variable canónica $Y_j = a_jX$ es aquella que maximiza el cociente $J(a)$ bajo la restricción de que no esté correlacionada, dentro de los grupos, con las variables canónicas anteriores, es decir,

$$a_j = \arg \max_a J(a) \quad \text{sujeto a} \quad \text{Cov}[Y_i, Y_j|G] = 0 \quad \text{para } i < j$$

Es importante notar que el número máximo de variables canónicas que se pueden obtener es $\min(p, K - 1)$, donde p es el número de características en nuestro vector aleatorio X y K es el número de clases en nuestra población. Esto se debe a que la matriz de dispersión entre los grupos SB tiene rango máximo $r = \min(p, K - 1)$. Finalmente, se puede verificar que las funciones

$$\Delta_{i,j}(x) = \delta_i(x) - \delta_j(x)$$

solo dependen de las primeras r variables canónicas. En particular, esto implica que el clasificador de Bayes también solo depende de estas variables.

Capítulo 5

Ajuste y adecuación del modelo discriminante gaussiano

En el capítulo anterior discutimos el modelo del discriminante gaussiano desde un punto de vista teórico. También describimos como reducir la dimensionalidad de nuestro modelo proyectando los resultados de nuestras observaciones en el espacio LDA que construimos en ese capítulo y, finalmente, mostramos como podemos construir funciones discriminantes lineales que nos permiten clasificar nuestras observaciones basadas solamente en la información contenida en nuestro espacio LDA. En este capítulo estudiaremos como podemos ajustar este modelo a un conjunto de datos dado y verificar la adecuación de este ajuste. Una vez que tenemos un modelo ajustado y verificado, podemos utilizar las técnicas descritas en el capítulo anterior para reducir la dimensionalidad de nuestro conjunto de datos y construir funciones discriminantes lineales que nos permitan clasificar nuevas observaciones.

5.1. Ajuste del modelo discriminante gaussiano

Recordemos que el modelo discriminante gaussiano depende de los siguientes parámetros:

- Los vectores de medias μ_k para cada clase $k = 1, \dots, K$.
- La matriz de covarianza común Σ .
- Los pesos a priori π_k para cada clase $k = 1, \dots, K$.

Nuestro objetivo es estimar estos parámetros a partir de un conjunto de datos etiquetado $\{(x_i, g_i)\}_{i=1}^n$, donde x_i es el vector de características y g_i es la etiqueta de clase correspondiente. Existen dos enfoques principales para ajustar el modelo discriminante gaussiano: el enfoque clásico de LDA que utiliza la estimación de Fisher (FE) para la matriz de varianza común, y el enfoque basado en la estimación por máxima verosimilitud (MLE).

5.1.1. El método de estimación de Fisher (FE)

Para este método de estimación, utilizamos estimadores insesgados para los parámetros del modelo discriminante gaussiano. Las fórmulas para estimar los parámetros son las siguientes:

- Las medias de cada clase se estiman como el promedio de los vectores de características dentro de cada clase:

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i|g_i=k} x_i,$$

donde n_k es el número de observaciones en la clase k , y estamos sumando sobre todos los índices i tales que la etiqueta de clase g_i es igual a k .

- La matriz de covarianza común se estima como la media ponderada de las matrices de covarianza dentro de cada clase:

$$\hat{\Sigma}_{\text{MLE}} = \frac{1}{n - K} \sum_{k=1}^K \sum_{i|g_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^T,$$

- Los pesos a priori se estiman como la proporción de observaciones en cada clase:

$$\hat{\pi}_k = \frac{n_k}{n}$$

Este enfoque es el que se utiliza comúnmente en la literatura estadística y que se implementa en R a través de la función `lda()` del paquete `MASS`.

5.1.2. El método de máxima verosimilitud (MLE)

En este método de estimación, buscamos los parámetros que maximizan la función de verosimilitud del modelo discriminante gaussiano dado el conjunto de datos etiquetado. En este caso, las fórmulas para estimar los parámetros son:

- Las medias de cada clase se estiman de la misma manera que en el método FE:

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i|g_i=k} x_i$$

- La matriz de covarianza común se estima como:

$$\hat{\Sigma}_{\text{MLE}} = \frac{1}{n} \sum_{k=1}^K \sum_{i|g_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^T$$

- Los pesos a priori se estiman como:

$$\hat{\pi}_k = \frac{n_k}{n}$$

Notemos que en este caso, el estimador de la matriz de covarianza común es sesgado, pero consistente. Este enfoque es más común en la literatura de aprendizaje automático y se utiliza en implementaciones como la función `LinearDiscriminantAnalysis` del paquete `scikit-learn` en Python.

5.1.3. Comparación de los enfoques FE y MLE

Notemos que la única diferencia entre estos dos enfoques está dada en la forma en la que estimamos la matriz de covarianza común Σ . De manera más precisa, tenemos que:

$$\hat{\Sigma}_{\text{FE}} = \frac{n}{n - K} \hat{\Sigma}_{\text{MLE}}$$

En términos prácticos, esto significa que cuando utilizamos el enfoque FE para calcular las funciones discriminantes, estas funciones le dan más importancia a los valores de los priors en comparación con el enfoque MLE que le da más peso al cálculo de las medias de las clases. Cada uno de estos métodos tiene sus propias ventajas y desventajas, y la elección entre ellos depende de las características específicas del conjunto de datos y del problema en cuestión. A continuación, presentamos una tabla que resume las situaciones en las que cada enfoque puede ser más adecuado:

Contexto	FE LDA	MLE LDA
Tamaño de muestra muy pequeño	✓	
Priors muy desbalanceados	✓	
Confianza alta en los valores de los priors	✓	
Clases balanceadas		✓
Clases bien separadas		✓
Alta dimensionalidad	✓	
Muestras muy grandes	✓	✓

Tabla 5.1: Comparación de los enfoques FE y MLE para el ajuste del modelo discriminante gaussiano.

5.2. Verificación de la adecuación del modelo discriminante gaussiano

Una vez ajustado el modelo discriminante gaussiano a un conjunto de datos, es crucial verificar la adecuación de este ajuste. Esto implica evaluar si las suposiciones del modelo se cumplen y si el modelo es capaz de capturar la estructura subyacente de los datos. A continuación describiremos las pruebas y técnicas más comunes para verificar la adecuación del modelo discriminante gaussiano.

5.2.1. Pruebas de normalidad multivariada

Una de las suposiciones fundamentales del modelo discriminante gaussiano es que las observaciones dentro de cada clase siguen una distribución normal multivariada. Para verificar esta suposición, podemos utilizar pruebas estadísticas como la prueba de Mardia, la prueba de Henze-Zirkler o la prueba de Royston. Estas pruebas evalúan si los datos dentro de cada clase se ajustan a una distribución normal multivariada. Para realizar estas pruebas en R, podemos utilizar el paquete **MVN** que proporciona funciones para llevar a cabo estas pruebas de normalidad multivariada.

Otro método para evaluar la normalidad multivariada es mediante gráficos Q-Q multivariados o gráficos de dispersión de pares de variables dentro de cada clase. Estos gráficos nos permiten visualizar si los datos se ajustan a la distribución normal multivariada esperada.

5.2.2. Pruebas de Homoscedasticidad

Para evaluar si las matrices de covarianza de las diferentes clases son iguales (homoscedasticidad), podemos utilizar la prueba de Box's M. Esta prueba evalúa la hipótesis nula de que todas las matrices de covarianza son iguales contra la alternativa de que al menos una es diferente. En R, podemos utilizar la función `boxM()` del paquete `biotools` para llevar a cabo esta prueba.

Además de la prueba de Box's M, podemos utilizar gráficos de dispersión de las variables dentro de cada clase para visualizar las diferencias en las matrices de covarianza. Si las elipses de dispersión son similares en forma y tamaño, esto sugiere homoscedasticidad.

5.2.3. Evaluación del rendimiento del modelo

Finalmente, es importante evaluar el rendimiento del modelo discriminante gaussiano en términos de su capacidad para clasificar correctamente las observaciones. Podemos utilizar técnicas como la validación cruzada para estimar la tasa de error de clasificación del modelo. Además, podemos construir una matriz de confusión para visualizar el desempeño del modelo en términos de verdaderos positivos, falsos positivos, verdaderos negativos y falsos negativos.

5.3. Modelos alternativos

En caso de que las suposiciones del modelo discriminante gaussiano no se cumplan, podemos considerar modelos alternativos como el modelo discriminante cuadrático (QDA) que permite diferentes matrices de covarianza para cada clase, o modelos basados en técnicas no paramétricas como los árboles de decisión o los métodos de vecinos más cercanos (k-NN). Estos modelos pueden ser más flexibles y adaptarse mejor a conjuntos de datos que no cumplen con las suposiciones del modelo discriminante gaussiano.