



**Tecnológico
de Monterrey**

**MA2003B Aplicación de Métodos Multivariados
en Ciencia de Datos**

Módulo 2: Relaciones de Dependencia

Profesor: Raul Gomez
Correo: rgomez@tec.mx
Oficina: A4-123A

Tabla de contenidos

I	Análisis de Regresión	3
1.	Método de mínimos cuadrados	5
2.	El modelo de regresión lineal simple	15
2.1.	Estimación de parámetros por intervalos de confianza	16
2.2.	Bandas de confianza y de predicción	17

Parte I

Análisis de Regresión

Capítulo 1

Método de mínimos cuadrados

Supongamos que tenemos un conjunto de datos

$$((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$$

Por ejemplo, consideremos el siguiente conjunto de datos simulado:

```
library(tidyverse)
library(krulRutils)
library(latex2exp)

set.seed(123)

n <- 50
x_data <- runif(n, min = 0, max = 10)
epsilon_data <- rnorm(n, mean = 0, sd = 1)
y_data <- x_data + epsilon_data

sample_data_tbl <- tibble(
  x = x_data,
  y = y_data
)
```

Notemos que podemos visualizar estos datos mediante un diagrama de dispersión:

```
sample_data_plot <- sample_data_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_point(
    color = c_pal("C red"),
    size = 1,
    alpha = 1
  ) +
  coord_fixed() +
  labs(
```

```
title = "Datos simulados",
x = TeX("$X_{0}$"),
y = TeX("$Y_{0}$")
) +
theme_krul()

sample_data_plot
```




Figura 1.1: Diagrama de dispersión de los datos simulados.

Nos gustaría encontrar la línea recta que mejor se ajuste a estos datos. Hay varias formas de definir “mejor ajuste”, pero una de las más comunes es minimizar la suma de los errores al cuadrado (SSE por sus siglas en inglés) entre los valores observados y los valores correspondientes sobre la línea recta propuesta. De manera más precisa, buscamos una recta

$$Y_0 = \hat{f}(X_0) = \hat{\beta}_0 + \hat{\beta}_1 X_0$$

tal que si definimos $\hat{y}_i = \hat{f}(x_i)$ entonces minimicemos la suma

$$\text{SSE} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (1.1)$$

```
fitted_data_tbl <- sample_data_tbl %>%
  mutate(
    fitted = fitted(lm(y ~ x, data = .))
  )
```



```
fitted_data_plot <- fitted_data_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
  geom_segment(
    aes(xend = x, yend = fitted),
    color = c_pal("C green"),
    alpha = 1
  ) +
  geom_point(color = c_pal("C red"), size = 1, alpha = 1) +
  geom_point(
    aes(x = x, y = fitted),
    color = c_pal("C red"),
    size = 1,
    alpha = 1
  ) +
  coord_fixed() +
  labs(
    title = "Recta ajustada",
    x = TeX("$X_{0}$"),
    y = TeX("$Y_{0}$")
  ) +
  theme_krul()

fitted_data_plot
```




Figura 1.2: Línea recta que mejor se ajusta a los datos simulados, bajo el criterio de mínimos cuadrados. En otras palabras, esta es la línea recta que minimiza el SSE.

Para encontrar la fórmula para $\hat{\beta}_0$ y $\hat{\beta}_1$ en términos de nuestros datos, utilizaremos un poco de álgebra lineal. Empecemos por fijar los vectores

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

que llamaremos el *vector de las observaciones independientes* y el *vector de las observaciones dependientes*, respectivamente. Fijamos ahora la llamada *matriz de diseño*, dada por,

$$\Phi = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}$$

y notamos que si definimos

$$\hat{y} = \begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_n \end{bmatrix}$$

entonces $\hat{y} = \Phi \hat{\beta}$ donde

$$\hat{\beta} = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{bmatrix}$$

Notemos que para minimizar la suma de los errores al cuadrado dada en la ecuación (1.1), necesitamos encontrar la proyección ortogonal del vector y sobre el espacio generado por las columnas de la matriz Φ . Empezamos por calcular la *matriz de coeficientes*

$$D^2 = (\Phi^T \Phi)^{-1} = \begin{bmatrix} \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} & -\frac{\bar{x}}{S_{xx}} \\ -\frac{\bar{x}}{S_{xx}} & \frac{1}{S_{xx}} \end{bmatrix}$$

donde

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{y} \quad S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$$

Calculamos ahora la *matriz de estimadores de mínimos cuadrados*

$$A = D^2 \Phi^T = (\Phi^T \Phi)^{-1} \Phi^T = \begin{bmatrix} \frac{1}{n} + \frac{\bar{x}(\bar{x}-x_1)}{S_{xx}} & \cdots & \frac{1}{n} + \frac{\bar{x}(\bar{x}-x_n)}{S_{xx}} \\ \frac{x_1-\bar{x}}{S_{xx}} & \cdots & \frac{x_n-\bar{x}}{S_{xx}} \end{bmatrix}$$

y, finalmente, calculamos la *matriz sombrero*

$$H = \Phi A = \Phi (\Phi^T \Phi)^{-1} \Phi^T$$

Notemos que las entradas de la matriz H están dadas por:

$$h_{ij} = \frac{1}{n} + \frac{(x_i - \bar{x})(x_j - \bar{x})}{S_{xx}}$$

en particular,

$$h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}$$

Utilizando estas matrices, podemos calcular

$$\hat{\beta} = Ay \quad \text{y} \quad \hat{y} = Hy$$

Para ilustrar este procedimiento, consideremos el siguiente ejemplo.

Ejemplo. Consideremos el siguiente conjunto de datos:

```
set.seed(123)

n <- 5
x_data <- 1:n
epsilon_data <- rnorm(n, mean = 0, sd = n / 10)
y_data <- x_data + epsilon_data
sample_data_tbl <- tibble(
  x = x_data,
  y = y_data
)
```

Notemos que los vectores de observaciones independientes y dependientes son:

$$x = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{bmatrix} \quad y = \begin{bmatrix} 0.72 \\ 1.88 \\ 3.78 \\ 4.04 \\ 5.06 \end{bmatrix}$$

y la matriz de diseño es:

```
Phi <- matrix(c(rep(1, n), x_data), nrow = n, ncol = 2)
```

$$\Phi = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{bmatrix}$$

Calculamos ahora la matriz de coeficientes:

```
D2 <- solve(t(Phi) %*% Phi)
```

$$D^2 = \begin{bmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{bmatrix}$$

y la matriz de estimadores de mínimos cuadrados:

```
A <- D2 %*% t(Phi)
```

$$A = \begin{bmatrix} 0.8 & 0.5 & 0.2 & -0.1 & -0.4 \\ -0.2 & -0.1 & 0 & 0.1 & 0.2 \end{bmatrix}$$

Finalmente, la matriz sombrero es:

```
H <- Phi %*% A
```

$$H = \begin{bmatrix} 0.6 & 0.4 & 0.2 & 0 & -0.2 \\ 0.4 & 0.3 & 0.2 & 0.1 & 0 \\ 0.2 & 0.2 & 0.2 & 0.2 & 0.2 \\ 0 & 0.1 & 0.2 & 0.3 & 0.4 \\ -0.2 & 0 & 0.2 & 0.4 & 0.6 \end{bmatrix}$$

Utilizando estas matrices, podemos rápidamente calcular los vectores $\hat{\beta}$ y $\hat{y}$:

```
beta_hat <- A %*% y_data
y_hat <- H %*% y_data
```

$$\hat{\beta} = \begin{bmatrix} -0.16 \\ 1.08 \end{bmatrix} \quad \hat{y} = \begin{bmatrix} 0.93 \\ 2.01 \\ 3.1 \\ 4.18 \\ 5.26 \end{bmatrix}$$

Notemos que en este caso la suma de los errores al cuadrado (SSE) es:

```
sse <- sum((y_data - y_hat)^2)
```

$$\text{SSE} = 0.59$$

La siguiente figura ilustra el ajuste por mínimos cuadrados para este conjunto de datos:

```
fitted_example_data_tbl <- sample_data_tbl %>%
  mutate(
    fitted = as.vector(y_hat)
  )
fitted_example_data_plot <- fitted_example_data_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
  geom_segment(
    aes(xend = x, yend = fitted),
    color = c_pal("C green"),
    alpha = 1
  ) +
  geom_point(color = c_pal("C red"), size = 1, alpha = 1) +
```

```
geom_point(  
  aes(x = x, y = fitted),  
  color = c_pal("C red"),  
  size = 1,  
  alpha = 1  
) +  
coord_fixed() +  
labs(  
  title = "Recta ajustada",  
  x = TeX("$X_{0}$"),  
  y = TeX("$Y_{0}$")  
) +  
theme_krul()  
fitted_example_data_plot
```




Figura 1.3: Ajuste por mínimos cuadrados para el conjunto de datos del ejemplo.

Notemos que este proceso se puede aplicar a cualquier conjunto de datos dado, sin embargo una de las aplicaciones más comunes de este método es tratar de predecir el valor de la variable Y_0 dado un valor específico de la variable X_0 que no se encuentre en el conjunto de datos original. Se sigue que para que estas predicciones sean de utilidad, es necesario que el comportamiento de nuestros datos siga una tendencia lineal, ya que en caso contrario las predicciones podrían no ser confiables. Por ejemplo, consideremos el ajuste por el método de mínimos cuadrados para los siguientes conjuntos de datos:

```
library(patchwork)

set.seed(123)

n <- 500
x_data1 <- runif(n, min = 0, max = 10)
epsilon_data1 <- rnorm(n, mean = 0, sd = 50)
y_data1 <- (x_data1)^3 + epsilon_data1

x_data2 <- runif(n, min = 0, max = 10)
epsilon_data2 <- rnorm(n, mean = 0, sd = 0.1)
y_data2 <- sin(x_data2) + epsilon_data2

x_data3 <- runif(n, min = 0, max = 10)
y_data3 <- runif(n, min = 0, max = 10)

x_data4 <- runif(n, min = 0, max = 10)
y_data4 <- mapply(function(mu, sigma) rnorm(1, mean = mu, sd = sigma),
                  mu = x_data4,
                  sigma = x_data4)

sample_data1_tbl <- tibble(
  x = x_data1,
  y = y_data1
)

sample_data2_tbl <- tibble(
  x = x_data2,
  y = y_data2
)

sample_data3_tbl <- tibble(
  x = x_data3,
  y = y_data3
)

sample_data4_tbl <- tibble(
  x = x_data4,
  y = y_data4
)

sample_data1_plot <- sample_data1_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_point(
    color = c_pal("C red"),
```

```
      size = 1,
      alpha = 1
    ) +
    geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
    labs(
      title = "Datos cúbicos",
      x = "",
      y = ""
    ) +
    theme_krul()

sample_data2_plot <- sample_data2_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_point(
    color = c_pal("C red"),
    size = 1,
    alpha = 1
  ) +
  geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
  labs(
    title = "Datos senoidales",
    x = "",
    y = ""
  ) +
  theme_krul()

sample_data3_plot <- sample_data3_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_point(
    color = c_pal("C red"),
    size = 1,
    alpha = 1
  ) +
  geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
  labs(
    title = "Datos aleatorios",
    x = "",
    y = ""
  ) +
  theme_krul()

sample_data4_plot <- sample_data4_tbl %>%
  ggplot(aes(x = x, y = y)) +
  geom_point(
    color = c_pal("C red"),
```

```
size = 1,
alpha = 1
) +
geom_smooth(method = "lm", se = FALSE, color = c_pal("C blue")) +
labs(
  title = "Datos con varianza creciente",
  x = "",
  y = ""
) +
theme_krul()

sample_data_plot <- (sample_data1_plot + sample_data2_plot) /
  (sample_data3_plot + sample_data4_plot)

sample_data_plot
```




Figura 1.4: Ajuste por mínimos cuadrados para diferentes conjuntos de datos.

Es bastante claro que en estos casos el ajuste por mínimos cuadrados no es el método adecuado para realizar predicciones confiables. En general, este método solo es efectivo cuando se cumplen ciertas hipótesis que estudiaremos en las siguientes secciones, cuando introduciremos el modelo de regresión lineal desde un punto de vista estadístico.

Capítulo 2

El modelo de regresión lineal simple

En un *modelo de regresión simple*, suponemos que tenemos una *variable independiente* X_0 (también conocida como *variable explicativa* o *predictora*), y una *variable dependiente* Y_0 (también conocida como *variable de respuesta*). Suponemos además que estas variables satisfacen una relación de la forma:

$$Y_0 = f_0(X_0) + \epsilon_0$$

donde f_0 es una función desconocida que describe la relación entre ambas variables, y ϵ_0 es una variable aleatoria que representa el *error* o *ruido* en la relación entre X_0 e Y_0 . Uno de los objetivos del *aprendizaje estadístico* (también conocido como *aprendizaje automático* o *machine learning*), es tratar de aproximar la función f_0 a partir de un conjunto de datos

$$((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$$

dado. De manera más precisa, consideremos vectores aleatorios

$$\begin{aligned} X &= (X_1, X_2, \dots, X_n) \\ Y &= (Y_1, Y_2, \dots, Y_n) \end{aligned}$$

que representan los posibles valores de las observaciones independientes y dependientes, respectivamente, en una muestra dada. En este contexto, un *método de aprendizaje* consiste de una función $\hat{F}$, que depende de los vectores aleatorios X e Y , y que cuando se evalúa en los datos observados produce una función $\hat{f}$ que aproxima a la función desconocida f_0 .

Nota 2.0.1. En muchos modelos de aprendizaje estadístico es común tomar el vector $X = x$ como fijo, en cuyo caso la función $\hat{F}$ depende únicamente del vector aleatorio Y .

Para hacer estas ideas un poco más concretas, consideremos el caso particular en el que la función desconocida f_0 es una función lineal, es decir,

$$f_0(X_0) = b_0 + b_1 X_0$$

y supondremos además que $\epsilon_0 \sim \mathcal{N}(0, \sigma^2)$ es una variable aleatoria con distribución normal de media 0 y varianza σ^2 . Este contexto se conoce como el *modelo de regresión lineal simple* y es uno de los modelos más utilizados en aprendizaje estadístico. Notemos que en este caso nuestro

objetivo es encontrar una expresión que nos permita aproximar los parámetros desconocidos b_0 y b_1 en términos de los datos observados. Para ello consideraremos las expresiones que obtuvimos en la sección anterior para los coeficientes de la recta de mejor ajuste por mínimos cuadrados, pero utilizando ahora el vector aleatorio Y en lugar del vector de observaciones y . En otras palabras, definiremos

$$\Phi = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}$$

y consideraremos las matrices $D^2 = (\Phi^T \Phi)^{-1}$, $A = D^2 \Phi^T$ y $H = \Phi A$. Entonces podemos definir el *vector aleatorio de estimadores de mínimos cuadrados* como:

$$\hat{B} = AY$$

Notemos que, a diferencia de la sección anterior, en este caso $\hat{B}$ no es un vector de valores fijos, sino que es un vector aleatorio que depende linealmente del vector aleatorio Y . Además, de las propiedades de la distribución normal multivariada, sabemos que

$$\hat{B} \sim \mathcal{N}(b, \sigma^2 D^2)$$

donde

$$b = \begin{bmatrix} b_0 \\ b_1 \end{bmatrix}$$

es el vector de parámetros desconocidos. Notemos que, en particular, el vector aleatorio $\hat{B}$ es un estimador insesgado del vector de parámetros b , es decir, $E[\hat{B}] = b$. Notemos además que si evaluamos el vector aleatorio $\hat{B}$ en los datos observados $Y = y$, obtenemos el vector de coeficientes $\hat{\beta}$ de la recta de mejor ajuste por mínimos cuadrados que obtuvimos en la sección anterior. Una vez hechas estas observaciones, nuestro siguiente objetivo será construir los intervalos de confianza para los parámetros b_0 y b_1 .

2.1. Estimación de parámetros por intervalos de confianza

Empecemos por definir las cantidades

$$d_0^2 = D_{11}^2 = \frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}$$

$$d_1^2 = D_{22}^2 = \frac{1}{S_{xx}}$$

donde

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$$

tal y como lo habíamos definido en la sección anterior. Entonces

$$\hat{B}_0 \sim \mathcal{N}(b_0, \sigma^2 d_0^2)$$

$$\hat{B}_1 \sim \mathcal{N}(b_1, \sigma^2 d_1^2)$$

Consideremos ahora la variable aleatoria

$$\hat{S}^2 = \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

donde

$$\hat{Y} = \begin{bmatrix} \hat{Y}_1 \\ \hat{Y}_2 \\ \vdots \\ \hat{Y}_n \end{bmatrix} = HY$$

es el *vector aleatorio de predicciones por mínimos cuadrados*. Entonces tenemos que

$$\frac{(n-2)\hat{S}^2}{\sigma^2} \sim \chi_{n-2}^2$$

y, además, la variable aleatoria $\hat{S}^2$ es independiente de las variables aleatorias $\hat{B}_0$ y $\hat{B}_1$. Por lo tanto, podemos construir las nuevas variables aleatorias

$$T_0 = \frac{\hat{B}_0 - b_0}{\hat{S}d_0} \sim t_{n-2}$$

$$T_1 = \frac{\hat{B}_1 - b_1}{\hat{S}d_1} \sim t_{n-2}$$

donde t_{n-2} denota la distribución t de Student con $n-2$ grados de libertad. Con esta información, podemos construir ahora los intervalos de confianza para los parámetros b_0 y b_1 , tal y como nos lo habíamos propuesto. Empecemos por fijar un nivel de significancia α y sea $t_{\alpha/2, n-2}$ el cuantil superior de orden $\alpha/2$ de la distribución t de Student correspondiente. Entonces, si tomamos $\hat{s}$ como el valor de la variable aleatoria $\hat{S}$ evaluada en el vector de datos observados $Y = y$, tenemos que los intervalos de confianza buscados son

$$(\hat{\beta}_0 - t_{\alpha/2, n-2}\hat{s}d_0, \hat{\beta}_0 + t_{\alpha/2, n-2}\hat{s}d_0)$$

para b_0 , y

$$(\hat{\beta}_1 - t_{\alpha/2, n-2}\hat{s}d_1, \hat{\beta}_1 + t_{\alpha/2, n-2}\hat{s}d_1)$$

para b_1 .

2.2. Bandas de confianza y de predicción

Una vez obtenidos los intervalos de confianza para los parámetros b_0 y b_1 , nos gustaría obtener ahora los intervalos de confianza para los posibles valores de la variable dependiente Y_0 en un valor específico de la variable independiente $X_0 = x_0$. Para esto empezaremos por considerar la matriz de diseño en el punto x_0 :

$$\Phi_0 = \begin{bmatrix} 1 & x_0 \end{bmatrix}$$

y definiremos el vector aleatorio

$$\hat{Y}_0 = \Phi_0 \hat{B} = \hat{B}_0 + \hat{B}_1 x_0$$

Notemos que este vector aleatorio depende solamente de las variables $\hat{B}_0$ y $\hat{B}_1$ (las cuales, a su vez, dependen solamente de las variables $Y_1, Y_2, \dots, Y_n$), y es independiente de la variable aleatoria Y_0 . Usando nuevamente las propiedades de la distribución normal multivariada, podemos ver que

$$\hat{Y}_0 \sim \mathcal{N}(\Phi_0 b, \sigma^2 d_c^2)$$

donde

$$d_c^2 = \Phi_0 D^2 \Phi_0^T = \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}$$

Finalmente, como $\hat{Y}_0$ es independiente de la variable aleatoria $\hat{S}^2$, podemos construir la variable aleatoria

$$T_c = \frac{\hat{Y}_0 - \Phi_0 b}{\hat{S} d_c} \sim t_{n-2}$$

Se sigue que para construir un intervalo de confianza para el valor esperado de la variable dependiente Y_0 en el punto $X_0 = x_0$, basta con tomar el intervalo

$$(\hat{y}_0 - t_{\alpha/2, n-2} \hat{S} d_c, \hat{y}_0 + t_{\alpha/2, n-2} \hat{S} d_c)$$

donde $\hat{y}_0$ es el valor de la variable aleatoria $\hat{Y}_0$ evaluada en los datos observados $Y = y$. Notemos que este intervalo depende del punto $X_0 = x_0$ que hayamos elegido. De manera más general, podemos considerar el conjunto de todos los intervalos de confianza para todos los posibles valores de x_0 , el cual se conoce como la *banda de confianza* del modelo de regresión lineal simple.

Para terminar, notemos que como Y_0 es independiente de $\hat{Y}_0$, tenemos que

$$Y_0 - \hat{Y}_0 \sim \mathcal{N}(0, \sigma^2 d_p^2)$$

donde

$$d_p^2 = 1 + d_c^2 = 1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}$$

Usando nuevamente la variable aleatoria $\hat{S}^2$, podemos definir ahora

$$T_p = \frac{Y_0 - \hat{Y}_0}{\hat{S} d_p} \sim t_{n-2}$$

y, de manera similar a como lo hicimos antes, podemos construir un *intervalo de predicción* para el valor de la variable dependiente Y_0 en el punto $X_0 = x_0$ como

$$(\hat{y}_0 - t_{\alpha/2, n-2} \hat{S} d_p, \hat{y}_0 + t_{\alpha/2, n-2} \hat{S} d_p)$$

Nuevamente, el conjunto de todos estos intervalos de predicción para todos los posibles valores de x_0 se conoce como la *banda de predicción* del modelo de regresión lineal simple.