



Tecnológico de Monterrey

Aplicación de Métodos Multivariados en Ciencia de Datos

Módulo 1: Relaciones de Interdependencia

Raúl Gómez Muñoz
Blanca Rosa Ruiz Hernández

Tabla de contenidos

I Introducción al análisis multivariado

1. Estructura y organización de datos	1
1.1. Datos ordenados	1
1.1.1. Tibbles y pipes	1
1.1.2. Ejemplo: Ordenando el conjunto de datos <code>who</code>	2
1.2. La Gramática de los Gráficos	6
1.2.1. Capas en <code>ggplot2</code>	7
1.2.2. Graficación con <code>ggplot2</code>	8
1.3. Actividad: Limpieza de datos	9
2. Evaluación de normalidad univariada	11
2.1. Los momentos estandarizados	11
2.1.1. Asimetría	12
2.1.2. Curtosis	18
2.2. Gráficos QQ	21
2.3. Asimetría y curtosis muestrales	25
2.4. Escalamiento y estandarización	27
2.4.1. Escalamiento de variables aleatorias	27
2.4.2. Escalamiento de muestras	30
2.5. Actividad: Visualizando la no normalidad de muestras	35

Parte I

Introducción al análisis multivariado

Capítulo 1

Estructura y organización de datos

Todo proyecto de ciencia de datos debe comenzar con la adquisición y organización de los conjuntos de datos requeridos. La forma en la que esta información se estructura y organiza puede tener un impacto significativo en la calidad del análisis que se desea desarrollar. En esta sección introduciremos los conceptos fundamentales del Tidyverse, un conjunto de herramientas en R que facilita la manipulación y visualización de nuestros datos siguiendo principios específicos de estructura y organización [5, 6, 7].

1.1. Datos ordenados

La idea central detrás del diseño del Tidyverse es la definición de datos ordenados [3]:

Definición 1.1.1. *Datos ordenados* es una forma de estructurar un conjunto de datos para facilitar su uso. En datos ordenados:

1. Cada variable forma una columna.
2. Cada observación forma una fila.
3. Cada tipo de unidad observacional forma una tabla.

Esta estructura facilita la manipulación, análisis y visualización de nuestra información, ya que se alinea con la forma en la que los datos se procesan típicamente en R.

1.1.1. Tibbles y pipes

En el Tidyverse, los datos suelen representarse mediante un tipo especial de data frame llamado *tibble*. Los tibbles son más amigables que los data frames tradicionales, ya que ofrecen una mejor impresión y manejo de subconjuntos de datos. Además, están diseñados para trabajar de manera fluida con el operador pipe (ya sea `|>` o bien `%>%`), que permite encadenar múltiples operaciones (conocidas como “verbos” en el contexto del Tidyverse) de manera clara y concisa. Para ilustrar estas ideas, en la siguiente sección realizaremos la limpieza del conjunto de datos `who` de la OMS, lo que nos permitirá generar un tibble que contenga esta información y que cumpla con los principios de datos ordenados. Este suele ser el primer paso en el Análisis Exploratorio de Datos (EDA) y es crucial para garantizar que los datos estén en un formato adecuado para su análisis y visualización.

1.1.2. Ejemplo: Ordenando el conjunto de datos who

Antes de comenzar, debemos cargar las librerías necesarias y el conjunto de datos `who`:

```
library(tidyverse)
library(here)
library(krulRutils)
library(magrittr)
library(kableExtra)

options(scipen = 999)
data(who)
```

Ahora podemos iniciar nuestro proceso de ordenamiento. El problema principal de este conjunto es que contiene variables (como “new_sp_m014”) que no son muy claras y que incluyen más de una unidad de información.

```
who |>
  glimpse()
```

Rows: 7,240

Columns: 60

```
$ country      <chr> "Afghanistan", "Afghanistan", "Afghanistan", "Afghanistan~
$ iso2         <chr> "AF", "AF", "AF", "AF", "AF", "AF", "AF", "AF", "AF", "AF~
$ iso3         <chr> "AFG", "AFG", "AFG", "AFG", "AFG", "AFG", "AFG", "AFG", "~
$ year         <dbl> 1980, 1981, 1982, 1983, 1984, 1985, 1986, 1987, 1988, 198~
$ new_sp_m014  <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_m1524 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_m2534 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_m3544 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_m4554 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_m5564 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_m65   <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_f014  <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_f1524 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_f2534 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_f3544 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_f4554 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_f5564 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_f65   <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_m014  <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_m1524 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_m2534 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_m3544 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_m4554 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_m5564 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_m65   <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_f014  <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
```


1. Estructura y organización de datos

```
$ new_sn_f1524 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_f2534 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_f3544 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_f4554 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_f5564 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_f65 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_m014 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_m1524 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_m2534 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_m3544 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_m4554 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_m5564 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_m65 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_f014 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_f1524 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_f2534 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_f3544 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_f4554 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_f5564 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_f65 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_m014 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_m1524 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_m2534 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_m3544 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_m4554 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_m5564 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_m65 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_f014 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_f1524 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_f2534 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_f3544 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_f4554 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_f5564 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_f65 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
```

Es por eso que necesitamos separar estas variables e introducir nombres más claros para ellas y para sus valores asociados.

```
# Empezamos creando la variable "who_tidy"
# que contiene el conjunto de datos de la OMS ya limpio
who_tidy <- who |>
# Usamos pivot_longer para eliminar las variables que empiezan con "new"
# y usarlas como valores en su lugar
pivot_longer(
  cols = starts_with("new"),
  names_to = "key",
  values_to = "cases",
```

```
values_drop_na = TRUE
) |>
mutate(
  key = if_else(
    startsWith(key, "newrel"),
    sub("newrel", "new_rel", key),
    key
  ),
  cases = as.integer(cases)
) |>
separate(key, into = c("new", "type", "sexage"), sep = "_") |>
separate(sexage, into = c("sex", "age"), sep = 1) |>
select(-new, -iso2, -iso3) %T>%
# Finalmente, guardamos los datos ordenados en formato RDS y CSV
saveRDS(here("data", "who_tidy.rds")) |>
write_csv(here("data", "who_tidy.csv")) |>
glimpse()
```

Rows: 76,046

Columns: 6

```
$ country <chr> "Afghanistan", "Afghanistan", "Afghanistan", "Afghanistan", "A~
$ year    <dbl> 1997, 1997, 1997, 1997, 1997, 1997, 1997, 1997, 1997, 1997, 19~
$ type    <chr> "sp", "sp", "sp", "sp", "sp", "sp", "sp", "sp", "sp", "sp", "s~
$ sex     <chr> "m", "m", "m", "m", "m", "m", "m", "f", "f", "f", "f", "f", "f~
$ age     <chr> "014", "1524", "2534", "3544", "4554", "5564", "65", "014", "1~
$ cases   <int> 0, 10, 6, 3, 5, 2, 0, 5, 38, 36, 14, 8, 0, 1, 30, 129, 128, 90~
```

Ahora queremos convertir las columnas “type”, “sex” y “age” en factores. Empezamos construyendo las siguientes tablas de correspondencia:

```
who_type_lookup_tbl <- tibble(
  code = c("ep", "rel", "sn", "sp"),
  label = c(
    "TB extrapulmonar",
    "Caso de recaída",
    "TB pulmonar baciloscopía negativa",
    "TB pulmonar baciloscopía positiva"
  )
)

who_sex_lookup_tbl <- tibble(
  code = c("f", "m"),
  label = c("Mujer", "Hombre")
)

who_age_lookup_tbl <- tibble(
```

1. Estructura y organización de datos

```
code = c(
  "014",
  "1524",
  "2534",
  "3544",
  "4554",
  "5564",
  "65"
),
label = c(
  "0-14",
  "15-24",
  "25-34",
  "35-44",
  "45-54",
  "55-64",
  "65+"
)
)
```

Utilizando estas tablas, podemos agregar ahora estas columnas a nuestro conjunto de datos:

```
# Agregamos las columnas de factores como información adicional
who_factor <- who_tidy |>
  convert_codes_to_factor(
    code_col = type,
    lookup_tbl = who_type_lookup_tbl,
    lookup_code_col = code,
    lookup_label_col = label,
    new_factor_col_name = Tipo
  ) |>
  convert_codes_to_factor(
    code_col = sex,
    lookup_tbl = who_sex_lookup_tbl,
    lookup_code_col = code,
    lookup_label_col = label,
    new_factor_col_name = Sexo
  ) |>
  convert_codes_to_factor(
    code_col = age,
    lookup_tbl = who_age_lookup_tbl,
    lookup_code_col = code,
    lookup_label_col = label,
    new_factor_col_name = Edad
  ) |>
  glimpse()
```

Rows: 76,046

Columns: 9

```
$ country <chr> "Afghanistan", "Afghanistan", "Afghanistan", "Afghanistan", "A~
$ year    <dbl> 1997, 1997, 1997, 1997, 1997, 1997, 1997, 1997, 1997, 19~
$ type    <chr> "sp", "sp", "sp", "sp", "sp", "sp", "sp", "sp", "sp", "sp", "s~
$ sex     <chr> "m", "m", "m", "m", "m", "m", "m", "f", "f", "f", "f", "f", "f~
$ age     <chr> "014", "1524", "2534", "3544", "4554", "5564", "65", "014", "1~
$ cases   <int> 0, 10, 6, 3, 5, 2, 0, 5, 38, 36, 14, 8, 0, 1, 30, 129, 128, 90~
$ Tipo    <fct> TB pulmonar baciloscopía positiva, TB pulmonar baciloscopía po~
$ Sexo    <fct> Hombre, Hombre, Hombre, Hombre, Hombre, Hombre, Hombre, Mujer,~
$ Edad    <fct> 0-14, 15-24, 25-34, 35-44, 45-54, 55-64, 65+, 0-14, 15-24, 25-~
```

Finalmente, queremos usar esta información para analizar el número de casos de tuberculosis por tipo y sexo. Empezamos generando el tibble de frecuencias correspondiente:

```
who_type_sex_tbl <- who_factor |>
  count(Tipo, Sexo, wt = cases, name = "Casos")

kable(
  who_type_sex_tbl,
  booktabs = TRUE,
) |>
  kable_styling(latex_options = "hold_position")
```

Tabla 1.1: Número de casos de tuberculosis por tipo y sexo

Tipo	Sexo	Casos
TB extrapulmonar	Mujer	941880
TB extrapulmonar	Hombre	1044299
Caso de recaída	Mujer	1201596
Caso de recaída	Hombre	2018976
TB pulmonar baciloscopía negativa	Mujer	2439139
TB pulmonar baciloscopía negativa	Hombre	3840388
TB pulmonar baciloscopía positiva	Mujer	11324409
TB pulmonar baciloscopía positiva	Hombre	20586831

1.2. La Gramática de los Gráficos

El concepto de la *Gramática de los Gráficos* fue introducido por Leland Wilkinson en su libro “The Grammar of Graphics” [8], y proporciona un marco para entender cómo crear visualizaciones de forma sistemática ya que descompone el proceso de construir una gráfica en componentes como datos, estéticas, geometrías, estadísticas, coordenadas y temas. El paquete `ggplot2` [4] implementa esta gramática en R, permitiendo construir visualizaciones complejas por capas. Para más información sobre su historia y aplicaciones, consulte: [1, 2].

1. Estructura y organización de datos

1.2.1. Capas en ggplot2

En `ggplot2`, las gráficas se construyen añadiendo múltiples *capas* que definen los componentes de la visualización. Cada capa corresponde a un aspecto específico de la gráfica y, en conjunto, forman la composición completa. Estas capas incluyen:

1. **Datos:** El conjunto a visualizar (usualmente un data frame o tibble). Es la fuente de información de la gráfica.
2. **Estéticas:** Mapeos que relacionan variables con propiedades visuales, por ejemplo:
 - Posición en los ejes x e y .
 - Color, relleno.
 - Tamaño, forma.
 - Transparencia.

Estos mapeos definen *qué* datos se muestran y *cómo* se representan visualmente.

3. **Geometrías:** Objetos geométricos que muestran los datos; por ejemplo:
 - `geom_point()` para diagramas de dispersión.
 - `geom_line()` para gráficas de líneas.
 - `geom_col()` para barras.
 - `geom_histogram()` para histogramas.

La geometría controla *cómo* se dibujan los datos.

4. **Transformaciones estadísticas:** Cálculos opcionales aplicados a los datos antes de graficar, como:
 - `stat_bin()` para agrupar en histogramas.
 - `stat_smooth()` para ajustar curvas suaves.

Estos son pasos de preprocesamiento para la visualización.

5. **Escalas:** Definen cómo se traducen los valores a propiedades visuales; también controlan marcas de ejes, leyendas y guías.
6. **Coordenadas:** El sistema usado, como cartesiano (`coord_cartesian()`), polar (`coord_polar()`) o invertido (`coord_flip()`).
7. **Facetado:** Métodos para dividir los datos en subconjuntos y mostrar múltiples gráficas en una cuadrícula:
 - `facet_wrap()`
 - `facet_grid()`
8. **Etiquetas:** `labs()` agrega títulos, etiquetas de ejes y pies.
9. **Temas:** `theme()` controla la apariencia general (fuentes, fondo, rejillas).

Cada capa puede combinarse y personalizarse para construir gráficas complejas y elegantes. Esta *gramática por capas* invita a pensar en la gráfica como una composición de componentes independientes en lugar de un objeto monolítico.

1.2.2. Graficación con ggplot2

Ilustraremos estos conceptos graficando el número de casos de tuberculosis por tipo y sexo, usando el tibble de frecuencias que creamos antes.

```
# Generamos la gráfica usando ggplot2
# Cada capa corresponde a una componente de la gramática de los gráficos
who_type_sex_plot <- who_type_sex_tbl |>
  ggplot(aes(x = Tipo, y = Casos, fill = Sexo)) +
  geom_col(position = "dodge") +
  c_scale_fill("C rose", "C blue") +
  labs(
    title = "Casos de tuberculosis por tipo y sexo",
    x = "Tipo de tuberculosis",
    y = "Casos",
    fill = "Sexo"
  ) +
  theme_krul()

# Visualizamos la gráfica
who_type_sex_plot
```




Figura 1.1: Esta gráfica muestra un análisis comparativo del número de casos de tuberculosis por tipo y sexo. Como se observa, el número de casos es consistentemente mayor en la población masculina en todos los tipos de tuberculosis.

1. Estructura y organización de datos

1.3. Actividad: Limpieza de datos

1. En la sección anterior se mostró cómo usar el operador `|>` para encadenar múltiples operaciones en el Tidyverse. En este ejercicio, muestre el resultado de todos los pasos intermedios en el proceso de ordenamiento del conjunto de datos `who` usando el operador pipe.
2. El problema con el conjunto `relig_income`, es que los distintos niveles de ingreso están representados como columnas, lo que dificulta analizar los datos. Utilizando las técnicas vistas hasta ahora, ordene el conjunto para analizar la distribución del nivel de ingreso entre los distintos grupos religiosos en Estados Unidos, y genere una gráfica de barras que muestre esta información.
3. El problema con el conjunto `Billboard`, es que las semanas en que una canción apareció en la lista están representadas como columnas, lo que dificulta analizar los datos. Utilizando las técnicas vistas hasta ahora, ordene el conjunto para analizar la evolución del ranking de la canción “Who Let The Dogs Out” de “Baha Men” en el Billboard Hot 100. La visualización final debe lucir como la que se muestra abajo.




Figura 1.2: Evolución del ranking de la canción 'Who Let The Dogs Out' de 'Baha Men' en el Billboard Hot 100. La canción alcanzó el puesto 40 en la semana del 21 de octubre de 2000 y permaneció varias semanas en el top 100.

Bibliografía

- [1] Cleveland, W. S. (1993) *The Elements of Graphing Data*. Hobart Press.
- [2] Hyndman, R. J., and Athanasopoulos, G. (2021) *Forecasting: Principles and Practice* (3rd ed.). OTexts. <https://otexts.com/fpp3/>
- [3] Wickham, H. (2014) Tidy data. *Journal of Statistical Software*, 59(10), 1–23. <https://doi.org/10.18637/jss.v059.i10>
- [4] Wickham, H. (2016) *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag.
- [5] Wickham, H., and Grolemund, G. (2017) *R for Data Science: Import, Tidy, Transform, Visualize, and Model Data*. O’Reilly Media.
- [6] Wickham, H. (2019) Functional programming with purrr. *UseR! Conference*.
- [7] Wickham, H., et al. (2019) Welcome to the tidyverse. *Journal of Open Source Software*, 4(43), 1686. <https://doi.org/10.21105/joss.01686>
- [8] Wilkinson, L. (1999) *The Grammar of Graphics*. Springer-Verlag.

Capítulo 2

Evaluación de normalidad univariada

En muchos métodos estadísticos univariados se asume que los datos siguen una distribución normal. Sin embargo, en la práctica, no todos nuestros conjuntos de datos satisfacen esta suposición. En estos casos no se justifica el uso de estos métodos y su uso indiscriminado puede llevar a conclusiones erróneas, que nos podrían llevar a tomar malas decisiones bajo la ilusión de un respaldo estadístico que no existe. Es por eso que resulta fundamental contar con herramientas que nos permitan evaluar la normalidad de nuestros datos antes de aplicar cualquier método estadístico que dependa de esta suposición.

En este capítulo, exploraremos algunas de estas herramientas, incluyendo las medidas de asimetría y curtosis, los gráficos QQ y algunas pruebas estadísticas para evaluar la normalidad. En el siguiente capítulo, describiremos ciertas transformaciones que podemos aplicar a nuestros datos para hacerlos más cercanos a una distribución normal, en caso de que no lo sean. Pero antes de comenzar, cargaremos las librerías necesarias y definiremos algunas opciones globales para nuestro análisis.

```
library(tidyverse)
library(patchwork)
library(krulRutils)
library(e1071)
library(latex2exp)
library(greybox)

options(scipen = 999)
```

2.1. Los momentos estandarizados

Como es bien sabido, cualquier distribución normal queda completamente determinada por su media y su varianza. Se sigue que todos sus momentos estandarizados de orden superior quedan fijos y se pueden utilizar para comparar otras distribuciones contra la normal. En particular, el tercer y cuarto momentos estandarizados, conocidos como asimetría y curtosis respectivamente, son de gran utilidad para describir la forma de una distribución.

2.1.1. Asimetría

Definición 2.1.1. La *asimetría* de una variable aleatoria X se define como el tercer momento estandarizado, dado por

$$\gamma_1 = \frac{\mu_3}{\sigma^3} = \frac{\mathbb{E}[(X - \mu)^3]}{\sigma^3},$$

donde $\mu = \mathbb{E}[X]$ es la media y $\sigma = \sqrt{\mathbb{E}[(X - \mu)^2]}$ es la desviación estándar de X .

La asimetría, como su nombre lo indica, mide la falta de simetría de una distribución. Una distribución es *positivamente asimétrica* (*sesgo a la derecha*) si posee una cola más larga a la derecha, y *negativamente asimétrica* (*sesgo a la izquierda*) si la cola más larga está a la izquierda. Una distribución perfectamente simétrica tiene asimetría cero.

Para ilustrar estas ideas, introduciremos la distribución Gamma.

Definición 2.1.2. Decimos que una variable aleatoria continua X sigue una *distribución Gamma* con parámetro de forma $\alpha > 0$ y parámetro de tasa $\beta > 0$, si su función de densidad de probabilidad (PDF) está dada por

$$f_X(x; \alpha, \beta) = \begin{cases} \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, & x > 0, \\ 0, & x \leq 0, \end{cases} \quad (2.1)$$

donde $\Gamma(\alpha)$ denota la función Gamma, definida como

$$\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t} dt. \quad (2.2)$$

En este caso escribimos $X \sim \text{Gamma}(\alpha, \beta)$.

Observación 2.1.3. La distribución Gamma se usa frecuentemente en procesos de Poisson para modelar tiempos de espera hasta la ocurrencia de ciertos eventos. Por ejemplo, puede modelar el tiempo que pasa hasta que una compañía de seguros reciba un cierto número de reclamaciones.

Es un resultado conocido que la asimetría de una distribución Gamma está dada por

$$\gamma_1 = \frac{2}{\sqrt{\alpha}}.$$

En particular, la asimetría siempre es positiva y tiende a cero conforme α aumenta. En otras palabras, la distribución se vuelve más simétrica conforme aumenta el valor de α .

Mostraremos ahora cómo graficar la PDF de la distribución Gamma para $\alpha = 2$ y $\beta = 1$, destacando su media y su mediana. Notemos que para estos parámetros tenemos que

$$\begin{aligned} \text{media} &= \alpha/\beta = 2 \\ \text{mediana} &\approx 1.678347 \end{aligned}$$

En particular, la media es mayor que la mediana, lo cual es común en distribuciones con asimetría positiva.

2. Evaluación de normalidad univariada

```
# Asignamos los parámetros
alpha <- 2 # forma
beta <- 1 # tasa

# Creamos una secuencia de valores para X
x_data <- seq(0, 8, length.out = 500)

# Calculamos la PDF de la distribución Gamma
gamma_distribution_tbl <- tibble(
  x_data = x_data,
  density_data = dgamma(x_data, shape = alpha, rate = beta)
)

# Calculamos la media y la mediana
gamma_mean <- alpha / beta
gamma_median <- qgamma(0.5, shape = alpha, rate = beta)
gamma_sd <- sqrt(alpha) / beta

# Generamos la gráfica
gamma_distribution_plot <- gamma_distribution_tbl |>
  ggplot(aes(x = x_data, y = density_data)) +
  geom_line(color = c_palette["C blue"], linewidth = 1) +
  geom_vline(
    xintercept = gamma_mean,
    color = c_palette["C red"],
    linetype = "dashed",
    linewidth = 1
  ) +
  geom_vline(
    xintercept = gamma_median,
    color = c_palette["C green"],
    linetype = "dashed",
    linewidth = 1
  ) +
  annotate(
    "text",
    x = gamma_mean,
    y = 0.5,
    label = "Media",
    color = c_palette["C red"],
    hjust = -0.1
  ) +
  annotate(
    "text",
    x = gamma_median,
```

```

y = 0.5,
label = "Mediana",
color = c_palette["C green"],
hjust = 1.1
) +
labs(
  title = "Función de densidad de la distribución Gamma(2,1)",
  x = TeX("$X$"),
  y = "Densidad"
) +
theme_krul()

gamma_distribution_plot

```




Figura 2.1: Función de densidad de la distribución Gamma con parámetros $\alpha = 2$ y $\beta = 1$. Notemos que para estos parámetros la media es mayor que la mediana, lo cual es común en distribuciones con asimetría positiva.

Finalmente, usaremos la distribución Gamma para generar una gráfica comparativa de una distribución con sesgo a la izquierda, una simétrica y una con sesgo a la derecha.

```

# Calculamos la PDF de la distribución con sesgo negativo
left_skew_distribution_tbl <- tibble(
  x_data = -x_data,
  density_data = dgamma(-x_data, shape = alpha, rate = beta)
)

```

2. Evaluación de normalidad univariada

```
# Calculamos la PDF de la distribución simétrica
symmetric_distribution_tbl <- tibble(
  x_data = x_data - 4,
  density_data = dnorm(x_data)
)

# Calculamos la PDF de la distribución con sesgo positivo
right_skew_distribution_tbl <- tibble(
  x_data = x_data,
  density_data = dgamma(x_data, shape = alpha, rate = beta)
)

# Generamos la gráfica de la distribución con sesgo negativo
left_skew_distribution_plot <- left_skew_distribution_tbl |>
  ggplot(aes(x = x_data, y = density_data)) +
  geom_line(color = c_palette["C blue"], linewidth = 1) +
  geom_vline(
    xintercept = -gamma_mean,
    color = c_palette["C red"],
    linetype = "dashed",
    linewidth = 1
  ) +
  geom_vline(
    xintercept = -gamma_median,
    color = c_palette["C green"],
    linetype = "dashed",
    linewidth = 1
  ) +
  annotate(
    "text",
    x = -gamma_mean,
    y = 0.5,
    label = "Media",
    color = c_palette["C red"],
    hjust = 1.1
  ) +
  annotate(
    "text",
    x = -gamma_median,
    y = 0.5,
    label = "Mediana",
    color = c_palette["C green"],
    hjust = -0.1
  ) +
  labs(
```

```
    title = "Sesgo a la izquierda",
    x = TeX("$X$"),
    y = "Densidad"
  ) +
  theme_krul()

# Generamos la gráfica de la distribución simétrica
symmetric_distribution_plot <- symmetric_distribution_tbl |>
  ggplot(aes(x = x_data, y = density_data)) +
  geom_line(color = c_palette["C blue"], linewidth = 1) +
  geom_vline(
    xintercept = 0,
    color = c_palette["C red"],
    linetype = "dashed",
    linewidth = 1
  ) +
  geom_vline(
    xintercept = 0,
    color = c_palette["C green"],
    linetype = "dashed",
    linewidth = 1
  ) +
  annotate(
    "text",
    x = 0,
    y = 0.5,
    label = "Media y Mediana",
    color = c_palette["C red"],
    hjust = -0.1
  ) +
  labs(
    title = "Simétrica",
    x = TeX("$X$"),
    y = "Densidad"
  ) +
  theme_krul()

# Generamos la gráfica de la distribución con sesgo positivo
right_skew_distribution_plot <- right_skew_distribution_tbl |>
  ggplot(aes(x = x_data, y = density_data)) +
  geom_line(color = c_palette["C blue"], linewidth = 1) +
  geom_vline(
    xintercept = gamma_mean,
    color = c_palette["C red"],
    linetype = "dashed",
```

2. Evaluación de normalidad univariada

```
    linewidth = 1
  ) +
  geom_vline(
    xintercept = gamma_median,
    color = c_palette["C green"],
    linetype = "dashed",
    linewidth = 1
  ) +
  annotate(
    "text",
    x = gamma_mean,
    y = 0.5,
    label = "Media",
    color = c_palette["C red"],
    hjust = -0.1
  ) +
  annotate(
    "text",
    x = gamma_median,
    y = 0.5,
    label = "Mediana",
    color = c_palette["C green"],
    hjust = 1.1
  ) +
  labs(
    title = "Sesgo a la derecha",
    x = TeX("$X$"),
    y = "Densidad"
  ) +
  theme_krul()

skew_comparison_plot <- left_skew_distribution_plot +
  symmetric_distribution_plot +
  right_skew_distribution_plot +
  plot_annotation(
    title = "Comparación de distribuciones con distintos niveles de asimetría",
    theme = theme(
      plot.title = element_text(
        size = 24,
        face = "bold"
      )
    )
  )

skew_comparison_plot
```

Comparación de distribuciones con distintos niveles de asimetría




Figura 2.2: Gráfica comparativa de distribuciones con sesgo a la izquierda, simétrica y con sesgo a la derecha. Notemos como la asimetría afecta la forma de la distribución y la relación entre la media y la mediana.

2.1.2. Curtosis

Definición 2.1.4. La *curtosis* de una variable aleatoria X se define como el cuarto momento estandarizado, dado por

$$\beta_2 = \frac{\mu_4}{\sigma^4} = \frac{\mathbb{E}[(X - \mu)^4]}{\sigma^4},$$

donde $\mu = \mathbb{E}[X]$ es la media y $\sigma = \sqrt{\mathbb{E}[(X - \mu)^2]}$ es la desviación estándar de X .

La curtosis mide el grosor de las colas de una distribución. Una distribución con alta curtosis (*leptocúrtica*) suele tener colas más pesadas y un pico más agudo que la normal. En cambio, una distribución con baja curtosis (*platicúrtica*) suele tener colas más ligeras y un pico más plano. La curtosis de la normal es 3, por lo cual es común calcular el *exceso de curtosis* de una distribución la cual está dada por:

$$\gamma_2 = \beta_2 - 3.$$

Para ilustrar estas ideas, introduciremos la distribución normal generalizada, también conocida como la distribución de Subbotin.

Definición 2.1.5. Decimos que una variable aleatoria X sigue una *distribución normal generalizada* con parámetros de localización $\mu \in \mathbb{R}$, escala $\alpha > 0$ y forma $\beta > 0$, si su función de densidad de probabilidad (PDF) está dada por

$$f_X(x; \mu, \alpha, \beta) = \frac{\beta}{2\alpha\Gamma(1/\beta)} e^{-\left(\frac{|x-\mu|}{\alpha}\right)^\beta}, \quad x \in \mathbb{R}, \quad (2.3)$$

donde Γ nuevamente denota a la función Gamma, que definimos en (2.2). En este caso escribimos $X \sim \text{NormalGeneralizada}(\mu, \alpha, \beta)$.

2. Evaluación de normalidad univariada

Los momentos de la distribución normal generalizada están dados por:

$$\begin{aligned}\text{media} &= \mu, \\ \text{varianza} &= \alpha^2 \frac{\Gamma(3/\beta)}{\Gamma(1/\beta)}, \\ \text{asimetría} &= 0, \\ \text{curtosis excesiva} &= \frac{\Gamma(5/\beta)\Gamma(1/\beta)}{\Gamma(3/\beta)^2} - 3.\end{aligned}$$

Notemos que la asimetría es cero para cualquier valor de β , lo cual indica que la distribución siempre es simétrica. En cuanto a la curtosis, observamos que:

- Si $0 < \beta < 2$, la curtosis excesiva es positiva, indicando colas más pesadas que la normal (distribución leptocúrtica).
- Si $\beta = 2$, la curtosis excesiva es cero, coincidiendo con la normal.
- Si $\beta > 2$, la curtosis excesiva es negativa, indicando colas más ligeras que la normal (distribución platicúrtica).

Observación 2.1.6. Notemos que para $\beta = 1$ la distribución normal generalizada coincide con la distribución de Laplace cuya PDF está dada por

$$f_X(x; \mu, b) = \frac{1}{2b} e^{-\frac{|x-\mu|}{b}}, \quad x \in \mathbb{R}, \quad (2.4)$$

donde $b > 0$ es un parámetro de escala (que corresponde al valor de α en la normal generalizada). En este caso, la curtosis excesiva es 3, indicando colas más pesadas que la normal. Por otro lado, cuando $\beta = 2$ obtenemos la distribución normal con media μ y varianza $2\alpha^2$. Finalmente, a medida que β tiende a infinito, la distribución normal generalizada converge a una distribución uniforme en el intervalo $(\mu - \alpha, \mu + \alpha)$, la cual tiene curtosis excesiva de -1.2 , indicando colas más ligeras que la normal.

Mostraremos ahora la gráfica de la PDF de la distribución normal generalizada para $\mu = 0$, $\alpha = 1$ y distintos valores de β , destacando sus colas y la forma del pico central.

```
# Creamos una secuencia de valores para X
x_data <- seq(-3.5, 3.5, length.out = 500)

# Seleccionamos los valores de beta a graficar
beta_values <- c(0.5, 1, 1.5, 2, 3, 8)

# Calculamos las densidades para cada valor de beta
dgnorm_distribution_family_tbl <- expand_grid(
  x_data = x_data,
  beta = beta_values
) |>
mutate(
  density_data = dgnorm(
    x_data,
```

```
mu = 0,
scale = 1,
shape = beta
),
beta = factor(beta)
)

# Generamos la gráfica
dgnorm_distribution_family_plot <- ggplot(
  dgnorm_distribution_family_tbl,
  aes(
    x = x_data,
    y = density_data,
    color = beta
  )
) +
  geom_line(linewidth = 1) +
  scale_color_manual(
    values = unname(c_pal(
      "C red",
      "C yellow",
      "C orange",
      "C green",
      "C blue",
      "C magenta"
    )),
    labels = c(
      TeX("$\\beta$ = 0.5 (Colas muy pesadas)"),
      TeX("$\\beta$ = 1 (Laplace)"),
      TeX("$\\beta$ = 1.5 (Colas pesadas)"),
      TeX("$\\beta$ = 2 (Normal)"),
      TeX("$\\beta$ = 3 (Colas ligeras)"),
      TeX("$\\beta$ = 8 (Colas muy ligeras)")
    )
  ) +
  labs(
    title = "Distribucion normal generalizada para distintos valores de beta",
    x = TeX("$X$"),
    y = "Densidad",
    color = "Parámetro de forma"
  ) +
  theme_krul()

dgnorm_distribution_family_plot
```

2. Evaluación de normalidad univariada

Distribucion normal generalizada para distintos valores de beta




Figura 2.3: Funciones de densidad de la distribución normal generalizada para $\mu = 0$, $\alpha = 1$ y distintos valores de β . Notemos cómo cambia la forma de la distribución conforme varía el parámetro de forma β , afectando el grosor de las colas y la forma del pico central.

2.2. Gráficos QQ

Los gráficos QQ (quantile–quantile) son herramientas para comparar la distribución de un conjunto de datos con una distribución teórica (por ejemplo, la normal). Son especialmente útiles para evaluar la normalidad.

Para construir un gráfico QQ, siga estos pasos:

1. **Ordene los datos muestrales:** Coloque los datos en orden creciente:

$$x_{(1)} \leq x_{(2)} \leq \cdots \leq x_{(n)}.$$

2. **Calcule posiciones de trazado (cuantiles empíricos):** Para cada valor ordenado $x_{(i)}$, calcule la probabilidad correspondiente

$$p_i = \frac{2i - 1}{2n}, \quad i = 1, 2, \dots, n.$$

3. **Obtenga los cuantiles teóricos de la normal:** A partir de la función cuantil (inversa de la CDF) de la normal estándar:

$$q_i = \Phi^{-1}(p_i),$$

donde Φ^{-1} es la función cuantil de la normal estándar.

4. **Trace los puntos:** Grafique los pares $(q_i, x_{(i)})$ con q_i en el eje x y $x_{(i)}$ en el eje y.

5. **Agregue una línea de referencia:** Trazar, por ejemplo, una recta por el primer y tercer cuartil ayuda a evaluar la normalidad.

Mientras más cerca caigan los puntos de esa recta, más se parece la muestra a la distribución normal especificada.

Para ilustrar estas ideas, generaremos muestras de las distribuciones Gamma y Laplace y construiremos sus gráficos QQ e histogramas. Primero, generamos las muestras:

```
set.seed(123) # for reproducibility

# Sample size
n <- 300
mu <- 0
b <- 1
# Generate random samples from the Gamma distribution
gamma_sample <- rgamma(n, shape = alpha, rate = beta)

gamma_sample_tbl <- tibble(
  sample = gamma_sample
)

# Generate uniform random numbers in (0,1)
u <- runif(n)

# Apply inverse CDF of Laplace
laplace_sample <- ifelse(u < 0.5,
  mu + b * log(2 * u),
  mu - b * log(2 * (1 - u))
)

laplace_sample_tbl <- tibble(
  sample = laplace_sample
)
```

Ahora construiremos los correspondientes gráficos QQ e histogramas. Empezamos con las muestras de la distribución Gamma:

```
gamma_qq_plot <- gamma_sample_tbl %>%
  ggplot(aes(sample = sample)) +
  geom_qq(
    color = c_palette["C red"],
    size = 0.3
  ) +
  geom_qq_line(
    color = c_palette["C blue"],
    linewidth = 0.5
  ) +
```

2. Evaluación de normalidad univariada

```
labs(
  title = "Gráfico QQ",
  x = "Cuantiles teóricos",
  y = "Cuantiles muestrales"
) +
theme_krul()

gamma_histogram <- gamma_sample_tbl %>%
  ggplot(aes(x = sample)) +
  geom_histogram(
    bins = 30,
    fill = c_palette["C blue"],
    color = "black",
    alpha = 0.7
  ) +
  labs(
    title = "Histograma",
    x = "Valores muestrales",
    y = "Densidad"
  ) +
  theme_krul()

gamma_plot <- gamma_qq_plot + gamma_histogram +
  plot_layout(ncol = 2) +
  plot_annotation(
    title = "Distribución Gamma: gráfico QQ e histograma",
    theme = theme(
      plot.title = element_text(
        size = 24,
        face = "bold"
      )
    )
  )

gamma_plot
```

Distribución Gamma: gráfico QQ e histograma




Figura 2.4: Gráfico QQ e histograma de las muestras de la distribución Gamma.

Construimos ahora el gráfico QQ y el histograma para las muestras de Laplace:

```
laplace_qq_plot <- laplace_sample_tbl %>%
  ggplot(aes(sample = sample)) +
  geom_qq(
    color = c_palette["C red"],
    size = 0.3
  ) +
  geom_qq_line(
    color = c_palette["C blue"],
    linewidth = 0.5
  ) +
  labs(
    title = "Gráfico QQ",
    x = "Cuantiles teóricos",
    y = "Cuantiles muestrales"
  ) +
  theme_krul()

laplace_histogram <- laplace_sample_tbl %>%
  ggplot(aes(x = sample)) +
  geom_histogram(
    bins = 30,
    fill = c_palette["C blue"],
    color = "black",
    alpha = 0.7
  )
```

```
) +  
labs(  
  title = "Histograma",  
  x = "Valores muestrales",  
  y = "Densidad"  
) +  
theme_krul()  
laplace_plot <- laplace_qq_plot + laplace_histogram +  
plot_layout(ncol = 2) +  
plot_annotation(  
  title = "Distribución de Laplace: gráfico QQ e histograma",  
  theme = theme(  
    plot.title = element_text(  
      size = 24,  
      face = "bold"  
    )  
  )  
)  
laplace_plot
```

Distribución de Laplace: gráfico QQ e histograma




Figura 2.5: Gráfico QQ e histograma de las muestras de la distribución de Laplace.

2.3. Asimetría y curtosis muestrales

Hasta ahora hemos definido asimetría y curtosis para variables aleatorias. Sin embargo, en la práctica trabajamos con muestras y no con poblaciones completas. Por ello, necesitamos definir la asimetría y la curtosis *muestrales*.

Definición 2.3.1. Sean $x_1, x_2, \dots, x_n$ una muestra de tamaño n . La *media muestral* $\bar{x}$ y la *varianza muestral* s^2 están dadas por

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

La *asimetría muestral* g_1 está dada por

$$g_1 = \frac{n}{(n-1)(n-2)} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^3.$$

La *curtosis en exceso muestral* g_2 está dada por

$$g_2 = \frac{n(n+1)}{(n-1)(n-2)(n-3)} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^4 - \frac{3(n-1)^2}{(n-2)(n-3)}.$$

Como ejemplo, calcularemos la asimetría y la curtosis en exceso muestrales de las muestras de Gamma y Laplace generadas antes. Para la muestra Gamma tenemos:

```
# Compute sample skewness and excess kurtosis for Gamma distribution
gamma_sample_tbl %>%
  summarise(
    sample_skewness = skewness(sample, type = 2),
    sample_excess_kurtosis = kurtosis(sample, type = 2)
  ) %>%
  glimpse()
```

```
Rows: 1
Columns: 2
$ sample_skewness      <dbl> 1.293772
$ sample_excess_kurtosis <dbl> 2.164353
```

Para la muestra de Laplace tenemos:

```
# Compute sample skewness and excess kurtosis for Laplace distribution
laplace_sample_tbl %>%
  summarise(
    sample_skewness = skewness(sample, type = 2),
    sample_excess_kurtosis = kurtosis(sample, type = 2)
  ) %>%
  glimpse()
```

```
Rows: 1
Columns: 2
$ sample_skewness      <dbl> -0.07876743
$ sample_excess_kurtosis <dbl> 3.726374
```


2. Evaluación de normalidad univariada

2.4. Escalamiento y estandarización

En muchas situaciones, las unidades con que medimos distintas variables no son comparables (p.ej., estatura en cm y peso en kg). En esos casos conviene *escalar* las variables para hacerlas comparables. En esta sección discutimos los métodos más comunes para escalar y estandarizar variables y muestras.

2.4.1. Escalamiento de variables aleatorias

Definición 2.4.1. Una *transformación afín* de una variable aleatoria X es de la forma

$$Y = aX + b$$

donde a y b son constantes.

Comentario 2.4.2. En estadística, a menudo se habla de *escalamiento* (aunque incluya traslación) para referirse a transformaciones afines.

Suponga que X tiene media μ y desviación estándar σ . Entonces la variable

$$Y = aX + b$$

tendrá media $a\mu + b$ y desviación estándar $|a|\sigma$. En particular, si elegimos $a = 1/\sigma$ y $b = -\mu/\sigma$, la variable

$$Z = \frac{X - \mu}{\sigma}$$

tendrá media 0 y desviación estándar 1. Esta transformación se llama *estandarización*, y Z es la versión *estandarizada* de X (también llamada *puntaje z*).

Comentario 2.4.3. Si X no es normal, Z no será normal estándar. La estandarización no transforma una distribución no normal en normal.

Observación 2.4.4. Por definición,

$$\gamma_1(Z) = \mathbb{E}[Z^3] = \frac{\mathbb{E}[(X - \mu)^3]}{\sigma^3} = \gamma_1(X)$$

y

$$\gamma_2(Z) = \mathbb{E}[Z^4] - 3 = \frac{\mathbb{E}[(X - \mu)^4]}{\sigma^4} - 3 = \gamma_2(X).$$

Como ejemplo, consideremos de nuevo la distribución Gamma. En este caso

$$\mu = \frac{\alpha}{\beta} \quad \text{and} \quad \sigma = \frac{\sqrt{\alpha}}{\beta}.$$

Con esta información, generamos la gráfica de la versión estandarizada de la Gamma y la comparamos con la original.

```
# Calculate density values
z_gamma_distribution_tbl <- gamma_distribution_tbl %>%
  mutate(
    z_data = (x_data - gamma_mean) / gamma_sd,
    z_density = dgamma(x_data, shape = alpha, rate = beta) * gamma_sd
  ) %>%
  select(z_data, z_density)

# Calculate mean and median
z_gamma_mean <- 0
z_gamma_median <- (gamma_median - gamma_mean) / gamma_sd

# Plot
z_gamma_distribution_plot <- z_gamma_distribution_tbl %>%
  ggplot(aes(x = z_data, y = z_density)) +
  geom_line(
    color = c_palette["C blue"],
    linewidth = 1
  ) +
  geom_vline(
    xintercept = z_gamma_mean,
    color = c_palette["C red"],
    linetype = "dashed",
    linewidth = 1
  ) +
  geom_vline(
    xintercept = z_gamma_median,
    color = c_palette["C green"],
    linetype = "dotted",
    linewidth = 1
  ) +
  annotate(
    "text",
    x = z_gamma_mean,
    y = 0.55,
    label = "Media",
    color = c_palette["C red"],
    hjust = -0.1
  ) +
  annotate(
    "text",
    x = z_gamma_median,
    y = 0.55,
    label = "Mediana",
    color = c_palette["C green"],
```

2. Evaluación de normalidad univariada

```
  hjust = 1.1
) +
coord_cartesian(ylim = c(0, 0.6)) +
labs(
  title = paste(
    "Estandarizada"
  ),
  x = "X",
  y = "Densidad"
) +
theme_krul()

gamma_distribution_plot <- gamma_distribution_plot +
  labs(
    title = "Original"
  )

combined_gamma_plot <- gamma_distribution_plot + z_gamma_distribution_plot +
  plot_layout(ncol = 2) +
  plot_annotation(
    title = "Distribución Gamma: original y estandarizada",
    theme = theme(
      plot.title = element_text(
        size = 24,
        face = "bold"
      )
    )
  )

combined_gamma_plot
```

Distribución Gamma: original y estandarizada




Figura 2.6: Comparación de la función de densidad (PDF) de la distribución Gamma original y su versión estandarizada.

2.4.2. Escalamiento de muestras

Para una muestra dada, no siempre se conoce la distribución subyacente; en particular, pueden desconocerse la media y la desviación poblacionales. Aun así, podemos escalar los datos; hay varios métodos comunes:

1. *Estandarización*: Usa la media y desviación muestrales. La muestra estandarizada es

$$T = \frac{X - \bar{X}}{S},$$

donde $\bar{X}$ es la media muestral y S la desviación muestral.

2. *Escalamiento Min-Max*: Escala a un rango fijo, usualmente $[0,1]$. La muestra escalada es

$$T = \frac{X - \min(X)}{\max(X) - \min(X)},$$

donde $\min(X)$ y $\max(X)$ son el mínimo y máximo de la muestra. Es muy sensible a atípicos al usar extremos.

3. *Escalamiento robusto*: Usa la mediana y el rango intercuartil (IQR). La muestra escalada es

$$T = \frac{X - \text{median}(X)}{\text{IQR}(X)},$$

2. Evaluación de normalidad univariada

donde $\text{IQR}(X) = Q_3 - Q_1$. Es más robusto a atípicos que Min-Max.

4. *Normalización*: Divide cada dato por la norma del vector. La muestra normalizada es

$$T = \frac{X}{\|X\|},$$

donde $\|X\|$ es la norma. Se usa con menor frecuencia que los anteriores.

Comentario 2.4.5. Como se mencionó, escalar no vuelve normal una distribución no normal. En particular, la asimetría y la curtosis en exceso muestrales no cambian.

Como ejemplo, consideraremos los distintos métodos de escalado aplicados a la muestra de la distribución Gamma que generamos anteriormente.

```
scale_lookup_tbl <- tibble(
  code = c(
    "sample",
    "sample_standard",
    "sample_min_max",
    "sample_robust",
    "sample_normal"
  ),
  label = c(
    "Original Sample",
    "Estandarizada",
    "Min-Max Scaled",
    "Robust Scaled",
    "Normalized"
  )
)

scaled_gamma_sample_tbl <- gamma_sample_tbl %>%
  mutate(
    sample_standard = standard_scale(sample),
    sample_min_max = min_max_scale(sample),
    sample_robust = robust_scale(sample),
    sample_normal = normal_scale(sample)
  ) %>%
  pivot_longer(
    cols = everything(),
    names_to = "scaling_method",
    values_to = "sample_scaled"
  ) %>%
  convert_codes_to_factor(
    code_col = scaling_method,
    lookup_tbl = scale_lookup_tbl,
    lookup_code_col = code,
    lookup_label_col = label,
```

```
    new_factor_col_name = scaling_method_factor
  )

scaled_gamma_qq_plot <- scaled_gamma_sample_tbl %>%
  ggplot(aes(sample = sample_scaled)) +
  facet_wrap(
    ~scaling_method_factor,
    nrow = 5,
    scales = "free"
  ) +
  geom_qq(
    color = c_palette["C red"],
    size = 0.3
  ) +
  geom_qq_line(
    color = c_palette["C blue"],
    linewidth = 0.5
  ) +
  labs(
    title = "Gráficos QQ",
    x = "Cuantiles teóricos",
    y = "Cuantiles muestrales"
  ) +
  theme_krul()

scaled_gamma_histogram <- scaled_gamma_sample_tbl %>%
  ggplot(aes(x = sample_scaled)) +
  facet_wrap(
    ~scaling_method_factor,
    nrow = 5,
    scales = "free"
  ) +
  geom_histogram(
    bins = 30,
    fill = c_pal("C blue"),
    color = "black",
    alpha = 0.7
  ) +
  labs(
    title = "Histogramas",
    x = "Valores muestrales",
    y = "Densidad"
  ) +
  theme_krul()
```

2. Evaluación de normalidad univariada

```
scaled_gamma_plot <- scaled_gamma_qq_plot + scaled_gamma_histogram +  
  plot_layout(ncol = 2) +  
  plot_annotation(  
    title = "Comparación de métodos de escalamiento aplicados a la muestra Gamma",  
    theme = theme(  
      plot.title = element_text(  
        size = 24,  
        face = "bold"  
      )  
    )  
  )  
scaled_gamma_plot
```

Comparación de métodos de escalamiento aplicados a la muestra Gamma




Figura 2.7: Comparación de distintos métodos de escalamiento aplicados a la muestra Gamma. Note que los QQ-plots son versiones reescaladas del gráfico QQ original y, por tanto, tienen la misma forma.

2. Evaluación de normalidad univariada

2.5. Actividad: Visualizando la no normalidad de muestras

Para cada una de las siguientes distribuciones, construya una muestra de tamaño 300 y calcule la asimetría y curtosis muestrales. Después, construya y compare sus gráficos QQ e histogramas.

1. Distribución exponencial con tasa $\lambda = 1$.
2. Distribución uniforme en $[0, 1]$.
3. Distribución beta con $\alpha = 2$ y $\beta = 5$.
4. Distribución de Cauchy con localización $x_0 = 0$ y escala $\gamma = 1$.
5. Distribución χ_k^2 con $k = 3$ grados de libertad.

