



Tecnológico de Monterrey

Aplicación de Métodos Multivariados en Ciencia de Datos

Módulo 1: Relaciones de Interdependencia

Raúl Gómez Muñoz
Blanca Rosa Ruiz Hernández

Tabla de contenidos

I Introducción al análisis multivariado

1. Evaluación de normalidad univariada	1
1.1. Los momentos estandarizados	1
1.1.1. Asimetría	2
1.1.2. Curtosis	9
1.1.3. Asimetría y curtosis muestrales	14
1.2. Gráficos QQ	20
1.3. Escalamiento y estandarización	24
1.3.1. Escalamiento de variables aleatorias	25
1.3.2. Escalamiento de muestras	28
1.4. Actividad: Visualizando la no normalidad de muestras	33

Parte I

Introducción al análisis multivariado

Capítulo 1

Evaluación de normalidad univariada

En muchos métodos estadísticos univariados se asume que los datos siguen una distribución normal. Sin embargo, en la práctica, no todos nuestros conjuntos de datos satisfacen esta suposición. En estos casos no se justifica el uso de estos métodos y su uso indiscriminado puede llevar a conclusiones erróneas, que nos podrían llevar a tomar malas decisiones bajo la ilusión de un respaldo estadístico que no existe. Es por eso que resulta fundamental contar con herramientas que nos permitan evaluar la normalidad de nuestros datos antes de aplicar cualquier método estadístico que dependa de esta suposición.

En este capítulo exploraremos algunas de estas herramientas, incluyendo las medidas de asimetría y curtosis, los gráficos QQ y algunas pruebas estadísticas para evaluar la normalidad. En el siguiente capítulo, describiremos ciertas transformaciones que podemos aplicar a nuestros datos para hacerlos más cercanos a una distribución normal, en caso de que no lo sean. Pero antes de comenzar, cargaremos las librerías necesarias y definiremos algunas opciones globales para nuestro análisis.

```
library(tidyverse)
library(patchwork)
library(krnlRutils)
library(e1071)
library(latex2exp)
library(greybox)
library(kableExtra)

options(scipen = 999)
```

1.1. Los momentos estandarizados

Como es bien sabido, cualquier distribución normal queda completamente determinada por su media y su varianza. Se sigue que todos sus momentos estandarizados de orden superior quedan fijos y se pueden utilizar para comparar otras distribuciones contra la normal. En particular, el tercer y cuarto momentos estandarizados, conocidos como asimetría y curtosis respectivamente, son de gran utilidad para describir la forma de una distribución.

1.1.1. Asimetría

Definición 1.1.1. La *asimetría* de una variable aleatoria X se define como el tercer momento estandarizado, dado por

$$\gamma_1 = \frac{\mu_3}{\sigma^3} = \frac{\mathbb{E}[(X - \mu)^3]}{\sigma^3},$$

donde $\mu = \mathbb{E}[X]$ es la media y $\sigma = \sqrt{\mathbb{E}[(X - \mu)^2]}$ es la desviación estándar de X .

La asimetría, como su nombre lo indica, mide la falta de simetría de una distribución. Una distribución es *positivamente asimétrica* (*sesgo a la derecha*) si posee una cola más larga a la derecha, y *negativamente asimétrica* (*sesgo a la izquierda*) si la cola más larga está a la izquierda. Una distribución perfectamente simétrica tiene asimetría cero.

Para ilustrar estas ideas, introduciremos la distribución Gamma.

Definición 1.1.2. Decimos que una variable aleatoria continua X sigue una *distribución Gamma* con parámetro de forma $\alpha > 0$ y parámetro de tasa $\beta > 0$, si su función de densidad de probabilidad (PDF) está dada por

$$f_X(x; \alpha, \beta) = \begin{cases} \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, & x > 0, \\ 0, & x \leq 0, \end{cases} \quad (1.1)$$

donde $\Gamma(\alpha)$ denota la función Gamma, definida como

$$\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t} dt. \quad (1.2)$$

En este caso escribimos $X \sim \text{Gamma}(\alpha, \beta)$.

Observación 1.1.3. La distribución Gamma se usa frecuentemente en procesos de Poisson para modelar tiempos de espera hasta la ocurrencia de ciertos eventos. Por ejemplo, puede modelar el tiempo que pasa hasta que una compañía de seguros reciba un cierto número de reclamaciones.

La siguiente tabla resume las características poblacionales más importantes de la distribución Gamma:

```
# Creamos la tabla de características
gamma_tbl <- tibble(
  `Característica` = c(
    "Media",
    "Varianza",
    "Asimetría"
  ),
  `Valor` = c(
    "$\\alpha/\\beta$",
    "$\\alpha/\\beta^2$",
    "$2/\\sqrt{\\alpha} $"
  )
)
```


1. Evaluación de normalidad univariada

```
# Formatear y mostrar la tabla
kable(
  gamma_tbl,
  booktabs = TRUE,
  escape = FALSE,
)
```

Tabla 1.1: Características poblacionales de la distribución Gamma con parámetros α y β .

Característica	Valor
Media	α/β
Varianza	α/β^2
Asimetría	$2/\sqrt{\alpha}$

Notemos que la asimetría siempre es positiva y tiende a cero conforme α aumenta. En otras palabras, la distribución se vuelve más simétrica conforme aumenta el valor de α . Por otro lado, aunque no existe una fórmula cerrada para la mediana de la distribución Gamma, podemos calcularla numéricamente en R usando la función `qgamma()`. La mediana en una distribución Gamma siempre es menor que la media, lo cual es consistente con la asimetría positiva de esta distribución.

Observación 1.1.4. Más adelante definiremos la *curtosis excesiva* de una variable aleatoria, pero por el momento mencionaremos que la curtosis excesiva de la distribución Gamma está dada por $6/\alpha$. Notemos que, al igual que la asimetría, la curtosis excesiva es siempre positiva y tiende a cero conforme α aumenta, indicando que la distribución se vuelve más parecida a la normal conforme aumenta α .

Mostraremos ahora cómo graficar la PDF de la distribución Gamma para $\alpha = 2$ y $\beta = 1$, destacando su media y su mediana. Notemos que para estos parámetros tenemos que

$$\begin{aligned} \text{media} &= \alpha/\beta = 2 \\ \text{mediana} &\approx 1.678347 \\ \text{asimetría} &= 2/\sqrt{\alpha} = \sqrt{2} \approx 1.4142136 \end{aligned}$$

En particular, la media es mayor que la mediana, lo cual es común en distribuciones con asimetría positiva.

```
# Asignamos los parámetros
alpha <- 2 # forma
beta <- 1 # tasa

# Creamos una secuencia de valores para X
x_data <- seq(0, 8, length.out = 500)

# Calculamos la PDF de la distribución Gamma
gamma_distribution_tbl <- tibble(
  x_data = x_data,
```

```
density_data = dgamma(x_data, shape = alpha, rate = beta)
)

# Calculamos la media, la mediana y la desviación estándar
gamma_mean <- alpha / beta
gamma_median <- qgamma(0.5, shape = alpha, rate = beta)
gamma_sd <- sqrt(alpha) / beta

# Generamos la gráfica
gamma_distribution_plot <- gamma_distribution_tbl |>
  ggplot(aes(x = x_data, y = density_data)) +
  geom_line(color = c_palette["C blue"], linewidth = 1) +
  geom_vline(
    xintercept = gamma_mean,
    color = c_palette["C red"],
    linetype = "dashed",
    linewidth = 1
  ) +
  geom_vline(
    xintercept = gamma_median,
    color = c_palette["C green"],
    linetype = "dashed",
    linewidth = 1
  ) +
  annotate(
    "text",
    x = gamma_mean,
    y = 0.5,
    label = "Media",
    color = c_palette["C red"],
    hjust = -0.1
  ) +
  annotate(
    "text",
    x = gamma_median,
    y = 0.5,
    label = "Mediana",
    color = c_palette["C green"],
    hjust = 1.1
  ) +
  labs(
    title = "Función de densidad de la distribución Gamma(2,1)",
    x = TeX("$X$"),
    y = "Densidad"
  ) +
```

```
theme_krul()
```

```
gamma_distribution_plot
```




Figura 1.1: Función de densidad de la distribución Gamma con parámetros $\alpha = 2$ y $\beta = 1$. Notemos que para estos parámetros la media es mayor que la mediana, lo cual es común en distribuciones con asimetría positiva.

Finalmente, usaremos la distribución Gamma para generar una gráfica comparativa de una distribución con sesgo a la izquierda, una simétrica y una con sesgo a la derecha.

```
# Calculamos la PDF de la distribución con sesgo negativo
left_skew_distribution_tbl <- tibble(
  x_data = -x_data,
  density_data = dgamma(-x_data, shape = alpha, rate = beta)
)

# Calculamos la PDF de la distribución simétrica
symmetric_distribution_tbl <- tibble(
  x_data = x_data - 4,
  density_data = dnorm(x_data)
)

# Calculamos la PDF de la distribución con sesgo positivo
right_skew_distribution_tbl <- tibble(
  x_data = x_data,
  density_data = dgamma(x_data, shape = alpha, rate = beta)
```

```
)

# Generamos la gráfica de la distribución con sesgo negativo
left_skew_distribution_plot <- left_skew_distribution_tbl |>
  ggplot(aes(x = x_data, y = density_data)) +
  geom_line(color = c_palette["C blue"], linewidth = 1) +
  geom_vline(
    xintercept = -gamma_mean,
    color = c_palette["C red"],
    linetype = "dashed",
    linewidth = 1
  ) +
  geom_vline(
    xintercept = -gamma_median,
    color = c_palette["C green"],
    linetype = "dashed",
    linewidth = 1
  ) +
  annotate(
    "text",
    x = -gamma_mean,
    y = 0.5,
    label = "Media",
    color = c_palette["C red"],
    hjust = 1.1
  ) +
  annotate(
    "text",
    x = -gamma_median,
    y = 0.5,
    label = "Mediana",
    color = c_palette["C green"],
    hjust = -0.1
  ) +
  labs(
    title = "Sesgo a la izquierda",
    x = TeX("$X$"),
    y = "Densidad"
  ) +
  theme_krul()

# Generamos la gráfica de la distribución simétrica
symmetric_distribution_plot <- symmetric_distribution_tbl |>
  ggplot(aes(x = x_data, y = density_data)) +
  geom_line(color = c_palette["C blue"], linewidth = 1) +
```

1. Evaluación de normalidad univariada

```
geom_vline(  
  xintercept = 0,  
  color = c_palette["C red"],  
  linetype = "dashed",  
  linewidth = 1  
) +  
geom_vline(  
  xintercept = 0,  
  color = c_palette["C green"],  
  linetype = "dashed",  
  linewidth = 1  
) +  
annotate(  
  "text",  
  x = 0,  
  y = 0.5,  
  label = "Media y Mediana",  
  color = c_palette["C red"],  
  hjust = -0.1  
) +  
labs(  
  title = "Simétrica",  
  x = TeX("$X$"),  
  y = "Densidad"  
) +  
theme_krul()  
  
# Generamos la gráfica de la distribución con sesgo positivo  
right_skew_distribution_plot <- right_skew_distribution_tbl |>  
ggplot(aes(x = x_data, y = density_data)) +  
geom_line(color = c_palette["C blue"], linewidth = 1) +  
geom_vline(  
  xintercept = gamma_mean,  
  color = c_palette["C red"],  
  linetype = "dashed",  
  linewidth = 1  
) +  
geom_vline(  
  xintercept = gamma_median,  
  color = c_palette["C green"],  
  linetype = "dashed",  
  linewidth = 1  
) +  
annotate(  
  "text",
```

```
x = gamma_mean,
y = 0.5,
label = "Media",
color = c_palette["C red"],
hjust = -0.1
) +
annotate(
  "text",
  x = gamma_median,
  y = 0.5,
  label = "Mediana",
  color = c_palette["C green"],
  hjust = 1.1
) +
labs(
  title = "Sesgo a la derecha",
  x = TeX("$X$"),
  y = "Densidad"
) +
theme_krul()

skew_comparison_plot <- left_skew_distribution_plot +
  symmetric_distribution_plot +
  right_skew_distribution_plot +
  plot_annotation(
    title = "Comparación de distribuciones con distintos niveles de asimetría",
    theme = theme(
      plot.title = element_text(
        size = 24,
        face = "bold"
      )
    )
  )

skew_comparison_plot
```

1. Evaluación de normalidad univariada

Comparación de distribuciones con distintos niveles de asimetría




Figura 1.2: Gráfica comparativa de distribuciones con sesgo a la izquierda, simétrica y con sesgo a la derecha. Notemos como la asimetría afecta la forma de la distribución y la relación entre la media y la mediana.

1.1.2. Curtosis

Definición 1.1.5. La *curtosis* de una variable aleatoria X se define como el cuarto momento estandarizado, dado por

$$\beta_2 = \frac{\mu_4}{\sigma^4} = \frac{\mathbb{E}[(X - \mu)^4]}{\sigma^4},$$

donde $\mu = \mathbb{E}[X]$ es la media y $\sigma = \sqrt{\mathbb{E}[(X - \mu)^2]}$ es la desviación estándar de X .

La curtosis mide el grosor de las colas de una distribución. Una distribución con alta curtosis (*leptocúrtica*) suele tener colas más pesadas y un pico más agudo que la normal. En cambio, una distribución con baja curtosis (*platicúrtica*) suele tener colas más ligeras y un pico más plano. La curtosis de la normal es 3, por lo cual es común calcular el *exceso de curtosis* de una distribución la cual está dada por:

$$\gamma_2 = \beta_2 - 3.$$

Para ilustrar estas ideas, introduciremos la distribución normal generalizada, también conocida como la distribución de Subbotin.

Definición 1.1.6. Decimos que una variable aleatoria X sigue una *distribución normal generalizada* con parámetros de localización $\mu \in \mathbb{R}$, escala $\alpha > 0$ y forma $\beta > 0$, si su función de densidad de probabilidad (PDF) está dada por

$$f_X(x; \mu, \alpha, \beta) = \frac{\beta}{2\alpha\Gamma(1/\beta)} e^{-\left(\frac{|x-\mu|}{\alpha}\right)^\beta}, \quad x \in \mathbb{R}, \quad (1.3)$$

donde Γ nuevamente denota a la función Gamma, que definimos en (1.2). En este caso escribimos $X \sim \text{NormalGeneralizada}(\mu, \alpha, \beta)$.

Los momentos de la distribución normal generalizada están dados por:

$$\begin{aligned}\text{media} &= \mu, \\ \text{varianza} &= \alpha^2 \frac{\Gamma(3/\beta)}{\Gamma(1/\beta)}, \\ \text{asimetría} &= 0, \\ \text{curtosis excesiva} &= \frac{\Gamma(5/\beta)\Gamma(1/\beta)}{\Gamma(3/\beta)^2} - 3.\end{aligned}$$

Notemos que la asimetría es cero para cualquier valor de β , lo cual indica que la distribución siempre es simétrica. En cuanto a la curtosis, observamos que:

- Si $0 < \beta < 2$, la curtosis excesiva es positiva, indicando colas más pesadas que la normal (distribución leptocúrtica).
- Si $\beta = 2$, la curtosis excesiva es cero, coincidiendo con la normal (distribución mesocúrtica).
- Si $\beta > 2$, la curtosis excesiva es negativa, indicando colas más ligeras que la normal (distribución platicúrtica).

Observación 1.1.7. Notemos que para $\beta = 1$ la distribución normal generalizada coincide con la distribución de Laplace cuya PDF está dada por

$$f_X(x; \mu, b) = \frac{1}{2b} e^{-\frac{|x-\mu|}{b}}, \quad x \in \mathbb{R}, \quad (1.4)$$

donde $b > 0$ es un parámetro de escala (que corresponde al valor de α en la normal generalizada). En este caso, la curtosis excesiva es 3, indicando colas más pesadas que la normal. Por otro lado, cuando $\beta = 2$ obtenemos la distribución normal con media μ y varianza $2\alpha^2$. Finalmente, a medida que β tiende a infinito, la distribución normal generalizada converge a una distribución uniforme en el intervalo $(\mu - \alpha, \mu + \alpha)$, la cual tiene curtosis excesiva de -1.2 , indicando colas más ligeras que la normal.

Mostraremos ahora la gráfica de la PDF de la distribución normal generalizada para $\mu = 0$, $\alpha = 1$ y distintos valores de β , destacando sus colas y la forma del pico central.

```
# Creamos una secuencia de valores para X
x_data <- seq(-3.5, 3.5, length.out = 500)

# Seleccionamos los valores de beta a graficar
beta_values <- c(0.5, 1, 1.5, 2, 3, 8)

# Calculamos las densidades para cada valor de beta
dgnorm_distribution_family_tbl <- expand_grid(
  x_data = x_data,
  beta = beta_values
) |>
mutate(
  density_data = dgnorm(
    x_data,
```


1. Evaluación de normalidad univariada

```
mu = 0,
scale = 1,
shape = beta
),
beta = factor(beta)
)

# Generamos la gráfica
dgnorm_distribution_family_plot <- ggplot(
  dgnorm_distribution_family_tbl,
  aes(
    x = x_data,
    y = density_data,
    color = beta
  )
) +
  geom_line(linewidth = 1) +
  scale_color_manual(
    values = unname(c_pal(
      "C red",
      "C yellow",
      "C orange",
      "C green",
      "C blue",
      "C magenta"
    )),
    labels = c(
      TeX("$\\beta$ = 0.5 (Colas muy pesadas)"),
      TeX("$\\beta$ = 1 (Laplace)"),
      TeX("$\\beta$ = 1.5 (Colas pesadas)"),
      TeX("$\\beta$ = 2 (Normal)"),
      TeX("$\\beta$ = 3 (Colas ligeras)"),
      TeX("$\\beta$ = 8 (Colas muy ligeras)")
    )
  ) +
  labs(
    title = "Distribucion normal generalizada para distintos valores de beta",
    x = TeX("$X$"),
    y = "Densidad",
    color = "Parámetro de forma"
  ) +
  theme_krul()

dgnorm_distribution_family_plot
```

Distribucion normal generalizada para distintos valores de beta




Figura 1.3: Funciones de densidad de la distribución normal generalizada para $\mu = 0$, $\alpha = 1$ y distintos valores de β . Notemos cómo cambia la forma de la distribución conforme varía el parámetro de forma β , afectando el grosor de las colas y la forma del pico central.

Finalmente, utilizaremos la distribución normal generalizada, con parámetros $\mu = 0$, $\alpha = 1$ y $\beta = 1, 2, 3$, para generar una gráfica comparativa de una distribución leptocúrtica, una mesocúrtica y una platicúrtica.

```
x_data <- seq(-2, 2, length.out = 500)

# Calculamos la PDF de la distribución leptocúrtica
leptokurtic_distribution_tbl <- tibble(
  x_data = x_data,
  density_data = dgnorm(x_data, mu = 0, scale = 1, shape = 1)
)

# Calculamos la PDF de la distribución mesocúrtica
mesokurtic_distribution_tbl <- tibble(
  x_data = x_data,
  density_data = dgnorm(x_data, mu = 0, scale = 1, shape = 2)
)

# Calculamos la PDF de la distribución platicúrtica
platykurtic_distribution_tbl <- tibble(
  x_data = x_data,
  density_data = dgnorm(x_data, mu = 0, scale = 1, shape = 3)
)
```

1. Evaluación de normalidad univariada

```
# Generamos la gráfica de la distribución leptocúrtica
leptokurtic_distribution_plot <- leptokurtic_distribution_tbl |>
  ggplot(aes(x = x_data, y = density_data)) +
  geom_line(color = c_palette["C blue"], linewidth = 1) +
  labs(
    title = "Leptocúrtica",
    x = TeX("$X$"),
    y = "Densidad"
  ) +
  theme_krul()

# Generamos la gráfica de la distribución mesocúrtica
mesokurtic_distribution_plot <- mesokurtic_distribution_tbl |>
  ggplot(aes(x = x_data, y = density_data)) +
  geom_line(color = c_palette["C blue"], linewidth = 1) +
  labs(
    title = "Mesocúrtica",
    x = TeX("$X$"),
    y = "Densidad"
  ) +
  theme_krul()

# Generamos la gráfica de la distribución platicúrtica
platykurtic_distribution_plot <- platykurtic_distribution_tbl |>
  ggplot(aes(x = x_data, y = density_data)) +
  geom_line(color = c_palette["C blue"], linewidth = 1) +
  labs(
    title = "Platicúrtica",
    x = TeX("$X$"),
    y = "Densidad"
  ) +
  theme_krul()

kurtosis_comparison_plot <- leptokurtic_distribution_plot +
  mesokurtic_distribution_plot +
  platykurtic_distribution_plot +
  plot_annotation(
    title = "Comparación de distribuciones con distintos niveles de curtosis",
    theme = theme(
      plot.title = element_text(
        size = 24,
        face = "bold"
      )
    )
  )
```

kurtosis_comparison_plot

Comparación de distribuciones con distintos niveles de kurtosis




Figura 1.4: Gráfica comparativa de distribuciones leptocúrtica, mesocúrtica y platicúrtica. Notemos cómo la kurtosis afecta la forma de la distribución, especialmente en las colas y el pico central.

1.1.3. Asimetría y kurtosis muestrales

Hasta ahora hemos definido la asimetría y kurtosis para variables aleatorias. Sin embargo, en la práctica trabajamos con muestras y no con poblaciones completas, por lo que necesitamos definir la asimetría y kurtosis *muestrales*. Empecemos por recordar que, dado un *vector muestral*

$$X = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{bmatrix},$$

definimos su *media muestral* como

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Para la varianza muestral, tenemos dos versiones, la *varianza muestral sesgada*

$$\tilde{S}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2,$$

y la *varianza muestral insesgada*

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

En estadística, es más común utilizar la varianza muestral insesgada ya que, como su nombre lo indica, esta resulta ser un estimador insesgado de la varianza poblacional. Para definir la asimetría muestral, definiremos primero el tercer momento muestral. Igual que con la varianza muestral, existen dos versiones del tercer momento muestral: el *tercer momento muestral sesgado*

$$\tilde{M}_3 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^3,$$

1. Evaluación de normalidad univariada

y el tercer momento muestral insesgado

$$M_3 = \frac{n}{(n-1)(n-2)} \sum_{i=1}^n (X_i - \bar{X})^3.$$

A partir de estas definiciones, hay varias posibles definiciones de la asimetría muestral que podemos considerar. Las más comunes son la *asimetría muestral de tipo 1*

$$\tilde{G}_1 = \frac{\tilde{M}_3}{\tilde{S}^3} = \frac{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^3}{\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \right)^{3/2}},$$

y la *asimetría muestral de tipo 2*

$$G_1 = \frac{M_3}{S^3} = \frac{\frac{n}{(n-1)(n-2)} \sum_{i=1}^n (X_i - \bar{X})^3}{\left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \right)^{3/2}}.$$

Aunque menos común, también podemos definir la *asimetría muestral de tipo 3* como

$$G_1^* = \frac{\tilde{M}_3}{S^3} = \frac{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^3}{\left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \right)^{3/2}}.$$

Observación 1.1.8. Es importante destacar que no existe un estimador insesgado de la asimetría poblacional. Sin embargo, todas estas versiones de la asimetría muestral son consistentes, es decir, convergen en probabilidad a la asimetría poblacional conforme el tamaño muestral n tiende a infinito. En particular, para muestras grandes, las tres versiones de la asimetría muestral son aproximadamente iguales.

En R, podemos calcular las tres versiones de la asimetría muestral utilizando la función `skewness()` del paquete `e1071`, especificando el argumento `type` como 1, 2 o 3 según la versión que deseemos calcular. El paquete `moments` también ofrece una función similar llamada `skewness()`, pero esta solo calcula la asimetría muestral de tipo 1.

Mostraremos ahora un ejemplo de una muestra que viene de una distribución con sesgo a la izquierda, una simétrica y una con sesgo a la derecha.

```
# Para asegurar la reproducibilidad de los resultados
set.seed(123)

# Parámetros para generar las muestras
n <- 30000      # tamaño de la muestra
alpha <- 2      # forma
beta <- 1       # tasa

# Generamos las muestras
left_skew_sample <- rgamma(n, shape = alpha, rate = beta)
symmetric_sample <- rnorm(n)
right_skew_sample <- rgamma(n, shape = alpha, rate = beta)
```

```
# Generamos las gráficas de las muestras
# y las presentamos en un solo gráfico
# como hicimos antes
left_skew_sample_tbl <- tibble(
  sample = left_skew_sample
)

symmetric_sample_tbl <- tibble(
  sample = symmetric_sample
)

right_skew_sample_tbl <- tibble(
  sample = right_skew_sample
)

left_skew_sample_plot <- left_skew_sample_tbl %>%
  ggplot(aes(x = sample)) +
  geom_histogram(
    bins = 30,
    fill = c_pal("C blue"),
    color = "black",
    alpha = 0.7
  ) +
  labs(
    title = "Sesgo a la izquierda",
    x = "Valores muestrales",
    y = "Frecuencia absoluta"
  ) +
  theme_krul()

symmetric_sample_plot <- symmetric_sample_tbl %>%
  ggplot(aes(x = sample)) +
  geom_histogram(
    bins = 30,
    fill = c_palette["C blue"],
    color = "black",
    alpha = 0.7
  ) +
  labs(
    title = "Simétrica",
    x = "Valores muestrales",
    y = "Frecuencia absoluta"
  ) +
```

```
theme_krul()

right_skew_sample_plot <- right_skew_sample_tbl %>%
  ggplot(aes(x = sample)) +
  geom_histogram(
    bins = 30,
    fill = c_palette["C blue"],
    color = "black",
    alpha = 0.7
  ) +
  labs(
    title = "Sesgo a la derecha",
    x = "Valores muestrales",
    y = "Frecuencia absoluta"
  ) +
  theme_krul()

skew_sample_comparison_plot <- left_skew_sample_plot +
  symmetric_sample_plot +
  right_skew_sample_plot +
  plot_annotation(
    title = "Comparación de muestras con distintos niveles de asimetría",
    theme = theme(
      plot.title = element_text(
        size = 24,
        face = "bold"
      )
    )
  )

skew_sample_comparison_plot
```

Comparación de muestras con distintos niveles de asimetría




Figura 1.5: Gráfica comparativa de muestras con sesgo a la izquierda, simétrica y con sesgo a la derecha. Notemos como la asimetría nos indica de la existencia de valores atípicos en las colas de la distribución en la dirección del sesgo.

Constuiremos ahora una tabla que nos muestre los valores de la media, la mediana y los tres tipos de asimetría muestral para cada una de las muestras generadas anteriormente.

```
# Calcular media, mediana
# y los tre tipos de asimetría muestral para cada muestra
skew_sample_summary_tbl <- tibble(
  Estadística = c(
    "Media",
    "Mediana",
    "Asimetría Tipo 1",
    "Asimetría Tipo 2",
    "Asimetría Tipo 3"
  ),
  `Sesgo a la izquierda` = c(
    mean(left_skew_sample),
    median(left_skew_sample),
    skewness(left_skew_sample, type = 1),
    skewness(left_skew_sample, type = 2),
    skewness(left_skew_sample, type = 3)
  ),
  `Simétrica` = c(
    mean(symmetric_sample),
    median(symmetric_sample),
    skewness(symmetric_sample, type = 1),
    skewness(symmetric_sample, type = 2),
    skewness(symmetric_sample, type = 3)
  ),
  `Sesgo a la derecha` = c(
    mean(right_skew_sample),
    median(right_skew_sample),
    skewness(right_skew_sample, type = 1),
    skewness(right_skew_sample, type = 2),
    skewness(right_skew_sample, type = 3)
  )
)

# Formatear y mostrar la tabla
# Redondeando a 4 decimales
kable(
  skew_sample_summary_tbl,
  booktabs = TRUE,
  digits = 4,
) |>
kable_styling(latex_options = "hold_position")
```


1. Evaluación de normalidad univariada

Tabla 1.2: Tabla de media, mediana y asimetría muestral para las muestras con sesgo a la izquierda, simétrica y con sesgo a la derecha que generamos.

Estadística	Sesgo a la izquierda	Simétrica	Sesgo a la derecha
Media	-1.9913	-0.0033	2.0076
Mediana	-1.6736	-0.0047	1.6845
Asimetría Tipo 1	-1.4112	-0.0103	1.4215
Asimetría Tipo 2	-1.4113	-0.0103	1.4215
Asimetría Tipo 3	-1.4111	-0.0103	1.4214

Ahora, como sabemos que estas muestras vienen de distribuciones con media, mediana y asimetría conocida, podemos comparar los valores de obtenidos para estos estadísticos muestrales con los valores de las características poblacionales que estamos estimando.

```
# Valores poblacionales conocidos
population_values_tbl <- tibble(
  `Caraterística` = c(
    "Media",
    "Mediana",
    "Asimetría"
  ),
  `Sesgo a la izquierda` = c(
    -alpha / beta,
    -qgamma(0.5, shape = alpha, rate = beta),
    -2 / sqrt(alpha)
  ),
  `Simétrica` = c(
    0,
    0,
    0
  ),
  `Sesgo a la derecha` = c(
    alpha / beta,
    qgamma(0.5, shape = alpha, rate = beta),
    2 / sqrt(alpha)
  )
)

# Formatear y mostrar la tabla
kable(
  population_values_tbl,
  booktabs = TRUE,
  digits = 4,
) |>
kable_styling(latex_options = "hold_position")
```

Tabla 1.3: Tabla de valores poblacionales conocidos para la media, mediana y asimetría de las distribuciones consideradas con sesgo a la izquierda, simétrica y con sesgo a la derecha.

Caraterística	Sesgo a la izquierda	Simétrica	Sesgo a la derecha
Media	-2.0000	0	2.0000
Mediana	-1.6783	0	1.6783
Asimetría	-1.4142	0	1.4142

Observación 1.1.9. Comparando estas tablas, notamos lo siguiente:

- Los valores de los distintos tipos de asimetría muestral son ligeramente diferentes entre sí, pero todos indican correctamente la dirección del sesgo de la distribución de la cual se extrajo la muestra. En particular, cuando el tamaño de la muestra es lo suficientemente grande, los tres tipos de asimetría muestral proporcionan esencialmente la misma información.
- Los valores de estos estadísticos son ligeramente diferentes a los valores poblacionales conocidos, pero se acercan más conforme el tamaño de la muestra aumenta. Esto ilustra la propiedad de consistencia de estos estimadores, pero también ilustra la diferencia entre los valores de los estadísticos de una muestra (que suelen cambiar de una muestra a otra) y los parámetros poblacionales (que son fijos).

1.2. Gráficos QQ

Los gráficos QQ (quantile–quantile) son herramientas para comparar la distribución de un conjunto de datos con una distribución teórica (por ejemplo, la normal). Son especialmente útiles para evaluar la normalidad.

Para construir un gráfico QQ, siga estos pasos:

1. **Ordene los datos muestrales:** Coloque los datos en orden creciente:

$$x_{(1)} \leq x_{(2)} \leq \cdots \leq x_{(n)}.$$

2. **Calcule posiciones de trazado (cuantiles empíricos):** Para cada valor ordenado $x_{(i)}$, calcule la probabilidad correspondiente

$$p_i = \frac{2i - 1}{2n}, \quad i = 1, 2, \dots, n.$$

3. **Obtenga los cuantiles teóricos de la normal:** A partir de la función cuantil (inversa de la CDF) de la normal estándar:

$$q_i = \Phi^{-1}(p_i),$$

donde Φ^{-1} es la función cuantil de la normal estándar.

4. **Trace los puntos:** Grafique los pares $(q_i, x_{(i)})$ con q_i en el eje x y $x_{(i)}$ en el eje y.
5. **Agregue una línea de referencia:** Trazar, por ejemplo, una recta por el primer y tercer cuartil ayuda a evaluar la normalidad.

1. Evaluación de normalidad univariada

Mientras más cerca caigan los puntos de esa recta, más se parece la muestra a la distribución normal especificada.

Para ilustrar estas ideas, generaremos muestras de las distribuciones Gamma y Laplace y construiremos sus gráficos QQ e histogramas. Primero, generamos las muestras:

```
set.seed(123) # for reproducibility

# Sample size
n <- 300
mu <- 0
b <- 1
# Generate random samples from the Gamma distribution
gamma_sample <- rgamma(n, shape = alpha, rate = beta)

gamma_sample_tbl <- tibble(
  sample = gamma_sample
)

# Generate uniform random numbers in (0,1)
u <- runif(n)

# Apply inverse CDF of Laplace
laplace_sample <- ifelse(u < 0.5,
  mu + b * log(2 * u),
  mu - b * log(2 * (1 - u))
)

laplace_sample_tbl <- tibble(
  sample = laplace_sample
)
```

Ahora construiremos los correspondientes gráficos QQ e histogramas. Empezamos con las muestras de la distribución Gamma:

```
gamma_qq_plot <- gamma_sample_tbl %>%
  ggplot(aes(sample = sample)) +
  geom_qq(
    color = c_palette["C red"],
    size = 0.3
  ) +
  geom_qq_line(
    color = c_palette["C blue"],
    linewidth = 0.5
  ) +
  labs(
    title = "Gráfico QQ",
```

```
x = "Cuantiles teóricos",
y = "Cuantiles muestrales"
) +
theme_krul()

gamma_histogram <- gamma_sample_tbl %>%
  ggplot(aes(x = sample)) +
  geom_histogram(
    bins = 30,
    fill = c_palette["C blue"],
    color = "black",
    alpha = 0.7
  ) +
  labs(
    title = "Histograma",
    x = "Valores muestrales",
    y = "Densidad"
  ) +
  theme_krul()

gamma_plot <- gamma_qq_plot + gamma_histogram +
  plot_layout(ncol = 2) +
  plot_annotation(
    title = "Distribución Gamma: gráfico QQ e histograma",
    theme = theme(
      plot.title = element_text(
        size = 24,
        face = "bold"
      )
    )
  )

gamma_plot
```

Distribución Gamma: gráfico QQ e histograma




Figura 1.6: Gráfico QQ e histograma de las muestras de la distribución Gamma.

Construimos ahora el gráfico QQ y el histograma para las muestras de Laplace:

```
laplace_qq_plot <- laplace_sample_tbl %>%  
  ggplot(aes(sample = sample)) +  
  geom_qq(  
    color = c_palette["C red"],  
    size = 0.3  
  ) +  
  geom_qq_line(  
    color = c_palette["C blue"],  
    linewidth = 0.5  
  ) +  
  labs(  
    title = "Gráfico QQ",  
    x = "Cuantiles teóricos",  
    y = "Cuantiles muestrales"  
  ) +  
  theme_krul()  
  
laplace_histogram <- laplace_sample_tbl %>%  
  ggplot(aes(x = sample)) +  
  geom_histogram(  
    bins = 30,  
    fill = c_palette["C blue"],  
    color = "black",  
    alpha = 0.7  
  )
```

```
) +
labs(
  title = "Histograma",
  x = "Valores muestrales",
  y = "Densidad"
) +
theme_krul()
laplace_plot <- laplace_qq_plot + laplace_histogram +
plot_layout(ncol = 2) +
plot_annotation(
  title = "Distribución de Laplace: gráfico QQ e histograma",
  theme = theme(
    plot.title = element_text(
      size = 24,
      face = "bold"
    )
  )
)
laplace_plot
```

Distribución de Laplace: gráfico QQ e histograma




Figura 1.7: Gráfico QQ e histograma de las muestras de la distribución de Laplace.

1.3. Escalamiento y estandarización

En muchas situaciones, las unidades con que medimos distintas variables no son comparables (p.ej., estatura en cm y peso en kg). En esos casos conviene *escalar* las variables para hacerlas comparables. En esta sección discutimos los métodos más comunes para escalar y estandarizar

1. Evaluación de normalidad univariada

variables y muestras.

1.3.1. Escalamiento de variables aleatorias

Definición 1.3.1. Una *transformación afín* de una variable aleatoria X es de la forma

$$Y = aX + b$$

donde a y b son constantes.

Comentario 1.3.2. En estadística, a menudo se habla de *escalamiento* (aunque incluya traslación) para referirse a transformaciones afines.

Suponga que X tiene media μ y desviación estándar σ . Entonces la variable

$$Y = aX + b$$

tendrá media $a\mu + b$ y desviación estándar $|a|\sigma$. En particular, si elegimos $a = 1/\sigma$ y $b = -\mu/\sigma$, la variable

$$Z = \frac{X - \mu}{\sigma}$$

tendrá media 0 y desviación estándar 1. Esta transformación se llama *estandarización*, y Z es la versión *estandarizada* de X (también llamada *puntaje z*).

Comentario 1.3.3. Si X no es normal, Z no será normal estándar. La estandarización no transforma una distribución no normal en normal.

Observación 1.3.4. Por definición,

$$\gamma_1(Z) = \mathbb{E}[Z^3] = \frac{\mathbb{E}[(X - \mu)^3]}{\sigma^3} = \gamma_1(X)$$

y

$$\gamma_2(Z) = \mathbb{E}[Z^4] - 3 = \frac{\mathbb{E}[(X - \mu)^4]}{\sigma^4} - 3 = \gamma_2(X).$$

Como ejemplo, consideremos de nuevo la distribución Gamma. En este caso

$$\mu = \frac{\alpha}{\beta} \quad \text{and} \quad \sigma = \frac{\sqrt{\alpha}}{\beta}.$$

Con esta información, generamos la gráfica de la versión estandarizada de la Gamma y la comparamos con la original.

```
# Calculate density values
z_gamma_distribution_tbl <- gamma_distribution_tbl %>%
  mutate(
    z_data = (x_data - gamma_mean) / gamma_sd,
    z_density = dgamma(x_data, shape = alpha, rate = beta) * gamma_sd
  ) %>%
  select(z_data, z_density)
```

```
# Calculate mean and median
z_gamma_mean <- 0
z_gamma_median <- (gamma_median - gamma_mean) / gamma_sd

# Plot
z_gamma_distribution_plot <- z_gamma_distribution_tbl %>%
  ggplot(aes(x = z_data, y = z_density)) +
  geom_line(
    color = c_palette["C blue"],
    linewidth = 1
  ) +
  geom_vline(
    xintercept = z_gamma_mean,
    color = c_palette["C red"],
    linetype = "dashed",
    linewidth = 1
  ) +
  geom_vline(
    xintercept = z_gamma_median,
    color = c_palette["C green"],
    linetype = "dotted",
    linewidth = 1
  ) +
  annotate(
    "text",
    x = z_gamma_mean,
    y = 0.55,
    label = "Media",
    color = c_palette["C red"],
    hjust = -0.1
  ) +
  annotate(
    "text",
    x = z_gamma_median,
    y = 0.55,
    label = "Mediana",
    color = c_palette["C green"],
    hjust = 1.1
  ) +
  coord_cartesian(ylim = c(0, 0.6)) +
  labs(
    title = paste(
      "Estandarizada"
    ),
    x = "X",
```


1. Evaluación de normalidad univariada

```
  y = "Densidad"
) +
theme_krul()

gamma_distribution_plot <- gamma_distribution_plot +
  labs(
    title = "Original"
  )

combined_gamma_plot <- gamma_distribution_plot + z_gamma_distribution_plot +
  plot_layout(ncol = 2) +
  plot_annotation(
    title = "Distribución Gamma: original y estandarizada",
    theme = theme(
      plot.title = element_text(
        size = 24,
        face = "bold"
      )
    )
  )

combined_gamma_plot
```

Distribución Gamma: original y estandarizada




Figura 1.8: Comparación de la función de densidad (PDF) de la distribución Gamma original y su versión estandarizada.

1.3.2. Escalamiento de muestras

Para una muestra dada, no siempre se conoce la distribución subyacente; en particular, pueden desconocerse la media y la desviación poblacionales. Aun así, podemos escalar los datos; hay varios métodos comunes:

1. *Estandarización*: Usa la media y desviación muestrales. La muestra estandarizada es

$$T = \frac{X - \bar{X}}{S},$$

donde $\bar{X}$ es la media muestral y S la desviación muestral.

2. *Escalamiento Min-Max*: Escala a un rango fijo, usualmente $[0,1]$. La muestra escalada es

$$T = \frac{X - \min(X)}{\max(X) - \min(X)},$$

donde $\min(X)$ y $\max(X)$ son el mínimo y máximo de la muestra. Es muy sensible a atípicos al usar extremos.

3. *Escalamiento robusto*: Usa la mediana y el rango intercuartil (IQR). La muestra escalada es

$$T = \frac{X - \text{median}(X)}{\text{IQR}(X)},$$

1. Evaluación de normalidad univariada

donde $\text{IQR}(X) = Q_3 - Q_1$. Es más robusto a atípicos que Min-Max.

4. *Normalización*: Divide cada dato por la norma del vector. La muestra normalizada es

$$T = \frac{X}{\|X\|},$$

donde $\|X\|$ es la norma. Se usa con menor frecuencia que los anteriores.

Comentario 1.3.5. Como se mencionó, escalar no vuelve normal una distribución no normal. En particular, la asimetría y la curtosis en exceso muestrales no cambian.

Como ejemplo, consideraremos los distintos métodos de escalado aplicados a la muestra de la distribución Gamma que generamos anteriormente.

```
scale_lookup_tbl <- tibble(
  code = c(
    "sample",
    "sample_standard",
    "sample_min_max",
    "sample_robust",
    "sample_normal"
  ),
  label = c(
    "Original Sample",
    "Estandarizada",
    "Min-Max Scaled",
    "Robust Scaled",
    "Normalized"
  )
)

scaled_gamma_sample_tbl <- gamma_sample_tbl %>%
  mutate(
    sample_standard = standard_scale(sample),
    sample_min_max = min_max_scale(sample),
    sample_robust = robust_scale(sample),
    sample_normal = normal_scale(sample)
  ) %>%
  pivot_longer(
    cols = everything(),
    names_to = "scaling_method",
    values_to = "sample_scaled"
  ) %>%
  convert_codes_to_factor(
    code_col = scaling_method,
    lookup_tbl = scale_lookup_tbl,
    lookup_code_col = code,
    lookup_label_col = label,
```

```
new_factor_col_name = scaling_method_factor
)

scaled_gamma_qq_plot <- scaled_gamma_sample_tbl %>%
  ggplot(aes(sample = sample_scaled)) +
  facet_wrap(
    ~scaling_method_factor,
    nrow = 5,
    scales = "free"
  ) +
  geom_qq(
    color = c_palette["C red"],
    size = 0.3
  ) +
  geom_qq_line(
    color = c_palette["C blue"],
    linewidth = 0.5
  ) +
  labs(
    title = "Gráficos QQ",
    x = "Cuantiles teóricos",
    y = "Cuantiles muestrales"
  ) +
  theme_krul()

scaled_gamma_histogram <- scaled_gamma_sample_tbl %>%
  ggplot(aes(x = sample_scaled)) +
  facet_wrap(
    ~scaling_method_factor,
    nrow = 5,
    scales = "free"
  ) +
  geom_histogram(
    bins = 30,
    fill = c_pal("C blue"),
    color = "black",
    alpha = 0.7
  ) +
  labs(
    title = "Histogramas",
    x = "Valores muestrales",
    y = "Densidad"
  ) +
  theme_krul()
```

1. Evaluación de normalidad univariada

```
scaled_gamma_plot <- scaled_gamma_qq_plot + scaled_gamma_histogram +  
  plot_layout(ncol = 2) +  
  plot_annotation(  
    title = "Comparación de métodos de escalamiento aplicados a la muestra Gamma",  
    theme = theme(  
      plot.title = element_text(  
        size = 24,  
        face = "bold"  
      )  
    )  
  )  
scaled_gamma_plot
```

Comparación de métodos de escalamiento aplicados a la muestra Gamma




Figura 1.9: Comparación de distintos métodos de escalamiento aplicados a la muestra Gamma. Note que los QQ-plots son versiones reescaladas del gráfico QQ original y, por tanto, tienen la misma forma.

1.4. Actividad: Visualizando la no normalidad de muestras

Para cada una de las siguientes distribuciones, construya una muestra de tamaño 300 y calcule la asimetría y curtosis muestrales. Después, construya y compare sus gráficos QQ e histogramas.

1. Distribución exponencial con tasa $\lambda = 1$.
2. Distribución uniforme en $[0, 1]$.
3. Distribución beta con $\alpha = 2$ y $\beta = 5$.
4. Distribución de Cauchy con localización $x_0 = 0$ y escala $\gamma = 1$.
5. Distribución χ_k^2 con $k = 3$ grados de libertad.

