



Tecnológico de Monterrey

Aplicación de Métodos Multivariados en Ciencia de Datos

Módulo 1: Relaciones de Interdependencia

Raúl Gómez Muñoz
Blanca Rosa Ruiz Hernández

Tabla de contenidos

I Introducción al análisis multivariado

1. Estructura y organización de datos	1
1.1. Datos ordenados	1
1.1.1. Tibbles y pipes	1
1.1.2. Ejemplo: Ordenando el conjunto de datos <code>who</code>	2
1.2. La Gramática de los Gráficos	6
1.2.1. Capas en <code>ggplot2</code>	7
1.2.2. Graficación con <code>ggplot2</code>	8
1.3. Actividad: Limpieza de datos	9

Parte I

Introducción al análisis multivariado

Capítulo 1

Estructura y organización de datos

Todo proyecto de ciencia de datos debe comenzar con la adquisición y organización de los conjuntos de datos requeridos. La forma en la que esta información se estructura y organiza puede tener un impacto significativo en la calidad del análisis que se desea desarrollar. En esta sección introduciremos los conceptos fundamentales del Tidyverse, un conjunto de herramientas en R que facilita la manipulación y visualización de nuestros datos siguiendo principios específicos de estructura y organización [5, 6, 7].

1.1. Datos ordenados

La idea central detrás del diseño del Tidyverse es la definición de datos ordenados [3]:

Definición 1.1.1. *Datos ordenados* es una forma de estructurar un conjunto de datos para facilitar su uso. En datos ordenados:

1. Cada variable forma una columna.
2. Cada observación forma una fila.
3. Cada tipo de unidad observacional forma una tabla.

Esta estructura facilita la manipulación, análisis y visualización de nuestra información, ya que se alinea con la forma en la que los datos se procesan típicamente en R.

1.1.1. Tibbles y pipes

En el Tidyverse, los datos suelen representarse mediante un tipo especial de data frame llamado *tibble*. Los tibbles son más amigables que los data frames tradicionales, ya que ofrecen una mejor impresión y manejo de subconjuntos de datos. Además, están diseñados para trabajar de manera fluida con el operador pipe (ya sea `|>` o bien `%>%`), que permite encadenar múltiples operaciones (conocidas como “verbos” en el contexto del Tidyverse) de manera clara y concisa. Para ilustrar estas ideas, en la siguiente sección realizaremos la limpieza del conjunto de datos `who` de la OMS, lo que nos permitirá generar un tibble que contenga esta información y que cumpla con los principios de datos ordenados. Este suele ser el primer paso en el Análisis Exploratorio de Datos (EDA) y es crucial para garantizar que los datos estén en un formato adecuado para su análisis y visualización.

1.1.2. Ejemplo: Ordenando el conjunto de datos who

Antes de comenzar, debemos cargar las librerías necesarias y el conjunto de datos `who`:

```
library(tidyverse)
library(here)
library(krulRutils)
library(magrittr)
library(kableExtra)

options(scipen = 999)
data(who)
```

Ahora podemos iniciar nuestro proceso de ordenamiento. El problema principal de este conjunto es que contiene variables (como “new_sp_m014”) que no son muy claras y que incluyen más de una unidad de información.

```
who |>
  glimpse()
```

Rows: 7,240

Columns: 60

```
$ country      <chr> "Afghanistan", "Afghanistan", "Afghanistan", "Afghanistan~
$ iso2         <chr> "AF", "AF", "AF", "AF", "AF", "AF", "AF", "AF", "AF", "AF~
$ iso3         <chr> "AFG", "AFG", "AFG", "AFG", "AFG", "AFG", "AFG", "AFG", "~
$ year         <dbl> 1980, 1981, 1982, 1983, 1984, 1985, 1986, 1987, 1988, 198~
$ new_sp_m014  <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_m1524 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_m2534 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_m3544 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_m4554 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_m5564 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_m65   <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_f014  <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_f1524 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_f2534 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_f3544 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_f4554 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_f5564 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sp_f65   <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_m014  <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_m1524 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_m2534 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_m3544 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_m4554 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_m5564 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_m65   <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_f014  <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
```


1. Estructura y organización de datos

```
$ new_sn_f1524 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_f2534 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_f3544 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_f4554 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_f5564 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_sn_f65 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_m014 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_m1524 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_m2534 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_m3544 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_m4554 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_m5564 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_m65 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_f014 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_f1524 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_f2534 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_f3544 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_f4554 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_f5564 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ new_ep_f65 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_m014 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_m1524 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_m2534 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_m3544 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_m4554 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_m5564 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_m65 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_f014 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_f1524 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_f2534 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_f3544 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_f4554 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_f5564 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ newrel_f65 <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
```

Es por eso que necesitamos separar estas variables e introducir nombres más claros para ellas y para sus valores asociados.

```
# Empezamos creando la variable "who_tidy"
# que contiene el conjunto de datos de la OMS ya limpio
who_tidy <- who |>
# Usamos pivot_longer para eliminar las variables que empiezan con "new"
# y usarlas como valores en su lugar
pivot_longer(
  cols = starts_with("new"),
  names_to = "key",
  values_to = "cases",
```

```
values_drop_na = TRUE
) |>
mutate(
  key = if_else(
    startsWith(key, "newrel"),
    sub("newrel", "new_rel", key),
    key
  ),
  cases = as.integer(cases)
) |>
separate(key, into = c("new", "type", "sexage"), sep = "_") |>
separate(sexage, into = c("sex", "age"), sep = 1) |>
select(-new, -iso2, -iso3) %T>%
# Finalmente, guardamos los datos ordenados en formato RDS y CSV
saveRDS(here("data", "who_tidy.rds")) |>
write_csv(here("data", "who_tidy.csv")) |>
glimpse()
```

Rows: 76,046

Columns: 6

```
$ country <chr> "Afghanistan", "Afghanistan", "Afghanistan", "Afghanistan", "A~
$ year    <dbl> 1997, 1997, 1997, 1997, 1997, 1997, 1997, 1997, 1997, 1997, 19~
$ type    <chr> "sp", "sp", "sp", "sp", "sp", "sp", "sp", "sp", "sp", "sp", "s~
$ sex     <chr> "m", "m", "m", "m", "m", "m", "m", "f", "f", "f", "f", "f", "f~
$ age     <chr> "014", "1524", "2534", "3544", "4554", "5564", "65", "014", "1~
$ cases   <int> 0, 10, 6, 3, 5, 2, 0, 5, 38, 36, 14, 8, 0, 1, 30, 129, 128, 90~
```

Ahora queremos convertir las columnas “type”, “sex” y “age” en factores. Empezamos construyendo las siguientes tablas de correspondencia:

```
who_type_lookup_tbl <- tibble(
  code = c("ep", "rel", "sn", "sp"),
  label = c(
    "TB extrapulmonar",
    "Caso de recaída",
    "TB pulmonar baciloscopía negativa",
    "TB pulmonar baciloscopía positiva"
  )
)

who_sex_lookup_tbl <- tibble(
  code = c("f", "m"),
  label = c("Mujer", "Hombre")
)

who_age_lookup_tbl <- tibble(
```

1. Estructura y organización de datos

```
code = c(
  "014",
  "1524",
  "2534",
  "3544",
  "4554",
  "5564",
  "65"
),
label = c(
  "0-14",
  "15-24",
  "25-34",
  "35-44",
  "45-54",
  "55-64",
  "65+"
)
)
```

Utilizando estas tablas, podemos agregar ahora estas columnas a nuestro conjunto de datos:

```
# Agregamos las columnas de factores como información adicional
who_factor <- who_tidy |>
  convert_codes_to_factor(
    code_col = type,
    lookup_tbl = who_type_lookup_tbl,
    lookup_code_col = code,
    lookup_label_col = label,
    new_factor_col_name = Tipo
  ) |>
  convert_codes_to_factor(
    code_col = sex,
    lookup_tbl = who_sex_lookup_tbl,
    lookup_code_col = code,
    lookup_label_col = label,
    new_factor_col_name = Sexo
  ) |>
  convert_codes_to_factor(
    code_col = age,
    lookup_tbl = who_age_lookup_tbl,
    lookup_code_col = code,
    lookup_label_col = label,
    new_factor_col_name = Edad
  ) |>
  glimpse()
```

Rows: 76,046

Columns: 9

```
$ country <chr> "Afghanistan", "Afghanistan", "Afghanistan", "Afghanistan", "A~
$ year    <dbl> 1997, 1997, 1997, 1997, 1997, 1997, 1997, 1997, 1997, 19~
$ type    <chr> "sp", "sp", "sp", "sp", "sp", "sp", "sp", "sp", "sp", "sp", "s~
$ sex     <chr> "m", "m", "m", "m", "m", "m", "m", "f", "f", "f", "f", "f", "f~
$ age     <chr> "014", "1524", "2534", "3544", "4554", "5564", "65", "014", "1~
$ cases   <int> 0, 10, 6, 3, 5, 2, 0, 5, 38, 36, 14, 8, 0, 1, 30, 129, 128, 90~
$ Tipo    <fct> TB pulmonar baciloscopía positiva, TB pulmonar baciloscopía po~
$ Sexo    <fct> Hombre, Hombre, Hombre, Hombre, Hombre, Hombre, Hombre, Mujer,~
$ Edad    <fct> 0-14, 15-24, 25-34, 35-44, 45-54, 55-64, 65+, 0-14, 15-24, 25-~
```

Finalmente, queremos usar esta información para analizar el número de casos de tuberculosis por tipo y sexo. Empezamos generando el tibble de frecuencias correspondiente:

```
who_type_sex_tbl <- who_factor |>
  count(Tipo, Sexo, wt = cases, name = "Casos")

kable(
  who_type_sex_tbl,
  booktabs = TRUE,
) |>
  kable_styling(latex_options = "hold_position")
```

Tabla 1.1: Número de casos de tuberculosis por tipo y sexo

Tipo	Sexo	Casos
TB extrapulmonar	Mujer	941880
TB extrapulmonar	Hombre	1044299
Caso de recaída	Mujer	1201596
Caso de recaída	Hombre	2018976
TB pulmonar baciloscopía negativa	Mujer	2439139
TB pulmonar baciloscopía negativa	Hombre	3840388
TB pulmonar baciloscopía positiva	Mujer	11324409
TB pulmonar baciloscopía positiva	Hombre	20586831

1.2. La Gramática de los Gráficos

El concepto de la *Gramática de los Gráficos* fue introducido por Leland Wilkinson en su libro “The Grammar of Graphics” [8], y proporciona un marco para entender cómo crear visualizaciones de forma sistemática ya que descompone el proceso de construir una gráfica en componentes como datos, estéticas, geometrías, estadísticas, coordenadas y temas. El paquete `ggplot2` [4] implementa esta gramática en R, permitiendo construir visualizaciones complejas por capas. Para más información sobre su historia y aplicaciones, consulte: [1, 2].

1. Estructura y organización de datos

1.2.1. Capas en ggplot2

En `ggplot2`, las gráficas se construyen añadiendo múltiples *capas* que definen los componentes de la visualización. Cada capa corresponde a un aspecto específico de la gráfica y, en conjunto, forman la composición completa. Estas capas incluyen:

1. **Datos:** El conjunto a visualizar (usualmente un data frame o tibble). Es la fuente de información de la gráfica.
2. **Estéticas:** Mapeos que relacionan variables con propiedades visuales, por ejemplo:
 - Posición en los ejes x e y .
 - Color, relleno.
 - Tamaño, forma.
 - Transparencia.

Estos mapeos definen *qué* datos se muestran y *cómo* se representan visualmente.

3. **Geometrías:** Objetos geométricos que muestran los datos; por ejemplo:
 - `geom_point()` para diagramas de dispersión.
 - `geom_line()` para gráficas de líneas.
 - `geom_col()` para barras.
 - `geom_histogram()` para histogramas.

La geometría controla *cómo* se dibujan los datos.

4. **Transformaciones estadísticas:** Cálculos opcionales aplicados a los datos antes de graficar, como:
 - `stat_bin()` para agrupar en histogramas.
 - `stat_smooth()` para ajustar curvas suaves.

Estos son pasos de preprocesamiento para la visualización.

5. **Escalas:** Definen cómo se traducen los valores a propiedades visuales; también controlan marcas de ejes, leyendas y guías.
6. **Coordenadas:** El sistema usado, como cartesiano (`coord_cartesian()`), polar (`coord_polar()`) o invertido (`coord_flip()`).
7. **Facetado:** Métodos para dividir los datos en subconjuntos y mostrar múltiples gráficas en una cuadrícula:
 - `facet_wrap()`
 - `facet_grid()`
8. **Etiquetas:** `labs()` agrega títulos, etiquetas de ejes y pies.
9. **Temas:** `theme()` controla la apariencia general (fuentes, fondo, rejillas).

Cada capa puede combinarse y personalizarse para construir gráficas complejas y elegantes. Esta *gramática por capas* invita a pensar en la gráfica como una composición de componentes independientes en lugar de un objeto monolítico.

1.2.2. Graficación con ggplot2

Ilustraremos estos conceptos graficando el número de casos de tuberculosis por tipo y sexo, usando el tibble de frecuencias que creamos antes.

```
# Generamos la gráfica usando ggplot2
# Cada capa corresponde a una componente de la gramática de los gráficos
who_type_sex_plot <- who_type_sex_tbl |>
  ggplot(aes(x = Tipo, y = Casos, fill = Sexo)) +
  geom_col(position = "dodge") +
  c_scale_fill("C rose", "C blue") +
  labs(
    title = "Casos de tuberculosis por tipo y sexo",
    x = "Tipo de tuberculosis",
    y = "Casos",
    fill = "Sexo"
  ) +
  theme_krul()

# Visualizamos la gráfica
who_type_sex_plot
```




Figura 1.1: Esta gráfica muestra un análisis comparativo del número de casos de tuberculosis por tipo y sexo. Como se observa, el número de casos es consistentemente mayor en la población masculina en todos los tipos de tuberculosis.

1. Estructura y organización de datos

1.3. Actividad: Limpieza de datos

1. En la sección anterior se mostró cómo usar el operador `|>` para encadenar múltiples operaciones en el Tidyverse. En este ejercicio, muestre el resultado de todos los pasos intermedios en el proceso de ordenamiento del conjunto de datos `who` usando el operador pipe.
2. El problema con el conjunto `relig_income`, es que los distintos niveles de ingreso están representados como columnas, lo que dificulta analizar los datos. Utilizando las técnicas vistas hasta ahora, ordene el conjunto para analizar la distribución del nivel de ingreso entre los distintos grupos religiosos en Estados Unidos, y genere una gráfica de barras que muestre esta información.
3. El problema con el conjunto `Billboard`, es que las semanas en que una canción apareció en la lista están representadas como columnas, lo que dificulta analizar los datos. Utilizando las técnicas vistas hasta ahora, ordene el conjunto para analizar la evolución del ranking de la canción “Who Let The Dogs Out” de “Baha Men” en el Billboard Hot 100. La visualización final debe lucir como la que se muestra abajo.




Figura 1.2: Evolución del ranking de la canción 'Who Let The Dogs Out' de 'Baha Men' en el Billboard Hot 100. La canción alcanzó el puesto 40 en la semana del 21 de octubre de 2000 y permaneció varias semanas en el top 100.

Bibliografía

- [1] Cleveland, W. S. (1993) *The Elements of Graphing Data*. Hobart Press.
- [2] Hyndman, R. J., and Athanasopoulos, G. (2021) *Forecasting: Principles and Practice* (3rd ed.). OTexts. <https://otexts.com/fpp3/>
- [3] Wickham, H. (2014) Tidy data. *Journal of Statistical Software*, 59(10), 1–23. <https://doi.org/10.18637/jss.v059.i10>
- [4] Wickham, H. (2016) *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag.
- [5] Wickham, H., and Grolemund, G. (2017) *R for Data Science: Import, Tidy, Transform, Visualize, and Model Data*. O’Reilly Media.
- [6] Wickham, H. (2019) Functional programming with purrr. *UseR! Conference*.
- [7] Wickham, H., et al. (2019) Welcome to the tidyverse. *Journal of Open Source Software*, 4(43), 1686. <https://doi.org/10.21105/joss.01686>
- [8] Wilkinson, L. (1999) *The Grammar of Graphics*. Springer-Verlag.